高等线性代数选讲

先入土后入门

作者：刘余
单位：清华大学数学基础教学中心
时间：May 26, 2026
版本：V1-小白鼠版
邮箱：yliu2018@mail.tsinghua.edu.cn

余霞散成绮，澄江静如练

目录

1 第 1 部分 * 复线性空间

第 1 章 复线性代数 2
1.1 复数 . . . 2
1.1.1 复数的定义与运算 . . . 2
1.1.2 复数的极式 . . . 4
1.1.3 单位根 . . . 6
第 2 章 复线性空间与 Hermite 内积 10
2.1 基本概念 . . . 10
2.2 Gram-Schimidt 正交化，QR 分解 . . . 15
2.3 酉矩阵和 Hermitian 矩阵 . . . 17
2.4 实正规矩阵 . . . 23
第 3 章 若尔当标准型 25
3.1 Schur 定理和 Cayley-Hamilton 定理 . . . 25
3.2 Jordan 标准型的证明 . . . 29

2 第 2 部分 * 奇异值分解及其应用

第 4 章 奇异值分解 61
4.1 复矩阵的奇异值分解 . . . 62
4.1.1 广义逆 . . . 63
4.1.2 几何意义：旋转-拉伸-旋转 . . . 65
4.1.3 数值稳定性 . . . 66
4.2 矩阵范数 . . . 67
4.2.1 谱范数（算子范数） . . . 67
4.2.2 Frobenius 范数 . . . 70
4.2.3 误差分析与条件数 . . . 73

3 第 3 部分 * 张量积

第 5 章 张量积及其应用 76

5.1 卷积 . . . 76
5.1.1 示例 . . . 76
5.1.2 卷积的向量描述 . . . 79
5.1.3 循环卷积与快速傅里叶变换 . . . 81
5.2 二维离散傅里叶变换 . . . 89
5.2.1 矩阵表示 . . . 89
5.3 张量 . . . 90
5.3.1 从标量、向量、矩阵到张量 . . . 91
5.3.1.1 张量的纤维与展开的关系 . . . 93
5.3.1.2 逆操作：折叠 (Fold) . . . 93
5.3.1.3 展开与 Kronecker 积的关系 . . . 93
5.4 张量的运算与分解 . . . 94
5.4.1 Kronecker 积 . . . 94
5.4.2 Mode-*n* 乘积（张量与矩阵的乘法） . . . 94
5.4.3 缩并 (Contraction) . . . 94
5.4.4 CP 分解 . . . 94
5.4.4.1 算法：交替最小二乘 (ALS) . . . 96
5.4.5 CP 与 Fourier 的联系：循环卷积的 CP 结构 . . . 97
5.4.5.1 CP 秩与多维离散傅里叶变换的结构 . . . 98
5.5 Tucker 分解 . . . 98
5.5.1 性质 . . . 99
5.5.2 与 CP 分解的对比 . . . 100
5.5.3 算法 . . . 100
5.5.4 Tucker 分解的典型应用 . . . 101
5.6 二维傅里叶变换与张量的深层关系 . . . 101
5.6.1 图像 . . . 101
5.6.2 2D 离散傅里叶变换 . . . 101
5.6.3 更深层的数学联系 . . . 102
5.6.3.1 群表示论视角 . . . 102
5.6.3.2 张量积 Hilbert 空间 . . . 102

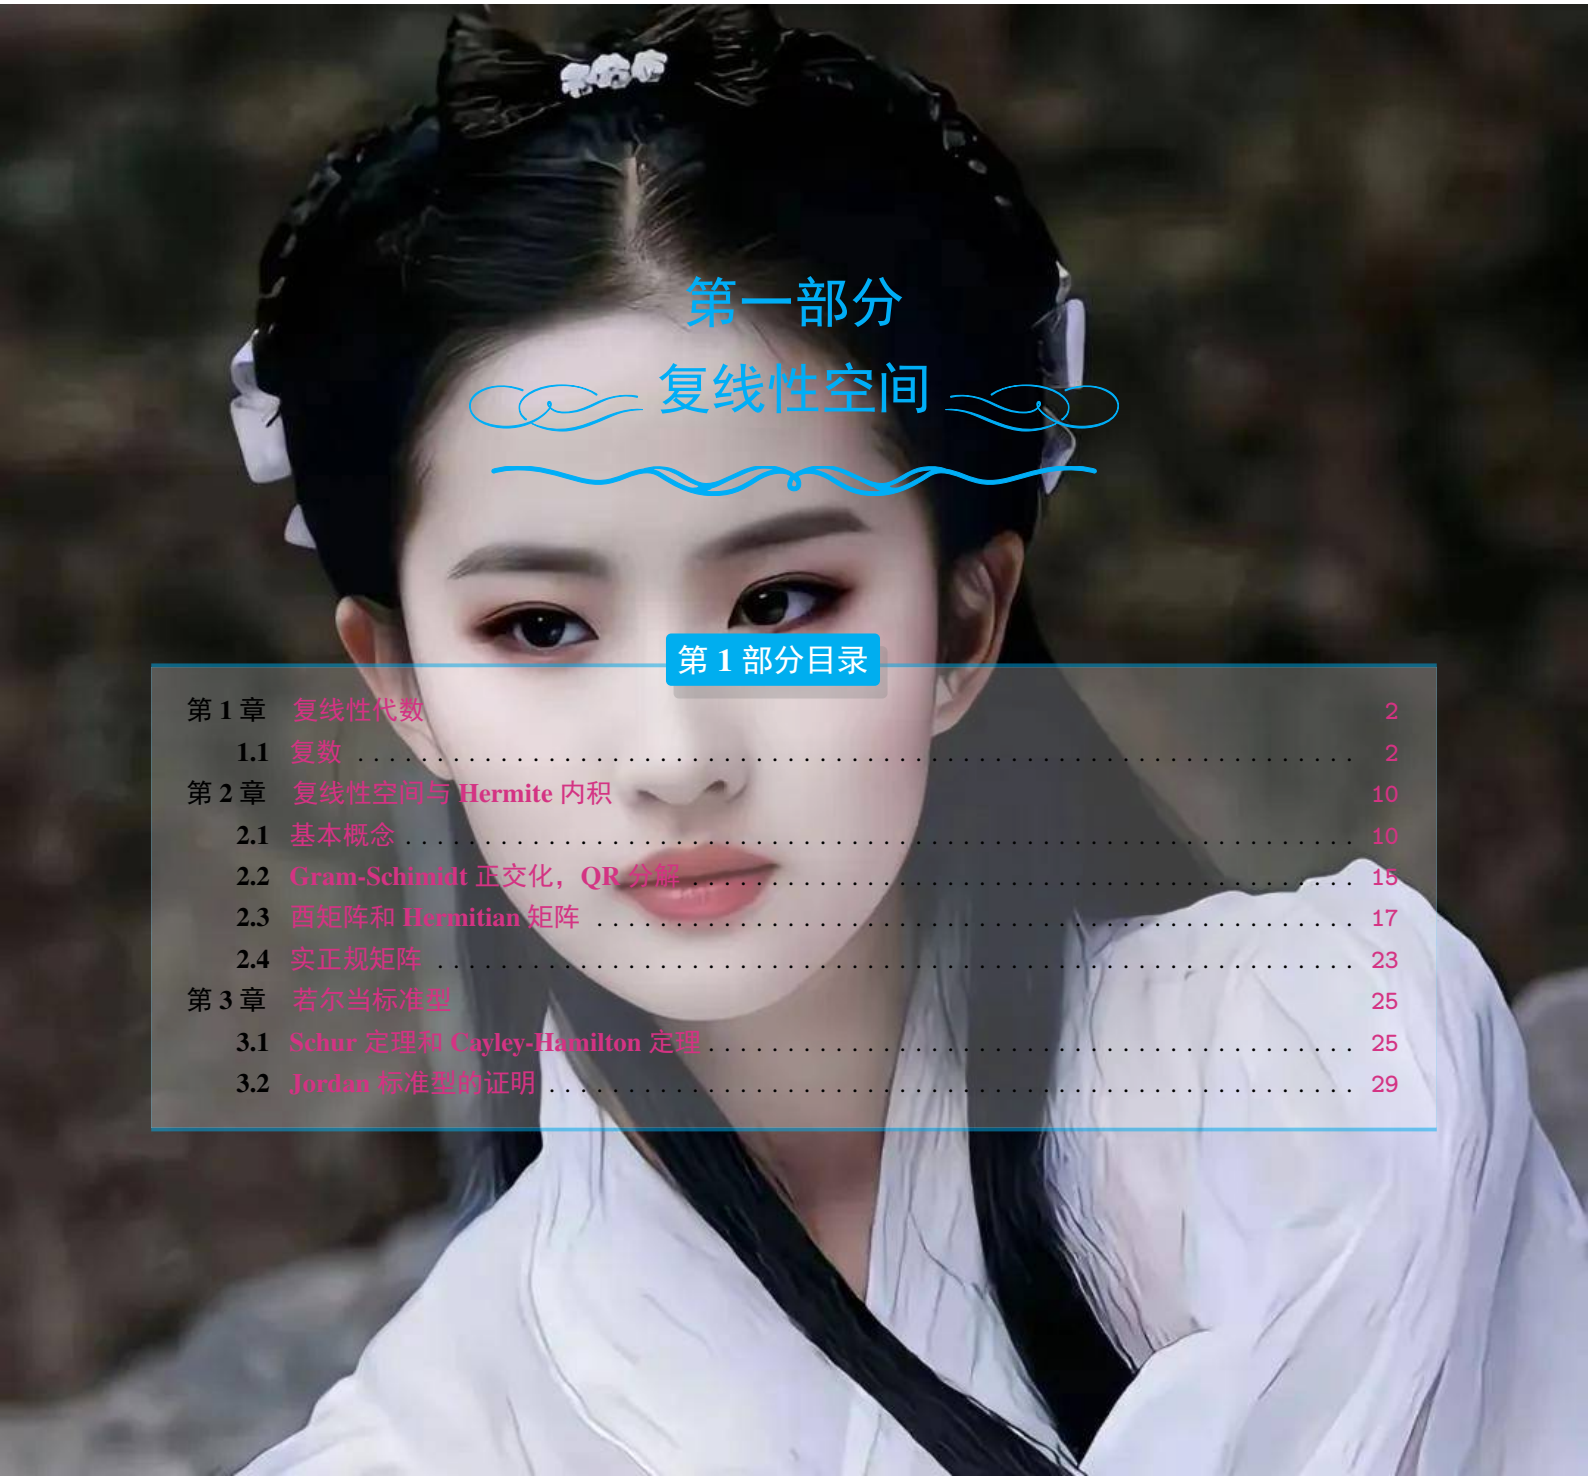

第一部分
复线性空间

第 1 部分目录

第 1 章 复线性代数 2
1.1 复数 2
第 2 章 复线性空间与 Hermite 内积 10
2.1 基本概念 10
2.2 Gram-Schimidt 正交化，QR 分解 15
2.3 酉矩阵和 Hermitian 矩阵 17
2.4 实正规矩阵 23
第 3 章 若尔当标准型 25
3.1 Schur 定理和 Cayley-Hamilton 定理 25
3.2 Jordan 标准型的证明 29

第 1 章 复线性代数

1.1 复数

1.1.1 复数的定义与运算

复数（complex numbers）指形如 $a+b\mathrm{i}$ 的数，这里 a,b 是实数，i 暂且可看成一个符号. 所有复数构成的集合记作 $\mathbb{C}=\{a+b\mathrm{i}:a,b\in\mathbb{R}\}$.

实数有两种运算：加法和乘法. 实数的加法满足交换律，结合律，实数 0 满足任意的实数 a 加 0 等于 a，而且对任意的实数 a，存在实数 b 使得 $a+b=0$（当然满足这个条件的 b 就是 a 的相反数 $-a$）. 实数的乘法满足交换律，结合律，实数 1 满足 $a1=a$，且对任意的非零实数 a，存在实数 b 使得 $ab=1$（当然满足这个条件的 b 就是 a 的倒数 $\frac{1}{a}$）. 实数的加法和乘法还满足分配律.

复数也有加法和乘法，且满足与实数的加法和乘法一样的运算法则. 复数的加法定义如下

$$(a+b\mathrm{i})+(c+d\mathrm{i})=(a+c)+(b+d)\mathrm{i}.$$

复数的乘法定义如下

$$(a+b\mathrm{i})(c+d\mathrm{i})=(ac-bd)+(ad+bc)\mathrm{i}.$$

特别的 $\mathrm{i}^2=\mathrm{ii}=-1$.

在一定意义上可以说，复数的运算由实数的运算和 $\mathrm{i}^2=-1$ 这个公式完全决定.

我们通常用 z 表示复数. 若 $z=a+b\mathrm{i}$，则称 a 是 z 的实部（real part），b 是 z 的虚部（imaginary part），记作

$$a=\mathrm{Re}(z),\quad b=\mathrm{Im}(z).$$

z 是实数当且仅当 z 的虚部 $b=0$. 若 z 的实部为 0，则称 z 是纯虚数 (purely imaginary). 对任意的复数 $z=a+b\mathrm{i}$，定义 z 的共轭（conjugate）为 $\bar{z}=a+(-b)\mathrm{i}$. 容易验证

$$z\bar{z}=(a+b\mathrm{i})(a+(-b)\mathrm{i})=a^2+b^2\geq 0.$$

定义 z 的模或绝对值（modulus or absolute value）为

$$|z|=\sqrt{a^2+b^2}=\sqrt{\mathrm{Re}(z)^2+\mathrm{Im}(z)^2},$$

则有 $z\bar{z}=|z|^2$，$|z|\geq 0$，且等号成立当且仅当 $z=0$.

复数的加法和乘法运算满足以下性质

1. $z+w=w+z$,
2. $(z_1+z_2)+z_3=z_1+(z_2+z_3)$,

3. $z+0=0+z=z$,
4. $\forall z\in\mathbb{C}$，$\exists w\in\mathbb{C}$ s.t. $z+w=0$,
5. $zw=wz$,
6. $(z_1z_2)z_3=z_1(z_2z_3)$,
7. $z1=1z=z$,
8. $\forall z\in\mathbb{C}, z\neq 0, \exists w\in\mathbb{C}$ s.t. $zw=1$,
9. $z(w_1+w_2)=zw_1+zw_2$.

性质 4 中，若 $z=a+b\mathrm{i}$，则取 $w=(-a)+(-b)\mathrm{i}$. 性质 8 中，若 $z=a+b\mathrm{i}\neq 0$，则取

$$w=\frac{\bar z}{|z|^2}=\frac{a}{a^2+b^2}+\frac{-b}{a^2+b^2}\mathrm{i},$$

这是因为当 $z\neq 0$ 时，

$$z\frac{\bar z}{|z|^2}=\frac{z\bar z}{|z|^2}=1.$$

满足 4 的 w 唯一，记为 $-z$；满足 8 的 w 也唯一，记作 $\frac{1}{z}$ 或 z^{-1}. 由此我们可以定义复数的减法和除法：$z-w:=z+(-w)$, $\frac{z}{w}$ $(w\neq 0)$. 具体的公式是

$$(a+b\mathrm{i})-(c+d\mathrm{i})=(a-c)+(b-d)\mathrm{i},$$
$$\frac{a+b\mathrm{i}}{c+d\mathrm{i}}=\frac{(a+b\mathrm{i})(c-d\mathrm{i})}{c^2+d^2}=\frac{ac+bd+(bc-ad)\mathrm{i}}{c^2+d^2}.$$

由于复数的加法运算满足结合律和交换律，故多个复数相加时，结果与相加的顺序无关，所以不需要加括号. 同理，多个复数相乘时也不需要加括号.

复数的共轭和模与复数的加法和乘法运算之间满足下面的性质.

命题 1.1.1

1. $\overline{z+w}=\bar z+\bar w$, $\overline{zw}=\bar z\bar w$.
2. $|zw|=|z||w|$, $||z|-|w||\leq|z+w|\leq|z|+|w|$.
3. $|\bar z|=|z|$, $|z^{-1}|=|z|^{-1}$ $(z\neq 0)$.

♠

证明

1. 按定义验证. 比如，设 $z=a+b\mathrm{i}, w=c+d\mathrm{i}$，则 $zw=(ac-bd)+(ad+bc)\mathrm{i}$, 故 $\overline{zw}=(ac-bd)+(-ad-bc)\mathrm{i}$. 同时计算 $\bar z\bar w=(a-b\mathrm{i})(c-d\mathrm{i})=ac-bd+(-ad-bc)\mathrm{i}$, 比较得 $\overline{zw}=\bar z\bar w$.
2. - $|zw|^2=(ac-bd)^2+(ad+bc)^2=a^2c^2-2acbd+b^2d^2+a^2d^2+2adbc+b^2c^2=a^2c^2+b^2d^2+a^2d^2+b^2c^2=(a^2+b^2)(c^2+d^2)=|z|^2|w|^2$，取平方根即得 $|zw|=|z||w|$.
   - 若将复数 $z=a+b\mathrm{i}$ 看作 2 维实向量 $v=(a,b)$，即考虑 $\mathbb{C}$ 到 $\mathbb{R}^2$ 的一一对应

     $$\mathbb{C}\to\mathbb{R}^2,\quad a+b\mathrm{i}\mapsto(a,b),$$

     则 $|z|=\sqrt{a^2+b^2}=\|\boldsymbol{v}\|$, 即复数 z 的模等于向量 v 的长度，而且若复数 $\boldsymbol{w}=c+d\mathrm{i}$ 对应的向量是 $\boldsymbol{u}=(c,d)$，则 $z+w=(a+c)+(b+d)\mathrm{i}$ 对应的向量是 $\boldsymbol{v}+\boldsymbol{u}=(a+c,b+d)$，故只需证明

     $$|\|\boldsymbol{v}\|-\|\boldsymbol{u}\||\leq\|\boldsymbol{v}+\boldsymbol{u}\|\leq\|\boldsymbol{v}\|+\|\boldsymbol{u}\|,$$

     而这正是 $\mathbb{R}^2$ 中向量满足的三角不等式.
3. 略

✍ 练习 1.1 证明

1. $\mathrm{Re}(z)=\frac{z+\bar z}{2}$, $\mathrm{Im}(z)=\frac{z-\bar z}{2\mathrm{i}}$,
2. $z\in\mathbb{R}$ 当且仅当 $z=\bar z$，$z\in\mathrm{i}\mathbb{R}$[1] 当且仅当 $\bar z=-z$,
3. 当 $|z|=1$ 时，$z^{-1}=\bar z$.
4. $\prod_{i=1}^n z_i=0$ 当且仅当某个 z_i 是 0.

[1] $\mathrm{i}\mathbb{R}=\{\mathrm{i}b:b\in\mathbb{R}\}$ 是纯虚数的集合

注 1.1.1

实数 $\mathbb{R}$ 以及实数的加法与乘法运算、复数 $\mathbb{C}$ 以及复数的加法和乘法运算均满足前面罗列的 9 条公理. 验证：有理数

$$\mathbb{Q}=\left\{\frac{m}{n}:m,n\in\mathbb{Z},n\neq 0\right\}$$

以及有理数的加法与乘法也满足这 9 条公理. 一般的，若集合 F 上有两个二元运算 $+,\cdot$，而且 F 中有两个不一样的元素 $0_F,1_F$，若它们满足上面的 9 条公理，则称 $(F,+,\cdot,0_F,1_F)$ 或 F 是域（field）. 例如，$\mathbb{R},\mathbb{C},\mathbb{Q}$ 都是域，分别称为实数域、复数域、和有理数域.

整数 $\mathbb{Z}$，非负实数 $\mathbb{R}_{\geq 0}$ 不是域，为什么？

最简单的域是二元域 $\mathbb{F}_2=\{0,1\}$. 这里的 $0,1$ 不是你熟知的整数 0，整数 1，而只是 $\mathbb{F}_2$ 中的两个元素. 根据定义，任何一个域 F 中至少包含两个元素，即加法幺元 0_F 和乘法幺元 1_F，这里的 $0,1$ 就是域 $\mathbb{F}_2$ 中的加法和乘法幺元，为了简略省去了 $0_{\mathbb{F}_2},1_{\mathbb{F}_2}$ 中的下标. $\mathbb{F}_2$ 中的加法与乘法定义如下

$$0+0=0,\quad 1+0=0+1=1,\quad 1+1=0,$$

$$0\cdot 0=1\cdot 0=0\cdot 1=0,\quad 1\cdot 1=1.$$

容易验证 $\mathbb{F}_2$ 在这样的运算下是一个域. 思考：在 $\mathbb{F}_2$ 中，$-1=?$，这里 -1 指 1 的加法负元.

包含有限个元素的域称为有限域. 除了 $\mathbb{F}_2$，对任意的素数 p，我们有 p 元域

$$\mathbb{F}_p=\{0,1,\cdots,p-1\}.$$

$\mathbb{F}_p$ 的构造以及 $\mathbb{F}_p$ 上的加法与乘法运算我们会在第三章中讨论. 更一般的，对任意的素数 p，和正整数 $n\geq 1$，存在 q 元域 $\mathbb{F}_q$，其中 $q=p^n$，而且有限域只有这些. 欲知详情（$\mathbb{F}_q$ 的构造，有限域的分类等），请移步抽象代数.

1.1.2 复数的极式

除了用实部和虚部表示复数之外，复数还有一种非常有用的表示形式：极式 (polar form). 如果说在一一对应 $\mathbb{C}\to\mathbb{R}^2,a+b\mathrm{i}\mapsto(a,b)$ 下，复数的实部和虚部对应于平面中向量或点的直角坐标的话，那么复数的极式对应的是平面中点的极坐标.

回顾微积分中指数函数的 Taylor 级数

$$\mathrm{e}^x=1+x+\frac{x^2}{2!}+\cdots+\frac{x^n}{n!}+\cdots,$$

这里 x 是实数. 对任意的实数 x，无穷级数 $\sum\limits_{n=0}^{\infty}\frac{x^n}{n!}$ 绝对收敛. 我们也可以代入复变量 z，即考虑无穷复级数 $\sum\limits_{n=0}^{\infty}\frac{z^n}{n!}$.

关于复数数列、复数级数的收敛的一些背景知识：我们称复数数列 $z_0,z_1,\cdots,z_n,\cdots$ 收敛且极限是 z，如果对任意的 $\epsilon>0$，存在 $N\geq 1$ 使得 $|z_n-z|<\epsilon$ 对任意的 $n\geq N$ 成立，这里 $|\cdot|$ 是复数的模. 我们称复级数 $\sum\limits_{n=0}^{\infty}z_n$ 收敛，如果部分和 $\left\{\sum\limits_{n=0}^{m}z_n\right\}_{m\geq 0}$ 构成的复数列收敛. 我们称复级数 $\sum\limits_{n=0}^{\infty}z_n$ 绝对收敛，如果 $\sum\limits_{n=0}^{\infty}|z_n|$ 收敛.

练习 1.2

1. 利用不等式

$$\max\Big(|\operatorname{Re}(w)|,|\operatorname{Im}(w)|\Big)\leq|w|\leq|\operatorname{Re}(w)|+|\operatorname{Im}(w)|,w\in\mathbb{C}$$

证明：复数列 $\{z_n\}_{n\geq 0}$ 收敛当且仅当实数列 $\{\operatorname{Re}(z_n)\}_{n\geq 0},\{\operatorname{Im}(z_n)\}_{n\geq 0}$ 均收敛.

2. 证明：$\sum\limits_{n=0}^{\infty}z_n$ 绝对收敛当且仅当 $\sum\limits_{n=0}^{\infty}\operatorname{Re}(z_n)$ 和 $\sum\limits_{n=0}^{\infty}\operatorname{Im}(z_n)$ 绝对收敛.

3. 证明：若 $\sum\limits_{n=0}^{\infty}z_n$ 绝对收敛，则 $\sum\limits_{n=0}^{\infty}z_n$ 收敛.

因为 $\left|\frac{z^n}{n!}\right| = \frac{|z|^n}{n!}$，所以复无穷级数 $\sum_{n=0}^{\infty} \frac{z^n}{n!}$ 绝对收敛，其极限记作 e^z，

$$\mathrm{e}^z = 1 + z + \frac{z^2}{2!} + \cdots + \frac{z^n}{n!} + \cdots = \sum_{n=0}^{\infty} \frac{z^n}{n!}.$$

和实指数函数 e^x 一样，复指数函数 e^z 满足下面的性质

$$\mathrm{e}^{z+w} = \mathrm{e}^z \mathrm{e}^w, \quad \forall z, w \in \mathbb{C}.$$

这是因为

$$\mathrm{e}^{z+w} = \sum_{n=0}^{\infty} \frac{(z+w)^n}{n!} = \sum_{n=0}^{\infty} \sum_{i=0}^{n} \frac{C_n^i z^i w^{n-i}}{n!} = \sum_{n=0}^{\infty} \sum_{i=0}^{n} \frac{z^i}{i!} \frac{w^{n-i}}{(n-i)!} = \sum_{i=0}^{\infty} \frac{z^i}{i!} \sum_{j=0}^{\infty} \frac{w^j}{j!} = \mathrm{e}^z \mathrm{e}^w,$$

其中倒数第二个等号成立依赖于数列的绝对收敛性，可参照实数版本，细节略.

下面我们计算 $\mathrm{e}^{\mathrm{i}\theta}, \theta \in \mathbb{R}$. 根据定义，

$$\mathrm{e}^{\mathrm{i}\theta} = 1 + \mathrm{i}\theta + \frac{(\mathrm{i}\theta)^2}{2!} + \frac{(\mathrm{i}\theta)^3}{3!} + \frac{(\mathrm{i}\theta)^4}{4!} + \cdots = \sum_{n=0}^{\infty} \frac{(\mathrm{i}\theta)^n}{n!},$$

其中偶数项均是实数 $1, -\frac{\theta^2}{2!}, \frac{\theta^4}{4!}, \cdots$，奇数项均是纯虚数 $\mathrm{i}\theta, -\mathrm{i}\frac{\theta^3}{3!}, \mathrm{i}\frac{\theta^5}{5!}, \cdots$，故

$$\mathrm{e}^{\mathrm{i}\theta} = \left(1 - \frac{\theta^2}{2!} + \frac{\theta^4}{4!} - \cdots\right) + \mathrm{i}\left(\theta - \frac{\theta^3}{3!} + \frac{\theta^5}{5!} - \cdots\right).$$

上式中的实部与虚部分别是 $\cos\theta$ 和 $\sin\theta$ 的 Taylor 级数，由此我们得到著名的 Euler 公式

$$\mathrm{e}^{\mathrm{i}\theta} = \cos\theta + \mathrm{i}\sin\theta.$$

将欧拉公式代入

$$\mathrm{e}^{\mathrm{i}(\alpha+\beta)} = \mathrm{e}^{\mathrm{i}\alpha}\mathrm{e}^{\mathrm{i}\beta}, \quad \alpha, \beta \in \mathbb{R}$$

可以推导出大家熟知的三角函数和公式

$$\cos(\alpha+\beta) = \cos(\alpha)\cos(\beta) - \sin(\alpha)\sin(\beta),$$
$$\sin(\alpha+\beta) = \sin(\alpha)\cos(\beta) + \cos(\alpha)\sin(\beta).$$

设 $z = a + \mathrm{i}b$ 是非零复数，z 对应于 xy-平面中的点 $P = (a, b)$，记

$$r = |z| = \sqrt{a^2 + b^2} = |\overrightarrow{OP}|,$$

并记正 x-轴逆时针旋转至射线 $\overrightarrow{OP}$ 的角度为 θ，则 $a = r\cos\theta, b = r\sin\theta$，故

$$z = r\cos\theta + \mathrm{i}r\sin\theta = r(\cos\theta + \mathrm{i}\sin\theta) = r\mathrm{e}^{\mathrm{i}\theta}.$$

以上就是复数 z 的极式，r 是 z 的模，θ 称为 z 的辐角（argument）. 注意，z 的辐角不唯一，若 θ 是 z 的辐角，则 $\theta + 2k\pi$ 仍是 z 的辐角，其中 k 是任意整数，且 z 的辐角均具有这种形式. 模为 1 的复数均形如 $\mathrm{e}^{\mathrm{i}\theta}, \theta \in \mathbb{R}$.

例题 1.1.

- 1 的辐角是 $2k\pi$, $1 = \mathrm{e}^0 = \mathrm{e}^{2\pi\mathrm{i}} = \mathrm{e}^{4\pi\mathrm{i}} = \mathrm{e}^{2k\pi\mathrm{i}}$.
- -1 的辐角是 $\pi + 2k\pi = (2k+1)\pi$, 故 $-1 = \mathrm{e}^{\pi\mathrm{i}} = \mathrm{e}^{-\pi\mathrm{i}} = \mathrm{e}^{3\pi\mathrm{i}} = \mathrm{e}^{-3\pi\mathrm{i}} = \mathrm{e}^{(2k+1)\pi\mathrm{i}}$.
- $\mathrm{i} = \mathrm{e}^{\frac{\pi}{2}\mathrm{i}}$. $1 + \mathrm{i} = \sqrt{2}\mathrm{e}^{\frac{\pi}{4}\mathrm{i}}$. $1 - \mathrm{i} = \sqrt{2}\mathrm{e}^{\frac{7\pi}{4}\mathrm{i}} = \sqrt{2}\mathrm{e}^{-\frac{\pi}{4}\mathrm{i}}$.

命题 1.1.2

设 $z = r\mathrm{e}^{\mathrm{i}\theta}, w = r'\mathrm{e}^{\mathrm{i}\theta'}$ 均是非零复数，则

1. $zw = rr'\mathrm{e}^{\mathrm{i}(\theta+\theta')}$,
2. $z^n = r^n\mathrm{e}^{\mathrm{i}n\theta}$ $(n \in \mathbb{Z})$,
3. $\bar{z} = r\mathrm{e}^{-\mathrm{i}\theta}$.

证明 容易，略.

这告诉我们，两个复数相乘时，模相乘，辐角相加.

练习 1.3 计算 $(1+\mathrm{i})^{100}, \mathrm{i}^{123}$.

注 1.1.2

若 $w=a+\mathrm{i}b$，则 $\mathrm{e}^w=\mathrm{e}^{a+\mathrm{i}b}=\mathrm{e}^a\mathrm{e}^{\mathrm{i}b}=\mathrm{e}^a(\cos b+\mathrm{i}\sin b)$. 因 e^a 恒大于 0，故 e^w 的模是 e^a，辐角是 b，

$$|\mathrm{e}^w|=\mathrm{e}^{\mathrm{Re}(w)},\quad \mathrm{Arg}(\mathrm{e}^w)=\mathrm{Im}(w).$$

复指数函数 e^w 可看作是从 $\mathbb{C}$ 到 $\mathbb{C}^\times=\mathbb{C}\setminus\{0\}$ 的函数，它把水平直线 $\{(a,b_0):a\in\mathbb{R}\}$ (b_0 是常数) 映射成 $\mathbb{C}^\times$ 中从原点出发，与正 x-轴夹角为 b_0 的开射线. 从整体上看，函数 e^w 可以这样 visualize. 先用直线 $b=0, b=\pm2\pi, b=\pm4\pi$, etc 把 w-复平面 $\mathbb{C}\cong\mathbb{R}^2$ 分割成可数个水平条形区域，并把这些条形区域卷起来，即将任意一点 w 与在 w 的正上方或正下方间隔为 2π 的整数倍的点叠在一起（$\mathrm{e}^w=\mathrm{e}^{w+2\pi\mathrm{i}k}$），从而得到一个圆柱面，把实部负无穷处的开口半径缩小成 0，实部正无穷处的开口半径张大到正无穷，然后摊开压平，得到少一个点的平面. 通过函数 e^w，我们用复平面 $\mathbb{C}$ 把 $\mathbb{C}^\times$ 覆盖了无数遍，数学家把这种映射称为覆叠映射（covering map）.

反之，若 $z=r\mathrm{e}^{\mathrm{i}\theta}\neq0$，其中 $r=|z|>0$，则 $r=\mathrm{e}^{\log r}$，故 $z=\mathrm{e}^{\log r}\mathrm{e}^{\mathrm{i}\theta}=\mathrm{e}^{\log r+\mathrm{i}\theta}$. 这个公式启发我们定义 $z=\mathrm{e}^w$ 的反函数为

$$\log z=\log r+\mathrm{i}\theta.$$

注意，非零复数 z 的辐角 θ 不唯一，所以上面定义的 $\log z$ 是个多值函数 (multi-valued function). 接着，我们定义

$$z^w=\mathrm{e}^{w\log z},$$

其中 $z\in\mathbb{C}^\times, w\in\mathbb{C}$. 当 $w\notin\mathbb{Z}$ 时，z^w 是 z 的多值函数.

1.1.3 单位根

众所周知，-1 在实数域中无平方根，即实系数方程 $x^2+1=0$ 无实数解. 更一般的满足 $b^2-4ac<0$ 的二次实系数方程 $ax^2+bx+c=0$ ($a\neq0$) 无实数解. 在一定意义下（可用数学语言精确化），复数域实际上是在实数域里“添加” $\mathrm{i}=\sqrt{-1}$ 后扩张而来，记为 $\mathbb{C}=\mathbb{R}[\mathrm{i}]$. 于是，$-1$ 在复数域中有两个平方根 $\mathrm{i},-\mathrm{i}$，或者说 $z^2+1=0$ 有两个复数解 $\pm\mathrm{i}$. 事实上，任意的负实数在 $\mathbb{C}$ 中都有平方根，比如 -3 的平方根是 $\sqrt{3}\mathrm{i}$ 和 $-\sqrt{3}\mathrm{i}$，这是因为“$\sqrt{-3}=\sqrt{3}\sqrt{-1}$”. 接下来，我们指出任意的复数都有复平方根.

例题 1.2.

求解 $z^2=\mathrm{i}$. 先把 i 写成极式

$$\mathrm{i}=\mathrm{e}^{\frac{\pi}{2}\mathrm{i}},$$

由等式 $(\mathrm{e}^{\mathrm{i}\theta})^n=\mathrm{e}^{\mathrm{i}n\theta}$ 知 $(\mathrm{e}^{\frac{\pi}{4}\mathrm{i}})^2=\mathrm{e}^{\frac{\pi}{2}\mathrm{i}}=\mathrm{i}$，而

$$\mathrm{e}^{\frac{\pi}{4}\mathrm{i}}=\cos\frac{\pi}{4}+\mathrm{i}\sin\frac{\pi}{4}=\frac{\sqrt{2}}{2}+\frac{\sqrt{2}}{2}\mathrm{i},$$

于是我们找到了 i 的一个平方根，另一个平方根是上面平方根的相反数

$$-\mathrm{e}^{\frac{\pi}{4}\mathrm{i}}=-\frac{\sqrt{2}}{2}-\frac{\sqrt{2}}{2}\mathrm{i},$$

它也可以从 i 的另一个极表达式得来：因

$$\mathrm{i}=\mathrm{e}^{\frac{5\pi}{2}\mathrm{i}},$$

故

$$e^{\frac{5\pi}{4}i} = -\frac{\sqrt{2}}{2} - \frac{\sqrt{2}}{2}i$$

也是 i 的平方根.

这个方法可以推广到任意的非零复数. 设 $w = re^{i\theta}(r > 0)$，则 $z^2 = w$ 的解是

$$\sqrt{r}e^{i\frac{\theta}{2}}, -\sqrt{r}e^{i\frac{\theta}{2}} = \sqrt{r}e^{i(\frac{\theta}{2}+\pi)}.$$

我们可以进一步计算复数的立方根.

例题 1.3.

求解 $z^3 = i$. 将 i 写成

$$i = e^{\frac{\pi}{2}i} = e^{\frac{5\pi}{2}i} = e^{\frac{9\pi}{2}i},$$

于是下面三个复数的立方等于 i

$$e^{\frac{\pi}{6}i} = \frac{\sqrt{3}}{2} + \frac{1}{2}i, \quad e^{\frac{5\pi}{6}i} = -\frac{\sqrt{3}}{2} + \frac{1}{2}i, \quad e^{\frac{3\pi}{2}i} = -i.$$

一般的，若 $w = re^{i\theta}(r > 0)$，则 $z^3 = w$ 有三个不同的复根

$$\sqrt[3]{r}e^{i\frac{\theta}{3}}, \quad \sqrt[3]{r}e^{i(\frac{\theta}{3}+\frac{2\pi}{3})} = \sqrt[3]{r}e^{i\frac{\theta}{3}}e^{i\frac{2\pi}{3}}, \quad \sqrt[3]{r}e^{i(\frac{\theta}{3}+\frac{4\pi}{3})} = \sqrt[3]{r}e^{i\frac{\theta}{3}}e^{i\frac{4\pi}{3}}.$$

注意，$1, e^{i\frac{2\pi}{3}}, e^{i\frac{4\pi}{3}}$ 这三个数与 w 无关，它们出现在任一非零复数的立方根表达式中.

更一般的，我们可以计算复数 w 的所有 n 次根. 下面，我们仅考虑 $w = 1$ 的情形. 若复数 z 满足 $z^n = 1$，则 $|z|^n = |z^n| = |1| = 1$，又因 $|z| \geq 0$，故必有 $|z| = 1$，即 z 在单位圆上. 不妨设 $z = e^{i\theta}, \theta \in \mathbb{R}$，则 $z^n = e^{in\theta}$，故 $z^n = 1$ 当且仅当 $n\theta$ 是 2π 的整数倍. 满足这个条件的 θ 在不计 2π 的整数倍的意义下共有 n 个：$0, \frac{2\pi}{n}, \frac{2\pi}{n}\cdot 2, \cdots, \frac{2\pi}{n}(n-1)$，故 $z^n - 1 = 0$ 的全部复根是

$$1, e^{\frac{2\pi i}{n}}, e^{\frac{2\pi i}{n}\cdot 2}, \cdots, e^{\frac{2\pi i}{n}(n-1)}.$$

若记 $\xi = e^{\frac{2\pi i}{n}}$，则它们依次是

$$1, \xi, \xi^2, \cdots, \xi^{n-1}.$$

这 n 个复数均匀的分布在单位圆上，从 1 开始，且相邻两个数的辐角差为 $\frac{2\pi}{n}$. 当然，

$$\xi^k = e^{\frac{2\pi i}{n}k} = \cos\left(\frac{2\pi k}{n}\right) + i\sin\left(\frac{2\pi k}{n}\right).$$

定义 1.1.1

设 $z \in \mathbb{C}$. 若 $z^n = 1$, 其中 $n \geq 1$, 则称 z 是n 次单位根（n-th root of unity）. 若 $z^n = 1$ 且 $z^m \neq 1\ (\forall m, 1 \leq m < n)$, 则称 z 是n 次本原单位根（primitive n-th root of unity）.

从上面的讨论看出，对任意的正整数 n，共有 n 个 n 次单位根，它们是 $e^{\frac{2\pi i}{n}k}, 0 \leq k \leq n-1$. 当 $k = 1$ 时，$e^{\frac{2\pi i}{n}}$ 还是 n 次本原单位根. 若 z 是 n 次（本原）单位根，则 $\bar{z}$ 也是 n 次（本原）单位根.

例题 1.4.

- $n=1$：1 次单位根只有 1.
- $n=2$：2 次单位根有 $1,-1$，其中 -1 是 2 次本原单位根，$x^2-1=(x+1)(x-1)$.
- $n=3$：3 次单位根有 $1,e^{\frac{2\pi}{3}i}=-\frac{1}{2}+\frac{\sqrt{3}}{2}i,e^{\frac{4\pi}{3}i}=-\frac{1}{2}-\frac{\sqrt{3}}{2}i$，其中后两个是 3 次本原单位根，$x^3-1=(x-1)(x^2+x+1)=(x-1)\left(x+\frac{1}{2}-\frac{\sqrt{3}}{2}i\right)\left(x+\frac{1}{2}+\frac{\sqrt{3}}{2}i\right)$.
- $n=4$：4 次单位根有 $\pm1,\pm i$，其中 $\pm i$ 是 4 次本原单位根，$x^4-1=(x+1)(x-1)(x^2+1)=(x+1)(x-1)(x+i)(x-i)$.
- $n=5$：5 次单位根是 $1,\cos\left(\frac{2\pi}{5}\right)\pm i\sin\left(\frac{2\pi}{5}\right),\cos\left(\frac{4\pi}{5}\right)\pm i\sin\left(\frac{4\pi}{5}\right)$，且除 1 之外，其余 4 个都是 5 次本原单位根. 在题1.6中，你会计算 $\cos\left(\frac{2\pi}{5}\right)=\frac{\sqrt{5}-1}{4},\cos\left(\frac{4\pi}{5}\right)=-\frac{\sqrt{5}+1}{4}$.
- $n=6$：6 次单位根是 $\pm1,-\frac{1}{2}\pm\frac{\sqrt{3}}{2}i,\frac{1}{2}\pm\frac{\sqrt{3}}{2}i$，只有最后两个是 6 次本原单位根，中间两个是 3 次本原单位根.

练习 1.4 证明

1. 若 $d\mid n$[2]，则 d 次单位根都是 n 次单位根.
2. 若 ω 是 n 次本原单位根，则
   (a). $\omega^m=1$ 当且仅当 $n\mid m$,
   (b). $\{\omega^k:0\le k\le n-1\}$ 是所有的 n 次单位根,
   (c). ω^k 是 $\frac{n}{(n,k)}$ 次本原单位根，这里 (n,k) 表示 n,k 的最大公约数.

注 1.1.3

四个 4 次单位根中，1 是 1 次本原单位根，-1 是 2 次本原单位根，$\pm i$ 是 4 次本原单位根. 一般的，若 d 是 n 的真因子，则 $e^{\frac{2\pi i}{n}d}$ 是 $\frac{n}{d}$ 次本原单位根. 更一般的，对任意的 $k,1\le k\le n,e^{\frac{2\pi i}{n}k}$ 是 $\frac{n}{(n,k)}$ 次本原单位根. 以 n 次本原单位根为全部复根的首一多项式称为 n 次分圆多项式（nth cyclotomic polynomial），记作 $\Phi_n(x)$. 由于 $e^{\frac{2\pi i}{n}k}$ 是 n 次本原单位根当且仅当 $(k,n)=1$，故

$$\Phi_n(x)=\prod_{\substack{1\le k\le n\\(k,n)=1}}(x-e^{\frac{2\pi i}{n}k}).$$

我们可以把所有的 n 次单位根按照它们是几次本原单位根分类. 比如，4 次单位根分成三类，分别是 1,2,4 次本原单位根，6 次单位根分成四类，分别是 1,2,3,6 次本原单位根. 注意，1,2,4 均是 4 的因子，1,2,3,6 均是 6 的因子. 于是我们可以把 x^n-1 分解成 $\Phi_d(x),d\mid n$ 的乘积：

$$x^n-1=\prod_{k=1}^{n}(x-e^{\frac{2\pi i}{n}k})=\prod_{\substack{1\le d\le n\\d\mid n}}\prod_{\substack{1\le k\le n\\(k,n)=\frac{n}{d}}}(x-e^{\frac{2\pi i}{n}k})=\prod_{\substack{1\le d\le n\\d\mid n}}\Phi_d(x).$$

最后一个等式是因为当 k 跑遍 $1,\cdots,n$ 中与 n 的最大公约数等于 $\frac{n}{d}$ 的正整数时，$e^{\frac{2\pi i}{n}k}$ 穷尽了所有的 d 次本原单位根. 例如，

$$\begin{aligned}
&&\Phi_1(x)&=x-1,\\
x^2-1=(x-1)(x+1)&=\Phi_1(x)\Phi_2(x),&\Phi_2(x)&=x+1,\\
x^3-1=(x-1)(x^2+x+1)&=\Phi_1(x)\Phi_3(x),&\Phi_3(x)&=x^2+x+1,\\
x^4-1=(x-1)(x+1)(x^2+1)&=\Phi_1(x)\Phi_2(x)\Phi_4(x),&\Phi_4(x)&=x^2+1,\\
x^5-1=(x-1)(x^4+x^3+x^2+x+1)&=\Phi_1(x)\Phi_5(x),&\Phi_5(x)&=x^4+x^3+x^2+x+1,\\
x^6-1=(x-1)(x+1)(x^2+x+1)(x^2-x+1)&=\Phi_1(x)\Phi_2(x)\Phi_3(x)\Phi_6(x),&\Phi_6(x)&=x^2-x+1,
\end{aligned}$$

等等. 可以递归证明 $\Phi_n(x)$ 是首一整系数多项式.

[2]这个符号的意思是 d 整除 n.

✍ **练习 1.5**

1. 计算所有的 8 次单位根，并指出哪些是本原的，
2. 计算 $\Phi_7(x), \Phi_8(x), \Phi_9(x), \Phi_{10}(x), \Phi_{11}(x)$.
3. 对任意的素数 p，计算 $\Phi_p(x)$.

我们在上面讨论了形如 $z^n - w = 0$ 的方程如何求解，其中 w 是某固定的复数. 当 $w = 0$ 时，$z^n = 0$ 只有零解，但重数为 n. 当 $w \neq 0$ 时，$z^n = w$ 有 n 个互异复数解. 更一般的，我们有如下的 代数学基本定理，即任一 n 次复系数多项式在计入重数意义下恰有 n 个复根[3]. 这是复数域 $\mathbb{C}$ 优于实数域 $\mathbb{R}$ 的地方. 用域论的语言说，$\mathbb{C}$ 是代数封闭域（algebraically closed field），而 $\mathbb{R}$ 不是.

定理 1.1.1 (代数学基本定理)

设 $f(z) = a_n z^n + a_{n-1} z^{n-1} + \cdots + a_1 z + a_0$，其中 $a_n, a_{n-1}, \cdots, a_1, a_0 \in \mathbb{C}$ 且 $a_n \neq 0$，则存在复数 $z_1, \cdots, z_n$ 使得

$$f(z) = a_n (z - z_1) \cdots (z - z_n).$$

♡

✍ **练习 1.6 切比雪夫多项式** 大家都知道倍角公式 $\cos(2\theta) = 2\cos^2(\theta) - 1$, $\sin(2\theta) = 2\sin(\theta)\cos(\theta)$.

1. 证明：$\cos(3\theta) = 4\cos^3(\theta) - 3\cos(\theta)$.
2. 定义多项式 $T_n(x), n \geq 0$ 如下

$$T_0(x) = 1, T_1(x) = x, \quad T_{n+1}(x) = 2xT_n(x) - T_{n-1}(x).$$

计算 $T_2(x), T_3(x)$，并证明

$$\cos(n\theta) = T_n(\cos(\theta)), \quad \forall n \geq 0.$$

3. $T_n(x)$ 称为第一类切比雪夫多项式（Chebyshev polynomials of the first kind）. 证明 $T_n(x)$ 是 n 次整系数多项式，求 $T_n(x)$ 的所有实根，并证明当 $|x| \leq 1$ 时，$|T_n(x)| \leq 1$.
4. 证明：$\sin(3\theta) = \sin(\theta)(4\cos^2(\theta) - 1)$.
5. 定义多项式 $U_n(x), n \geq 0$ 如下

$$U_0(x) = 1, U_1(x) = 2x, \quad U_{n+1}(x) = 2xU_n(x) - U_{n-1}(x).$$

计算 $U_2(x), U_3(x)$，并证明 $\sin((n+1)\theta) = \sin(\theta)U_n(\cos(\theta)), \forall n \geq 0$.

6. $U_n(x)$ 称为第二类切比雪夫多项式（Chebyshev polynomials of the second kind）. 证明 $U_n(x)$ 是 n 次整系数多项式，并求 $U_n(x)$ 的所有实根.
7. 利用 $\cos\left(\frac{4\pi}{5}\right) = \cos\left(\frac{6\pi}{5}\right)$ 证明 $\cos\left(\frac{2\pi}{5}\right) = \frac{\sqrt{5}-1}{4}$.
8. 回顾 Strang 最喜爱的矩阵（之一？）

$$K_n = \begin{bmatrix} 2 & -1 & & & \\ -1 & 2 & -1 & & \\ & \ddots & \ddots & \ddots & \\ & & -1 & 2 & -1 \\ & & & -1 & 2 \end{bmatrix}.$$

证明 K_n 的特征多项式是 $U_n\left(\frac{\lambda-2}{2}\right)$，并由此计算 K_n 的所有特征值. 你可以算出 K_n 的所有特征向量吗？

[3]但是我们没有计算这些复根的一般公式

第 2 章 复线性空间与 Hermite 内积

2.1 基本概念

线性代数可以在任何一个域上做. 若 F 是域，我们可以考虑 F-线性空间，F-线性变换，F-矩阵等，通常也称 F 为系数域或基域. 上学期学习的是实数域 $\mathbb{R}$ 上的线性代数，其中的很大一部分内容仅依赖于实数的加减乘除运算以及运算满足的性质，即 $\mathbb{R}$ 是域这个事实，这部分内容可以不做修改的搬到任何域上，即把出现 $\mathbb{R}$ 的地方全部改成 F，其余一字不变. 有些依赖于实数域的特有性质的部分则不能照搬. 哪些性质是实数域有而一般的域没有的呢？比如，实数有正实数负实数，一般的域 F 中的元素没有正负这个概念. 再比如，若干个实数的平方和等于 0 当且仅当这些实数都是 0，这个性质对复数域已然不成立 $1^2+\mathrm{i}^2=0$ 而 $1\neq 0,\mathrm{i}\neq 0$. 与实数的这些特有性质密切相关的内容主要集中在点积以及围绕点积展开的部分，比如正交、投影等. 幸运的是，把 $\mathbb{R}^n$ 上的点积换成 $\mathbb{C}^n$ 上的厄米特内积之后，这部分内容也可以轻松搬到复数域上.

回忆一下什么是实线性空间. 实线性空间是一个集合上面带两个运算，加法和数乘，加法是集合中两个元素相加，和仍然在集合中，数乘是集合中的一个元素和一个实数相乘，乘积在集合中，而且这两个运算满足 8 条公理（加法交换律，加法结合律，0 元素的存在，加法和数乘满足的分配律等）. 把实数改成复数，就得到复线性空间的概念. 复线性空间中向量的线性组合，线性表出，线性相关，线性无关，子空间，基，维数等概念与实线性空间同.

例题 2.1. 复线性空间的例子

$\mathbb{C}^n, M_{m\times n}(\mathbb{C}), M_n(\mathbb{C})$ 分别是 n, mn, n^2 维复线性空间. $\mathbb{C}[x]$，$C([0,1])$ = 区间 $[0,1]$ 上的复值连续函数，$\mathbb{C}^{\mathbb{N}}=\{(z_0,z_1,\cdots,z_n,\cdots): z_i\in\mathbb{C}, i\geq 0\}$，是无限维复线性空间.

以下这些也都可以不费吹灰之力从实数推广到复数.

1. 用高斯消元法解复系数线性方程组，用消元判定复方阵是否可逆，初等变换，初等方阵，求逆矩阵的高斯-若当方法，简化行阶梯形 $\mathrm{rref}(A)$，A 的秩 $r(A)$[1].
2. 复矩阵 $A\in M_{m\times n}(\mathbb{C})$ 的四个基本子空间 $C(A), C(A^{\mathrm{T}}), N(A), N(A^{\mathrm{T}})$，维数分别是 $r(A), r(A), n-r(A), m-r(A)$，基可分别取作 A 的主元列，$\mathrm{rref}(A)$ 的非零行，$A\boldsymbol{x}=0$ 的特殊解，$A^{\mathrm{T}}\boldsymbol{y}=0$ 的特殊解.
3. 复方阵的行列式，行列式满足的性质，Laplace 公式，矩阵可逆与行列式的关系，Cramer 法则.
4. 复方阵的特征多项式、特征值、特征向量、特征子空间，可相似对角化的充要条件.

[1] 可定义为 $\mathrm{rref}(A)$ 中主元的个数

5. 复线性变换，复线性变换的矩阵.

复数的共轭可以推广到复矩阵的共轭.

定义 2.1.1

设 $A=\left[a_{ij}\right]\in M_{m\times n}(\mathbb{C})$, A 的共轭（矩阵）定义为 $\bar{A}=\left[\bar{a}_{ij}\right]\in M_{m\times n}(\mathbb{C})$，$A$ 的实部是 $\mathrm{Re}(A)=\left[\mathrm{Re}(a_{ij})\right]$，$A$ 的虚部是 $\mathrm{Im}(A)=\left[\mathrm{Im}(a_{ij})\right]$.

引理 2.1.1

1. $\overline{A+B}=\bar{A}+\bar{B}$, $\overline{cA}=\bar{c}\bar{A}$, $\overline{AB}=\bar{A}\bar{B}$, $(\bar{A})^{\mathrm{T}}=\overline{A^{\mathrm{T}}}$, $\overline{AB^{\mathrm{T}}}=\bar{B}^{\mathrm{T}}\bar{A}^{\mathrm{T}}$.
2. 若 A 可逆，则 $(\bar{A})^{-1}=\overline{A^{-1}}$.
3. $\mathrm{rref}(\bar{A})=\overline{\mathrm{rref}(A)}$, $r(\bar{A})=r(A)$.
4. $\det(\bar{A})=\overline{\det(A)}$.

证明 1, 2, 4 略. 3，存在可逆复矩阵 P 使得 $PA=R$，其中 $R=\mathrm{rref}(A)$. 取共轭得 $\bar{P}\bar{A}=\overline{PA}=\bar{R}$. 由 2 知，$\bar{P}$ 可逆；由 rref 的定义知 $\bar{R}$ 也是简化行阶梯形；最后由矩阵的 rref 的唯一性知 $\bar{R}=\mathrm{rref}(\bar{A})$.

引理2.1.1的 1 说明了复矩阵的共轭与转置交换，2 说明了共轭与取逆交换. 与实矩阵相同，复矩阵的转置和取逆也交换，所以对于复矩阵来说，这三种运算：共轭、转置、取逆是两两交换的.

$\mathbb{R}^n$ 中向量的点积有正定性，即 $\boldsymbol{x}^{\mathrm{T}}\boldsymbol{x}\geq 0$ 且等号成立当且仅当 $\boldsymbol{x}=0$，于是 $\mathbb{R}^n$ 中正交的子空间的交为 0. 实矩阵 A 的列空间 $C(A)$ 与左零空间 $N(A^{\mathrm{T}})$ 就是一个例子. 从定义容易看出 $C(A)$ 与 $N(A^{\mathrm{T}})$ 正交，于是 $C(A)\cap N(A^{\mathrm{T}})=0$. 这个性质对复矩阵不再成立. 原因是若对复向量照搬实向量的点积公式，即考虑

$$\boldsymbol{z}\cdot\boldsymbol{w}=z^{\mathrm{T}}w=z_1w_1+\cdots+z_nw_n,$$

则 $\boldsymbol{z}\cdot\boldsymbol{z}=z_1^2+\cdots+z_n^2$，然而若干个非零复数的平方和可以是 0，比如 $1^2+\mathrm{i}^2=0$. 考虑复矩阵 $A=\begin{bmatrix}1\\ \mathrm{i}\end{bmatrix}$, 则

$$C(A)=\mathrm{Span}\left(\begin{bmatrix}1\\ \mathrm{i}\end{bmatrix}\right),$$

$$N(A^{\mathrm{T}})=\left\{\begin{bmatrix}z_1\\ z_2\end{bmatrix}\in\mathbb{C}^2:\begin{bmatrix}1 & \mathrm{i}\end{bmatrix}\begin{bmatrix}z_1\\ z_2\end{bmatrix}=0\right\}=\mathrm{Span}\left(\begin{bmatrix}-\mathrm{i}\\ 1\end{bmatrix}\right).$$

因 $\begin{bmatrix}-\mathrm{i}\\ 1\end{bmatrix}=-\mathrm{i}\begin{bmatrix}1\\ \mathrm{i}\end{bmatrix}$, 故 $C(A)=N(A^{\mathrm{T}})$ 是 $\mathbb{C}^2$ 的 1 维复子空间，特别的 $C(A)\cap N(A^{\mathrm{T}})\neq 0$.

回忆实矩阵的另一个性质：若 $A\in M_{m\times n}(\mathbb{R})$，则 $r(A)=r(A^{\mathrm{T}}A)$. 最快捷的证明方法是比较 $N(A)$ 和 $N(A^{\mathrm{T}}A)$. 显然 $A\boldsymbol{x}=0$ 推出 $A^{\mathrm{T}}A\boldsymbol{x}=0$. 反之，若 $A^{\mathrm{T}}A\boldsymbol{x}=0$，则 $\boldsymbol{x}^{\mathrm{T}}A^{\mathrm{T}}A\boldsymbol{x}=0$，等号左边恰是 $(A\boldsymbol{x})^{\mathrm{T}}(A\boldsymbol{x})$，故用点积的正定性推出 $A\boldsymbol{x}=0$. 于是 $N(A)=N(A^{\mathrm{T}}A)$. 最后结合零空间的维数公式 $\dim N(A)=n-r(A)$ 和 $\dim N(A^{\mathrm{T}}A)=n-r(A^{\mathrm{T}}A)$ 推出 $r(A)=r(A^{\mathrm{T}}A)$.

这个性质对复矩阵也不再成立. 同样考虑 $A=\begin{bmatrix}1 & \mathrm{i}\end{bmatrix}$，显然 $r(A)=1$，而

$$A^{\mathrm{T}}A=\begin{bmatrix}1\\ \mathrm{i}\end{bmatrix}\begin{bmatrix}1 & \mathrm{i}\end{bmatrix}=1^2+\mathrm{i}^2=0,$$

故 $r(A^{\mathrm{T}}A)=0\neq 1=r(A)$.

为了“修复”这些不再成立的性质，我们引入 $\mathbb{C}^n$ 上的 Hermite 内积.

定义 2.1.2

设 $\boldsymbol{\alpha}=\begin{bmatrix}z_1\\ \vdots\\ z_n\end{bmatrix},\boldsymbol{\beta}=\begin{bmatrix}w_1\\ \vdots\\ w_n\end{bmatrix}\in\mathbb{C}^n$，定义

$$\langle\boldsymbol{\alpha},\boldsymbol{\beta}\rangle=\bar{\boldsymbol{\alpha}}^{\mathrm{T}}\boldsymbol{\beta}=[\bar{z}_1\cdots\bar{z}_n]\begin{bmatrix}w_1\\ \vdots\\ w_n\end{bmatrix}=\bar{z}_1w_1+\cdots+\bar{z}_nw_n,$$

特别的 $\langle\boldsymbol{\alpha},\boldsymbol{\alpha}\rangle=|z_1|^2+\cdots+|z_n|^2\geq 0$.

定义 $\boldsymbol{\alpha}$ 的长度是 $\|\boldsymbol{\alpha}\|=\sqrt{\langle\boldsymbol{\alpha},\boldsymbol{\alpha}\rangle}=\sqrt{\bar{\boldsymbol{\alpha}}^{\mathrm{T}}\boldsymbol{\alpha}}$.

引理 2.1.2

1. $\langle a_1\boldsymbol{\alpha}_1+a_2\boldsymbol{\alpha}_2,\boldsymbol{\beta}\rangle=\bar{a}_1\langle\boldsymbol{\alpha}_1,\boldsymbol{\beta}\rangle+\bar{a}_2\langle\boldsymbol{\alpha}_2,\boldsymbol{\beta}\rangle$,
2. $\langle\boldsymbol{\alpha},b_1\boldsymbol{\beta}_1+b_2\boldsymbol{\beta}_2\rangle=b_1\langle\boldsymbol{\alpha},\boldsymbol{\beta}_1\rangle+b_2\langle\boldsymbol{\alpha},\boldsymbol{\beta}_2\rangle$,
3. $\langle\boldsymbol{\beta},\boldsymbol{\alpha}\rangle=\overline{\langle\boldsymbol{\alpha},\boldsymbol{\beta}\rangle}$,
4. $\langle\boldsymbol{\alpha},\boldsymbol{\alpha}\rangle\geq 0$ 且 $\langle\boldsymbol{\alpha},\boldsymbol{\alpha}\rangle=0\iff\boldsymbol{\alpha}=0$.
5. $\|c\boldsymbol{\alpha}\|=|c|\|\boldsymbol{\alpha}\|$，其中 $c\in\mathbb{C},\boldsymbol{\alpha}\in\mathbb{C}^n$.

证明 1-3: 用引理 2.1.1. 4: 显然. 5：$\langle c\boldsymbol{\alpha},c\boldsymbol{\alpha}\rangle=\bar{c}\langle\boldsymbol{\alpha},c\boldsymbol{\alpha}\rangle=\bar{c}c\langle\boldsymbol{\alpha},\boldsymbol{\alpha}\rangle=|c|^2\langle\boldsymbol{\alpha},\boldsymbol{\alpha}\rangle$.

注 2.1.1

若 $\boldsymbol{\alpha}$ 是 $\mathbb{R}^n$ 中的单位向量，则 $\boldsymbol{\alpha}$ 生成的 1 维实线性子空间 $\mathbb{R}\boldsymbol{\alpha}$ 中的单位向量有且仅有两个 $\boldsymbol{\alpha},-\boldsymbol{\alpha}$. 作为对比，若 $\boldsymbol{\alpha}$ 是 $\mathbb{C}^n$ 中的单位向量，则 $\boldsymbol{\alpha}$ 生成的 1 维复线性子空间 $\mathbb{C}\boldsymbol{\alpha}$ 中的单位向量均形如 $\mathrm{e}^{\mathrm{i}\theta}\boldsymbol{\alpha}$，其中 $\theta\in\mathbb{R}$.

例题 2.2.

$\boldsymbol{\alpha}=(1+\mathrm{i},1-\mathrm{i}),\boldsymbol{\beta}=(3+2\mathrm{i},5\mathrm{i})$，计算得

$$\begin{aligned}\langle\boldsymbol{\alpha},\boldsymbol{\beta}\rangle&=\overline{(1+\mathrm{i})}(3+2\mathrm{i})+\overline{(1-\mathrm{i})}(5\mathrm{i})=(1-\mathrm{i})(3+2\mathrm{i})+(1+\mathrm{i})(5\mathrm{i})\\&=5-\mathrm{i}+5\mathrm{i}-5=4\mathrm{i},\\\langle\boldsymbol{\alpha},\boldsymbol{\alpha}\rangle&=|1+\mathrm{i}|^2+|1-\mathrm{i}|^2=1^2+1^2+1^2+1^2=4,\\\langle\boldsymbol{\beta},\boldsymbol{\beta}\rangle&=|3+2\mathrm{i}|^2+|5\mathrm{i}|^2=3^2+2^2+5^2=38.\end{aligned}$$

于是 $\|\boldsymbol{\alpha}\|=2,\|\boldsymbol{\beta}\|=\sqrt{38}$. 注意，$|\langle\boldsymbol{\alpha},\boldsymbol{\beta}\rangle|=|4i|=4\leq 2\sqrt{38}=\|\boldsymbol{\alpha}\|\|\boldsymbol{\beta}\|$.

Hermite 内积有 Cauchy-Schwarz 不等式吗？

这两个向量的和是 $\boldsymbol{\alpha}+\boldsymbol{\beta}=(4+3\mathrm{i},1+4\mathrm{i})$，其长度平方是

$$\|\boldsymbol{\alpha}+\boldsymbol{\beta}\|^2=4^2+3^2+1^2+4^2=42=4+38=\|\boldsymbol{\alpha}\|^2+\|\boldsymbol{\beta}\|^2.$$

虽然 $\boldsymbol{\alpha}$ 与 $\boldsymbol{\beta}$ 不“正交”（即 Hermite 内积不是 0），但是 $\|\boldsymbol{\alpha}\|,\|\boldsymbol{\beta}\|,\|\boldsymbol{\alpha}+\boldsymbol{\beta}\|$ 满足勾股定理，这是为什么呢？

引理 2.1.3

1. $\|\boldsymbol{\alpha}+\boldsymbol{\beta}\|^2=\|\boldsymbol{\alpha}\|^2+2\operatorname{Re}\langle\boldsymbol{\alpha},\boldsymbol{\beta}\rangle+\|\boldsymbol{\beta}\|^2$.
2. （勾股定理）若 $\langle\boldsymbol{\alpha},\boldsymbol{\beta}\rangle=0$，则 $\|\boldsymbol{\alpha}+\boldsymbol{\beta}\|^2=\|\boldsymbol{\alpha}\|^2+\|\boldsymbol{\beta}\|^2$.
3. （平行四边形等式）$\|\boldsymbol{\alpha}+\boldsymbol{\beta}\|^2+\|\boldsymbol{\alpha}-\boldsymbol{\beta}\|^2=2(\|\boldsymbol{\alpha}\|^2+\|\boldsymbol{\beta}\|^2)$.

证明 $\|\boldsymbol{\alpha}+\boldsymbol{\beta}\|^2=\langle\boldsymbol{\alpha}+\boldsymbol{\beta},\boldsymbol{\alpha}+\boldsymbol{\beta}\rangle=\langle\boldsymbol{\alpha},\boldsymbol{\alpha}\rangle+\langle\boldsymbol{\alpha},\boldsymbol{\beta}\rangle+\langle\boldsymbol{\beta},\boldsymbol{\alpha}\rangle+\langle\boldsymbol{\beta},\boldsymbol{\beta}\rangle$，再用 $\langle\boldsymbol{\beta},\boldsymbol{\alpha}\rangle=\overline{\langle\boldsymbol{\alpha},\boldsymbol{\beta}\rangle}$ 即可. 1 推出 2. 3 略.

定义 2.1.3

设 $\boldsymbol{\alpha},\boldsymbol{\beta}\in\mathbb{C}^n$. 若 $\langle\boldsymbol{\alpha},\boldsymbol{\beta}\rangle=0$ ($\Longleftrightarrow\ \langle\boldsymbol{\beta},\boldsymbol{\alpha}\rangle=0$)，则称 $\boldsymbol{\alpha}$ 与 $\boldsymbol{\beta}$ 正交. 若子空间 U 中的向量与子空间 V 中的向量都正交，则称 U 与 V 正交. 子空间 U 的正交补是

$$U^{\perp}=\{\boldsymbol{\beta}\in\mathbb{C}^n:\langle\boldsymbol{\beta},\boldsymbol{\alpha}\rangle=0,\forall\boldsymbol{\alpha}\in U\}=\{\boldsymbol{\beta}\in\mathbb{C}^n:\langle\boldsymbol{\alpha},\boldsymbol{\beta}\rangle=0,\forall\boldsymbol{\alpha}\in U\}.$$

命题 2.1.1

设 U,V 是 $\mathbb{C}^n$ 的复线性子空间，

1. 若 $U\perp V$，则 $U\cap V=0$.
2. $U^{\perp}$ 是子空间，且 $\dim_{\mathbb{C}}U^{\perp}=n-\dim_{\mathbb{C}}U$.
3. $(U^{\perp})^{\perp}=U$.

证明 1. 用 Hermite 内积的正定性. 若 $\boldsymbol{\alpha}\in U\cap V,U\perp V$，则 $\langle\boldsymbol{\alpha},\boldsymbol{\alpha}\rangle=0$，于是 $\boldsymbol{\alpha}=0$.

2. 用 Hermite 内积关于第一个向量的“共轭线性”$\langle b_1\boldsymbol{\beta}_1+b_2\boldsymbol{\beta}_2,\boldsymbol{\alpha}\rangle=\bar{b}_1\langle\boldsymbol{\beta}_1,\boldsymbol{\alpha}\rangle+\bar{b}_2\langle\boldsymbol{\beta}_2,\boldsymbol{\alpha}\rangle$ 验证 $U^{\perp}$ 在加法和数乘运算下封闭.

取 U 的一组基 $\boldsymbol{\alpha}_1,\cdots,\boldsymbol{\alpha}_k$，构造矩阵 $A=\begin{bmatrix}\boldsymbol{\alpha}_1 & \cdots & \boldsymbol{\alpha}_k\end{bmatrix}\in M_{n\times k}(\mathbb{C})$，则

$$\begin{aligned}\boldsymbol{\beta}\in U^{\perp} &\Longleftrightarrow \bar{\boldsymbol{\beta}}^{\mathrm{T}}\boldsymbol{\alpha}_i=0\quad(1\le i\le k) &&\Longleftrightarrow \bar{\boldsymbol{\beta}}^{\mathrm{T}}A=0\\ &\Longleftrightarrow \bar{A}^{\mathrm{T}}\boldsymbol{\beta}=0 &&\Longleftrightarrow \boldsymbol{\beta}\in N(\bar{A}^{\mathrm{T}}),\end{aligned}$$

于是 $\dim U^{\perp}=\dim N(\bar{A}^{\mathrm{T}})=n-r(\bar{A}^{\mathrm{T}})=n-r(A)=n-k=n-\dim U$.

3. 从 $U^{\perp}$ 的定义知 $U\perp U^{\perp}$，于是 $U\subseteq(U^{\perp})^{\perp}$. 比较维数发现

$$\dim(U^{\perp})^{\perp}=n-\dim U^{\perp}=n-(n-\dim U)=\dim U,$$

于是 $U=(U^{\perp})^{\perp}$.

命题 2.1.2

若 $A\in M_{m\times n}(\mathbb{C})$，则 $C(A)$ 与 $N(\bar{A}^{\mathrm{T}})$ 在 $\mathbb{C}^m$ 中互为正交补，$C(A^{\mathrm{T}})$ 与 $N(\bar{A})$ 在 $\mathbb{C}^n$ 中互为正交补，特别的 $C(A)\cap N(\bar{A}^{\mathrm{T}})=0,C(A^{\mathrm{T}})\cap N(\bar{A})=0$.

证明 从命题 8 中关于正交补空间维数部分的证明可以看出 $C(A)^{\perp}=N(\bar{A}^{\mathrm{T}})$. 用 A^{T} 替换 A 得 $C(A^{\mathrm{T}})^{\perp}=N(\bar{A})$.

命题 2.1.3

若 $A\in M_{m\times n}(\mathbb{C})$，则 $r(A)=r(\bar{A}^{\mathrm{T}}A)$.

证明 一方面，$Az=0\Longrightarrow\bar{A}^{\mathrm{T}}Az=0$. 另一方面，$\bar{A}^{\mathrm{T}}Az=0\Longrightarrow\bar{z}^{\mathrm{T}}\bar{A}^{\mathrm{T}}Az=0\Longleftrightarrow\|Az\|^2=0\Longrightarrow Az=0$. 于是 $N(A)=N(\bar{A}^{\mathrm{T}}A)$，取维数得 $n-r(A)=n-r(\bar{A}^{\mathrm{T}}A)$，所以 $r(A)=r(\bar{A}^{\mathrm{T}}A)$.

注 2.1.2

事实上，$A,\bar{A},A^{\mathrm{T}},\bar{A}^{\mathrm{T}},\bar{A}^{\mathrm{T}}A,A^{\mathrm{T}}\bar{A},A\bar{A}^{\mathrm{T}},\bar{A}A^{\mathrm{T}}$ 的秩都相等.

例题 2.3.

$A=\begin{bmatrix}1\\ \mathrm{i}\end{bmatrix}$，已计算 $C(A)=N(A^{\mathrm{T}})=\mathrm{Span}\left(\begin{bmatrix}1\\ \mathrm{i}\end{bmatrix}\right)$，$A^{\mathrm{T}}A=0$. 而

$$N(\bar{A}^{\mathrm{T}})=\left\{\begin{bmatrix}z_1\\ z_2\end{bmatrix}:\begin{bmatrix}1 & -\mathrm{i}\end{bmatrix}\begin{bmatrix}z_1\\ z_2\end{bmatrix}=0\right\}=\mathrm{Span}\left(\begin{bmatrix}\mathrm{i}\\ 1\end{bmatrix}\right)=\mathrm{Span}\left(\begin{bmatrix}1\\ -\mathrm{i}\end{bmatrix}\right),$$

$$\bar{A}^{\mathrm{T}}A=\begin{bmatrix}1\\-\mathrm{i}\end{bmatrix}\begin{bmatrix}1&\mathrm{i}\end{bmatrix}=(2).$$

故 $r(\bar{A}^{\mathrm{T}}A)=1=r(A)$ 且 $C(A)=\mathrm{Span}\left(\begin{bmatrix}1\\\mathrm{i}\end{bmatrix}\right)$ 和 $N(\bar{A}^{\mathrm{T}})=\mathrm{Span}\left(\begin{bmatrix}1\\-\mathrm{i}\end{bmatrix}\right)$ 是 $\mathbb{C}^2$ 中两条互相“垂直”的“复”直线.

定义 2.1.4

设 $\epsilon_1,\cdots,\epsilon_n\in\mathbb{C}^n$. 若 $\langle\epsilon_i,\epsilon_j\rangle=\bar{\epsilon}_i^{\mathrm{T}}\epsilon_j=\delta_{ij}$，则称 $\epsilon_1,\cdots,\epsilon_n$ 是 $\mathbb{C}^n$ 的标准正交基. 若只是 $\epsilon_i\neq 0\ (1\leq i\leq n)$ 且 $\langle\epsilon_i,\epsilon_j\rangle=0\ (i\neq j)$，则称 $\epsilon_1,\cdots,\epsilon_n$ 是 $\mathbb{C}^n$ 的正交基.

例题 2.4.

$e_1=\begin{bmatrix}1\\0\\\vdots\end{bmatrix},\cdots,e_n=\begin{bmatrix}0\\\vdots\\1\end{bmatrix}$ 是 $\mathbb{C}^n$ 的标准正交基. $\forall\theta_1,\cdots,\theta_n\in\mathbb{R}$, $\mathrm{e}^{\mathrm{i}\theta_1}e_1,\cdots,\mathrm{e}^{\mathrm{i}\theta_n}e_n$ 也是 $\mathbb{C}^n$ 的标准正交基.

引理 2.1.4

设 $\boldsymbol{\alpha},\boldsymbol{\beta}\in\mathbb{C}^n$，$\boldsymbol{\alpha}\neq 0$，则 $\boldsymbol{\beta}-\frac{\langle\boldsymbol{\alpha},\boldsymbol{\beta}\rangle}{\langle\boldsymbol{\alpha},\boldsymbol{\alpha}\rangle}\boldsymbol{\alpha}$ 与 $\boldsymbol{\alpha}$ 正交.

证明 直接验证 $\left\langle\boldsymbol{\alpha},\boldsymbol{\beta}-\frac{\langle\boldsymbol{\alpha},\boldsymbol{\beta}\rangle}{\langle\boldsymbol{\alpha},\boldsymbol{\alpha}\rangle}\boldsymbol{\alpha}\right\rangle=\langle\boldsymbol{\alpha},\boldsymbol{\beta}\rangle-\frac{\langle\boldsymbol{\alpha},\boldsymbol{\beta}\rangle}{\langle\boldsymbol{\alpha},\boldsymbol{\alpha}\rangle}\langle\boldsymbol{\alpha},\boldsymbol{\alpha}\rangle=0.$

注 2.1.3

注意，与 $\boldsymbol{\alpha}$ 正交的不是 $\boldsymbol{\beta}-\frac{\langle\boldsymbol{\beta},\boldsymbol{\alpha}\rangle}{\langle\boldsymbol{\alpha},\boldsymbol{\alpha}\rangle}\boldsymbol{\alpha}=\boldsymbol{\beta}-\frac{\overline{\langle\boldsymbol{\alpha},\boldsymbol{\beta}\rangle}}{\langle\boldsymbol{\alpha},\boldsymbol{\alpha}\rangle}\boldsymbol{\alpha}$. 有些地方 Hermite 内积定义为 $\langle\boldsymbol{\alpha},\boldsymbol{\beta}\rangle_1=\boldsymbol{\alpha}^{\mathrm{T}}\bar{\boldsymbol{\beta}}$，与 $\langle\boldsymbol{\alpha},\boldsymbol{\beta}\rangle=\bar{\boldsymbol{\alpha}}^{\mathrm{T}}\boldsymbol{\beta}$ 差一个共轭，但向量的长度和两个向量正交与否在这两种定义下是一致的.

定理 2.1.1 (Cauchy-Schwarz 不等式)

$\forall\boldsymbol{\alpha},\boldsymbol{\beta}\in\mathbb{C}^n$,

$$|\langle\boldsymbol{\alpha},\boldsymbol{\beta}\rangle|\leq\|\boldsymbol{\alpha}\|\|\boldsymbol{\beta}\|,$$

且等号成立当且仅当 $\boldsymbol{\alpha},\boldsymbol{\beta}$ 线性相关.

证明 当 $\boldsymbol{\alpha}=0$ 时，定理显然成立. 不妨设 $\boldsymbol{\alpha}\neq 0$. 由引理2.1.4知

$$\boldsymbol{\beta}=\underbrace{\frac{\langle\boldsymbol{\alpha},\boldsymbol{\beta}\rangle}{\langle\boldsymbol{\alpha},\boldsymbol{\alpha}\rangle}\boldsymbol{\alpha}}_{\boldsymbol{\beta}_1}+\underbrace{\left(\boldsymbol{\beta}-\frac{\langle\boldsymbol{\alpha},\boldsymbol{\beta}\rangle}{\langle\boldsymbol{\alpha},\boldsymbol{\alpha}\rangle}\boldsymbol{\alpha}\right)}_{\boldsymbol{\beta}_2},$$

其中 $\boldsymbol{\beta}_1=\mathrm{Proj}_{\mathbb{C}\boldsymbol{\alpha}}\boldsymbol{\beta}$ 与 $\boldsymbol{\beta}_2=\mathrm{Proj}_{(\mathbb{C}\boldsymbol{\alpha})^\perp}\boldsymbol{\beta}$ 正交. 再由引理2.1.3知

$$\|\boldsymbol{\beta}\|^2=\|\boldsymbol{\beta}_1\|^2+\|\boldsymbol{\beta}_2\|^2,$$

所以 $\|\boldsymbol{\beta}\|^2\geq\|\boldsymbol{\beta}_1\|^2=\left|\frac{\langle\boldsymbol{\alpha},\boldsymbol{\beta}\rangle}{\langle\boldsymbol{\alpha},\boldsymbol{\alpha}\rangle}\right|^2\|\boldsymbol{\alpha}\|^2=\frac{|\langle\boldsymbol{\alpha},\boldsymbol{\beta}\rangle|^2}{\|\boldsymbol{\alpha}\|^2}$，整理即得 CS 不等式，而且此时等号成立当且仅当 $\|\boldsymbol{\beta}_2\|=0$，也就是 $\boldsymbol{\beta}=\frac{\langle\boldsymbol{\alpha},\boldsymbol{\beta}\rangle}{\langle\boldsymbol{\alpha},\boldsymbol{\alpha}\rangle}\boldsymbol{\alpha}$.

推论 2.1.1 (三角不等式)

$\forall \boldsymbol{\alpha}, \boldsymbol{\beta} \in \mathbb{C}^n$,

$$|\|\boldsymbol{\alpha}\| - \|\boldsymbol{\beta}\|| \leq \|\boldsymbol{\alpha} + \boldsymbol{\beta}\| \leq \|\boldsymbol{\alpha}\| + \|\boldsymbol{\beta}\|.$$

♠

证明　由引理2.1.3知 $\|\boldsymbol{\alpha} + \boldsymbol{\beta}\|^2 = \|\boldsymbol{\alpha}\|^2 + 2\operatorname{Re}\langle \boldsymbol{\alpha}, \boldsymbol{\beta}\rangle + \|\boldsymbol{\beta}\|^2$. 代入 $\operatorname{Re}\langle \boldsymbol{\alpha}, \boldsymbol{\beta}\rangle \leq |\operatorname{Re}\langle \boldsymbol{\alpha}, \boldsymbol{\beta}\rangle| \leq |\langle \boldsymbol{\alpha}, \boldsymbol{\beta}\rangle| \leq \|\boldsymbol{\alpha}\|\|\boldsymbol{\beta}\|$，得到

$$\|\boldsymbol{\alpha} + \boldsymbol{\beta}\|^2 \leq \|\boldsymbol{\alpha}\|^2 + 2\|\boldsymbol{\alpha}\|\|\boldsymbol{\beta}\| + \|\boldsymbol{\beta}\|^2 = (\|\boldsymbol{\alpha}\| + \|\boldsymbol{\beta}\|)^2,$$

取平方根得到 $\|\boldsymbol{\alpha} + \boldsymbol{\beta}\| \leq \|\boldsymbol{\alpha}\| + \|\boldsymbol{\beta}\|$.

另一个方向的不等式可以用 $\operatorname{Re}\langle \boldsymbol{\alpha}, \boldsymbol{\beta}\rangle \geq -|\operatorname{Re}\langle \boldsymbol{\alpha}, \boldsymbol{\beta}\rangle| \geq -|\langle \boldsymbol{\alpha}, \boldsymbol{\beta}\rangle| \geq -\|\boldsymbol{\alpha}\|\|\boldsymbol{\beta}\|$.

2.2 Gram-Schimidt 正交化，QR 分解

定理 2.2.1 (Gram-Schmidt)

设 $\boldsymbol{\alpha}_1, \cdots, \boldsymbol{\alpha}_k$ 是 $\mathbb{C}^n$ 中 k 个线性无关的向量，则存在唯一的一组向量 $\boldsymbol{\beta}_1, \cdots, \boldsymbol{\beta}_k$ 使得

1. $\boldsymbol{\beta}_j = \boldsymbol{\alpha}_j + \sum_{1 \leq i < j} a_{ij}\boldsymbol{\alpha}_i$ $(1 \leq j \leq k)$,
2. $\boldsymbol{\beta}_1, \cdots, \boldsymbol{\beta}_k$ 两两正交.

事实上，这组向量可以用如下的公式计算

$$\begin{aligned}
\boldsymbol{\beta}_1 &= \boldsymbol{\alpha}_1, \\
\boldsymbol{\beta}_2 &= \boldsymbol{\alpha}_2 - \frac{\langle \boldsymbol{\beta}_1, \boldsymbol{\alpha}_2\rangle}{\langle \boldsymbol{\beta}_1, \boldsymbol{\beta}_1\rangle}\boldsymbol{\beta}_1, \\
&\vdots \\
\boldsymbol{\beta}_k &= \boldsymbol{\alpha}_k - \frac{\langle \boldsymbol{\beta}_1, \boldsymbol{\alpha}_k\rangle}{\langle \boldsymbol{\beta}_1, \boldsymbol{\beta}_1\rangle}\boldsymbol{\beta}_1 - \cdots - \frac{\langle \boldsymbol{\beta}_{k-1}, \boldsymbol{\alpha}_k\rangle}{\langle \boldsymbol{\beta}_{k-1}, \boldsymbol{\beta}_{k-1}\rangle}\boldsymbol{\beta}_{k-1}.
\end{aligned}$$

♡

例题 2.5.

设 $\boldsymbol{\alpha}_1 = \begin{bmatrix} 1 \\ \mathrm{i} \\ 1-\mathrm{i} \end{bmatrix}, \boldsymbol{\alpha}_2 = \begin{bmatrix} 1+\mathrm{i} \\ 2\mathrm{i} \\ 2+\mathrm{i} \end{bmatrix}$，求 $\operatorname{Span}(\boldsymbol{\alpha}_1, \boldsymbol{\alpha}_2)$ 的标准正交基，并扩充为 $\mathbb{C}^3$ 的标准正交基.

解. 解答：令 $\boldsymbol{\beta}_1 = \boldsymbol{\alpha}_1 = \begin{bmatrix} 1 \\ \mathrm{i} \\ 1-\mathrm{i} \end{bmatrix}$. 计算得

$$\frac{\langle \boldsymbol{\alpha}_1, \boldsymbol{\alpha}_2\rangle}{\langle \boldsymbol{\alpha}_1, \boldsymbol{\alpha}_1\rangle} = \frac{1(1+\mathrm{i}) - \mathrm{i}(2\mathrm{i}) + (1+\mathrm{i})(2+\mathrm{i})}{1^2 + |\mathrm{i}|^2 + |1-\mathrm{i}|^2} = \frac{4+4\mathrm{i}}{4} = 1+\mathrm{i},$$

于是

$$\boldsymbol{\beta}_2 = \boldsymbol{\alpha}_2 - \frac{\langle \boldsymbol{\alpha}_1, \boldsymbol{\alpha}_2\rangle}{\langle \boldsymbol{\alpha}_1, \boldsymbol{\alpha}_1\rangle}\boldsymbol{\alpha}_1 = \begin{bmatrix} 1+\mathrm{i} \\ 2\mathrm{i} \\ 2+\mathrm{i} \end{bmatrix} - (1+\mathrm{i})\begin{bmatrix} 1 \\ \mathrm{i} \\ 1-\mathrm{i} \end{bmatrix} = \begin{bmatrix} 0 \\ 1+\mathrm{i} \\ \mathrm{i} \end{bmatrix}.$$

易知 $\boldsymbol{\beta}_1, \boldsymbol{\beta}_2$ 是 $\operatorname{Span}(\boldsymbol{\alpha}_1, \boldsymbol{\alpha}_2)$ 的正交基. 为求标准正交基，计算 $\boldsymbol{\beta}_1, \boldsymbol{\beta}_2$ 的长度得 $\|\boldsymbol{\beta}_1\| = \sqrt{4} = 2$, $\|\boldsymbol{\beta}_2\| = \sqrt{2+1} = \sqrt{3}$.

于是

$$\epsilon_1 = \begin{bmatrix} \frac{1}{2} \\ \frac{\mathrm{i}}{2} \\ \frac{1-\mathrm{i}}{2} \end{bmatrix}, \quad \epsilon_2 = \begin{bmatrix} 0 \\ \frac{1+\mathrm{i}}{\sqrt{3}} \\ \frac{\mathrm{i}}{\sqrt{3}} \end{bmatrix}$$

是 $\mathrm{Span}(\boldsymbol{\alpha}_1, \boldsymbol{\alpha}_2)$ 的标准正交基.

还需计算 $\mathrm{Span}(\boldsymbol{\alpha}_1, \boldsymbol{\alpha}_2)^\perp$. 令 $\gamma = \begin{bmatrix} z_1 \\ z_2 \\ z_3 \end{bmatrix}$，则 γ 与 $\boldsymbol{\beta}_1, \boldsymbol{\beta}_2$ 正交当且仅当

$$\begin{cases} \bar{1} z_1 + \bar{\mathrm{i}} z_2 + \overline{(1-\mathrm{i})} z_3 = 0 \\ \bar{0} z_1 + \overline{(1+\mathrm{i})} z_2 + \bar{\mathrm{i}} z_3 = 0 \end{cases} \iff \begin{cases} z_1 - \mathrm{i} z_2 + (1+\mathrm{i}) z_3 = 0 \\ (1-\mathrm{i}) z_2 - \mathrm{i} z_3 = 0 \end{cases}.$$

当 $z_2 = 1$ 时，方程组的解为 $z_3 = -1 - \mathrm{i}, z_1 = 3\mathrm{i}$. 单位化后得到

$$\epsilon_3 = \begin{bmatrix} \frac{\sqrt{3}\mathrm{i}}{2} \\ \frac{1}{2\sqrt{3}} \\ \frac{-1-\mathrm{i}}{2\sqrt{3}} \end{bmatrix}.$$

于是 $\epsilon_1, \epsilon_2, \epsilon_3$ 构成 $\mathbb{C}^3$ 的标准正交基.

引理 2.2.1

设 $Q \in M_{m\times n}(\mathbb{C})$，则 Q 的列是单位正交向量组当且仅当 $\bar{Q}^{\mathrm{T}} Q = I_n$.

命题 2.2.1

设 $A \in M_{m\times n}(\mathbb{C})$ 是列满秩矩阵，则存在唯一的满足 $\bar{Q}^{\mathrm{T}} Q = I_n$ 的 $m \times n$ 阶复矩阵 Q 和对角线元素大于 0 的 n 阶上三角复方阵 R 使得 $A = QR$.

证明 证明方法同实矩阵的 QR 分解. Q 的列向量是对 A 的列作 Gram-Schmidt 正交化，然后再单位化后得到的向量. 若 A 有两个这样的分解 $A = Q_1 R_1 = Q_2 R_2$，则 $Q_2 = Q_1 R$，其中 $R = R_1 R_2^{-1}$ 仍是对角线元素大于 0 的 n 阶上三角阵. 计算得 $\bar{Q}_2^{\mathrm{T}} Q_2 = \bar{R}^{\mathrm{T}} \bar{Q}_1^{\mathrm{T}} Q_1 R$. 由于 $\bar{Q}_2^{\mathrm{T}} Q_2 = \bar{Q}_1^{\mathrm{T}} Q_1 = I_n$，于是 $\bar{R}^{\mathrm{T}} R = I_n$，再结合 R 的性质可以推出 $R = I_n$（题 4），于是 $R_1 = R_2, Q_1 = Q_2$.

例题 2.6.

$A = \begin{bmatrix} 1 & 1+\mathrm{i} \\ \mathrm{i} & 2\mathrm{i} \\ 1-\mathrm{i} & 2+\mathrm{i} \end{bmatrix}$. A 的列是例2.2中的向量 $\boldsymbol{\alpha}_1, \boldsymbol{\alpha}_2$. 从例2.2的计算提炼出下面的关系式

$$[\epsilon_1\ \epsilon_2] = [\boldsymbol{\beta}_1\ \boldsymbol{\beta}_2] \begin{bmatrix} \frac{1}{2} & 0 \\ 0 & \frac{1}{\sqrt{3}} \end{bmatrix} = [\boldsymbol{\alpha}_1\ \boldsymbol{\alpha}_2] \begin{bmatrix} 1 & -1-\mathrm{i} \\ 0 & 1 \end{bmatrix} \begin{bmatrix} \frac{1}{2} & 0 \\ 0 & \frac{1}{\sqrt{3}} \end{bmatrix}.$$

故若令

$$Q = [\epsilon_1\ \epsilon_2] = \begin{bmatrix} \frac{1}{2} & 0 \\ \frac{\mathrm{i}}{2} & \frac{1+\mathrm{i}}{\sqrt{3}} \\ \frac{1-\mathrm{i}}{2} & \frac{\mathrm{i}}{\sqrt{3}} \end{bmatrix},$$

$$R = \left(\begin{bmatrix} 1 & -1-\mathrm{i} \\ 0 & 1 \end{bmatrix} \begin{bmatrix} \frac{1}{2} & 0 \\ 0 & \frac{1}{\sqrt{3}} \end{bmatrix} \right)^{-1} = \begin{bmatrix} 2 & 2+2\mathrm{i} \\ 0 & \sqrt{3} \end{bmatrix},$$

则 $A = QR$.

2.3 酉矩阵和 Hermitian 矩阵

定义 2.3.1

设 $Q \in M_n(\mathbb{C})$. 若 $\bar{Q}^{\mathrm{T}}Q = I_n$，则称 Q 是酉阵（unitary matrix）.

定理 2.3.1

设 $Q \in M_n(\mathbb{C})$，则以下条件等价

1. $\bar{Q}^{\mathrm{T}}Q = I_n$,
2. $Q\bar{Q}^{\mathrm{T}} = I_n$,
3. $\bar{Q}^{\mathrm{T}}Q = Q\bar{Q}^{\mathrm{T}} = I_n$,
4. Q 的列是 $\mathbb{C}^n$ 的标准正交基,
5. Q 的行（在不计转置意义下）是 $\mathbb{C}^n$ 的标准正交基,
6. 复线性变换 $Q : \mathbb{C}^n \to \mathbb{C}^n$ 保厄米特内积，即 $\langle Qz, Qw\rangle = \langle z, w\rangle, \forall z, w \in \mathbb{C}^n$.
7. 复线性变换 $Q : \mathbb{C}^n \to \mathbb{C}^n$ 保长度，即 $\|Qz\| = \|z\|, \forall z \in \mathbb{C}^n$.

证明　与实正交阵的各种等价刻画的证明一样，唯一有点难度的是 (7) 推 (1)，见题 5.

引理 2.3.1

若 Q 是酉阵，则 $\bar{Q}, Q^{\mathrm{T}}, Q^{-1} = \bar{Q}^{\mathrm{T}}$ 均是酉阵. 若 Q_1, Q_2 是同阶酉阵，则 Q_1Q_2 也是酉阵.

证明　练习.

例题 2.7.

1. 1 阶酉阵与模为 1 的复数一一对应.
2. $D = \mathrm{diag}(\mathrm{e}^{\mathrm{i}\theta_1}, \cdots, \mathrm{e}^{\mathrm{i}\theta_n})$ 是酉阵，其中 $\theta_1, \cdots, \theta_n \in \mathbb{R}$. 对角酉阵均具有这种形式.
3. 例2.2中的标准正交基 $\epsilon_1, \epsilon_2, \epsilon_3$ 给出 3 阶酉阵

$$\begin{bmatrix} \frac{1}{2} & +0 & \frac{\sqrt{3}\mathrm{i}}{2} \\ \frac{\mathrm{i}}{2} & \frac{1+\mathrm{i}}{\sqrt{3}} & \frac{1}{2\sqrt{3}} \\ \frac{1-\mathrm{i}}{2} & \frac{\mathrm{i}}{\sqrt{3}} & \frac{-1-\mathrm{i}}{2\sqrt{3}} \end{bmatrix}.$$

练习 2.1 设 n 阶复方阵 R 是上三角阵，对角线元素均是正实数，而且是酉阵，证明 $R = I_n$.

例题 2.8.

若 $\begin{bmatrix} z_1 & z_2 \\ z_3 & z_4 \end{bmatrix}$ 是 2 阶酉阵，则 $\begin{bmatrix} z_1 \\ z_2 \end{bmatrix}, \begin{bmatrix} z_3 \\ z_4 \end{bmatrix}$ 是单位向量且两者正交，即

$$|z_1|^2 + |z_2|^2 = |z_3|^2 + |z_4|^2 = 1, \quad \bar{z}_1 z_3 + \bar{z}_2 z_4 = 0.$$

若 $z_2 \neq 0$，则 $z_4 = -\frac{\bar{z}_1 z_3}{\bar{z}_2}$，

$$\begin{bmatrix} z_3 \\ z_4 \end{bmatrix} = \begin{bmatrix} z_3 \\ -\frac{\bar{z}_1 z_3}{\bar{z}_2} \end{bmatrix} = -\frac{z_3}{\bar{z}_2} \begin{bmatrix} -\bar{z}_2 \\ \bar{z}_1 \end{bmatrix}.$$

若 $z_1 \neq 0$，则 $z_3 = -\frac{\bar{z}_2 z_4}{\bar{z}_1}$，

$$\begin{bmatrix} z_3 \\ z_4 \end{bmatrix} = \begin{bmatrix} -\frac{\bar{z}_2 z_4}{\bar{z}_1} \\ z_4 \end{bmatrix} = \frac{z_4}{\bar{z}_1} \begin{bmatrix} -\bar{z}_2 \\ \bar{z}_1 \end{bmatrix}.$$

无论哪种情况，都存在 $c \in \mathbb{C}$ 使得

$$\begin{bmatrix} z_3 \\ z_4 \end{bmatrix} = c \begin{bmatrix} -\bar{z}_2 \\ \bar{z}_1 \end{bmatrix},$$

于是

$$\|z_3\|^2 + \|z_4\|^2 = \|c\|^2 \left(\| -\bar{z}_2\|^2 + \|z_1\|^2 \right).$$

由于 $\|z_1\|^2 + \|z_2\|^2 = \|z_3\|^2 + \|z_4\|^2 = 1$，所以 $\|c\| = 1$.
反之，容易验证形如

$$\begin{bmatrix} z_1 & z_2 \\ -c\bar{z}_2 & c\bar{z}_1 \end{bmatrix}$$

的矩阵是酉阵，其中 $\|z_1\|^2 + \|z_2\|^2 = 1 = \|c\|$.
上述酉阵的行列式是

$$cz_1\bar{z}_1 + cz_2\bar{z}_2 = c,$$

故行列式为 1 的 2 阶酉阵均形如

$$\begin{bmatrix} z_1 & z_2 \\ -\bar{z}_2 & \bar{z}_1 \end{bmatrix}, \quad \text{其中} \|z_1\|^2 + \|z_2\|^2 = 1.$$

引理 2.3.2

酉阵的特征值和行列式均是模为 1 的复数.

证明 设 $Q\boldsymbol{\alpha} = \lambda\boldsymbol{\alpha}$，其中 Q 是酉阵，λ 是其特征值，$0 \neq \boldsymbol{\alpha}$ 是特征向量. 由于酉阵保长度，故

$$\|\boldsymbol{\alpha}\| = \|Q\boldsymbol{\alpha}\| = \|\lambda\boldsymbol{\alpha}\| = |\lambda| \cdot \|\boldsymbol{\alpha}\|.$$

又因非零向量 $\boldsymbol{\alpha}$ 的长度 $\|\boldsymbol{\alpha}\|$ 大于 0，所以 $|\lambda| = 1$.

矩阵的行列式等于所有特征值的乘积，故酉阵的行列式也是模为 1 的复数.

另一个方法是在等式 $\bar{Q}^{\mathrm{T}}Q = I_n$ 的两边取行列式，并用行列式的性质 $\det \bar{A} = \overline{\det A}$, $\det A^{\mathrm{T}} = \det A$, $\det(AB) = \det(A)\det(B)$.

练习 2.2 设 $A \in M_{m\times n}(\mathbb{C})$ 是列满秩矩阵，则 $\mathbb{C}^m$ 中到 $C(A)$ 的投影矩阵是什么？

（复）酉阵是（实）正交阵的推广. 前者给出了 $\mathbb{C}^n$ 上保厄米特内积的复线性变换，后者给出了 $\mathbb{R}^n$ 上保点积的实线性变换. 实矩阵中的酉阵就是实正交阵.

下面，我们讨论实对称阵在复数域的推广.

定义 2.3.2

设 $S \in M_n(\mathbb{C})$，若 $\bar{S}^{\mathrm{T}} = S$，则称 S 是厄米特矩阵（Hermitian matrix）.

若 $S = \left[s_{ij}\right]$，则 $\bar{S}^{\mathrm{T}} = S$ 当且仅当 $\bar{s}_{ij} = s_{ji}$，即 S 的对角线元素 s_{ii} 都是实数，而关于对角线对称的元素互为共轭.

1 阶厄米特阵就是实数，2 阶厄米特阵形如

$$\begin{bmatrix} a & b+c\mathrm{i} \\ b-c\mathrm{i} & d \end{bmatrix}, \quad \text{其中} a,b,c,d \in \mathbb{R}.$$

若将 S 写成实部加虚部的形式 $S = A + \mathrm{i}B$，其中 $A, B \in M_n(\mathbb{R})$，则 S 是厄米特阵当且仅当

$$A + \mathrm{i}B = \bar{S}^{\mathrm{T}} = A^{\mathrm{T}} - \mathrm{i}B^{\mathrm{T}},$$

即 $A^{\mathrm{T}} = A,\ B^{\mathrm{T}} = -B$.

在上例中，

$$A = \begin{bmatrix} a & b \\ b & d \end{bmatrix}, \quad B = \begin{bmatrix} 0 & c \\ -c & 0 \end{bmatrix}.$$

Hermite 阵 S 定义的 Hermite 型是

$$H_S(z) = \bar{z}^{\mathrm{T}} S z, \quad z \in \mathbb{C}^n.$$

虽然 z, S 都是定义在复数上的，但是 $H_S(z)$ 的值总是实数，这是因为

$$\overline{\bar{z}^{\mathrm{T}} S z} = (\overline{\bar{z}^{\mathrm{T}} S z})^{\mathrm{T}} = \bar{z}^{\mathrm{T}} \bar{S}^{\mathrm{T}} (\bar{z}^{\mathrm{T}})^{\mathrm{T}} = \bar{z}^{\mathrm{T}} S z.$$

从元素的角度看，如果 $S = \left[s_{ij}\right], z = \begin{bmatrix} z_1 \\ \vdots \\ z_n \end{bmatrix}$，那么

$$\bar{z}^{\mathrm{T}} S z = \sum_{i,j} s_{ij} \bar{z}_i z_j = \sum_{i=1}^{n} s_{ii} |z_i|^2 + \sum_{1 \le i < j \le n} \left(s_{ij} \bar{z}_i z_j + \bar{s}_{ij} \bar{z}_j z_i \right).$$

最后括号中的两项互为共轭，故和为实数.

由于 Hermite 型的取值总是实数，我们可以像实二次型一样，定义什么是正定 Hermite 型，正定 Hermite 阵等. 比如，Hermite 阵 S 称为半正定，如果

$$\bar{z}^{\mathrm{T}} S z \ge 0, \quad \forall z \in \mathbb{C}^n.$$

与实对称阵一样，Hermite 阵的正定、负定等性质可通过它的特征值判定.

引理 2.3.3

Hermite 阵的特征值都是实数.

证明 设 $Sz = \lambda z$，其中 S 是 Hermite 阵，$0 \ne z \in \mathbb{C}^n, \lambda \in \mathbb{C}$，则

$$\bar{z}^{\mathrm{T}} S z = \bar{z}^{\mathrm{T}} \lambda z = \lambda \bar{z}^{\mathrm{T}} z = \lambda \|z\|^2.$$

因为 $\bar{z}^{\mathrm{T}} S z \in \mathbb{R}, \|z\| > 0$，所以 $\lambda \in \mathbb{R}$.

练习 2.3 设 S, S_1, S_2 是 n 阶厄米特阵，A 是 n 阶复方阵. 证明：

1. 若 $\bar{z}^{\mathrm{T}} S z = 0$，$\forall z \in \mathbb{C}^n$，则 $S = 0$.
2. 若 $\bar{z}^{\mathrm{T}} S_1 z = \bar{z}^{\mathrm{T}} S_2 z$，$\forall z \in \mathbb{C}^n$，则 $S_1 = S_2$.

3. $\bar{A}^{\mathrm{T}}A$ 是厄米特阵.
4. 若 A 满足 $\|Az\| = \|z\|$，$\forall z \in \mathbb{C}^n$，则 A 是酉阵.

例题 2.9.

若 $A \in M_{m\times n}(\mathbb{C})$，则 $\bar{A}^{\mathrm{T}}A$ 是 n 阶半正定 Hermite 阵，其特征值为非负实数.

注 2.3.1

从线性变换的角度看，Hermite 阵可由下面的性质刻画

$$\langle Sz, w\rangle = \langle z, Sw\rangle, \quad \forall z, w \in \mathbb{C}^n,$$

即 Hermite 阵定义的复线性变换相对于 $\mathbb{C}^n$ 的 Hermite 内积是“对称”的.
这是因为等式左边等于 $\overline{Sz}^{\mathrm{T}}w = \bar{z}^{\mathrm{T}}\bar{S}^{\mathrm{T}}w$，等式右边等于 $\bar{z}^{\mathrm{T}}(Sw) = \bar{z}^{\mathrm{T}}Sw$.
若还有 $Sz = \lambda z, Sw = \mu w$，其中 $\lambda, \mu \in \mathbb{R}$，$z, w \neq 0$，则

$$\langle Sz, w\rangle = \langle \lambda z, w\rangle = \bar{\lambda}\langle z, w\rangle = \lambda\langle z, w\rangle,$$

$$\langle z, Sw\rangle = \langle z, \mu w\rangle = \mu\langle z, w\rangle,$$

于是 $\lambda\langle z, w\rangle = \mu\langle z, w\rangle$. 若 $\lambda \neq \mu$，则 $\langle z, w\rangle = 0$.
这说明了 Hermite 阵的属于不同特征值的特征向量是正交的.
用类似的方法可以证明，酉阵的属于不同特征值的特征向量是正交的.
设 Q 是酉阵，且 $Qz = \lambda z$，$Qw = \mu w$，其中 $|\lambda| = |\mu| = 1$，$z, w \neq 0$. 酉矩阵保 Hermite 内积，故

$$\langle Qz, Qw\rangle = \langle z, w\rangle.$$

等式左边等于 $\langle \lambda z, \mu w\rangle = \bar{\lambda}\mu\langle z, w\rangle$.
由于 λ 的模为 1，所以 $\bar{\lambda}\mu = \lambda^{-1}\mu$，故当 $\lambda \neq \mu$ 时，$\bar{\lambda}\mu \neq 1$，从而 $\langle z, w\rangle = 0$.

例题 2.10.

$S = \begin{bmatrix} 2 & 3-3\mathrm{i} \\ 3+3\mathrm{i} & 5 \end{bmatrix}$ 是 Hermite 阵.

1. S 的特征多项式是 $\lambda^2 - 7\lambda - 8 = (\lambda+1)(\lambda-8)$，特征值是 $\lambda_1 = 8, \lambda_2 = -1$.
2. $S - 8I = \begin{bmatrix} -6 & 3-3\mathrm{i} \\ 3+3\mathrm{i} & -3 \end{bmatrix}$, $N(S-8I) = \mathbb{C}\alpha_1$，其中 $\alpha_1 = \begin{bmatrix} 1 \\ 1+\mathrm{i} \end{bmatrix}$.
3. $S - (-1)I_2 = \begin{bmatrix} 3 & 3-3\mathrm{i} \\ 3+3\mathrm{i} & 6 \end{bmatrix}$, $N(S+I_2) = \mathbb{C}\alpha_2$，其中 $\alpha_2 = \begin{bmatrix} 1-\mathrm{i} \\ -1 \end{bmatrix}$.
4. 若不相信可以验证 $\bar{\alpha}_1^{\mathrm{T}}\alpha_2 = 1(1-\mathrm{i}) + (1-\mathrm{i})(-1) = 0$.
5. 令

$$\epsilon_1 = \frac{\alpha_1}{\|\alpha_1\|} = \begin{bmatrix} \frac{1}{\sqrt{3}} \\ \frac{1+\mathrm{i}}{\sqrt{3}} \end{bmatrix}, \quad \epsilon_2 = \frac{\alpha_2}{\|\alpha_2\|} = \begin{bmatrix} \frac{1-\mathrm{i}}{\sqrt{3}} \\ \frac{-1}{\sqrt{3}} \end{bmatrix},$$

   则 ϵ_1, ϵ_2 是 $\mathbb{C}^2$ 的标准正交基，也是 S 的（单位）特征向量.
6. 令 $Q = [\epsilon_1\ \epsilon_2] = \begin{bmatrix} \frac{1}{\sqrt{3}} & \frac{1-i}{\sqrt{3}} \\ \frac{1+i}{\sqrt{3}} & -\frac{1}{\sqrt{3}} \end{bmatrix}$, 则 Q 是酉阵且 $SQ = Q\Lambda$, 其中 $\Lambda = \begin{bmatrix} 8 & 0 \\ 0 & -1 \end{bmatrix}$. 也可写作 $\bar{Q}^{\mathrm{T}}SQ = \Lambda$ 或 $S = Q\Lambda\bar{Q}^{\mathrm{T}}$.

例题 2.11.

$$Q=\begin{bmatrix}\frac{\sqrt{2}}{2} & \frac{1+\mathrm{i}}{2}\\ \frac{-1+\mathrm{i}}{2} & \frac{\sqrt{2}}{2}\end{bmatrix}$$

1. Q 的特征多项式是 $\lambda^2-\sqrt{2}\lambda+1=0$，特征值是 $\frac{\sqrt{2}\pm\sqrt{2-4}}{2}$. 令 $\lambda_1=\frac{\sqrt{2}+\sqrt{2}\mathrm{i}}{2}=\mathrm{e}^{\mathrm{i}\pi/4}$, $\lambda_2=\frac{\sqrt{2}-\sqrt{2}\mathrm{i}}{2}=\mathrm{e}^{-\mathrm{i}\pi/4}$.
2. $Q-\lambda_1 I=\begin{bmatrix}-\frac{\sqrt{2}}{2}\mathrm{i} & \frac{1+\mathrm{i}}{2}\\ \frac{-1+\mathrm{i}}{2} & -\frac{\sqrt{2}}{2}\mathrm{i}\end{bmatrix}$, $\alpha_1=\begin{bmatrix}\sqrt{2}-\sqrt{2}\mathrm{i}\\ 1\end{bmatrix}$, $\epsilon_1=\frac{\alpha_1}{2\sqrt{2}}$.
3. $Q-\lambda_2 I=\begin{bmatrix}\frac{\sqrt{2}}{2}\mathrm{i} & \frac{1+\mathrm{i}}{2}\\ \frac{-1+\mathrm{i}}{2} & \frac{\sqrt{2}}{2}\mathrm{i}\end{bmatrix}$, $\alpha_2=\begin{bmatrix}-\sqrt{2}+\sqrt{2}\mathrm{i}\\ 1\end{bmatrix}$, $\epsilon_2=\frac{\alpha_2}{2\sqrt{2}}$.
4. 若令 $Q_1=[\epsilon_1\ \epsilon_2]=\begin{bmatrix}\frac{1-\mathrm{i}}{2\sqrt{2}} & \frac{-1+\mathrm{i}}{2\sqrt{2}}\\ \frac{1}{2\sqrt{2}} & \frac{1}{2\sqrt{2}}\end{bmatrix}$, $\Lambda=\begin{bmatrix}\lambda_1 & 0\\ 0 & \lambda_2\end{bmatrix}=\begin{bmatrix}\mathrm{e}^{\mathrm{i}\pi/4} & 0\\ 0 & \mathrm{e}^{-\mathrm{i}\pi/4}\end{bmatrix}$, 则 $\bar{Q}_1^{\mathrm{T}}QQ_1=\Lambda$,

$$\underbrace{\begin{bmatrix}\frac{1+\mathrm{i}}{2\sqrt{2}} & \frac{1}{2\sqrt{2}}\\ \frac{-1-\mathrm{i}}{2\sqrt{2}} & \frac{1}{2\sqrt{2}}\end{bmatrix}}_{\bar{Q}_1^{\mathrm{T}}}\underbrace{\begin{bmatrix}\frac{\sqrt{2}}{2} & \frac{1+\mathrm{i}}{2}\\ \frac{-1+\mathrm{i}}{2} & \frac{\sqrt{2}}{2}\end{bmatrix}}_{Q}\underbrace{\begin{bmatrix}\frac{1-\mathrm{i}}{2\sqrt{2}} & \frac{-1+\mathrm{i}}{2\sqrt{2}}\\ \frac{1}{2\sqrt{2}} & \frac{1}{2\sqrt{2}}\end{bmatrix}}_{Q_1}=\underbrace{\begin{bmatrix}\mathrm{e}^{\mathrm{i}\pi/4} & 0\\ 0 & \mathrm{e}^{-\mathrm{i}\pi/4}\end{bmatrix}}_{\Lambda},$$

这里的 Q_1, Q, Λ 都是酉阵.

是否任意的 Hermite 阵或酉阵都可以酉相似对角化？答案是肯定的，但光从这两种特殊矩阵的属于不同特征值的特征向量正交还不能推出这个结论. 我们需要进一步探讨.

定义 2.3.3

设 $A\in M_n(\mathbb{C})$，若存在酉阵 Q 和对角阵 Λ 使得 $\bar{Q}^{\mathrm{T}}AQ=\Lambda$，则称 A 可酉相似对角化.

引理 2.3.4

若 A 可酉相似对角化，则 $A\bar{A}^{\mathrm{T}}=\bar{A}^{\mathrm{T}}A$.

证明 $A=Q\Lambda\bar{Q}^{\mathrm{T}}$, $\bar{A}^{\mathrm{T}}=Q\bar{\Lambda}^{\mathrm{T}}\bar{Q}^{\mathrm{T}}=Q\bar{\Lambda}\bar{Q}^{\mathrm{T}}$,

$$A\bar{A}^{\mathrm{T}}=Q\Lambda\bar{Q}^{\mathrm{T}}Q\bar{\Lambda}\bar{Q}^{\mathrm{T}}=Q\Lambda\bar{\Lambda}\bar{Q}^{\mathrm{T}},$$
$$\bar{A}^{\mathrm{T}}A=Q\bar{\Lambda}\bar{Q}^{\mathrm{T}}Q\Lambda\bar{Q}^{\mathrm{T}}=Q\bar{\Lambda}\Lambda\bar{Q}^{\mathrm{T}}.$$

由于 $\Lambda\bar{\Lambda}=\bar{\Lambda}\Lambda$，所以 $A\bar{A}^{\mathrm{T}}=\bar{A}^{\mathrm{T}}A$.

定义 2.3.4

设 $A\in M_n(\mathbb{C})$. 若 $A\bar{A}^{\mathrm{T}}=\bar{A}^{\mathrm{T}}A$，则称 A 是复（正规）矩阵（normal matrix）.

下面我们证明引理2.3.4的逆命题也成立，即正规方阵都可酉相似对角化. 注意，Hermite 阵、酉阵都是正规矩阵.

定理 2.3.2

若 A 是 n 阶复正规矩阵，则存在 n 阶酉阵 Q 和对角阵 Λ 使得 $\bar{Q}^{\mathrm{T}}AQ=\Lambda$.

证明 对 n 用数学归纳法. $n=1$ 的情形显然成立. 假设定理对 $n-1$ 阶正规矩阵成立，下面证明定理对 n 阶正规矩阵成立.

任取 A 的一个复特征值 λ_1，和属于 λ_1 的单位特征向量 ϵ_1. 把 ϵ_1 扩充为 $\mathbb{C}^n$ 的标准正交基 $\epsilon_1, \epsilon_2, \cdots, \epsilon_n$. 于是

$$A\begin{bmatrix}\epsilon_1 & \epsilon_2 & \cdots & \epsilon_n\end{bmatrix} = \begin{bmatrix}\lambda_1\epsilon_1 & A\epsilon_2 & \cdots & A\epsilon_n\end{bmatrix} = \begin{bmatrix}\epsilon_1 & \epsilon_2 & \cdots & \epsilon_n\end{bmatrix}\begin{bmatrix}\lambda_1 & \boldsymbol{\alpha}^{\mathrm{T}} \\ 0 & B\end{bmatrix}.$$

令 $Q_1 = \begin{bmatrix}\epsilon_1 & \epsilon_2 & \cdots & \epsilon_n\end{bmatrix}$，则 Q_1 是 n 阶酉阵，且

$$\bar{Q}_1^{\mathrm{T}} A Q_1 = \begin{bmatrix}\lambda_1 & \boldsymbol{\alpha}^{\mathrm{T}} \\ 0 & B\end{bmatrix}.$$

记上式右边的分块矩阵为 $\hat{A}$. 因为 A 正规，所以 $\bar{Q}_1^{\mathrm{T}} A Q_1$，也就是 $\hat{A}$，正规. 计算得 $\bar{\hat{A}}^{\mathrm{T}}\hat{A}$ 的左上角元素为 $\bar{\lambda}_1\lambda_1$，$\hat{A}\bar{\hat{A}}^{\mathrm{T}}$ 的左上角元素为 $\lambda_1\bar{\lambda}_1 + \boldsymbol{\alpha}^{\mathrm{T}}\bar{\boldsymbol{\alpha}}$，故 $\boldsymbol{\alpha}^{\mathrm{T}}\bar{\boldsymbol{\alpha}} = 0$，而 $\boldsymbol{\alpha}^{\mathrm{T}}\bar{\boldsymbol{\alpha}}$ 恰是 $\boldsymbol{\alpha}$ 中复元素的模的平方和，所以 $\boldsymbol{\alpha} = 0$. 于是

$$\hat{A} = \begin{bmatrix}\lambda_1 & 0 \\ 0 & B\end{bmatrix}$$

正规，从而 B 正规. 由归纳假设，存在 $n-1$ 阶酉阵 Q_2 使得 $\bar{Q}_2^{\mathrm{T}} B Q_2 = \Lambda_2$ 是对角阵. 令 $Q = Q_1\begin{bmatrix}1 & 0 \\ 0 & Q_2\end{bmatrix}$.

相似的矩阵有相同的特征多项式和相同的特征值，所以 Λ 的对角线元素就是 A 的特征值.

易见 Q 是 n 阶酉阵，而且

$$\bar{Q}^{\mathrm{T}} A Q = \begin{bmatrix}1 & 0 \\ 0 & \bar{Q}_2^{\mathrm{T}}\end{bmatrix}\bar{Q}_1^{\mathrm{T}} A Q_1 \begin{bmatrix}1 & 0 \\ 0 & Q_2\end{bmatrix} = \begin{bmatrix}1 & 0 \\ 0 & \bar{Q}_2^{\mathrm{T}}\end{bmatrix}\begin{bmatrix}\lambda_1 & 0 \\ 0 & B\end{bmatrix}\begin{bmatrix}1 & 0 \\ 0 & Q_2\end{bmatrix} = \begin{bmatrix}\lambda_1 & 0 \\ 0 & \Lambda_2\end{bmatrix}.$$

推论 2.3.1

1. 设 S 是 Hermite 阵，则存在酉阵 Q 使得 $\bar{Q}^{\mathrm{T}} S Q = \mathrm{diag}(\lambda_1, \cdots, \lambda_n)$，其中 $\lambda_1, \cdots, \lambda_n$ 是 S 的全部（实）特征值.
2. 设 Q 是酉阵，则存在酉阵 Q_1 使得 $\bar{Q}_1^{\mathrm{T}} Q Q_1 = \mathrm{diag}(\mathrm{e}^{\mathrm{i}\theta_1}, \cdots, \mathrm{e}^{\mathrm{i}\theta_n})$，其中 $\theta_i \in \mathbb{R}$, $\mathrm{e}^{\mathrm{i}\theta_1}, \cdots, \mathrm{e}^{\mathrm{i}\theta_n}$ 是 Q 的全部（模为 1 的）特征值.

正规矩阵还包含斜 Hermite 阵（$\bar{A}^{\mathrm{T}} = -A$）. 容易验证 A 是斜 Hermite 阵当且仅当 $\mathrm{i}A$ 是 Hermite 阵，故斜 Hermite 阵的特征值都是纯虚数. 实 Hermite 阵是实对称阵，实斜 Hermite 阵是实反对称阵，实酉阵是实正交阵.

注 2.3.2

正规矩阵可以酉相似对角化的根本原因是：不变子空间的正交补还是不变子空间.

命题 2.3.1

设 A 是复正规矩阵，$V \subseteq \mathbb{C}^n$ 是 A 的不变子空间，即 $AV \subseteq V$. 设 W 是 V 的正交补：

$$W = \left\{\boldsymbol{w} \in \mathbb{C}^n : \langle \boldsymbol{w}, \boldsymbol{v}\rangle = 0, \forall \boldsymbol{v} \in V\right\}.$$

则 $AW \subseteq W$.

取 V 的一组标准正交基 $\boldsymbol{v}_1, \cdots, \boldsymbol{v}_r$，取 W 的一组标准正交基 $\boldsymbol{w}_1, \cdots, \boldsymbol{w}_s$，则 $\boldsymbol{v}_1, \cdots, \boldsymbol{v}_r, \boldsymbol{w}_1, \cdots, \boldsymbol{w}_s$ 构成了 $\mathbb{C}^n$ 的一组标准正交基，即 $U = \begin{bmatrix}\boldsymbol{v}_1 & \cdots & \boldsymbol{v}_r & \boldsymbol{w}_1 & \cdots & \boldsymbol{w}_s\end{bmatrix}$ 是酉矩阵. 由于 V 是 A 的不变子空间，所以 $A\boldsymbol{v}_i \in V$，也就是说，它们实际上是 $\boldsymbol{v}_1, \cdots, \boldsymbol{v}_r$ 的线性组合：

$$A\boldsymbol{v}_i = a_{1i}\boldsymbol{v}_1 + a_{2i}\boldsymbol{v}_2 + \cdots + a_{ri}\boldsymbol{v}_r, \quad \forall 1 \leq i \leq r,$$

那么

$$\begin{aligned} AU &= \begin{bmatrix} A\boldsymbol{v}_1 & \cdots & A\boldsymbol{v}_r & A\boldsymbol{w}_1 & \cdots & A\boldsymbol{w}_s \end{bmatrix} \\ &= \begin{bmatrix} \boldsymbol{v}_1 & \cdots & \boldsymbol{v}_r & \boldsymbol{w}_1 & \cdots & \boldsymbol{w}_s \end{bmatrix} \begin{bmatrix} a_{11} & \cdots & a_{1r} & * & \cdots & * \\ \vdots & & \vdots & * & \cdots & * \\ a_{r1} & \cdots & a_{rr} & * & \cdots & * \\ 0 & \cdots & 0 & * & \cdots & * \\ \vdots & & \vdots & * & \cdots & * \\ 0 & \cdots & 0 & * & \cdots & * \end{bmatrix} \end{aligned} \tag{2.1}$$

即 $U^HAU = \begin{bmatrix} X & Y \\ \mathbf{0} & Z \end{bmatrix}$，那么 $U^HA^HU = (U^HAU)^H = \begin{bmatrix} X^H & \mathbf{0} \\ Y^H & Z^H \end{bmatrix}$，那么

$$U^HAA^HU = \begin{bmatrix} X & Y \\ \mathbf{0} & Z \end{bmatrix} \begin{bmatrix} X^H & \mathbf{0} \\ Y^H & Z^H \end{bmatrix} = \begin{bmatrix} XX^H + YY^H & YZ^H \\ ZY^H & ZZ^H \end{bmatrix}$$

$$U^HA^HAU = \begin{bmatrix} X^H & \mathbf{0} \\ Y^H & Z^H \end{bmatrix} \begin{bmatrix} X & Y \\ \mathbf{0} & Z \end{bmatrix} = \begin{bmatrix} X^HX & X^HY \\ Y^HX & Y^HY + Z^HZ \end{bmatrix}$$

比较各分量，有

$$XX^H + YY^H = X^HX, \quad YZ^H = Z^HY, \quad ZY^H = Y^HX, \quad ZZ^H = Y^HY + Z^HZ.$$

对 $XX^H + YY^H =$ 取迹，得

$$\operatorname{tr}(X^HX) = \operatorname{tr}(XX^H + YY^H) = \operatorname{tr}(XX^H) + \operatorname{tr}(YY^H),$$

根据迹的性质，有 $\operatorname{tr}(X^HX) = \operatorname{tr}(XX^H)$，故 $\operatorname{tr}(YY^H) = 0$. 而把 Y 的分量写出来 $Y = \begin{bmatrix} y_{ij} \end{bmatrix}$，计算矩阵乘法 YY^H，再把对角线相加，可知

$$\operatorname{tr}(YY^H) = \sum_{i,j} y_{ij}\bar{y}_{ij} = \sum_{i,j} |y_{ij}|^2,$$

所以 $y_{ij} = 0, \forall i, j$，即 Y 是零矩阵. 代回(2.1)式，说明 $A\boldsymbol{w}_j$ 都是 $\boldsymbol{w}_1, \cdots, \boldsymbol{w}_s$ 的线性组合. 所以 W 也是 A 的不变子空间.

2.4 实正规矩阵

定义 2.4.1

设 $A \in M_n(\mathbb{R})$. 若 $AA^{\mathrm{T}} = A^{\mathrm{T}}A$，则称 A 是（实）正规矩阵.

例题 2.12.

实正交阵、实对称阵、实反对称阵都是实正规阵.

显然，实正规矩阵是复正规矩阵，所以实正规矩阵可以酉相似对角化. 换言之，在实正规阵 A 的酉相似等价类 $\{\bar{Q}^{\mathrm{T}}AQ : Q \text{ 是酉阵}\}$ 中有（复）对角阵. 若用实正交阵代替酉矩阵，在实正规阵 A 的正交相似等价类 $\{Q^{\mathrm{T}}AQ : Q \text{ 是实正交阵}\}$ 中是否总有实对角阵呢？如果没有，有其他“标准型”吗？

第一个问题的答案是否定的，因为若存在实正交阵 Q 使得 $Q^{\mathrm{T}}AQ$ 是（实）对角阵，那么 A 的特征值都是实数，我们知道实正规阵不都有这个性质，比如实正交阵是实正规阵，但实正交阵可以有复特征值.

第二个问题的答案见下.

定理 2.4.1 (实正规阵的实正交相似标准型)

设 $A \in M_n(\mathbb{R})$, $AA^{\mathrm{T}} = A^{\mathrm{T}}A$，则存在实正交阵 Q 使得

$$Q^{\mathrm{T}}AQ = \operatorname{diag}\left(\begin{bmatrix} a_1 & -b_1 \\ b_1 & a_1 \end{bmatrix}, \cdots, \begin{bmatrix} a_k & -b_k \\ b_k & a_k \end{bmatrix}, \lambda_{2k+1}, \cdots, \lambda_n\right),$$

其中 $a_j, b_j, \lambda_\ell \in \mathbb{R}$, $b_j \neq 0$.

通过计算不难发现，等式右边的准对角阵的特征值，也就是 A 的特征值是

$$a_j \pm \mathrm{i}b_j \quad (1 \leq j \leq k), \quad \lambda_\ell \quad (2k+1 \leq \ell \leq n).$$

当 A 是实对称阵时，定理2.4.1就是实对称阵的谱定理. 当 A 是实正交阵时，因为实正交阵的特征值是模为 1 的复数，所以有下面的推论.

推论 2.4.1

设 Q 是 n 阶实正交阵，则存在实正交阵 Q_1 使得

$$Q_1^{\mathrm{T}}QQ_1 = \operatorname{diag}\left(\begin{bmatrix} \cos\theta_1 & -\sin\theta_1 \\ \sin\theta_1 & \cos\theta_1 \end{bmatrix}, \cdots, \begin{bmatrix} \cos\theta_k & -\sin\theta_k \\ \sin\theta_k & \cos\theta_k \end{bmatrix}, 1, \cdots, 1, -1, \cdots, -1\right),$$

其中 $\theta_j \in \mathbb{R}$, $\theta_j \notin \mathbb{Z}\pi$.

第 3 章 若尔当标准型

在第一章中，我们着重讨论了两种特殊的复矩阵：厄米特阵和酉阵；更一般的，我们讨论了复正规矩阵. 复正规矩阵是可以酉相似对角化的复矩阵. 在研究这些特殊矩阵的过程中，“酉阵”和“酉相似”几乎无处不在，根本原因是这些矩阵给出的 $\mathbb{C}^n$ 上的复线性变换和 $\mathbb{C}^n$ 上的厄米特内积 $\langle,\rangle$ 有“亲密互动”，而“酉阵”是 $\mathbb{C}^n$ 上厄米特内积的标准正交基（构成的矩阵）. 比如，

1. S 是厄米特阵当且仅当 $\langle Sz, w\rangle = \langle z, Sw\rangle$，$\forall z, w \in \mathbb{C}^n$,
2. Q 是酉阵当且仅当 $\langle Qz, Qw\rangle = \langle z, w\rangle$，$\forall z, w \in \mathbb{C}^n$,
3. A 是复正规矩阵当且仅当 $\langle Az, Aw\rangle = \langle A^H z, A^H w\rangle$，$\forall z, w \in \mathbb{C}^n$.

在第二章中，我们讨论一般的 n 阶复方阵，即它们给出的 $\mathbb{C}^n$ 上的一般的复线性变换. 一般的复线性变换和 $\mathbb{C}^n$ 上的厄米特内积没有联系，所以酉阵（或 $\mathbb{C}^n$ 的标准正交基）对研究一般的复矩阵没有什么助益，取而代之的是一般的可逆复矩阵（或 $\mathbb{C}^n$ 的基）.

给定 $A \in M_n(\mathbb{C})$, 我们的目标是寻找 $\mathbb{C}^n$ 的一组基，使得 A 在这组基上的作用尽量简单. 当 A 可对角化时，我们可以取 A 的 n 个线性无关的特征向量为 $\mathbb{C}^n$ 的基；由特征向量的性质知，A 作用在它的特征向量上就是乘相应的特征值. 这是最简单的情形，但是并不是所有的复矩阵都可对角化. 当 A 不可对角化时，我们又能做到什么呢？这是本章的主要内容.

3.1 Schur 定理和 Cayley-Hamilton 定理

把复正规矩阵的谱定理的证明稍作修改，我们可以证明，任意的复方阵可以上三角化.

定理 3.1.1 (Schur)

设 $A \in M_n(\mathbb{C})$, 则存在可逆复方阵 P 使得 $P^{-1}AP$ 是上三角阵.

证明 对 n 用数学归纳法. 由代数学基本定理知，关于 λ 的复系数多项式 $\det(\lambda I_n - A)$ 有复根. 任取 $\det(\lambda I_n - A)$ 的一个复数根 λ_1, 则存在 $\alpha_1 \in \mathbb{C}^n$，$\alpha_1 \neq 0$ 使得 $A\alpha_1 = \lambda_1\alpha_1$. 把 α_1 扩充为 $\mathbb{C}^n$ 的一组基 $\alpha_1, \alpha_2, \cdots, \alpha_n$, 并令 $P_1 = \begin{bmatrix}\alpha_1 & \alpha_2 & \cdots & \alpha_n\end{bmatrix}$，则 P_1 是 n 阶可逆复方阵且

$$P_1^{-1}AP_1 = \begin{bmatrix}\lambda_1 & * \\ 0 & B\end{bmatrix}. \tag{3.1}$$

由归纳假设知，存在 $n-1$ 阶可逆复方阵 P_2 使得

$$P_2^{-1}BP_2 = \begin{bmatrix} \lambda_2 & & * \\ & \ddots & \\ & & \lambda_n \end{bmatrix}. \tag{3.2}$$

于是

$$\begin{bmatrix} 1 & 0 \\ 0 & P_2^{-1} \end{bmatrix} P_1^{-1}AP_1 \begin{bmatrix} 1 & 0 \\ 0 & P_2 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & P_2^{-1} \end{bmatrix} \begin{bmatrix} \lambda_1 & * \\ 0 & B \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & P_2 \end{bmatrix} = \begin{bmatrix} \lambda_1 & * & \cdots & * \\ & \lambda_2 & \ddots & * \\ & & \ddots & \vdots \\ & & & \lambda_n \end{bmatrix}. \tag{3.3}$$

令 $P = P_1 \begin{bmatrix} 1 & 0 \\ 0 & P_2 \end{bmatrix}$ 即可.

注 3.1.1

由于相似的矩阵有相同的特征值，以及上三角阵的特征值就是对角线元素，(3.3)中的 $\lambda_1, \lambda_2, \cdots, \lambda_n$ 是原矩阵 A 的特征值. 事实上，我们可以指定它们在对角线上出现的顺序. 这是因为证明一开始的 λ_1 是我们任取的 A 的一个特征值；如果我们愿意，当然可以把 λ_1 取作任何一个我们“最喜欢”的 A 的特征值.

在(3.1)式中，A 的特征多项式和右边块上三角阵 $\begin{bmatrix} \lambda_1 & * \\ 0 & B \end{bmatrix}$ 的特征多项式相等，而从特征多项式的定义容易知道后者的特征多项式等于 $(\lambda - \lambda_1)$ 乘以 B 的特征多项式

$$\det(\lambda I_n - \begin{bmatrix} \lambda_1 & * \\ 0 & B \end{bmatrix}) = \det \begin{bmatrix} \lambda - \lambda_1 & -* \\ 0 & \lambda I_{n-1} - B \end{bmatrix} = (\lambda - \lambda_1)\det(\lambda I_{n-1} - B),$$

所以 B 的特征值是从 A 的全部特征值中扔掉我们一开始挑选的 λ_1 后剩下的. 对 n 用数学归纳法，我们知道可以选择 P_2 使得(3.1)式中的 $\lambda_2, \cdots, \lambda_n$ 以我们指定的顺序出现. 综上所述，(3.3)式最右端上三角阵中 A 的特征值可以以任意指定的顺序出现.

注 3.1.2

定理3.1.1中的 P 可取作酉阵，即我们有如下“加强版”

定理 3.1.2

设 $A \in M_n(\mathbb{C}), \lambda_1, \lambda_2, \cdots, \lambda_n$ 是 A 的（有序）复特征值，则存在酉阵 Q 使得

$$Q^HAQ = \begin{bmatrix} \lambda_1 & * & \cdots & * \\ & \lambda_2 & \cdots & * \\ & & \ddots & \vdots \\ & & & \lambda_n \end{bmatrix}.$$

证明的方法是一开始把 λ_1 的特征向量 $\boldsymbol{\alpha}_1$ 取作 λ_1 的单位特征向量 ϵ_1, 然后把 ϵ_1 扩充为 $\mathbb{C}^n$ 的标准正交基 $\epsilon_1, \epsilon_2, \cdots, \epsilon_n$, 于是 $Q_1 = [\epsilon_1\ \epsilon_2\ \cdots\ \epsilon_n]$ 是 n 阶酉阵而且

$$Q_1^HAQ_1 = \begin{bmatrix} \lambda_1 & * \\ 0 & B \end{bmatrix}.$$

利用归纳假设知，存在 $n-1$ 阶酉阵 Q_2 使得 $Q_2^HBQ_2 = \cdots$, 最后令 $Q = Q_1 \begin{bmatrix} 1 & 0 \\ 0 & Q_2 \end{bmatrix}$.

另一个方法是在定理3.1.1的基础上对 P 作 QR 分解. 若 $P = QR$, 则

$$P^{-1}AP = R^{-1}Q^HAQR,$$

于是

$$Q^HAQ = R(P^{-1}AP)R^{-1} = R\begin{bmatrix}\lambda_1 & & *\\ & \ddots & \\ & & \lambda_n\end{bmatrix}R^{-1}.$$

由于 R 是（对角线为正实数的）可逆上三角阵，所以上式右边仍是对角线为 $\lambda_1,\cdots,\lambda_n$ 的上三角阵.

注 3.1.3

定理3.1.1中 A 是复矩阵的假设仅是为了保证在复数域中可以找到 A 的全部特征值. 若 A 是实矩阵，且已知 A 的特征值全为实数，即 A 的特征多项式（一个实系数多项式）的根都是实数，则存在可逆实方阵 P，甚至实正交阵 Q，使得 $P^{-1}AP$，或者 $Q^{\mathrm{T}}AQ$，是上三角阵，且对角线上 A 的特征值以指定顺序出现.

练习 3.1 设 $A\in M_n(\mathbb{C})$ 的特征值是 $\lambda_1,\cdots,\lambda_n\in\mathbb{C}$. 证明：

$$\operatorname{tr}(A^HA)\geq|\lambda_1|^2+\cdots+|\lambda_n|^2$$

且等号成立当且仅当 A 是复正规矩阵.

用 Schur 定理可以证明 Cayley-Hamilton 定理.

定义 3.1.1

设 $A\in M_n(\mathbb{C})$, $f(x)=c_0+c_1x+\cdots+c_mx^m\in\mathbb{C}[x]$, 定义

$$f(A)=c_0I_n+c_1A+\cdots+c_mA^m.$$

若 $f(A)=0$（零矩阵），则称 $f(x)$ 是 A 的零化多项式.

引理 3.1.1

1. 若 $f(x)=g(x)+h(x)$, 则 $f(A)=g(A)+h(A)$. 特别的，若 $g(x),h(x)$ 都是 A 的零化多项式，则它们的和 $g(x)+h(x)$ 仍是 A 的零化多项式.
2. 若 $f(x)=g(x)h(x)$, 则 $f(A)=g(A)h(A)$. 特别的，若 $g(x)$ 是 A 的零化多项式，则 $g(x)$ 与任意多项式的积仍是 A 的零化多项式.
3. 若 P 是可逆阵，则 $f(P^{-1}AP)=P^{-1}f(A)P$.
4. 若 U 是对角线为 $\lambda_1,\cdots,\lambda_n$ 的上三角阵，则 $f(U)$ 是对角线为 $f(\lambda_1),\cdots,f(\lambda_n)$ 的上三角阵.
5. 若 $f(A)=0$, 则 A 的任一特征值 λ 满足 $f(\lambda)=0$, 即 A 的特征值必是 A 的零化多项式的根.

证明 （1）略.（2）略.（3）$(P^{-1}AP)^k=P^{-1}A^kP$.（4）略.（5）作业.

例题 3.1.

满足 $A^2=A$ 的矩阵称为幂等阵 (idempotent matrix). 由引理3.1.1(5) 知，幂等阵的特征值只有可能是 0 或 1. 同理若 $A^2=I$, 则 A 的特征值只有可能是 1 或 -1.

定理 3.1.3 (Cayley-Hamilton)

设 $A\in M_n(\mathbb{C})$, $f(\lambda)=\det(\lambda I_n-A)$ 是 A 的特征多项式，则 $f(A)=0$, 即 A 的特征多项式是 A 的零化多项式.

证明 设 $f(\lambda)=(\lambda-\lambda_1)\cdots(\lambda-\lambda_n),\lambda_1,\cdots,\lambda_n\in\mathbb{C}$. 由定理 33 知，存在可逆复方阵 P 使得

$$P^{-1}AP=\begin{bmatrix}\lambda_1 & & *\\ & \ddots & \\ & & \lambda_n\end{bmatrix}=:U.$$

由于 $f(A)=f(PUP^{-1})=Pf(U)P^{-1}$, 故只需证明 $f(U)=0$.

由引理3.1.1 (2) 知，

$$f(U)=(U-\lambda_1 I_n)\cdots(U-\lambda_n I_n).$$

记 $V_k=\mathrm{Span}_{\mathbb{C}}(e_1,\cdots,e_k)$ 是由 $\mathbb{C}^n$ 的标准基 $e_1,\cdots,e_n$ 中前 k 个向量张成的复子空间. 由于 $U-\lambda_k I$ 是对角线上 (k,k)-位置为 0 的上三角阵，所以

$$(U-\lambda_k I)V_k\subseteq V_{k-1},\quad 1\leq k\leq n.$$

于是

$$\begin{aligned}f(U)\mathbb{C}^n&=(U-\lambda_1 I)\cdots(U-\lambda_n I)V_n\\&\subseteq(U-\lambda_1 I)\cdots(U-\lambda_{n-1}I)V_{n-1}\\&\subseteq(U-\lambda_1 I)\cdots(U-\lambda_{n-2}I)V_{n-2}\\&\subseteq\cdots\subseteq(U-\lambda_1 I)V_1=0\end{aligned}$$

所以 $f(U)=0$.

例题 3.2.

对角线元素全为 0 的上三角阵称为严格上三角阵 (strictly upper-triangular). 若 A 是 n 阶严格上三角阵，则 $A^n=0$.

命题 3.1.1

设 $A\in M_n(\mathbb{C})$ 的全部复特征值是 $\lambda_1,\cdots,\lambda_n$ （在计入重数意义下），$f(x)\in\mathbb{C}[x]$，则 $f(A)$ 的全部复特征值是 $f(\lambda_1),\cdots,f(\lambda_n)$.

证明 由定理3.1.1知，存在可逆阵 P 使得 $P^{-1}AP=U$，其中 U 是对角线为 $\lambda_1,\cdots,\lambda_n$ 的上三角阵. 由引理3.1.1(3) 知 $f(A)=f(PUP^{-1})=Pf(U)P^{-1}$；由 (4) 知 $f(U)$ 是对角线为 $f(\lambda_1),\cdots,f(\lambda_n)$ 的上三角阵. 相似的矩阵有相同的特征值，故 $f(U)$ 的特征值，也就是 $f(\lambda_1),\cdots,f(\lambda_n)$，也是 $f(A)$ 的特征值.

命题 3.1.2

设 $A\in M_n(\mathbb{C})$, 则存在唯一的首一复系数多项式 $d(x)$ 使得

1. $d(A)=0$, 即 $d(x)$ 是 A 的零化多项式，
2. 若 $f(A)=0$, 则 $d(x)\mid f(x)$，即 A 的零化多项式必是 $d(x)$ 的倍式.

满足以上条件的 $d(x)$ 称为 A 的极小多项式或最小多项式. 特别的，$d(x)$ 整除 A 的特征多项式.

证明 考虑 A 的所有非零零化多项式构成的集合. 由 Cayley-Hamilton 定理知，这个集合非空. 设 $d(x)$ 是这个集合中次数最小的一个多项式[1]，则 $d(x)$ 自动满足 (1). 现设 $f(A)=0$. 由多项式的长除法知，存在（唯一的）复系数多项式 $q(x)$ 和 $r(x)$ 使得

$$f(x)=d(x)q(x)+r(x)$$

且 $\deg r(x)<\deg d(x)$. 在上式中代入 A 得

$$f(A)=d(A)q(A)+r(A).$$

因为 $f(A)=d(A)=0$, 所以 $r(A)=0$. 若 $r(x)$ 是非零多项式，则它是次数小于 $\deg d(x)$ 的 A 的非零化零多项式，这与 $d(x)$ 的选取矛盾，故 $r(x)=0$, 也就是 $d(x)\mid f(x)$. 把 $d(x)$ 除以它的首项系数就得到了满足条件 (1)(2) 的首一多项式. 还需证明唯一性. 若 $d_1(x),d_2(x)$ 都是满足 (1)(2) 的首一多项式，则从 $d_1(A)=0$ 和 $d_2(x)$ 满足 (2)，我们得知 $d_2(x)\mid d_1(x)$；同理也有 $d_1(x)\mid d_2(x)$，即 $d_1(x),d_2(x)$ 互相整除；故它们相差常数倍；又因为 d_1,d_2 都是

[1]暂时还不知道这样的多项式是否唯一，但肯定存在，任取一个即可

首一多项式，故常数是 1，也就是 $d_1(x) = d_2(x)$.

例题 3.3.

设 $D = \mathrm{diag}(\lambda_1 I_{m_1}, \cdots, \lambda_k I_{m_k})$, 即 D 是对角线上有 m_1 个 λ_1, m_2 个 λ_2, $\cdots$, m_k 个 λ_k 的对角阵；还假设 $\lambda_1, \cdots, \lambda_k$ 两两互异，则 D 的特征多项式是 $(\lambda - \lambda_1)^{m_1} \cdots (\lambda - \lambda_k)^{m_k}$, 对比之下 D 的最小多项式是 $(\lambda - \lambda_1) \cdots (\lambda - \lambda_k)$.

零矩阵的最小多项式是？

定义 3.1.2

设 $A \in M_n(\mathbb{C})$，若存在 $k \geq 1$ 使得 $A^k = 0$，则称 A 是幂零阵（nilpotent matrix）.

命题 3.1.3

设 $A \in M_n(\mathbb{C})$，则以下条件等价

1. A 是幂零阵，
2. A 有唯一的特征值 0,
3. $A^n = 0$.

证明 作业.

例题 3.4.

设 $N = \begin{bmatrix} 0 & 1 & & \\ & 0 & \ddots & \\ & & \ddots & 1 \\ & & & 0 \end{bmatrix}_{n\times n}$ 是副对角线上为 1 其余地方为 0 的矩阵. 容易验证 N^2 是 $(1,3), (2,4), \cdots, (n-2, n)$ 位置为 1 其余地方为 0 的矩阵. 以此类推，每乘一次 N, 那一串 1 就往右上角移一步，特别的 N^{n-1} 是 $(1,n)$-元素为 1 其余元素为 0 的矩阵，最后 $N^n = 0$. 于是 N 的特征多项式和最小多项式都等于 λ^n.

一般的，对任意的 $c \in \mathbb{C}$, $cI + N$ 的特征多项式和最小多项式都是 $(\lambda - c)^n$.

命题 3.1.4

设 $A = \begin{bmatrix} A_1 & & \\ & \ddots & \\ & & A_k \end{bmatrix}$ 是块对角阵，其中每个 A_j 都是方阵，则

1. A 的特征多项式是 $A_1, \cdots, A_k$ 的特征多项式的积.
2. A 的最小多项式是 $A_1, \cdots, A_k$ 的最小多项式的最小公倍式.

证明 易.

练习 3.2 证明：相似的矩阵有相同的最小多项式.

3.2 Jordan 标准型的证明

本节我们证明以下定理

定理 3.2.1 (Jordan)

设 $A \in M_n(\mathbb{C})$, 则存在可逆阵 P 使得

$$P^{-1}AP = \operatorname{diag}(J_{k_1}(\lambda_1), J_{k_2}(\lambda_2), \cdots, J_{k_m}(\lambda_m)), \tag{2.4}$$

其中

$$J_{k_j}(\lambda_j) = \begin{bmatrix} \lambda_j & 1 & & \\ & \lambda_j & \ddots & \\ & & \ddots & 1 \\ & & & \lambda_j \end{bmatrix}_{k_j \times k_j}.$$

这里的 $\lambda_1, \cdots, \lambda_m$ 中可能有重复数.

例题 3.5.

设 $P^{-1}AP = J_k(0) = \begin{bmatrix} 0 & 1 & & \\ & 0 & \ddots & \\ & & \ddots & 1 \\ & & & 0 \end{bmatrix}_{k\times k}$, 记 $P = \begin{bmatrix} \boldsymbol{\alpha}_1 & \cdots & \boldsymbol{\alpha}_k \end{bmatrix}$, 则 $\boldsymbol{\alpha}_1, \cdots, \boldsymbol{\alpha}_k$ 是 $\mathbb{C}^k$ 的基（特别的它们线性无关）且

$$A\begin{bmatrix} \boldsymbol{\alpha}_1 & \cdots & \boldsymbol{\alpha}_k \end{bmatrix} = \begin{bmatrix} \boldsymbol{\alpha}_1 & \cdots & \boldsymbol{\alpha}_k \end{bmatrix} \begin{bmatrix} 0 & 1 & & \\ & 0 & \ddots & \\ & & \ddots & 1 \\ & & & 0 \end{bmatrix}.$$

也就是说，

$$\begin{aligned} A\boldsymbol{\alpha}_1 &= 0 \\ A\boldsymbol{\alpha}_2 &= \boldsymbol{\alpha}_1 \\ &\vdots \\ A\boldsymbol{\alpha}_{k-1} &= \boldsymbol{\alpha}_{k-2} \\ A\boldsymbol{\alpha}_k &= \boldsymbol{\alpha}_{k-1}. \end{aligned}$$

任意的向量 $\boldsymbol{\beta}$ 可以写成 $\boldsymbol{\alpha}_1, \cdots, \boldsymbol{\alpha}_k$ 的线性组合

$$\boldsymbol{\beta} = c_1\boldsymbol{\alpha}_1 + \cdots + c_k\boldsymbol{\alpha}_k.$$

用上面的 k 个等式可以推出

$$A\boldsymbol{\beta} = c_1A\boldsymbol{\alpha}_1 + c_2A\boldsymbol{\alpha}_2 + \cdots + c_kA\boldsymbol{\alpha}_k = c_2\boldsymbol{\alpha}_1 + \cdots + c_k\boldsymbol{\alpha}_{k-1},$$

故 $A\boldsymbol{\beta} = 0$ 当且仅当 $c_2 = \cdots = c_k = 0$ （注意 $\boldsymbol{\alpha}_1, \cdots, \boldsymbol{\alpha}_{k-1}$ 线性无关），也就是说 $\boldsymbol{\beta} = c_1\boldsymbol{\alpha}_1$. 于是我们得到

$$N(A) = \operatorname{Span}(\boldsymbol{\alpha}_1).$$

用类似的方法可以证明

$$N(A^2) = \operatorname{Span}(\boldsymbol{\alpha}_1, \boldsymbol{\alpha}_2), \quad \cdots, \quad N(A^{k-1}) = \operatorname{Span}(\boldsymbol{\alpha}_1, \cdots, \boldsymbol{\alpha}_{k-1}).$$

矩阵 A 的零空间是 A 给出的线性变换 $A : \mathbb{C}^k \to \mathbb{C}^k, z \mapsto Az$ 的核（kernel），故有时我们也用 $\ker(A)$ 表示 $N(A)$.

线性变换 A 的另一个重要的子空间是它的像（image）

$$\mathrm{im}(A) = \{A\boldsymbol{z} \mid \boldsymbol{z} \in \mathbb{C}^k\}$$

也就是矩阵 A 的列空间 $C(A)$.

从 A 满足的条件不难推出

$$\begin{aligned}\mathrm{im}(A) &= \left\{A\boldsymbol{\beta} : \boldsymbol{\beta}\text{任意}\right\} \\ &= \left\{c_2\boldsymbol{\alpha}_1 + \cdots + c_k\boldsymbol{\alpha}_{k-1} : c_1, c_2, \cdots, c_k\text{任意}\right\} \\ &= \mathrm{Span}(\boldsymbol{\alpha}_1, \cdots, \boldsymbol{\alpha}_{k-1}) = C(A).\end{aligned}$$

类似的，我们有

$$C(A^2) = \mathrm{Span}(\boldsymbol{\alpha}_1, \cdots, \boldsymbol{\alpha}_{k-2}), \quad \cdots, \quad C(A^{k-1}) = \mathrm{Span}(\boldsymbol{\alpha}_1).$$

例题 3.6.

若 $P^{-1}AP = J_k(\lambda) = \begin{bmatrix} \lambda & 1 & & \\ & \lambda & \ddots & \\ & & \ddots & 1 \\ & & & \lambda \end{bmatrix}_{k\times k}$, 如上记 $P = [\boldsymbol{\alpha}_1 \ \cdots \ \boldsymbol{\alpha}_k]$, 则

$$\begin{aligned} A\boldsymbol{\alpha}_1 &= \lambda\boldsymbol{\alpha}_1 \\ A\boldsymbol{\alpha}_2 &= \lambda\boldsymbol{\alpha}_2 + \boldsymbol{\alpha}_1 \\ &\vdots \\ A\boldsymbol{\alpha}_{k-1} &= \lambda\boldsymbol{\alpha}_{k-1} + \boldsymbol{\alpha}_{k-2} \\ A\boldsymbol{\alpha}_k &= \lambda\boldsymbol{\alpha}_k + \boldsymbol{\alpha}_{k-1} \end{aligned}$$

或者

$$\begin{aligned} (A-\lambda)\boldsymbol{\alpha}_1 &= 0 \\ (A-\lambda)\boldsymbol{\alpha}_2 &= \boldsymbol{\alpha}_1 \\ &\vdots \\ (A-\lambda)\boldsymbol{\alpha}_{k-1} &= \boldsymbol{\alpha}_{k-2} \\ (A-\lambda)\boldsymbol{\alpha}_k &= \boldsymbol{\alpha}_{k-1}. \end{aligned}$$

于是

$$\begin{aligned} &\ker(A-\lambda) = \mathrm{im}(A-\lambda)^{k-1} = \mathrm{Span}(\boldsymbol{\alpha}_1), \\ &\vdots \\ &\ker(A-\lambda)^{k-1} = \mathrm{im}(A-\lambda) = \mathrm{Span}(\boldsymbol{\alpha}_1, \cdots, \boldsymbol{\alpha}_{k-1}). \end{aligned}$$

$\boldsymbol{\alpha}_1, \cdots, \boldsymbol{\alpha}_k$ 称为线性变换 A 的一个 Jordan 链.

定理3.2.1的结论是，给定 $\mathbb{C}^n$ 上的复线性变换 A, 存在 $\mathbb{C}^n$ 的一组基，使得这组基是若干个 A 的 Jordan 链的并.

由 Schur 定理知，存在可逆阵 P 使得

$$P^{-1}AP=\begin{bmatrix} B_1 & B_{12} & B_{13} & \cdots & B_{1k} \\ & B_2 & B_{23} & \cdots & B_{2k} \\ & & \ddots & \ddots & \vdots \\ & & & B_{k-1} & B_{k-1,k} \\ & & & & B_k \end{bmatrix}$$

其中

$$B_j=\begin{bmatrix} \lambda_j & & * \\ & \ddots & \\ & & \lambda_j \end{bmatrix}$$

是对角线元素全为 λ_j 的上三角阵，而且 $\lambda_1,\cdots,\lambda_k$ 两两互异（运用 Schur 定理的时候，把相同的特征值放在一起）.

证明定理3.2.1的第一步：把分块上三角阵非对角线上的子块 B_{ij} $(i\neq j)$ “变成 0”，当然这里的“变”是指在相似关系下.

可逆阵均是初等阵的乘积，故在矩阵 A 的左边乘可逆阵 P 等价于对 A 作若干次初等行变换. 类似的，在 A 的右边乘可逆阵 Q 等价于对 A 作若干次初等列变换. 如果 P,Q 没有任何关系，那么这些初等行变换与那些初等列变换之间没有关系. 矩阵的相似却不是这样. 与 A 相似的矩阵形如 $P^{-1}AP$，此时左边的可逆阵恰是右边的可逆阵的逆矩阵. 更具体的说，若 $P=P_1\cdots P_k$，P_i 是初等阵，则 $P^{-1}=P_k^{-1}\cdots P_1^{-1}$，于是

$$P^{-1}AP=P_k^{-1}\cdots P_2^{-1}(P_1^{-1}AP_1)P_2\cdots P_k,$$

也就是说把 A 化成 $P^{-1}AP$ 的过程中，每做一次初等行变换 P_i^{-1}，就要做一次对应的初等列变换 P_i.

初等矩阵共有三类. 为了简单起见，我们仅考虑 2 阶初等阵（不妨碍说明问题）. 设 A 是任意 2 阶矩阵.

1. $P=\begin{bmatrix}1 & c\\ 0 & 1\end{bmatrix}$，$P^{-1}=\begin{bmatrix}1 & -c\\ 0 & 1\end{bmatrix}$，$P^{-1}A$ 是把 A 的第二行的 $-c$ 倍加到第一行得到的矩阵，而 AP 是把 A 的第一列的 c 倍加到第二列得到的矩阵.
2. $P=\begin{bmatrix}a & 0\\ 0 & 1\end{bmatrix}$ $(a\neq 0)$，$P^{-1}=\begin{bmatrix}a^{-1} & 0\\ 0 & 1\end{bmatrix}$，$P^{-1}A$ 是把 A 的第一行乘以 a^{-1} 得到的矩阵，AP 是把 A 的第一列乘以 a 得到的矩阵.
3. $P=P^{-1}=\begin{bmatrix}0 & 1\\ 1 & 0\end{bmatrix}$，$P^{-1}A$ 是交换 A 的两行得到的矩阵，AP 是交换 A 的两列得到的矩阵.

一般的，“第 j 行的 c 倍加到第 i 行”对应的列变换是“第 i 列的 $-c$ 倍加到第 j 列”；“第 i 行乘以 a $(\neq 0)$”对应的是“第 i 列乘以 a^{-1}”；“交换第 i,j 行”对应的是“交换第 i,j 列”.

命题 3.2.1

设 $R\in M_r(\mathbb{C}),S\in M_{r\times t}(\mathbb{C}),T\in M_t(\mathbb{C})$，且 T 是上三角阵，如果 R 和 T 没有相同的特征值，则存在唯一的 $X\in M_{r\times t}(\mathbb{C})$，使得

$$\begin{bmatrix}I_r & X\\ 0 & I_t\end{bmatrix}^{-1}\begin{bmatrix}R & S\\ 0 & T\end{bmatrix}\begin{bmatrix}I_r & X\\ 0 & I_t\end{bmatrix}=\begin{bmatrix}R & 0\\ 0 & T\end{bmatrix}.$$

♠

证明 由于

$$\begin{bmatrix}I_r & X\\ 0 & I_t\end{bmatrix}^{-1}=\begin{bmatrix}I_r & -X\\ 0 & I_t\end{bmatrix},$$

直接计算得

$$\begin{bmatrix}I_r & X\\ 0 & I_t\end{bmatrix}^{-1}\begin{bmatrix}R & S\\ 0 & T\end{bmatrix}\begin{bmatrix}I_r & X\\ 0 & I_t\end{bmatrix}=\begin{bmatrix}R & S-XT+RX\\ 0 & T\end{bmatrix},$$

故只需证明关于矩阵的方程

$$RX + S = XT \tag{3.4}$$

有唯一解.

记

$$X = \begin{bmatrix} \boldsymbol{x}_1 & \boldsymbol{x}_2 & \cdots & \boldsymbol{x}_t \end{bmatrix}, \quad T = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1t} \\ & a_{22} & \cdots & a_{2t} \\ & & \ddots & \vdots \\ & & & a_{tt} \end{bmatrix}, \quad S = \begin{bmatrix} \boldsymbol{s}_1 & \boldsymbol{s}_2 & \cdots & \boldsymbol{s}_t \end{bmatrix},$$

则(3.4)式等价于

$$\begin{aligned} R\boldsymbol{x}_1 + \boldsymbol{s}_1 &= a_{11}\boldsymbol{x}_1 \\ R\boldsymbol{x}_2 + \boldsymbol{s}_2 &= a_{12}\boldsymbol{x}_1 + a_{22}\boldsymbol{x}_2 \\ R\boldsymbol{x}_3 + \boldsymbol{s}_3 &= a_{13}\boldsymbol{x}_1 + a_{23}\boldsymbol{x}_2 + a_{33}\boldsymbol{x}_3, \\ &\vdots \end{aligned}$$

由于 R 和 T 没有相同的特征值，故 a_{11} (T 的特征值）不是 R 的特征值，也就是说 $R - a_{11}I$ 可逆，故上面第一个等式有唯一解

$$\boldsymbol{x}_1 = -(R - a_{11}I)^{-1}\boldsymbol{s}_1.$$

同理，$R - a_{22}I$ 可逆，故在已解得 $\boldsymbol{x}_1$ 的基础上，第二个等式有唯一解

$$\boldsymbol{x}_2 = (R - a_{22}I)^{-1}(a_{12}\boldsymbol{x}_1 - \boldsymbol{s}_2).$$

续知，方程组有唯一解 $\boldsymbol{x}_1, \boldsymbol{x}_2, \cdots, \boldsymbol{x}_t$，故(3.4)有唯一解 X.

例题 3.7.

设 $A = \begin{bmatrix} \lambda & a \\ 0 & \mu \end{bmatrix}, \lambda \neq \mu, P = \begin{bmatrix} 1 & x \\ 0 & 1 \end{bmatrix}$, 则

$$P^{-1}AP = \begin{bmatrix} 1 & -x \\ 0 & 1 \end{bmatrix} \begin{bmatrix} \lambda & a \\ 0 & \mu \end{bmatrix} \begin{bmatrix} 1 & x \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} \lambda & a - \mu x + \lambda x \\ 0 & \mu \end{bmatrix},$$

故若取 $x = -\dfrac{a}{\lambda - \mu}$，则 P 把 A 对角化.

练习 3.3 设 $A \in M_m(\mathbb{C}), B \in M_n(\mathbb{C})$.

1. 证明：若 A, B 没有相同的特征值，则对任意的 $C \in M_{m\times n}(\mathbb{C})$, 存在唯一的矩阵 $X \in M_{m\times n}(\mathbb{C})$，使得 $AX - XB = C$. 特别的 $AX = XB$ 只有零解.
2. 证明：若 A, B 有相同的特征值，则存在非零矩阵 X 使得 $AX = XB$.

命题 3.2.2 (准素分解)

设 $A \in M_n(\mathbb{C})$, 特征值是 $\lambda_1, \cdots, \lambda_k$（互异），代数重数分别是 $n_1, \cdots, n_k$, 则存在可逆阵 P 使得

$$P^{-1}AP = \begin{bmatrix} \lambda_1 I_{n_1} + N_1 & & \\ & \ddots & \\ & & \lambda_k I_{n_k} + N_k \end{bmatrix},$$

其中 N_j 是 n_j 阶的严格上三角阵.

证明 由 Schur 定理知，A 相似于

$$\begin{bmatrix} \lambda_1 I_{n_1} + N_1 & B_{12} & \cdots & B_{1k} \\ & \lambda_2 I_{n_2} + N_2 & \cdots & B_{2k} \\ & & \ddots & \vdots \\ & & & \lambda_k I_{n_k} + N_k \end{bmatrix}. \tag{3.5}$$

因矩阵的相似是等价关系，故只需证明(3.5)相似于块对角阵 $\operatorname{diag}(\lambda_1 I_{n_1} + N_1, \lambda_2 I_{n_2} + N_2, \cdots, \lambda_k I_{n_k} + N_k)$.

我们对 k 用数学归纳法. $k = 1$ 时，不言自证. $k > 1$ 时，记

$$B = \begin{bmatrix} \lambda_2 I_{n_2} + N_2 & \cdots & B_{2k} \\ & \ddots & \vdots \\ & & \lambda_k I_{n_k} + N_k \end{bmatrix}.$$

由于 $\lambda_1 I_{n_1} + N_1$ 与 B 没有相同的特征值，故由命题3.2.1 知，(3.5)相似于 $\operatorname{diag}(\lambda_1 I_{n_1} + N_1, B)$. 再由归纳假设知，$B$ 相似于 $\operatorname{diag}(\lambda_2 I_{n_2} + N_2, \cdots, \lambda_k I_{n_k} + N_k)$，于是(3.5) 相似于 $\operatorname{diag}(\lambda_1 I_{n_1} + N_1, \lambda_2 I_{n_2} + N_2, \cdots, \lambda_k I_{n_k} + N_k)$.

接下来，我们证明每个 $\lambda_j I_{n_j} + N_j$ 相似于对角线元素为 λ_j 的 Jordan 块构成的块对角阵. 若我们可以证明 N_j 相似于对角线元素为 0 的 Jordan 块构成的块对角阵，即存在可逆阵 P_j 使得

$$P_j^{-1} N_j P_j = \begin{bmatrix} J_{m_1}(0) & & \\ & \ddots & \\ & & J_{m_\ell}(0) \end{bmatrix},$$

则

$$\begin{aligned} P_j^{-1}(\lambda_j I_{n_j} + N_j) P_j &= \lambda_j I_{n_j} + P_j^{-1} N_j P_j \\ &= \lambda_j I_{n_j} + \begin{bmatrix} J_{m_1}(0) & & \\ & \ddots & \\ & & J_{m_\ell}(0) \end{bmatrix} \\ &= \begin{bmatrix} J_{m_1}(\lambda_j) & & \\ & \ddots & \\ & & J_{m_\ell}(\lambda_j) \end{bmatrix}, \end{aligned}$$

所以我们证明严格上三角阵相似于 Jordan 块构成的块对角阵即可.

命题 3.2.3 (循环分解)

设 N 是 n 阶严格上三角阵，则 N 相似于 $\operatorname{diag}(J_{m_1}(0), \cdots, J_{m_\ell}(0))$, 其中 $m_1 \geq \cdots \geq m_\ell \geq 1$.

证明 对 N 的阶数 n 作数学归纳法. 设 $N = \begin{bmatrix} 0 & * \\ 0 & N' \end{bmatrix}$, 其中 N' 是 $n-1$ 阶严格上三角阵. 由归纳假设知，N' 相似于 $\operatorname{diag}(J_{m_1}(0), \cdots, J_{m_\ell}(0))$, 其中 $m_1 \geq \cdots \geq m_\ell \geq 1$, 故 N 相似于

$$N_1 = \begin{bmatrix} 0 & \boldsymbol{\alpha}_1^{\mathrm{T}} & \boldsymbol{\alpha}_2^{\mathrm{T}} & \cdots & \boldsymbol{\alpha}_\ell^{\mathrm{T}} \\ & J_{m_1}(0) & & & \\ & & J_{m_2}(0) & & \\ & & & \ddots & \\ & & & & J_{m_\ell}(0) \end{bmatrix}.$$

记 $\boldsymbol{\beta}^{\mathrm{T}}=[\boldsymbol{\alpha}_2^{\mathrm{T}}\ \cdots\ \boldsymbol{\alpha}_\ell^{\mathrm{T}}]$, $J=\operatorname{diag}(J_{m_2}(0),\cdots,J_{m_\ell}(0))$, 则

$$N_1=\begin{bmatrix}0 & \boldsymbol{\alpha}_1^{\mathrm{T}} & \boldsymbol{\beta}^{\mathrm{T}}\\ & J_{m_1}(0) & \\ & & J\end{bmatrix}.$$

引理 3.2.1

$$\begin{bmatrix}1 & -\boldsymbol{\alpha}^{\mathrm{T}}\\ J_m(0)^{\mathrm{T}} & I\end{bmatrix}\begin{bmatrix}0 & \boldsymbol{\alpha}^{\mathrm{T}}\\ J_m(0) & \end{bmatrix}\begin{bmatrix}1 & \boldsymbol{\alpha}^{\mathrm{T}}\\ J_m(0)^{\mathrm{T}} & I\end{bmatrix}=\begin{bmatrix}0 & \boldsymbol{\alpha}^{\mathrm{T}}e_1\\ e_1^{\mathrm{T}} & J_m(0)\end{bmatrix}.$$

证明 直接计算等号左边是

$$\begin{bmatrix}0 & \boldsymbol{\alpha}^{\mathrm{T}}\\ -\boldsymbol{\alpha}^{\mathrm{T}}J_m(0)^{\mathrm{T}} & J_m(0)\end{bmatrix}.$$

从 $J_m(0)$ 的定义知 $J_m(0)^{\mathrm{T}}J_m(0)=I_m-e_1e_1^{\mathrm{T}}$, 其中 $e_1e_1^{\mathrm{T}}$ 是 $(1,1)$ 位置是 1 其余位置全是 0 的矩阵. 于是前面矩阵的右上角是 $\boldsymbol{\alpha}^{\mathrm{T}}-\boldsymbol{\alpha}^{\mathrm{T}}(I_m-e_1e_1^{\mathrm{T}})=\boldsymbol{\alpha}^{\mathrm{T}}e_1e_1^{\mathrm{T}}$. 注意，$\boldsymbol{\alpha}^{\mathrm{T}}e_1e_1^{\mathrm{T}}$ 的第一行是 $\boldsymbol{\alpha}^{\mathrm{T}}e_1$ 其余行都是 0，所以它等于 $(\boldsymbol{\alpha}^{\mathrm{T}}e_1)e_1^{\mathrm{T}}$.

利用引理3.2.1和矩阵 $P_1=\begin{bmatrix}1 & \boldsymbol{\alpha}_1^{\mathrm{T}}J_{m_1}(0)^{\mathrm{T}} & \\ & I_{m_1} & \\ & & I\end{bmatrix}$，我们得知 N_1 相似于

$$P_1^{-1}N_1P_1=\begin{bmatrix}0 & \boldsymbol{\alpha}_1^{\mathrm{T}}e_1e_1^{\mathrm{T}} & \boldsymbol{\beta}^{\mathrm{T}}\\ & J_{m_1}(0) & \\ & & J\end{bmatrix}=N_2.$$

若 $\boldsymbol{\alpha}_1$ 的第一个坐标是 0，即 $\boldsymbol{\alpha}_1^{\mathrm{T}}\boldsymbol{e}_1=0$，则 N_2 相似于

$$N_3=\begin{bmatrix}J_{m_1}(0) & 0 & \boldsymbol{\beta}^{\mathrm{T}}\\ & 0 & \\ & & J\end{bmatrix}=P_2^{-1}N_2P_2,$$

其中 $P_2=\begin{bmatrix}0 & 1 & 0\\ I_{m_1} & 0 & 0\\ 0 & 0 & I\end{bmatrix}$. 由归纳假设知 $\begin{bmatrix}0 & \boldsymbol{\beta}^{\mathrm{T}}\\ & J\end{bmatrix}$ 相似于若干个 $J_m(0)$ 构成的块对角阵，于是 N_3 也可以.

下设 $c=\boldsymbol{\alpha}_1^{\mathrm{T}}\boldsymbol{e}_1\neq 0$. 令 $P_3=\begin{bmatrix}c & & \\ & I_{m_1} & \\ & & cI\end{bmatrix}$，则

$$P_3^{-1}N_2P_3=\begin{bmatrix}0 & \boldsymbol{e}_1^{\mathrm{T}} & \boldsymbol{\beta}^{\mathrm{T}}\\ & J_{m_1}(0) & \\ & & J\end{bmatrix}=N_4.$$

注意，N_4 的左上角就是 $J_{m_1+1}(0)=\begin{bmatrix}0 & e_1^{\mathrm{T}}\\ & J_{m_1}(0)\end{bmatrix}$. 于是

$$N_4=\begin{bmatrix}J_{m_1+1}(0) & e_1\boldsymbol{\beta}^{\mathrm{T}}\\ & J\end{bmatrix}.$$

最后令 $P_4 = \begin{bmatrix} I_{m_1+1} & -\sum_{i=1}^{m_1} e_{i+1}\boldsymbol{\beta}^{\mathrm{T}} J^{i-1} \\ & I \end{bmatrix}$，则

$$P_4^{-1} N_4 P_4 = \begin{bmatrix} I_{m_1+1} & \sum_{i=1}^{m_1} e_{i+1}\boldsymbol{\beta}^{\mathrm{T}} J^{i-1} \\ & I \end{bmatrix} \begin{bmatrix} J_{m_1+1}(0) & \boldsymbol{e}_1\boldsymbol{\beta}^{\mathrm{T}} \\ & J \end{bmatrix} \begin{bmatrix} I_{m_1+1} & -\sum_{i=1}^{m_1} e_{i+1}\boldsymbol{\beta}^{\mathrm{T}} J^{i-1} \\ & I \end{bmatrix}$$

$$= \begin{bmatrix} J_{m_1+1}(0) & \underbrace{\boldsymbol{e}\boldsymbol{\beta}^{\mathrm{T}} + \sum_{i=1}^{m_1} \boldsymbol{e}_{i+1}\boldsymbol{\beta}^{\mathrm{T}} J^{i-1} J - J_{m_1+1}(0) \sum_{i=1}^{m_1} \boldsymbol{e}_{i+1}\boldsymbol{\beta}^{\mathrm{T}} J^{i-1}}_{Z} \\ & J \end{bmatrix}.$$

因 $J_{m_1+1}(0)\boldsymbol{e}_{i+1} = \boldsymbol{e}_i$, 故

$$\begin{aligned} Z &= \boldsymbol{e}_1\boldsymbol{\beta}^{\mathrm{T}} + \sum_{i=1}^{m_1} \boldsymbol{e}_{i+1}\boldsymbol{\beta}^{\mathrm{T}} J^{i} - \sum_{i=1}^{m_1} \boldsymbol{e}_i\boldsymbol{\beta}^{\mathrm{T}} J^{i-1} \\ &= \boldsymbol{e}_{m_1+1}\boldsymbol{\beta}^{\mathrm{T}} J^{m_1}. \end{aligned}$$

由于 $m_1 \geq m_2 \geq \cdots \geq m_\ell$, 所以

$$J^{m_1} = \operatorname{diag}(J_{m_2}(0), \cdots, J_{m_\ell}(0))^{m_1} = \operatorname{diag}(J_{m_2}(0)^{m_1}, \cdots, J_{m_\ell}(0)^{m_1}) = 0,$$

从而 $Z = 0$.

例题 3.8.

引理3.2.1的结论是，若

$$A = \begin{bmatrix} 0 & \boldsymbol{\alpha}^{\mathrm{T}} \\ 0 & J_m(0) \end{bmatrix} = \begin{bmatrix} 0 & a_1 & a_2 & \cdots & a_m \\ & 0 & 1 & & \\ & & \ddots & \ddots & \\ & & & 0 & 1 \\ & & & & 0 \end{bmatrix}, \quad P = \begin{bmatrix} 1 & \boldsymbol{\alpha}^{\mathrm{T}} J_m(0)^{\mathrm{T}} \\ & I_m \end{bmatrix} = \begin{bmatrix} 1 & a_2 & \cdots & a_m & 0 \\ & 1 & & & \\ & & 1 & & \\ & & & \ddots & \\ & & & & 1 \end{bmatrix},$$

则

$$P^{-1}AP = \begin{bmatrix} 0 & \boldsymbol{\alpha}^{\mathrm{T}}\boldsymbol{e}_1\boldsymbol{e}_1^{\mathrm{T}} \\ 0 & J_m(0) \end{bmatrix} = \begin{bmatrix} 0 & a_1 & & & \\ & 0 & 1 & & \\ & & \ddots & \ddots & \\ & & & 0 & 1 \\ & & & & 0 \end{bmatrix}.$$

这背后的想法如下. 由 A 的形式知

$$\begin{aligned} A\boldsymbol{e}_1 &= 0 \\ A\boldsymbol{e}_2 &= a_1\boldsymbol{e}_1 \\ A\boldsymbol{e}_3 &= \boldsymbol{e}_2 + a_2\boldsymbol{e}_1 \\ &\vdots \\ A\boldsymbol{e}_m &= \boldsymbol{e}_{m-1} + a_{m-1}\boldsymbol{e}_1 \\ A\boldsymbol{e}_{m+1} &= \boldsymbol{e}_m + a_m\boldsymbol{e}_1. \end{aligned}$$

给 $\boldsymbol{e}_2,\cdots,\boldsymbol{e}_m$ 分别加上 $a_2\boldsymbol{e}_1,\cdots,a_m\boldsymbol{e}_1$ 后得到

$$\begin{aligned}
A\boldsymbol{e}_1 &= 0\\
A(\boldsymbol{e}_2+a_2\boldsymbol{e}_1) &= a_1\boldsymbol{e}_1\\
A(\boldsymbol{e}_3+a_3\boldsymbol{e}_1) &= \boldsymbol{e}_2+a_2\boldsymbol{e}_1\\
&\vdots\\
A(\boldsymbol{e}_m+a_m\boldsymbol{e}_1) &= \boldsymbol{e}_{m-1}+a_{m-1}\boldsymbol{e}_1\\
A\boldsymbol{e}_{m+1} &= \boldsymbol{e}_m+a_m\boldsymbol{e}_1.
\end{aligned}$$

若记 $\boldsymbol{\beta}_1=\boldsymbol{e}_1,\boldsymbol{\beta}_2=\boldsymbol{e}_2+a_2\boldsymbol{e}_1,\cdots,\boldsymbol{\beta}_m=\boldsymbol{e}_m+a_m\boldsymbol{e}_1,\boldsymbol{\beta}_{m+1}=\boldsymbol{e}_{m+1}$, 则

$$\begin{aligned}
A\boldsymbol{\beta}_1 &= 0\\
A\boldsymbol{\beta}_2 &= a_1\boldsymbol{\beta}_1\\
A\boldsymbol{\beta}_3 &= \boldsymbol{\beta}_2\\
&\vdots\\
A\boldsymbol{\beta}_m &= \boldsymbol{\beta}_{m-1}\\
A\boldsymbol{\beta}_{m+1} &= \boldsymbol{\beta}_m.
\end{aligned}$$

于是

$$\begin{aligned}
A\begin{bmatrix}\boldsymbol{\beta}_1 & \boldsymbol{\beta}_2 & \boldsymbol{\beta}_3 & \cdots & \boldsymbol{\beta}_m & \boldsymbol{\beta}_{m+1}\end{bmatrix} &= \begin{bmatrix}0 & a_1\boldsymbol{\beta}_1 & \boldsymbol{\beta}_2 & \cdots & \boldsymbol{\beta}_{m-1} & \boldsymbol{\beta}_m\end{bmatrix}\\
&= \begin{bmatrix}\boldsymbol{\beta}_1 & \boldsymbol{\beta}_2 & \boldsymbol{\beta}_3 & \cdots & \boldsymbol{\beta}_m & \boldsymbol{\beta}_{m+1}\end{bmatrix}\begin{bmatrix}0 & a_1 & & & & \\ & 0 & 1 & & & \\ & & \ddots & \ddots & & \\ & & & & 0 & 1\\ & & & & & 0\end{bmatrix}..
\end{aligned}$$

注意，$\boldsymbol{\beta}_1,\cdots,\boldsymbol{\beta}_{m+1}$ 仍是 $\mathbb{C}^{m+1}$ 的一组基，而且它们组成的矩阵 $\begin{bmatrix}\boldsymbol{\beta}_1 & \cdots & \boldsymbol{\beta}_{m+1}\end{bmatrix}$ 就是 P.

例题 3.9.

设

$$A=\begin{bmatrix}0 & \boldsymbol{e}_1^{\mathrm{T}} & \boldsymbol{\beta}^{\mathrm{T}}\\ & J_3(0) & \\ & & J_3(0)\end{bmatrix}=\begin{bmatrix}0 & 1 & & & & & & \\ & 0 & 1 & & & & & \\ & & 0 & 1 & & & & \\ & & & 0 & & & & \\ & & & & 0 & 1 & 0 & \\ & & & & & 0 & 1 & \\ & & & & & & 0 & \end{bmatrix},$$

则

$$\begin{aligned}
A\boldsymbol{e}_1 &= 0\\
A\boldsymbol{e}_2 &= \boldsymbol{e}_1\\
A\boldsymbol{e}_3 &= \boldsymbol{e}_2\\
A\boldsymbol{e}_4 &= \boldsymbol{e}_3\\
A\boldsymbol{e}_5 &= a\boldsymbol{e}_1\\
A\boldsymbol{e}_6 &= \boldsymbol{e}_5 + b\boldsymbol{e}_1\\
A\boldsymbol{e}_7 &= \boldsymbol{e}_6 + c\boldsymbol{e}_1.
\end{aligned}$$

令 $\boldsymbol{\beta}_5 = \boldsymbol{e}_5 + b\boldsymbol{e}_1, \boldsymbol{\beta}_6 = \boldsymbol{e}_6 + c\boldsymbol{e}_1$, 则

$$\begin{aligned}
A\boldsymbol{\beta}_5 &= a\boldsymbol{e}_1\\
A\boldsymbol{\beta}_6 &= \boldsymbol{\beta}_5\\
A\boldsymbol{e}_7 &= \boldsymbol{\beta}_6.
\end{aligned}$$

再令 $\boldsymbol{\gamma}_5 = \boldsymbol{\beta}_5 - a\boldsymbol{e}_2 = \boldsymbol{e}_5 + b\boldsymbol{e}_1 - a\boldsymbol{e}_2$

$$\boldsymbol{\gamma}_6 = \boldsymbol{\beta}_6 - a\boldsymbol{e}_3 = \boldsymbol{e}_6 + c\boldsymbol{e}_1 - a\boldsymbol{e}_3$$

$$\boldsymbol{\gamma}_7 = \boldsymbol{e}_7 - a\boldsymbol{e}_4,$$

则

$$\begin{aligned}
A\boldsymbol{\gamma}_5 &= 0\\
A\boldsymbol{\gamma}_6 &= \boldsymbol{\gamma}_5\\
A\boldsymbol{\gamma}_7 &= \boldsymbol{\gamma}_6.
\end{aligned}$$

于是

$$A\begin{bmatrix}\boldsymbol{e}_1 & \boldsymbol{e}_2 & \boldsymbol{e}_3 & \boldsymbol{e}_4 & \boldsymbol{\gamma}_5 & \boldsymbol{\gamma}_6 & \boldsymbol{\gamma}_7\end{bmatrix} = \begin{bmatrix}\boldsymbol{e}_1 & \boldsymbol{e}_2 & \boldsymbol{e}_3 & \boldsymbol{e}_4 & \boldsymbol{\gamma}_5 & \boldsymbol{\gamma}_6 & \boldsymbol{\gamma}_7\end{bmatrix}\begin{bmatrix}J_4(0) & \\ & J_3(0)\end{bmatrix},$$

即若令

$$P = \begin{bmatrix}\boldsymbol{e}_1 & \boldsymbol{e}_2 & \boldsymbol{e}_3 & \boldsymbol{e}_4 & \boldsymbol{\gamma}_5 & \boldsymbol{\gamma}_6 & \boldsymbol{\gamma}_7\end{bmatrix} = \begin{bmatrix}
1 & & & b & c & 0\\
& 1 & & -a & & \\
& & 1 & & -a & \\
& & & 1 & & -a\\
& & & & 1 & \\
& & & & & 1\\
& & & & & & 1
\end{bmatrix},$$

则 $P^{-1}AP = \operatorname{diag}(J_4(0), J_3(0))$. 然而这里的 P 并不是命题3.2.3的证明中最后部分的 P_4, 若按照 P_4 的公式,

得到的可逆阵是

$$P_4=\begin{bmatrix}1 & & & 0 & 0 & 0\\ & 1 & & -a & -b & -c\\ & & 1 & & -a & -b\\ & & & 1 & & -a\\ & & & & 1 & \\ & & & & & 1\end{bmatrix},$$

它也满足 $P_4^{-1}AP_4=\operatorname{diag}(J_4(0),J_3(0))$.

若把命题3.2.3的证明中的 P_4 换成下面的矩阵

$$P_5=\begin{bmatrix}I_{m_1+1} & R_2 & \cdots & R_\ell\\ & I_{m_2} & & \\ & & \ddots & \\ & & & I_{m_\ell}\end{bmatrix}$$

其中

$$R_j=\begin{bmatrix}\boldsymbol{\alpha}_j^{\mathrm{T}}J_{m_j}(0)^{\mathrm{T}}\\ -(\boldsymbol{\alpha}_j^{\mathrm{T}}\boldsymbol{e}_1)I_{m_j}\\ 0_{(m_1-m_j)\times m_j}\end{bmatrix}=\begin{bmatrix}a_{j2} & \cdots & a_{jm_j} & 0\\ -a_{j1} & & & \\ & \ddots & & \\ & & -a_{j1} & \\ & & & -a_{j1}\\ 0 & \cdots & 0 & 0\\ \vdots & \ddots & \vdots & \vdots\\ 0 & \cdots & 0 & 0\end{bmatrix},$$

则证明仍然成立.

综合命题3.2.2和命题3.2.3，我们得知定理3.2.1成立.

命题 3.2.4

设 $A\in M_n(\mathbb{C})$, A 的初等因子组是

$$(\lambda-\lambda_1)^{e_{11}},\cdots,(\lambda-\lambda_1)^{e_{1m_1}},\cdots,(\lambda-\lambda_k)^{e_{k1}},\cdots,(\lambda-\lambda_k)^{e_{km_k}},$$

其中 $\lambda_1,\cdots,\lambda_k$ 是 A 的互异特征值，$e_{11}\geq\cdots\geq e_{1m_1}\geq 1,\cdots,e_{k1}\geq\cdots\geq e_{km_k}\geq 1$, 则

1. A 的特征多项式是 $(\lambda-\lambda_1)^{\sum_{j=1}^{m_1}e_{1j}}\cdots(\lambda-\lambda_k)^{\sum_{j=1}^{m_k}e_{kj}}$,
2. A 的最小多项式是 $(\lambda-\lambda_1)^{e_{11}}\cdots(\lambda-\lambda_k)^{e_{k1}}$,
3. A 可相似对角化当且仅当 A 的最小多项式没有重根.

♠

证明　A 相似于 $J=\operatorname{diag}(J_{e_{ij}}(\lambda_i):1\leq i\leq k,1\leq j\leq m_i)$. 由于相似的矩阵有相同的特征多项式和相同的最小多项式，故我们计算 J 的特征多项式和最小多项式即可. 已知 Jordan 块 $J_{e_{ij}}(\lambda_i)$ 的特征多项式和最小多项式都等于 $(\lambda-\lambda_i)^{e_{ij}}$, 结合命题3.1.4就得到了 (1)(2). (3) 容易.

定义 3.2.1

设 $A\in M_n(\mathbb{C})$, λ 是 A 的特征值，$0\neq\boldsymbol{\alpha}\in\mathbb{C}^n$. 若存在 $m\geq 1$ 使得 $(A-\lambda I)^m\boldsymbol{\alpha}=0$, 则称 $\boldsymbol{\alpha}$ 是 A 的属于 λ 的广义特征向量（generalized eigenvectors）. 广义特征向量和零向量构成的集合称为广义特征子空间或根子

空间，记为

$$\ker(A-\lambda I)^{\infty}=\{\alpha\in\mathbb{C}^n:\exists m\geq 1 \text{ s.t. } (A-\lambda I)^m\alpha=0\}.$$

命题 3.2.5

设 A,λ_i,e_{ij} 如命题3.2.4，则 A 的属于 λ_i 的根子空间是

$$\ker(A-\lambda_i I)^{\infty}=\ker(A-\lambda_i I)^{e_{i1}},$$

其维数是 λ_i 的代数重数 $e_i=e_{i1}+\cdots+e_{im_i}$.
更具体的，若 $P^{-1}AP=\operatorname{diag}(J_1,\cdots,J_k)$, 其中 $J_i=\operatorname{diag}(J_{e_{ij}}(\lambda_i):1\leq j\leq m_i)$, 则 A 的属于 λ_i 的根子空间是由 P 的第 $e_1+\cdots+e_{i-1}+1,\cdots,e_1+\cdots+e_{i-1}+e_i$ 列张成的子空间.

其维数计算如下. 从 $(A-\lambda_i I)^{e_{i1}}=P(J-\lambda_i I)^{e_{i1}}P^{-1}$ 得知

$$\dim\ker(A-\lambda_i I)^{e_{i1}}=\dim\ker(J-\lambda_i I)^{e_{i1}},$$

而 $(J-\lambda_i I)^{e_{i1}}$ 是个块对角阵，且不难验证 $(J-\lambda_i I)^{e_{i1}}$ 中对应于 A 的特征值 λ_i 的块都是 0

$$(J_{e_{ij}}(\lambda_i)-\lambda_i I)^{e_{i1}}=J_{e_{ij}}(0)^{e_{i1}}=0\quad(e_{i1}\geq e_{ij}),$$

而对应于其他特征值 λ_j 的块都是可逆阵，故 $\ker(J-\lambda_i I)^{e_{i1}}$ 的维数等于 J 中属于 λ_i 的 Jordan 块的阶数的和，也就是 $e_i=e_{i1}+\cdots+e_{im_i}$.

余下略.

例题 3.10.

因 $\dfrac{\mathrm{d}}{\mathrm{d}t}\mathrm{e}^{\lambda t}=\lambda\mathrm{e}^{\lambda t}$，故 $\mathrm{e}^{\lambda t}$ 是微分算子 $D=\dfrac{\mathrm{d}}{\mathrm{d}t}$ 的“特征函数”，特征值是 λ. 用和公式计算 $t\mathrm{e}^{\lambda t}$ 的导数如下

$$D(t\mathrm{e}^{\lambda t})=\lambda t\mathrm{e}^{\lambda t}+\mathrm{e}^{\lambda t},$$

即 $(D-\lambda)(t\mathrm{e}^{\lambda t})=\mathrm{e}^{\lambda t}$. 因 $(D-\lambda)\mathrm{e}^{\lambda t}=0$，故 $(D-\lambda)^2(t\mathrm{e}^{\lambda t})=0$, 也就是说 $t\mathrm{e}^{\lambda t}$ 是 D 的属于 λ 的“广义特征函数”.
更一般的有

$$D\left(\frac{t^m}{m!}\mathrm{e}^{\lambda t}\right)=\frac{t^{m-1}}{(m-1)!}\mathrm{e}^{\lambda t}+\lambda\frac{t^m}{m!}\mathrm{e}^{\lambda t},$$

或

$$(D-\lambda)\left(\frac{t^m}{m!}\mathrm{e}^{\lambda t}\right)=\frac{t^{m-1}}{(m-1)!}\mathrm{e}^{\lambda t},$$

故 $\mathrm{e}^{\lambda t},t\mathrm{e}^{\lambda t},\dfrac{t^2}{2!}\mathrm{e}^{\lambda t},\cdots,\dfrac{t^m}{m!}\mathrm{e}^{\lambda t}$ 是求导算子 D 的属于 λ 的一个 Jordan 链.

例题 3.11.

设 $A=\begin{bmatrix}5&1&-2\\0&5&2\\0&0&5\end{bmatrix}$, 求 A 的 Jordan 标准型 J 和可逆阵 P 使得 $P^{-1}AP=J$.

证明 解：显然 A 的特征多项式是 $(\lambda-5)^3$，A 有唯一特征值 5.

计算得

$$A-5I=\begin{bmatrix}0&1&-2\\0&0&2\\0&0&0\end{bmatrix},$$

故 $r(A-5I)=2$, 于是 5 的几何重数是 $\dim\ker(A-5I)=3-2=1$, 所以属于 5 的 Jordan 块只有一个. 综上可知 A 的 Jordan 标准型是

$$J=\begin{bmatrix}5&1&0\\0&5&1\\0&0&5\end{bmatrix}.$$

计算得 $\ker(A-5I)=\mathrm{Span}\left(\begin{bmatrix}1\\0\\0\end{bmatrix}\right)$, 故令 $\boldsymbol{\alpha}_1=\begin{bmatrix}1\\0\\0\end{bmatrix}$. 接着我们求解方程 $(A-5I)\boldsymbol{\alpha}_2=\boldsymbol{\alpha}_1$, 可取 $\boldsymbol{\alpha}_2=\begin{bmatrix}0\\1\\0\end{bmatrix}$. 再求解 $(A-5I)\boldsymbol{\alpha}_3=\boldsymbol{\alpha}_2$, 可取 $\boldsymbol{\alpha}_3=\begin{bmatrix}0\\1\\\frac{1}{2}\end{bmatrix}$. 最后令 $P=\begin{bmatrix}1&0&0\\0&1&1\\0&0&\frac{1}{2}\end{bmatrix}$, 则 $P^{-1}AP=J$.

注意, 满足条件的 P 不唯一. 在这个例子中, P 的第一列可取作 $(1,0,0)$ 的任意非零倍, 在取定 $\boldsymbol{\alpha}_1=(1,0,0)$ 之后, $\boldsymbol{\alpha}_2$ 的选取也不唯一, 比如我们可以取 $\boldsymbol{\alpha}_2'=\boldsymbol{\alpha}_2-\boldsymbol{\alpha}_1=\begin{bmatrix}-1\\1\\0\end{bmatrix}$, 相应的取 $\boldsymbol{\alpha}_3'=\begin{bmatrix}0\\0\\\frac{1}{2}\end{bmatrix}$, 则

$$P'=\begin{bmatrix}1&-1&0\\0&1&0\\0&0&\frac{1}{2}\end{bmatrix}$$

也满足 $P'^{-1}AP'=J$.

练习 3.4 写下所有满足 $P^{-1}AP=J$ 的可逆阵 P.

例题 3.12.

设 $A=\begin{bmatrix}0&4&2\\-3&8&3\\4&-8&-2\end{bmatrix}$, 求 A 的 Jordan 标准型 J 和可逆阵 P 使得 $P^{-1}AP=J$.

解. 先计算 A 的特征多项式

$$\begin{aligned}\begin{vmatrix}\lambda&-4&-2\\3&\lambda-8&-3\\-4&8&\lambda+2\end{vmatrix}&=\lambda(\lambda^2-6\lambda+8)+4(3\lambda-6)-2(4\lambda-8)\\&=\lambda^3-6\lambda^2+12\lambda-8\\&=(\lambda-2)(\lambda^2-4\lambda+4)\\&=(\lambda-2)^3,\end{aligned}$$

故 A 有唯一特征值 2. 接着计算

$$A-2I=\begin{bmatrix}-2&4&2\\-3&6&3\\4&-8&-4\end{bmatrix}$$

2 个属于特征值 2 的 Jordan 块. 综上可知

$$J = \begin{bmatrix} 2 & 1 & \\ & 2 & \\ & & 2 \end{bmatrix}.$$

还需求可逆阵 $P = [\boldsymbol{\alpha}_1\ \boldsymbol{\alpha}_2\ \boldsymbol{\alpha}_3]$ 使得

$$\begin{aligned} A\boldsymbol{\alpha}_1 &= 2\boldsymbol{\alpha}_1, \\ A\boldsymbol{\alpha}_2 &= 2\boldsymbol{\alpha}_2 + \boldsymbol{\alpha}_1, \\ A\boldsymbol{\alpha}_3 &= 2\boldsymbol{\alpha}_3. \end{aligned}$$

满足条件的 $\boldsymbol{\alpha}_1, \boldsymbol{\alpha}_3$ 的 A 的属于 2 的特征子空间的基，故先求 $N(A-2I)$. 计算得

$$N(A-2I) = \mathrm{Span}\left(\begin{bmatrix} 2 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}\right).$$

但是 $(2,1,0), (1,0,1)$ 均不可取作 $\boldsymbol{\alpha}_1$！因为 $\boldsymbol{\alpha}_1$ 不仅要属于 $N(A-2I)$，而且从 $(A-2I)\boldsymbol{\alpha}_2 = \boldsymbol{\alpha}_1$ 知道 $\boldsymbol{\alpha}_1$ 还需属于 $C(A-2I)$, 而 $(2,1,0), (1,0,1)$ 都不属于 $C(A-2I)$. 事实上

$$C(A-2I) = \mathrm{Span}\left(\begin{bmatrix} 2 \\ 3 \\ -4 \end{bmatrix}\right).$$

不妨取 $\boldsymbol{\alpha}_1 = \begin{bmatrix} 2 \\ 3 \\ -4 \end{bmatrix}$. 注意

$$\begin{bmatrix} 2 \\ 3 \\ -4 \end{bmatrix} = 3\begin{bmatrix} 2 \\ 1 \\ 0 \end{bmatrix} - 4\begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix} \in N(A-2I).$$

不难看出 $(A-2I)\boldsymbol{\alpha}_2 = \boldsymbol{\alpha}_1$ 有特解 $(-1,0,0), (0,\frac{1}{2},0), (0,0,1)$ 等，通解是

$$\begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} + c_1\begin{bmatrix} 2 \\ 1 \\ 0 \end{bmatrix} + c_2\begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}, \quad c_1, c_2 \in \mathbb{C},$$

它们中的任何一个都可取作 $\boldsymbol{\alpha}_2$, 不妨令 $\boldsymbol{\alpha}_2 = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}$. 最后，取 $N(A-2I)$ 中任一与 $\boldsymbol{\alpha}_1$ 线性无关的向量作为 $\boldsymbol{\alpha}_3$ 即可，比如 $\boldsymbol{\alpha}_3 = \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}$. 于是矩阵

$$P = \begin{bmatrix} 2 & 0 & 1 \\ 3 & 0 & 0 \\ -4 & 1 & 1 \end{bmatrix}$$

满足 $P^{-1}AP = J$.

例题 3.13.

设 $A=\begin{bmatrix}3&-1&0&0\\1&1&0&0\\3&0&5&-3\\4&-1&3&-1\end{bmatrix}$，求 A 的 Jordan 标准型 J 和可逆阵 P 使得 $P^{-1}AP=J$.

解. 易见

$$\det(\lambda I_4-A)=\det\begin{bmatrix}\lambda-3&1&&\\-1&\lambda-1&&\\&&\lambda-5&3\\&&-3&\lambda+1\end{bmatrix}=(\lambda-2)^4,$$

故 A 有唯一的特征值 2.

为了确定 Jordan 块的个数和大小，我们计算

$$A-2I=\begin{bmatrix}1&-1&0&0\\1&-1&0&0\\3&0&3&-3\\4&-1&3&-3\end{bmatrix},$$

易见 $r(A-2I)=2$, 故 $\dim N(A-2I)=4-2=2$，于是 A 有两个（属于 2）的 Jordan 块，易见有以下两种可能：$J_3(2),J_1(2)$ 或 $J_2(2),J_2(2)$.

为了确定是哪种情形，我们还需计算

$$(A-2I)^2=\begin{bmatrix}1&-1&0&0\\1&-1&0&0\\3&0&3&-3\\4&-1&3&-3\end{bmatrix}\begin{bmatrix}1&-1&0&0\\1&-1&0&0\\3&0&3&-3\\4&-1&3&-3\end{bmatrix}=0,$$

故 A 的 Jordan 标准型是

$$J=\begin{bmatrix}2&1&&\\&2&&\\&&2&1\\&&&2\end{bmatrix}.$$

P 的计算留作练习.

例题 3.14.

设 $A=\begin{bmatrix}1&-3&0&3\\-2&-6&0&13\\0&-3&1&3\\-1&-4&0&8\end{bmatrix}$，求 A 的 Jordan 标准型 J 和可逆阵 P 使得 $P^{-1}AP=J$.

解. 先计算特征多项式

$$\begin{aligned}\det(\lambda - A) &= (\lambda-1)\begin{vmatrix}\lambda-1 & 3 & -3\\ 2 & \lambda+6 & -13\\ 1 & 4 & \lambda-8\end{vmatrix}\\ &= (\lambda-1)[(\lambda-1)(\lambda^2-2\lambda+4)-3(2\lambda-3)-3(2-\lambda)]\\ &= (\lambda-1)^4.\end{aligned}$$

再计算

$$A - I = \begin{bmatrix}0 & -3 & 0 & 3\\ -2 & -7 & 0 & 13\\ 0 & -3 & 0 & 3\\ -1 & -4 & 0 & 7\end{bmatrix}.$$

易见 $r(A-I)=2$, 故 $\dim N(A-I)=2$, 所以 A 有两个（属于 1）的 Jordan 块. 为了确定它们是 $J_3(1), J_1(1)$ 还是 $J_2(1), J_2(1)$，我们接着计算

$$(A-I)^2 = \begin{bmatrix}0 & -3 & 0 & 3\\ -2 & -7 & 0 & 13\\ 0 & -3 & 0 & 3\\ -1 & -4 & 0 & 7\end{bmatrix}\begin{bmatrix}0 & -3 & 0 & 3\\ -2 & -7 & 0 & 13\\ 0 & -3 & 0 & 3\\ -1 & -4 & 0 & 7\end{bmatrix} = \begin{bmatrix}3 & 9 & 0 & -18\\ 1 & 3 & 0 & -6\\ 3 & 9 & 0 & -18\\ 1 & 3 & 0 & -6\end{bmatrix}.$$

事实上，计算出 $(1,1)$ 元素是 $3\neq 0$ 就知道 $(A-I)^2\neq 0$，于是 A 的 Jordan 块是 $J_3(1), J_1(1)$,

即

$$J = \begin{bmatrix}1 & 1 & & \\ & 1 & 1 & \\ & & 1 & \\ & & & 1\end{bmatrix}.$$

为了求满足 $P^{-1}AP = J$ 的可逆阵 P, 我们需要找到 4 个线性无关的向量 $\boldsymbol{\alpha}_1, \boldsymbol{\alpha}_2, \boldsymbol{\alpha}_3, \boldsymbol{\alpha}_4$ 使得

$$(A-I)\boldsymbol{\alpha}_1 = 0,\quad (A-I)\boldsymbol{\alpha}_2 = \boldsymbol{\alpha}_1,\quad (A-I)\boldsymbol{\alpha}_3 = \boldsymbol{\alpha}_2,\quad (A-I)\boldsymbol{\alpha}_4 = 0.$$

易见 $\boldsymbol{\alpha}_1, \boldsymbol{\alpha}_4$ 是 $N(A-I)$ 的基，故先计算

$$N(A-I) = \mathrm{Span}\left(\begin{bmatrix}3\\1\\3\\1\end{bmatrix}, \begin{bmatrix}0\\0\\1\\0\end{bmatrix}\right).$$

由 $\boldsymbol{\alpha}_i$ 满足的条件知 $\boldsymbol{\alpha}_1 = (A-I)^2\boldsymbol{\alpha}_3 \in \mathrm{im}(A-I)^2$, 而

$$\mathrm{im}(A-I)^2 = \mathrm{Span}\left(\begin{bmatrix}3\\1\\3\\1\end{bmatrix}\right).$$

因 $\boldsymbol{\alpha}_1$ 是 $(A-I)^2$ 的第一列，故可取 $\boldsymbol{\alpha}_3 = \begin{bmatrix}1\\0\\0\\0\end{bmatrix}$，再计算 $\boldsymbol{\alpha}_2 = (A-I)\boldsymbol{\alpha}_3 = \begin{bmatrix}0\\-2\\0\\-1\end{bmatrix}$.

这样做的好处是，如果先求满足 $(A-I)\boldsymbol{\alpha}_2 = \boldsymbol{\alpha}_1$ 的 $\boldsymbol{\alpha}_2$，那么因解不唯一，选取不当的话会导致下一个方程 $(A-I)\boldsymbol{\alpha}_3 = \boldsymbol{\alpha}_2$ 无解，所以在确定 $\boldsymbol{\alpha}_2$ 的时候可能需要做一些调整；这里我们先求了 $\boldsymbol{\alpha}_3$，再往前计算 $\boldsymbol{\alpha}_2$ 就避免了这个问题.

最后，任取 $\boldsymbol{\alpha}_4$ 是 $N(A-I)$ 中与 $\boldsymbol{\alpha}_1$ 线性无关的向量即可，比如 $\boldsymbol{\alpha}_4=\begin{bmatrix}0\\0\\1\\0\end{bmatrix}$，故

$$P=\begin{bmatrix}3&0&1&0\\1&-2&0&0\\3&0&0&1\\1&-1&0&0\end{bmatrix}$$

即为所求.

例题 3.15.

$A=\begin{bmatrix}1&2&3\\0&1&1\\0&-1&-1\end{bmatrix}$，求 A 的 Jordan 标准型 J 和可逆阵 P 使得 $P^{-1}AP=J$.

解. 显然

$$\det(\lambda I_3-A)=(\lambda-1)\begin{vmatrix}\lambda-1&-1\\1&\lambda+1\end{vmatrix}=(\lambda-1)\lambda^2,$$

故 A 的特征值是 $1,0,0$.

易见 $N(A-I)=N\left(\begin{bmatrix}0&2&3\\0&0&1\\0&-1&-2\end{bmatrix}\right)=\mathrm{Span}\left(\begin{bmatrix}1\\0\\0\end{bmatrix}\right)$，$N(A)=\mathrm{Span}\left(\begin{bmatrix}1\\-1\\1\end{bmatrix}\right)$，特别的 $\dim N(A)=1$，故 A 仅有一个属于 0 的 Jordan 块，于是

$$J=\begin{bmatrix}1&&\\&0&1\\&&0\end{bmatrix}.$$

属于 1 的特征向量可取作 $\boldsymbol{\alpha}_1=\begin{bmatrix}1\\0\\0\end{bmatrix}$，属于 0 的特征向量可取作 $\boldsymbol{\alpha}_2=\begin{bmatrix}1\\-1\\1\end{bmatrix}$，满足 $A\boldsymbol{\alpha}_3=\boldsymbol{\alpha}_2$ 的 $\boldsymbol{\alpha}_3$ 可取作 $\boldsymbol{\alpha}_3=\begin{bmatrix}-1\\0\\1\end{bmatrix}$.

最后令

$$P=\begin{bmatrix}1&1&-1\\0&-1&0\\0&1&1\end{bmatrix}.$$

例题 3.16.

设 $N=J_{10}(0)$，求 N^3 的 Jordan 标准型 J 和可逆阵 P 使得 $P^{-1}N^3P=J$.

解. 解法 1. N,N^3 均是严格上三角阵，故 N^3 有唯一的特征值 0. 我们可以通过计算 $r((N^3)^k)$ 来确定 N^3 的（属于 0 的）Jordan 块的大小和个数. 易知

$$r(N^3)=7,\quad r(N^6)=4,\quad r(N^9)=1,\quad r(N^{12})=0,$$

故 N^3 共有

(a) $10-7=3$ 个 Jordan 块，即 $\#J_{\geq 1}(0)=3$,

(b) $7-4=3$ 个阶数 ≥ 2 的 Jordan 块，即 $\#J_{\geq 2}(0)=3$,

(c) $4-1=3$ 个阶数 ≥ 3 的 Jordan 块，即 $\#J_{\geq 3}(0)=3$,

(d) $1-0=1$ 个阶数 ≥ 4 的 Jordan 块，即 $\#J_{\geq 4}(0)=1$,

(e) 0 个阶数 ≥ 5 的 Jordan 块，即 $\#J_{\geq 5}(0)=0$.

故 $\#J_4(0)=1, \#J_3(0)=2, \#J_2(0)=0, \#J_1(0)=0$,

$$J=\operatorname{diag}(J_4(0),J_3(0),J_3(0)).$$

解法 2.：N 作用在 $\mathbb{C}^{10}$ 的标准基 $e_1,\cdots,e_{10}$ 上的效果是

$$e_{10}\xrightarrow{N}e_9\xrightarrow{N}e_8\xrightarrow{N}e_7\xrightarrow{N}e_6\xrightarrow{N}e_5\xrightarrow{N}e_4\xrightarrow{N}e_3\xrightarrow{N}e_2\xrightarrow{N}e_1\xrightarrow{N}0,$$

故 N^3 作用在标准基上的效果是

$$e_{10}\xrightarrow{N^3}e_7\xrightarrow{N^3}e_4\xrightarrow{N^3}e_1\xrightarrow{N^3}0$$
$$e_9\xrightarrow{N^3}e_6\xrightarrow{N^3}e_3\xrightarrow{N^3}0$$
$$e_8\xrightarrow{N^3}e_5\xrightarrow{N^3}e_2\xrightarrow{N^3}0.$$

这分别是长为 4，3，3 的 Jordan 链，故若令

$$P=\begin{bmatrix}e_1 & e_4 & e_7 & e_{10} & e_3 & e_6 & e_9 & e_2 & e_5 & e_8\end{bmatrix},$$

则 $P^{-1}N^3P=\operatorname{diag}(J_4(0),J_3(0),J_3(0))$.

命题 3.2.6

设 $A\in M_n(\mathbb{C}), f(x)\in\mathbb{C}[x], f(x)\neq 0, f(x)$ 无重根，$f(A)=0$, 则 A 可相似对角化.

证明 设 A 的最小多项式是 $d(x)$, 则由 $f(A)=0$ 知 $d(x)\mid f(x)$. 因 $f(x)\neq 0$ 且无重根，故 $d(x)$ 也无重根，故 A 可对角化.

例题 3.17.

满足 $A^2=A, A^2=I, A^2-2A-3I=0$ 的矩阵 A 都可相似对角化，因为多项式 x^2-x, x^2-1, x^2-2x-3 无重根.

定义 3.2.2

设 $f(x)=a_0+a_1x+\cdots+a_{n-1}x^{n-1}+x^n\in\mathbb{C}[x]$. 定义

$$C(f)=\begin{bmatrix}0 & & & -a_0\\ 1 & 0 & & -a_1\\ & 1 & \ddots & -a_2\\ & & \ddots\ 0 & \vdots\\ & & 1 & -a_{n-1}\end{bmatrix}.$$

$C(f)$ 称为多项式 f 的友阵（companion matrix）.

注 3.2.1

设 $u(t)$ 是 n 次连续可微函数且满足

$$\frac{\mathrm{d}^n u(t)}{\mathrm{d}t^n} + a_{n-1}\frac{\mathrm{d}^{n-1}u(t)}{\mathrm{d}t^{n-1}} + \cdots + a_1\frac{\mathrm{d}u(t)}{\mathrm{d}t} + a_0 u(t) = 0,$$

则 $(u(t), \frac{\mathrm{d}u(t)}{dt}, \cdots, \frac{\mathrm{d}^{n-1}u(t)}{\mathrm{d}t^{n-1}})$ 满足

$$\frac{\mathrm{d}}{\mathrm{d}t}\begin{bmatrix} u(t) \\ \frac{\mathrm{d}u(t)}{\mathrm{d}t} \\ \vdots \\ \frac{\mathrm{d}^{n-1}u(t)}{\mathrm{d}t^{n-1}} \end{bmatrix} = \begin{bmatrix} 0 & 1 & & & & \\ & 0 & 1 & & & \\ & & \ddots & \ddots & & \\ & & & 0 & 1 & \\ -a_0 & -a_1 & -a_2 & \cdots & -a_{n-2} & -a_{n-1} \end{bmatrix} \begin{bmatrix} u(t) \\ \frac{\mathrm{d}u(t)}{\mathrm{d}t} \\ \vdots \\ \frac{\mathrm{d}^{n-1}u(t)}{\mathrm{d}t^{n-1}} \end{bmatrix}.$$

等式右边的矩阵恰是 $C(f)^{\mathrm{T}}$, 其中 $f(x) = x^n + a_{n-1}x^{n-1} + \cdots + a_1 x + a_0$.

练习 3.5

1. 试证：$C(f)$ 的特征多项式是 $f(x)$.
2. 试证：$C(f)$ 的最小多项式是 $f(x)$.[2]
3. 设 λ 是 $C(f)$ 的特征值，求 $C(f)$ 的属于 λ 的左特征向量.
4. 试证：$C(f)$ 可相似对角化当且仅当 $f(x)$ 无重根.

练习 3.6 $J_n(\lambda)$ 与 $J_n(\lambda)^{\mathrm{T}}$ 是否相似？A 与 A^{T} 是否相似？

例题 3.18.

若 $A = \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix}$, 则 $A^2 = 0$，故

$$\mathrm{e}^A = I + A = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}.$$

更一般的，

$$\mathrm{e}^{J_n(0)} = I_n + J_n(0) + \frac{1}{2!}J_n(0)^2 + \cdots + \frac{1}{(n-1)!}J_n(0)^{n-1} = \begin{bmatrix} 1 & 1 & \frac{1}{2!} & \cdots & \frac{1}{(n-2)!} & \frac{1}{(n-1)!} \\ & 1 & 1 & \cdots & \frac{1}{(n-3)!} & \frac{1}{(n-2)!} \\ & & 1 & \ddots & \vdots & \vdots \\ & & & \ddots & 1 & \frac{1}{2!} \\ & & & & 1 & 1 \\ & & & & & 1 \end{bmatrix}.$$

当 A 是幂零阵时，级数 e^A 变成了有限和.

[2]提示：考虑 $C(f)\boldsymbol{e}_1, C(f)^2\boldsymbol{e}_1, C(f)^3\boldsymbol{e}_1, \cdots$ 等等

例题 3.19.

设 $A=\begin{bmatrix}0&1\\1&0\end{bmatrix}$ 是沿着直线 $y=x$ 的反射矩阵，A 可相似对角化. 事实上，若令

$$P=\begin{bmatrix}1&1\\1&-1\end{bmatrix},\quad \Lambda=\begin{bmatrix}1&0\\0&-1\end{bmatrix},$$

则 $P^{-1}AP=\Lambda$，故

$$\mathrm{e}^{A}=P\mathrm{e}^{\Lambda}P^{-1}=\begin{bmatrix}1&1\\1&-1\end{bmatrix}\begin{bmatrix}\mathrm{e}&0\\0&\mathrm{e}^{-1}\end{bmatrix}\frac{1}{2}\begin{bmatrix}1&1\\1&-1\end{bmatrix}=\begin{bmatrix}\frac{\mathrm{e}+\mathrm{e}^{-1}}{2}&\frac{\mathrm{e}-\mathrm{e}^{-1}}{2}\\\frac{\mathrm{e}-\mathrm{e}^{-1}}{2}&\frac{\mathrm{e}+\mathrm{e}^{-1}}{2}\end{bmatrix}.$$

例题 3.20.

设 $A=\begin{bmatrix}0&-\theta\\\theta&0\end{bmatrix}$, $\theta\in\mathbb{R}$, 则

$$\begin{aligned}\mathrm{e}^{A}&=\begin{bmatrix}1&0\\0&1\end{bmatrix}+\begin{bmatrix}0&-\theta\\\theta&0\end{bmatrix}+\frac{1}{2!}\begin{bmatrix}-\theta^2&0\\0&-\theta^2\end{bmatrix}+\frac{1}{3!}\begin{bmatrix}0&\theta^3\\-\theta^3&0\end{bmatrix}+\cdots\\&=\begin{bmatrix}1-\frac{\theta^2}{2!}+\frac{\theta^4}{4!}-\cdots&-\theta+\frac{\theta^3}{3!}-\frac{\theta^5}{5!}+\cdots\\\theta-\frac{\theta^3}{3!}+\frac{\theta^5}{5!}-\cdots&1-\frac{\theta^2}{2!}+\frac{\theta^4}{4!}-\cdots\end{bmatrix}\\&=\begin{bmatrix}\cos\theta&-\sin\theta\\\sin\theta&\cos\theta\end{bmatrix}.\end{aligned}$$

或者，也可以把 A 相似对角化后再计算. 因 $A=P\Lambda P^{-1}$, 其中

$$P=\begin{bmatrix}1&1\\-\mathrm{i}&\mathrm{i}\end{bmatrix},\quad \Lambda=\begin{bmatrix}\mathrm{i}\theta&0\\0&-\mathrm{i}\theta\end{bmatrix},$$

故

$$\mathrm{e}^{A}=P\mathrm{e}^{\Lambda}P^{-1}=\begin{bmatrix}1&1\\-\mathrm{i}&\mathrm{i}\end{bmatrix}\begin{bmatrix}\mathrm{e}^{\mathrm{i}\theta}&0\\0&\mathrm{e}^{-\mathrm{i}\theta}\end{bmatrix}\frac{1}{2\mathrm{i}}\begin{bmatrix}\mathrm{i}&-1\\\mathrm{i}&1\end{bmatrix}=\begin{bmatrix}\cos\theta&-\sin\theta\\\sin\theta&\cos\theta\end{bmatrix}.$$

命题 3.2.7

设 $A,B\in M_n(\mathbb{C})$. 若 $AB=BA$，则 $\mathrm{e}^{A+B}=\mathrm{e}^{A}\mathrm{e}^{B}$.

证明 由 $AB=BA$ 得知

$$(A+B)^m=\sum_{k=0}^{m}\frac{m!}{k!(m-k)!}A^kB^{m-k},$$

故

$$\begin{aligned}\mathrm{e}^{A+B} &= \sum_{m=0}^{\infty}\frac{(A+B)^m}{m!}\\ &= \sum_{m=0}^{\infty}\sum_{k=0}^{m}\frac{A^k}{k!}\frac{B^{m-k}}{(m-k)!}\\ &= \left(\sum_{k=0}^{\infty}\frac{A^k}{k!}\right)\left(\sum_{\ell=0}^{\infty}\frac{B^\ell}{\ell!}\right)\\ &= \mathrm{e}^{A}\mathrm{e}^{B}.\end{aligned}$$

（倒数第二个等号成立的原因细节略）

例题 3.21.

$$\mathrm{e}^{J_n(\lambda)} = \mathrm{e}^{\lambda I_n + J_n(0)} = \mathrm{e}^{\lambda I_n}\mathrm{e}^{J_n(0)} = \mathrm{e}^{\lambda}\mathrm{e}^{J_n(0)} = \begin{bmatrix} \mathrm{e}^{\lambda} & \mathrm{e}^{\lambda} & \frac{\mathrm{e}^{\lambda}}{2!} & \cdots & \frac{\mathrm{e}^{\lambda}}{(n-2)!} & \frac{\mathrm{e}^{\lambda}}{(n-1)!} \\ & \mathrm{e}^{\lambda} & \mathrm{e}^{\lambda} & \cdots & \frac{\mathrm{e}^{\lambda}}{(n-3)!} & \frac{\mathrm{e}^{\lambda}}{(n-2)!} \\ & & \mathrm{e}^{\lambda} & \ddots & \vdots & \vdots \\ & & & \ddots & \mathrm{e}^{\lambda} & \frac{\mathrm{e}^{\lambda}}{2!} \\ & & & & \mathrm{e}^{\lambda} & \mathrm{e}^{\lambda} \\ & & & & & \mathrm{e}^{\lambda} \end{bmatrix}.$$

例题 3.22.

命题3.2.7中 $AB = BA$ 的条件不可去掉. 比如，$A = \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix}$，$B = \begin{bmatrix} 0 & 0 \\ 1 & 0 \end{bmatrix}$，

$$AB = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix} \neq \begin{bmatrix} 0 & 0 \\ 0 & 1 \end{bmatrix} = BA, \quad A + B = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix},$$

此时

$$\begin{aligned}\mathrm{e}^{A+B} &= \begin{bmatrix} \frac{\mathrm{e}+\mathrm{e}^{-1}}{2} & \frac{\mathrm{e}-\mathrm{e}^{-1}}{2} \\ \frac{\mathrm{e}-\mathrm{e}^{-1}}{2} & \frac{\mathrm{e}+\mathrm{e}^{-1}}{2} \end{bmatrix},\\ \mathrm{e}^{A}\mathrm{e}^{B} &= \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}\begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix} = \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix}.\end{aligned}$$

命题 3.2.8

设 $A \in M_n(\mathbb{C})$，A 的特征值是 $\lambda_1, \cdots, \lambda_n$，则 e^A 的特征值是 $\mathrm{e}^{\lambda_1}, \cdots, \mathrm{e}^{\lambda_n}$. 特别的

$$\det(\mathrm{e}^A) = \mathrm{e}^{\mathrm{tr}(A)}.$$

♠

证明 由 Schur 定理知，存在可逆阵 P 使得 $A = PUP^{-1}$, 其中

$$U = \begin{bmatrix} \lambda_1 & & * \\ & \ddots & \\ & & \lambda_n \end{bmatrix}.$$

易见

$$\mathrm{e}^{U}=\begin{bmatrix}\mathrm{e}^{\lambda_1} & & * \\ & \ddots & \\ & & \mathrm{e}^{\lambda_n}\end{bmatrix},$$

于是 $\mathrm{e}^{A}=P\mathrm{e}^{U}P^{-1}$ 与 e^{U} 有相同的特征值 $\mathrm{e}^{\lambda_1},\cdots,\mathrm{e}^{\lambda_n}$. 最后

$$\det(\mathrm{e}^{A})=\mathrm{e}^{\lambda_1}\cdots\mathrm{e}^{\lambda_n}=\mathrm{e}^{\lambda_1+\cdots+\lambda_n}=e^{\mathrm{tr}(A)}.$$

练习 3.7

1. 设 $A\in \mathrm{U}(n)$，即 A 是 n 阶酉阵，试证：存在 n 阶斜厄米特阵 B 使得 $A=\mathrm{e}^{B}$.
2. 设 $A\in \mathrm{SO}(n)$，即 A 是 n 阶实正交阵且 $\det A=1$, 试证：存在 n 阶实反对称阵 B 使得 $A=\mathrm{e}^{B}$.

命题 3.2.9

设 $A\in M_n(\mathbb{C})$，$P^{-1}AP=J$，$J=\mathrm{diag}\left(J_{k_1}(\lambda_1),\cdots,J_{k_m}(\lambda_m)\right)$，则

$$\mathrm{e}^{A}=P\mathrm{e}^{J}P^{-1},$$

其中 $\mathrm{e}^{J}=\mathrm{diag}\left(\mathrm{e}^{J_{k_1}(\lambda_1)},\cdots,\mathrm{e}^{J_{k_m}(\lambda_m)}\right)$,

$$\mathrm{e}^{J_{k_j}(\lambda_j)}=\begin{bmatrix}\mathrm{e}^{\lambda_j} & \mathrm{e}^{\lambda_j} & \frac{\mathrm{e}^{\lambda_j}}{2!} & \cdots & \frac{\mathrm{e}^{\lambda_j}}{(k_j-2)!} & \frac{\mathrm{e}^{\lambda_j}}{(k_j-1)!}\\ & \mathrm{e}^{\lambda_j} & \mathrm{e}^{\lambda_j} & \cdots & \frac{\mathrm{e}^{\lambda_j}}{(k_j-3)!} & \frac{\mathrm{e}^{\lambda_j}}{(k_j-2)!}\\ & & \mathrm{e}^{\lambda_j} & \ddots & \vdots & \vdots\\ & & & \ddots & \mathrm{e}^{\lambda_j} & \frac{\mathrm{e}^{\lambda_j}}{2!}\\ & & & & \mathrm{e}^{\lambda_j} & \mathrm{e}^{\lambda_j}\\ & & & & & \mathrm{e}^{\lambda_j}\end{bmatrix}.$$

定义 3.2.3

设 $A=\left[a_{ij}\right]\in M_n(\mathbb{R})$，$u(t)=\begin{bmatrix}u_1(t) & \cdots & u_n(t)\end{bmatrix}^{\mathrm{T}}$ 是由 n 个未知函数构成的向量，则

$$\frac{\mathrm{d}u(t)}{\mathrm{d}t}=Au(t) \tag{3.6}$$

称为一阶常系数线性齐次微分方程组. 它等价于

$$\frac{\mathrm{d}u_i(t)}{\mathrm{d}t}=\sum_{j=1}^{n}a_{ij}u_j(t),\quad 1\le i\le n.$$

“一阶”指方程只包含函数 $u_i(t)$ 和它们的一阶导数，而不包含二阶或更高阶导数.“常系数”指 A 中的元素是常数，而不是 t 的函数，比如 $u'(t)+tu(t)=0$ 不是常系数微分方程.“线性”指 $\frac{\mathrm{d}}{\mathrm{d}t}-A$ 是线性微分算子，即它作用在函数上保加法和保常数乘.“齐次”指 $\frac{\mathrm{d}u(t)}{\mathrm{d}t}-Au(t)=0$ 的右边是 0，而不是某个非零函数 $f(t)$.

注 3.2.2

齐次线性微分方程的所有解构成一个线性空间.

例题 3.23.

$$\frac{\mathrm{d}}{\mathrm{d}t}\begin{bmatrix}u_1(t)\\ u_2(t)\end{bmatrix}=\begin{bmatrix}0 & 1\\ -1 & 0\end{bmatrix}\begin{bmatrix}u_1(t)\\ u_2(t)\end{bmatrix}$$

或

$$\begin{cases} \dfrac{\mathrm{d}u_1}{\mathrm{d}t} = u_2 \\ \dfrac{\mathrm{d}u_2}{\mathrm{d}t} = -u_1 \end{cases}.$$

易见 $\begin{bmatrix} \sin t \\ \cos t \end{bmatrix}, \begin{bmatrix} \cos t \\ -\sin t \end{bmatrix}$ 是解，故它们的任意线性组合 $\begin{bmatrix} c_1 \sin t + c_2 \cos t \\ c_1 \cos t - c_2 \sin t \end{bmatrix}$ 仍是解.

例题 3.24.

$$\frac{\mathrm{d}}{\mathrm{d}t}\begin{bmatrix} u_1(t) \\ u_2(t) \end{bmatrix} = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}\begin{bmatrix} u_1(t) \\ u_2(t) \end{bmatrix}$$

或

$$\begin{cases} \dfrac{\mathrm{d}u_1}{\mathrm{d}t} = u_2 \\ \dfrac{\mathrm{d}u_2}{\mathrm{d}t} = u_1 \end{cases}.$$

易见 $\begin{bmatrix} \mathrm{e}^{t} \\ \mathrm{e}^{t} \end{bmatrix}, \begin{bmatrix} \mathrm{e}^{-t} \\ -\mathrm{e}^{-t} \end{bmatrix}$ 是解，故它们的任意线性组合 $\begin{bmatrix} c_1\mathrm{e}^{t} + c_2\mathrm{e}^{-t} \\ c_1\mathrm{e}^{t} - c_2\mathrm{e}^{-t} \end{bmatrix}$ 仍是解.

在上例中，$\begin{bmatrix} \mathrm{e}^{t} \\ \mathrm{e}^{t} \end{bmatrix} = \mathrm{e}^{t}\begin{bmatrix} 1 \\ 1 \end{bmatrix}$，而 $\begin{bmatrix} 1 \\ 1 \end{bmatrix}$ 正是矩阵 $A = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$ 的属于特征值 1 的特征向量. 类似的，$\begin{bmatrix} \mathrm{e}^{-t} \\ -\mathrm{e}^{-t} \end{bmatrix} = \mathrm{e}^{-t}\begin{bmatrix} 1 \\ -1 \end{bmatrix}$，其中 $\begin{bmatrix} 1 \\ -1 \end{bmatrix}$ 是 A 的属于 -1 的特征向量.

一般的，若 z 是 A 的属于特征值 λ 的特征向量，则 $\mathrm{e}^{\lambda t}z$ 是 $\frac{\mathrm{d}u}{\mathrm{d}t} = Au$ 的解. 这是因为

$$\frac{\mathrm{d}}{\mathrm{d}t}\mathrm{e}^{\lambda t}z = \lambda\mathrm{e}^{\lambda t}z = A\mathrm{e}^{\lambda t}z = \mathrm{e}^{\lambda t}Az = \mathrm{e}^{\lambda t}\lambda z.$$

若 λ, z 分别是 A 的复特征值和复特征向量，则 $\mathrm{e}^{\lambda t}z$ 的实部和虚部均是 $\frac{\mathrm{d}u}{\mathrm{d}t} = Au$ 的解. 比如，在例3.2中，系数矩阵 A 有两复特征值 $\mathrm{i}, -\mathrm{i}$，对应的复特征向量分别是 $\begin{bmatrix} 1 \\ \mathrm{i} \end{bmatrix}$ 和 $\begin{bmatrix} 1 \\ -\mathrm{i} \end{bmatrix}$，而

$$\mathrm{e}^{\mathrm{i}t}\begin{bmatrix} 1 \\ \mathrm{i} \end{bmatrix} = \begin{bmatrix} \cos t + \mathrm{i}\sin t \\ -\sin t + \mathrm{i}\cos t \end{bmatrix},$$

的实部与虚部正是 $\begin{bmatrix} \cos t \\ -\sin t \end{bmatrix}, \begin{bmatrix} \sin t \\ \cos t \end{bmatrix}$.

命题 3.2.10

设 $A \in M_n(\mathbb{R})$, A 在复数域上可相似对角化，$z_1, \cdots, z_n$ 是 A 的 n 个（复）线性无关的复特征向量，特征值分别是 $\lambda_1, \cdots, \lambda_n$, 则

$$\begin{cases} \dfrac{\mathrm{d}u}{\mathrm{d}t} = Au \\ u(0) = u_0 \quad (u_0 \in \mathbb{R}^n) \end{cases} \tag{3.7}$$

的解是

$$c_1 e^{\lambda_1 t} z_1 + \cdots + c_n e^{\lambda_n t} z_n$$

其中 $(c_1, \cdots, c_n)$ 是 u_0 在 $z_1, \cdots, z_n$ 下的坐标.

证明　因(3.6)式是线性齐次微分方程组且 $e^{\lambda_1 t} z_1, \cdots, e^{\lambda_n t} z_n$ 都是(3.6)式的解，故它们的线性组合 $c_1 e^{\lambda_1 t} z_1 + \cdots + c_n e^{\lambda_n t} z_n$ 仍是(3.6)式的解. 还需验证初始条件. 当 $t = 0$ 时，$c_1 e^{\lambda_1 t} z_1 + \cdots + c_n e^{\lambda_n t} z_n$ 等于 $c_1 z_1 + \cdots + c_n z_n$，正是 u_0.

例题 3.25.

求解 $\dfrac{\mathrm{d}u}{\mathrm{d}t} = Au$, 其中 $A = \begin{bmatrix} 1 & 1 \\ 0 & 2 \end{bmatrix}$, 初始值是 $u(0) = \begin{bmatrix} 3 \\ 4 \end{bmatrix}$.

解. 显然 A 可对角化，特征值 1 的特征向量是 $\begin{bmatrix} 1 \\ 0 \end{bmatrix}$, 特征值 2 的特征向量是 $\begin{bmatrix} 1 \\ 1 \end{bmatrix}$, 它们给出的线性微分方程组的解分别是 $e^t \begin{bmatrix} 1 \\ 0 \end{bmatrix}$ 和 $e^{2t} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$.

用特征向量表示 $u(0)$ 是

$$\begin{bmatrix} 3 \\ 4 \end{bmatrix} = (-1) \begin{bmatrix} 1 \\ 0 \end{bmatrix} + 4 \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

故原问题的解是

$$(-1) e^t \begin{bmatrix} 1 \\ 0 \end{bmatrix} + 4 e^{2t} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} -e^t + 4e^{2t} \\ 4e^{2t} \end{bmatrix}.$$

当 A 不可对角化时，我们该如何求解(3.7)? 虽然 A 的特征值-特征向量组合 (λ, z) 仍然给出(3.6)的解 $e^{\lambda t} z$，但因 A 不可对角化，我们找不到 n 个线性无关的 A 的特征向量，故给定的初始值 $u(0)$ 不一定可以用 A 的现有的特征向量线性表示. 幸运的是，由 A 的 Jordan 标准型知，我们可找到 n 个线性无关的向量 $z_1, \cdots, z_n$ 使得它们是若干个 A 的 Jordan 链的并. 下面我们看如何从 A 的 Jordan 链构造出更多的(3.6)的解.

注 3.2.3

本小节的线性微分方程组在给定初始条件下都有唯一解，我们不在本课程讨论/证明解的唯一性.

命题 3.2.11

设 $\alpha_1, \alpha_2, \cdots, \alpha_m$ 是 A 的属于特征值 λ 的长度为 m 的 Jordan 链，即

$$\begin{aligned} A\alpha_1 &= \lambda \alpha_1 \\ A\alpha_2 &= \lambda \alpha_2 + \alpha_1 \\ &\vdots \\ A\alpha_m &= \lambda \alpha_m + \alpha_{m-1}, \end{aligned}$$

则

$$\frac{t^{m-1}}{(m-1)!} e^{\lambda t} \alpha_1 + \frac{t^{m-2}}{(m-2)!} e^{\lambda t} \alpha_2 + \cdots + t e^{\lambda t} \alpha_{m-1} + e^{\lambda t} \alpha_m \tag{3.8}$$

是 $\frac{\mathrm{d}u}{\mathrm{d}t} = Au$ 的解，其初始值是 α_m.

证明　记 $f_\ell(t) = \frac{t^\ell}{\ell!} e^{\lambda t}$，$u(t) = f_{m-1}(t)\alpha_1 + f_{m-2}(t)\alpha_2 + \cdots + f_1(t)\alpha_{m-1} + f_0(t)\alpha_m$.

直接计算得

$$\frac{\mathrm{d}f_\ell}{\mathrm{d}t}=\frac{\mathrm{d}}{\mathrm{d}t}\left(\frac{t^\ell}{\ell!}\mathrm{e}^{\lambda t}\right)=\frac{t^{\ell-1}}{(\ell-1)!}\mathrm{e}^{\lambda t}+\frac{t^\ell}{\ell!}\lambda\mathrm{e}^{\lambda t}=f_{\ell-1}+\lambda f_\ell$$

（规定 $f_{-1}=0$），故

$$\begin{aligned}\frac{\mathrm{d}u}{\mathrm{d}t}&=\frac{\mathrm{d}f_{m-1}}{\mathrm{d}t}\boldsymbol{\alpha}_1+\frac{\mathrm{d}f_{m-2}}{\mathrm{d}t}\boldsymbol{\alpha}_2+\cdots+\frac{\mathrm{d}f_1}{\mathrm{d}t}\boldsymbol{\alpha}_{m-1}+\frac{\mathrm{d}f_0}{\mathrm{d}t}\boldsymbol{\alpha}_m\\&=(\lambda f_{m-1}+f_{m-2})\boldsymbol{\alpha}_1+(\lambda f_{m-2}+f_{m-3})\boldsymbol{\alpha}_2+\cdots+(\lambda f_1+f_0)\boldsymbol{\alpha}_{m-1}+\lambda f_0\boldsymbol{\alpha}_m\\&=f_{m-1}\lambda\boldsymbol{\alpha}_1+f_{m-2}(\boldsymbol{\alpha}_1+\lambda\boldsymbol{\alpha}_2)+\cdots+f_1(\boldsymbol{\alpha}_{m-2}+\lambda\boldsymbol{\alpha}_{m-1})+f_0(\boldsymbol{\alpha}_{m-1}+\lambda\boldsymbol{\alpha}_m)\\&=f_{m-1}A\boldsymbol{\alpha}_1+f_{m-2}A\boldsymbol{\alpha}_2+\cdots+f_1A\boldsymbol{\alpha}_{m-1}+f_0A\boldsymbol{\alpha}_m\\&=A(f_{m-1}\boldsymbol{\alpha}_1+f_{m-2}\boldsymbol{\alpha}_2+\cdots+f_1\boldsymbol{\alpha}_{m-1}+f_0\boldsymbol{\alpha}_m)\\&=Au.\end{aligned}$$

又因 $f_{m-1}(0)=\cdots=f_1(0)=0, f_0(0)=1$, 故 $u(0)=\boldsymbol{\alpha}_m$.

命题 3.2.12

设 $P^{-1}AP=J$, 其中 J 是 A 的 Jordan 标准型, P 的列记为 $z_1,\cdots,z_n$, 则存在 u_k 使得 $\frac{\mathrm{d}u_k}{\mathrm{d}t}=Au_k$ 且 $u_k(0)=z_k$. 事实上，u_k 可由 $z_1,\cdots,z_n$ 和函数 $\frac{t^\ell}{\ell!}\mathrm{e}^{\lambda t}$ 表示，具体公式见(3.8). 一般的，(3.7)的解是 $c_1u_1+\cdots+c_nu_n$，其中 $(c_1,\cdots,c_n)$ 是 $u(0)$ 在 $z_1,\cdots,z_n$ 下的坐标.

例题 3.26.

求解 $\frac{\mathrm{d}u}{\mathrm{d}t}=Au$, 其中

$$A=\begin{bmatrix}1&1&1\\0&1&1\\0&0&1\end{bmatrix},\quad u(0)=\begin{bmatrix}1\\2\\1\end{bmatrix}.$$

解. A 有唯一特征值 1 且因 $r(A-I)=2, \dim N(A-I)=1$，A 有且仅有一个 Jordan 块 $J_3(1)$.

观察知 $(A-I)\boldsymbol{e}_1=0, (A-I)\boldsymbol{e}_2=\boldsymbol{e}_1, (A-I)\boldsymbol{e}_3=\boldsymbol{e}_1+\boldsymbol{e}_2$，故

$$\boldsymbol{e}_3\xrightarrow{A-I}\boldsymbol{e}_1+\boldsymbol{e}_2\xrightarrow{A-I}\boldsymbol{e}_1,$$

即 $\boldsymbol{e}_1,\boldsymbol{e}_1+\boldsymbol{e}_2,\boldsymbol{e}_3$ 是属于特征值 1 的 Jordan 链.

运用命题3.2.11得到 $\frac{\mathrm{d}u}{\mathrm{d}t}=Au$ 的如下解

(i) $\mathrm{e}^t\begin{bmatrix}1\\0\\0\end{bmatrix}=\begin{bmatrix}\mathrm{e}^t\\0\\0\end{bmatrix}$，初始值是 $\begin{bmatrix}1\\0\\0\end{bmatrix}$.

(ii) $t\mathrm{e}^t\begin{bmatrix}1\\0\\0\end{bmatrix}+\mathrm{e}^t\begin{bmatrix}1\\1\\0\end{bmatrix}=\begin{bmatrix}t\mathrm{e}^t+\mathrm{e}^t\\\mathrm{e}^t\\0\end{bmatrix}$，初始值是 $\begin{bmatrix}1\\1\\0\end{bmatrix}$.

(iii) $\frac{t^2}{2!}\mathrm{e}^t\begin{bmatrix}1\\0\\0\end{bmatrix}+t\mathrm{e}^t\begin{bmatrix}1\\1\\0\end{bmatrix}+\mathrm{e}^t\begin{bmatrix}0\\0\\1\end{bmatrix}=\begin{bmatrix}\frac{t^2}{2}\mathrm{e}^t+t\mathrm{e}^t\\t\mathrm{e}^t\\\mathrm{e}^t\end{bmatrix}$，初始值是 $\begin{bmatrix}0\\0\\1\end{bmatrix}$.

因 $\begin{bmatrix}1\\2\\1\end{bmatrix} = (-1)\begin{bmatrix}1\\0\\0\end{bmatrix} + 2\begin{bmatrix}1\\1\\0\end{bmatrix} + 1\begin{bmatrix}0\\0\\1\end{bmatrix}$，故要求的解是

$$-\begin{bmatrix}\mathrm{e}^t\\0\\0\end{bmatrix} + 2\begin{bmatrix}t\mathrm{e}^t + \mathrm{e}^t\\ \mathrm{e}^t\\0\end{bmatrix} + 1\begin{bmatrix}\frac{t^2}{2}\mathrm{e}^t + t\mathrm{e}^t\\ t\mathrm{e}^t\\ \mathrm{e}^t\end{bmatrix} = \begin{bmatrix}\frac{t^2}{2}\mathrm{e}^t + 3t\mathrm{e}^t + \mathrm{e}^t\\ t\mathrm{e}^t + 2\mathrm{e}^t\\ \mathrm{e}^t\end{bmatrix}.$$

事实上，(3.7)的解可以用矩阵的指数表示.

命题 3.2.13

设 $A \in M_n(\mathbb{R})$, 则满足 $\dfrac{\mathrm{d}u}{\mathrm{d}t} = Au$ 且初始值是 $u(0)$ 的解是 $\mathrm{e}^{At}u(0)$.

证明　因

$$\mathrm{e}^{At} = I + At + \frac{A^2t^2}{2!} + \cdots + \frac{A^mt^m}{m!} + \cdots,$$

故

$$\begin{aligned}\frac{\mathrm{d}}{\mathrm{d}t}\mathrm{e}^{At} &= A + A^2t + \cdots + \frac{A^mt^{m-1}}{(m-1)!} + \cdots\\ &= A\left(I + At + \cdots + \frac{A^{m-1}t^{m-1}}{(m-1)!} + \cdots\right)\\ &= A\mathrm{e}^{At}.\end{aligned}$$

注意，e^{At} 是矩阵，它的元素是 t 的（级数）函数，对 e^{At} 求导是对它的元素逐个求导. 我们也不进一步说明为何求导和无穷求和可交换. 上式说明 e^{At} 的每一列均是 $\dfrac{\mathrm{d}u}{\mathrm{d}t} = Au$ 的解，故它们的线性组合 $\mathrm{e}^{At}u(0)$ 也是 $\dfrac{\mathrm{d}u}{\mathrm{d}t} = Au$ 的解，且

$$(\mathrm{e}^{At}u(0))|_{t=0} = \mathrm{e}^{At}|_{t=0}u(0) = I_nu(0) = u(0).$$

注 3.2.4

下面我们解释命题3.2.11，命题3.2.12，和命题3.2.13之间的联系.

当 A 可对角化时，A 有 n 个线性无关的特征向量 $z_1,\cdots,z_n$，特征值分别是 $\lambda_1,\cdots,\lambda_n$. 若令 $P = \begin{bmatrix}z_1 & \cdots & z_n\end{bmatrix}$，则 P 可逆且 $P^{-1}AP = \Lambda = \mathrm{diag}(\lambda_1,\cdots,\lambda_n)$，此时 Λ 就是 A 的 Jordan 标准型. 于是

$$\begin{aligned}\mathrm{e}^{At} &= \mathrm{e}^{P\Lambda P^{-1}t} = P\mathrm{e}^{\Lambda t}P^{-1} = P\,\mathrm{diag}(\mathrm{e}^{\lambda_1 t},\cdots,\mathrm{e}^{\lambda_n t})P^{-1}\\ \mathrm{e}^{At}u(0) &= P\,\mathrm{diag}(\mathrm{e}^{\lambda_1 t},\cdots,\mathrm{e}^{\lambda_n t})P^{-1}u(0)\\ &= \begin{bmatrix}z_1 & \cdots & z_n\end{bmatrix}\begin{bmatrix}\mathrm{e}^{\lambda_1 t} & & \\ & \ddots & \\ & & \mathrm{e}^{\lambda_n t}\end{bmatrix}P^{-1}u(0)\\ &= \begin{bmatrix}\mathrm{e}^{\lambda_1 t}z_1 & \cdots & \mathrm{e}^{\lambda_n t}z_n\end{bmatrix}P^{-1}u(0)\\ &= \begin{bmatrix}\mathrm{e}^{\lambda_1 t}z_1 & \cdots & \mathrm{e}^{\lambda_n t}z_n\end{bmatrix}\begin{bmatrix}c_1\\ \vdots\\ c_n\end{bmatrix}\\ &= c_1\mathrm{e}^{\lambda_1 t}z_1 + \cdots + c_n\mathrm{e}^{\lambda_n t}z_n\end{aligned}$$

其中记 $P^{-1}u(0)=(c_1,\cdots,c_n)$. 因

$$u(0)=PP^{-1}u(0)=\begin{bmatrix}z_1 & \cdots & z_n\end{bmatrix}\begin{bmatrix}c_1\\ \vdots\\ c_n\end{bmatrix}=c_1z_1+\cdots+c_nz_n,$$

故 $(c_1,\cdots,c_n)$ 就是 $u(0)$ 在 $z_1,\cdots,z_n$ 下的坐标. 这说明当 A 可对角化时, 命题3.2.13的结论和命题3.2.11的结论一致.

一般的情形也可以通过类似的方法说明. 不妨设 $P^{-1}AP=J$, 其中

$$J=\operatorname{diag}(J_{k_1}(\lambda_1),\cdots,J_{k_m}(\lambda_m))$$

是 A 的 Jordan 标准型, 则

$$\mathrm{e}^{At}=\mathrm{e}^{PJP^{-1}t}=P\mathrm{e}^{Jt}P^{-1}=P\begin{bmatrix}\mathrm{e}^{J_{k_1}(\lambda_1)t} & & \\ & \ddots & \\ & & \mathrm{e}^{J_{k_m}(\lambda_m)t}\end{bmatrix}P^{-1},$$

其中

$$\begin{aligned}\mathrm{e}^{J_{k_j}(\lambda_j)t}&=\mathrm{e}^{\lambda_jtI+J_{k_j}(0)t}=\mathrm{e}^{\lambda_jt}\mathrm{e}^{J_{k_j}(0)t}\\&=\mathrm{e}^{\lambda_jt}\left(I+J_{k_j}(0)t+\frac{t^2}{2!}J_{k_j}(0)^2+\cdots+\frac{t^{k_j-1}}{(k_j-1)!}J_{k_j}(0)^{k_j-1}\right)\\&=e^{\lambda_jt}\begin{bmatrix}1 & t & \frac{t^2}{2!} & \cdots & \frac{t^{k_j-2}}{(k_j-2)!} & \frac{t^{k_j-1}}{(k_j-1)!}\\ & 1 & t & \cdots & \frac{t^{k_j-3}}{(k_j-3)!} & \frac{t^{k_j-2}}{(k_j-2)!}\\ & & 1 & \ddots & \vdots & \vdots\\ & & & \ddots & t & \frac{t^2}{2!}\\ & & & & 1 & t\\ & & & & & 1\end{bmatrix}\\&=\begin{bmatrix}\mathrm{e}^{\lambda_jt} & t\mathrm{e}^{\lambda_jt} & \frac{t^2}{2!}\mathrm{e}^{\lambda_jt} & \cdots & \frac{t^{k_j-2}}{(k_j-2)!}\mathrm{e}^{\lambda_jt} & \frac{t^{k_j-1}}{(k_j-1)!}\mathrm{e}^{\lambda_jt}\\ & e^{\lambda_jt} & t\mathrm{e}^{\lambda_jt} & \cdots & \frac{t^{k_j-3}}{(k_j-3)!}\mathrm{e}^{\lambda_jt} & \frac{t^{k_j-2}}{(k_j-2)!}\mathrm{e}^{\lambda_jt}\\ & & \mathrm{e}^{\lambda_jt} & \ddots & \vdots & \vdots\\ & & & \ddots & t\mathrm{e}^{\lambda_jt} & \frac{t^2}{2!}\mathrm{e}^{\lambda_jt}\\ & & & & \mathrm{e}^{\lambda_jt} & t\mathrm{e}^{\lambda_jt}\\ & & & & & \mathrm{e}^{\lambda_jt}\end{bmatrix}.\end{aligned}$$

最后整理 $\mathrm{e}^{At}u(0)=P\operatorname{diag}(\mathrm{e}^{J_{k_1}(\lambda_1)t},\cdots,\mathrm{e}^{J_{k_m}(\lambda_m)t})P^{-1}u(0)$ 就回到了命题 57 的结论.

设 $a_{n-1},\cdots,a_1,a_0\in\mathbb{R}$, 则关于 $u(t)$ 的 n 阶常系数线性齐次常微分方程

$$u^{(n)}(t)+a_{n-1}u^{(n-1)}(t)+\cdots+a_1u'(t)+a_0u(t)=0 \tag{3.9}$$

可转化为关于 $\begin{bmatrix} u(t) \\ u'(t) \\ \cdots \\ u^{(n-1)}(t) \end{bmatrix}$ 的一阶常系数线性齐次微分方程组

$$\frac{\mathrm{d}}{\mathrm{d}t}\begin{bmatrix} u(t) \\ u'(t) \\ u''(t) \\ \vdots \\ u^{(n-2)}(t) \\ u^{(n-1)}(t) \end{bmatrix} = \begin{bmatrix} 0 & 1 & & & & \\ & 0 & 1 & & & \\ & & \ddots & \ddots & & \\ & & & 0 & 1 & \\ & & & & 0 & 1 \\ -a_0 & -a_1 & -a_2 & \cdots & -a_{n-2} & -a_{n-1} \end{bmatrix}\begin{bmatrix} u(t) \\ u'(t) \\ u''(t) \\ \vdots \\ u^{(n-2)}(t) \\ u^{(n-1)}(t) \end{bmatrix},$$

故我们可用上面讨论的方法求解方程(3.9).

命题 3.2.14

记 $f(x) = x^n + a_{n-1}x^{n-1} + \cdots + a_1x + a_0 \in \mathbb{R}[x]$. 不妨设

$$f(x) = (x-\lambda_1)^{m_1}\cdots(x-\lambda_k)^{m_k}$$

其中 $\lambda_1, \cdots, \lambda_k$ 两两互异，且 $m_1, \cdots, m_k \geq 1$，则

$$u^{(n)}(t) + a_{n-1}u^{(n-1)}(t) + \cdots + a_1u'(t) + a_0u(t) = 0$$

的通解是下面函数的线性组合

$$\mathrm{e}^{\lambda_1 t}, t\mathrm{e}^{\lambda_1 t}, \cdots, t^{m_1-1}\mathrm{e}^{\lambda_1 t},$$
$$\cdots$$
$$\mathrm{e}^{\lambda_k t}, t\mathrm{e}^{\lambda_k t}, \cdots, t^{m_k-1}\mathrm{e}^{\lambda_k t}.$$

若某个 λ_j 是复数 $a+bi(b\neq 0)$，则它的共轭 $a-bi$ 也是 $f(x)$ 的根，且它们的重数相等，不妨记为 m，此时函数组 $t^j\mathrm{e}^{(a+bi)t}, t^j\mathrm{e}^{(a-bi)t}, 0 \leq j \leq m-1$ 用它们的实部和虚部代替

$$\mathrm{e}^{at}\cos(bt), t\mathrm{e}^{at}\cos(bt), \cdots, t^{m-1}\mathrm{e}^{at}\cos(bt),$$
$$\mathrm{e}^{at}\sin(bt), t\mathrm{e}^{at}\sin(bt), \cdots, t^{m-1}\mathrm{e}^{at}\sin(bt).$$

♠

证明 记 $D = \frac{\mathrm{d}}{\mathrm{d}t}$, D 在函数上的作用就是求导，比如 $Du = u', D^2u = D(Du) = D(u') = u''$ 等，一般的 $D^ku(t) = u^{(k)}(t)$. 令

$$L = D^n + a_{n-1}D^{n-1} + \cdots + a_1D + a_0$$

则(3.9)等价于 $Lu = 0$. 又因 $f(x) = (x-\lambda_1)^{m_1}\cdots(x-\lambda_k)^{m_k}$, 故

$$L = (D-\lambda_1)^{m_1}\cdots(D-\lambda_k)^{m_k}.$$

已知 $(D-\lambda)\mathrm{e}^{\lambda t} = 0, (D-\lambda)t\mathrm{e}^{\lambda t} = \mathrm{e}^{\lambda t}, (D-\lambda)t^2\mathrm{e}^{\lambda t} = 2t\mathrm{e}^{\lambda t}$，等等，故 $(D-\lambda)^k(t^{k-1}\mathrm{e}^{\lambda t}) = 0$, 于是

$$(D-\lambda_j)^{m_j}(\mathrm{e}^{\lambda_j t}) = (D-\lambda_j)^{m_j}(t\mathrm{e}^{\lambda_j t}) = \cdots = (D-\lambda_j)^{m_j}(t^{m_j-1}\mathrm{e}^{\lambda_j t}) = 0,$$

故 $\mathrm{e}^{\lambda_j t}, t\mathrm{e}^{\lambda_j t}, \cdots, t^{m_j-1}\mathrm{e}^{\lambda_j t}$ 均是 $Lu = 0$ 的解.

当 λ_j 是复非实数时，因微分算子 L 是定义在实数域上的，故 $\mathrm{e}^{\lambda_j t}, t\mathrm{e}^{\lambda_j t}, \cdots, t^{m_j-1}\mathrm{e}^{\lambda_j t}$ 的实部和虚部也是 $Lu = 0$ 的解. 我们不在这里证明由 $f(x)$ 的根 $\lambda_1, \cdots, \lambda_k$ 给出的这些解张成 $Lu = 0$ 的解空间.

例题 3.27.

求 $u''(t) - 2u'(t) + u(t) = 0$ 的通解和满足初始条件 $u(0) = 2, u'(0) = 3$ 的解.

解. 解法 **1**：特征方程 $\lambda^2-2\lambda+1=0$ 有唯一解 $\lambda=1$，重数为 2，故由命题 59 知，通解为

$$u(t)=c_1\mathrm{e}^t+c_2t\mathrm{e}^t.$$

代入 $t=0$ 得 $u(0)=c_1$，求导得 $u'(t)=c_1\mathrm{e}^t+c_2\mathrm{e}^t+c_2t\mathrm{e}^t$，故还有 $u'(0)=c_1+c_2$.

显然，线性方程组

$$\begin{cases}c_1=2\\ c_1+c_2=3\end{cases}$$

的解是 $(c_1,c_2)=(2,1)$，故在给定初始条件下的解是

$$2\mathrm{e}^t+t\mathrm{e}^t.$$

解法 **2**：把问题转化为 $(u(t),u'(t))$ 满足的方程

$$\frac{\mathrm{d}}{\mathrm{d}t}\begin{bmatrix}u(t)\\ u'(t)\end{bmatrix}=\begin{bmatrix}u'(t)\\ u''(t)\end{bmatrix}=\begin{bmatrix}u'(t)\\ 2u'(t)-u(t)\end{bmatrix}=\begin{bmatrix}0&1\\ -1&2\end{bmatrix}\begin{bmatrix}u(t)\\ u'(t)\end{bmatrix}.$$

$A=\begin{bmatrix}0&1\\ -1&2\end{bmatrix}$ 的特征多项式是 $\lambda^2-\operatorname{tr}(A)\lambda+\det A=\lambda^2-2\lambda+1$.

因 $A-I=\begin{bmatrix}-1&1\\ -1&1\end{bmatrix}$，故 $N(A-I)=\operatorname{Span}\begin{bmatrix}1\\ 1\end{bmatrix}$. 令 $\boldsymbol{\alpha}_1=\begin{bmatrix}1\\ 1\end{bmatrix}$，满足 $(A-I)\boldsymbol{\alpha}_2=\boldsymbol{\alpha}_1$ 的向量有 $\boldsymbol{\alpha}_2=\begin{bmatrix}0\\ 1\end{bmatrix}$.

方程组 $\frac{\mathrm{d}u}{\mathrm{d}t}=Au$ 有如下解

$$u_1(t)=\mathrm{e}^t\boldsymbol{\alpha}_1=\begin{bmatrix}\mathrm{e}^t\\ \mathrm{e}^t\end{bmatrix}$$

$$u_2(t)=t\mathrm{e}^t\boldsymbol{\alpha}_1+\mathrm{e}^t\boldsymbol{\alpha}_2=\begin{bmatrix}t\mathrm{e}^t\\ t\mathrm{e}^t+\mathrm{e}^t\end{bmatrix}$$

通解是

$$c_1u_1(t)+c_2u_2(t)=\begin{bmatrix}c_1\mathrm{e}^t+c_2t\mathrm{e}^t\\ (c_1+c_2)\mathrm{e}^t+c_2t\mathrm{e}^t\end{bmatrix}$$

其中第一个分量 $c_1\mathrm{e}^t+c_2t\mathrm{e}^t$ 是原二次线性齐次常微分方程 $u''-2u'+u=0$ 的通解.

因为

$$u_1(0)=\boldsymbol{\alpha}_1=\begin{bmatrix}1\\ 1\end{bmatrix},\quad u_2(0)=\boldsymbol{\alpha}_2=\begin{bmatrix}0\\ 1\end{bmatrix},\quad \begin{bmatrix}u(0)\\ u'(0)\end{bmatrix}=\begin{bmatrix}2\\ 3\end{bmatrix}=2u_1(0)+u_2(0)$$

所以 $\frac{\mathrm{d}u}{\mathrm{d}t}=Au$ 且 $u(0)=(2,3)$ 的解是

$$2u_1(t)+u_2(t)=2\begin{bmatrix}\mathrm{e}^t\\ \mathrm{e}^t\end{bmatrix}+\begin{bmatrix}t\mathrm{e}^t\\ t\mathrm{e}^t+\mathrm{e}^t\end{bmatrix}=\begin{bmatrix}2\mathrm{e}^t+t\mathrm{e}^t\\ 3\mathrm{e}^t+t\mathrm{e}^t\end{bmatrix}$$

其第一个分量 $2\mathrm{e}^t+t\mathrm{e}^t$ 与解法 1 中得到的函数一样.

解法 **3**：因 A 有唯一的特征值 1，故 $A-I$ 是幂零阵，故

$$\begin{aligned}\mathrm{e}^{At}&=\mathrm{e}^{(A-I)t+It}=\mathrm{e}^t\mathrm{e}^{(A-I)t}=\mathrm{e}^t(I+(A-I)t)\\ &=\mathrm{e}^t\left(\begin{bmatrix}1&0\\ 0&1\end{bmatrix}+\begin{bmatrix}-t&t\\ -t&t\end{bmatrix}\right)=\begin{bmatrix}(1-t)\mathrm{e}^t&t\mathrm{e}^t\\ -t\mathrm{e}^t&(1+t)\mathrm{e}^t\end{bmatrix}.\end{aligned}$$

于是

$$\mathrm{e}^{At}u(0)=\begin{bmatrix}(1-t)\mathrm{e}^t&t\mathrm{e}^t\\ -t\mathrm{e}^t&(1+t)\mathrm{e}^t\end{bmatrix}\begin{bmatrix}2\\ 3\end{bmatrix}=\begin{bmatrix}(2+t)\mathrm{e}^t\\ (3+t)\mathrm{e}^t\end{bmatrix}$$

与解法 2 同.

注 3.2.5

矩阵的指数函数 e^A 可以推广到任意的幂级数，甚至复解析函数. 微积分告诉我们，复系数幂级数 $f(z)=a_0+a_1z+a_2z^2+\cdots+a_nz^n+\cdots$ 的收敛半径是

$$R=\frac{1}{\limsup\sqrt[n]{|a_n|}}.$$

具体的说，当 $|z|<R$ 时，级数 $\sum_{n=0}^{\infty}a_nz^n$ 绝对收敛；当 $|z|>R$ 时，级数发散；而且对任意的 $0<R'<R$，级数 $\sum_{n=0}^{\infty}a_nz^n$ 在闭圆盘 $|z|\leq R'$ 上一致收敛，故 $\sum_{n=0}^{\infty}a_nz^n$ 定义了开圆盘 $D_R=\{z:|z|<R\}$ 上的复解析函数，记为 $f(z)$；$f(z)$ 在 D_R 上无穷次可微，且它的导数也可以用幂级数表示，比如

$$f'(z)=a_1+2a_2z+\cdots+na_nz^{n-1}+\cdots$$

若当标准形的收敛半径也是 R. 我们有下面的定理

定理 3.2.2

设复系数幂级数 $f(z)=a_0+a_1z+a_2z^2+\cdots+a_nz^n+\cdots$ 的收敛半径是

$$R=\frac{1}{\limsup\sqrt[n]{|a_n|}}.$$

若复矩阵 A 的特征值 λ 都满足 $|\lambda|<R$，则矩阵级数

$$a_0I+a_1A+a_2A^2+\cdots+a_nA^n+\cdots$$

收敛，极限记为 $f(A)$.

事实上，$f(A)$ 可以计算如下. 设 $A=PJP^{-1}$ 是 A 的 Jordan 分解，

$$J=\operatorname{diag}(J_{k_1}(\lambda_1),\cdots,J_{k_m}(\lambda_m)),$$

则

$$f(A)=Pf(J)P^{-1}$$

其中

$$f(J)=\operatorname{diag}(f(J_{k_1}(\lambda_1)),\cdots,f(J_{k_m}(\lambda_m))),$$

$$f(J_{k_j}(\lambda_j))=\begin{bmatrix}f(\lambda_j) & f'(\lambda_j) & \frac{f''(\lambda_j)}{2!} & \cdots & \frac{f^{(k_j-2)}(\lambda_j)}{(k_j-2)!} & \frac{f^{(k_j-1)}(\lambda_j)}{(k_j-1)!}\\ & f(\lambda_j) & f'(\lambda_j) & \cdots & \frac{f^{(k_j-3)}(\lambda_j)}{(k_j-3)!} & \frac{f^{(k_j-2)}(\lambda_j)}{(k_j-2)!}\\ & & f(\lambda_j) & \ddots & \vdots & \vdots\\ & & & \ddots & f'(\lambda_j) & \frac{f''(\lambda_j)}{2!}\\ & & & & f(\lambda_j) & f'(\lambda_j)\\ & & & & & f(\lambda_j)\end{bmatrix}.$$

更一般的，若 $f:\Omega\to\mathbb{C}$ 是开集 $\Omega\subseteq\mathbb{C}$ 上的复解析函数，复矩阵 A 的特征值都在 Ω 中，则我们可以用上面的公式定义 $f(A)$.

例题 3.28.

定义复变量的正弦和余弦函数为

$$\cos(z)=\frac{e^{iz}+e^{-iz}}{2},\quad \sin(z)=\frac{e^{iz}-e^{-iz}}{2i}.$$

也可以用下面的幂级数定义

$$\cos(z) = 1 - \frac{z^2}{2!} + \frac{z^4}{4!} - \frac{z^6}{6!} + \cdots$$

$$\sin(z) = z - \frac{z^3}{3!} + \frac{z^5}{5!} - \frac{z^7}{7!} + \cdots$$

收敛半径都是 $+\infty$. 代入矩阵 A 得到 $\sin(A), \cos(A)$，它们满足

$$\sin^2(A) + \cos^2(A) = I.$$

第二部分
奇异值分解及其应用

第 2 部分目录

第 4 章 奇异值分解 61
4.1 复矩阵的奇异值分解 62
4.2 矩阵范数 67

第 4 章 奇异值分解

在线性代数中，我们非常熟悉对称矩阵或更一般的 Hermite 矩阵的特征分解（也称为谱分解）. 对于一个 Hermite 矩阵 A，我们可以将其分解为 $A = Q\Lambda Q^H$，其中 Q 是酉矩阵，Λ 是对角矩阵. 这种分解揭示了矩阵的内在结构和主要作用方向.

然而，现实世界中的许多问题，例如信号处理、统计学和机器学习中的数据集，通常由非方阵或非 Hermite 矩阵来表示. 特征分解无法直接应用于这些更普遍的矩阵.

奇异值分解正是为了解决这个问题而生的. 它可以被看作是特征分解在任意 $m \times n$ 矩阵上的推广. SVD 不仅一定存在，而且有极好的数值稳定性，这些特性使得其成为线性代数中最强大、应用最广泛的工具之一. SVD 在众多领域都有广泛应用：

- 数据降维与主成分分析（PCA）：PCA 的本质就是对数据中心化后的协方差矩阵进行特征分解，而这等价于对数据矩阵本身进行 SVD. 通过保留前几个最大的奇异值及其对应的奇异向量，可以将高维数据投影到低维空间，同时最大限度地保留数据的主要信息（方差）.
- 图像与数据压缩：一张灰度图像可以表示为一个矩阵. 利用 SVD 的最优低秩逼近性质，我们可以只存储前 k 个奇异值和对应的奇异向量来近似原始图像. 当 k 远小于图像的原始维度时，就能实现高效的数据压缩.
- 去噪：在许多应用中，数据中的主要信息由大的奇异值表示，而噪声通常与小的奇异值相关联. 通过将小的奇异值删除，可以有效地从数据中去除噪声.
- 求解线性方程组与广义逆：对于病态的线性方程组 $\boldsymbol{Ax} = \boldsymbol{b}$，直接求解非常困难. 利用 SVD 可以稳定地计算矩阵 A 的 Moore-Penrose 广义逆 A^+，从而得到方程的最小二乘解 $x = A^+b$.
- 推荐系统：用户-产品评分矩阵通常非常巨大，而且是稀疏矩阵. SVD 可以用来发现用户和产品的潜在兴趣，通过低秩近似来预测用户对未评分产品的喜好，从而进行个性化推荐.

4.1 复矩阵的奇异值分解

定理 4.1.1

设 $A \in M_{m\times n}(\mathbb{C})$，则存在 m 阶酉矩阵 U, n 阶酉矩阵 V, 和 $m\times n$ 阶矩阵 Σ

$$\Sigma = \begin{bmatrix} \sigma_1 & & & \\ & \ddots & & \\ & & \sigma_r & \\ & & & 0_{(m-r)\times(n-r)} \end{bmatrix},$$

其中 $\sigma_1 \geq \cdots \geq \sigma_r > 0$，$r = r(A)$，使得 $A = U\Sigma V^H$.

证明 A^HA 是 n 阶半正定 Hermite 阵，故存在 n 阶酉阵 V 使得

$$V^HA^HAV = \operatorname{diag}(\lambda_1, \cdots, \lambda_r, \underbrace{0, \cdots, 0}_{n-r}),$$

其中 $\lambda_1 \geq \cdots \geq \lambda_r (> 0)$ 是 A^HA 的正特征值，$r = r(A^HA) = r(A)$.

记 $AV = [\alpha_1 \ \cdots \ \alpha_r \ \alpha_{r+1} \ \cdots \ \alpha_n]$ 其中 $\alpha_j \in \mathbb{C}^m$，则

$$\begin{bmatrix} \bar{\alpha}_1^{\mathrm{T}} \\ \vdots \\ \bar{\alpha}_r^{\mathrm{T}} \\ \bar{\alpha}_{r+1}^{\mathrm{T}} \\ \vdots \\ \bar{\alpha}_n^{\mathrm{T}} \end{bmatrix} \begin{bmatrix} \alpha_1 & \cdots & \alpha_r & \alpha_{r+1} & \cdots & \alpha_n \end{bmatrix} = \begin{bmatrix} \lambda_1 & & & & \\ & \ddots & & & \\ & & \lambda_r & & \\ & & & 0_{(n-r)\times(n-r)} \end{bmatrix},$$

特别的 $\bar{\alpha}_i^{\mathrm{T}}\alpha_j = \lambda_i\delta_{ij}$, $1 \leq i, j \leq r$, $\bar{\alpha}_k^{\mathrm{T}}\alpha_k = 0$, $r+1 \leq k \leq n$.

记 $\sigma_1 = \sqrt{\lambda_1}, \cdots, \sigma_r = \sqrt{\lambda_r}$, $\boldsymbol{u}_1 = \frac{\alpha_1}{\sigma_1}, \cdots, \boldsymbol{u}_r = \frac{\alpha_r}{\sigma_r}$, 于是 $\boldsymbol{u}_1, \cdots, \boldsymbol{u}_r$ 是 $\mathbb{C}^m$ 中的单位正交向量且 $\alpha_{r+1} = \cdots = \alpha_n = 0$. 然后，将 $\boldsymbol{u}_1, \cdots, \boldsymbol{u}_r$ 扩充为 $\mathbb{C}^m$ 的标准正交基 $\boldsymbol{u}_1, \cdots, \boldsymbol{u}_r, \boldsymbol{u}_{r+1}, \cdots, \boldsymbol{u}_m$, 并令 $U = [\boldsymbol{u}_1 \ \cdots \ \boldsymbol{u}_r \ \boldsymbol{u}_{r+1} \ \cdots \ \boldsymbol{u}_m]$, 则 U 是 m 阶酉矩阵且

$$AV = \begin{bmatrix} \alpha_1 & \cdots & \alpha_r & \underbrace{0 \cdots 0}_{n-r} \end{bmatrix} = \begin{bmatrix} \boldsymbol{u}_1 & \cdots & \boldsymbol{u}_r & \boldsymbol{u}_{r+1} & \cdots & \boldsymbol{u}_m \end{bmatrix} \begin{bmatrix} \sigma_1 & & & \\ & \ddots & & \\ & & \sigma_r & \\ & & & 0_{(m-r)\times(n-r)} \end{bmatrix} = U\Sigma.$$

右边乘以 V^H 即得 $A = U\Sigma V^H$.

注 4.1.1

与实矩阵的情形类似，若还记 $V = \begin{bmatrix} \boldsymbol{v}_1 & \cdots & \boldsymbol{v}_r & \boldsymbol{v}_{r+1} & \cdots & \boldsymbol{v}_n \end{bmatrix}$, 则

1. $\boldsymbol{v}_1, \cdots, \boldsymbol{v}_r$ 是 $C(A^H)$ 的标准正交基，
2. $\boldsymbol{v}_{r+1}, \cdots, \boldsymbol{v}_n$ 是 $N(A)$ 的标准正交基，
3. $\boldsymbol{u}_1, \cdots, u_r$ 是 $C(A)$ 的标准正交基，
4. $\boldsymbol{u}_{r+1}, \cdots, u_m$ 是 $N(A^H)$ 的标准正交基，
5. $A\boldsymbol{v}_1 = \sigma_1\boldsymbol{u}_1, \cdots, A\boldsymbol{v}_r = \sigma_r\boldsymbol{u}_r$,
6. $A^H\boldsymbol{u}_1 = \sigma_1\boldsymbol{v}_1, \cdots, A^H\boldsymbol{u}_r = \sigma_r\boldsymbol{v}_r$,
7. $A^HA\boldsymbol{v}_i = \sigma_i^2\boldsymbol{v}_i, \quad 1 \leq i \leq r$,
8. $AA^H\boldsymbol{u}_i = \sigma_i^2\boldsymbol{u}_i, \quad 1 \leq i \leq r$,

9. A^HA 的特征值是 $\sigma_1^2,\cdots,\sigma_r^2,\underbrace{0,\cdots,0}_{n-r}$,
10. AA^H 的特征值是 $\sigma_1^2,\cdots,\sigma_r^2,\underbrace{0,\cdots,0}_{m-r}$.

和奇异值分解的证明一样，可以按以下步骤计算奇异值分解：

1. 计算 A^HA，这是构造一个 $n\times n$ 的 Hermite 矩阵，并且是半正定的，其特征值均为非负实数.
2. 求解 A^HA 的特征值和特征向量：
   - 求解 A^HA 的特征值 λ_i 和对应的单位特征向量 $\boldsymbol{v}_i$.
   - $\boldsymbol{v}_1,\cdots,\boldsymbol{v}_n$ 就构成了右奇异向量矩阵 V.
   - 矩阵 A 的奇异值 σ_i 是 A^HA 特征值的平方根，即 $\sigma_i=\sqrt{\lambda_i}$.
3. 计算左奇异向量 U：
   - 对于每一个非零奇异值 σ_i，其对应的左奇异向量 $\boldsymbol{u}_i$ 可以通过下式计算：
   $$\boldsymbol{u}_i=\frac{1}{\sigma_i}A\boldsymbol{v}_i$$
   - 如果 $m>r$（r 为非零奇异值的个数），则需要通过 Gram-Schmidt 正交化等方法，找到 $m-r$ 个与 $\boldsymbol{u}_1,\cdots,\boldsymbol{u}_r$ 都正交的单位向量.
4. 令 $U=\begin{bmatrix}\boldsymbol{u}_1 & \boldsymbol{u}_2 & \cdots & \boldsymbol{u}_m\end{bmatrix}$，$V=\begin{bmatrix}\boldsymbol{v}_1 & \boldsymbol{v}_2 & \cdots & \boldsymbol{v}_n\end{bmatrix}$，得到奇异值分解：$A=U\Sigma V^{\mathrm{H}}$.

4.1.1 广义逆

定义 4.1.1 (广义逆)

A 的广义逆定义为

$$A^+=V\begin{bmatrix}\frac{1}{\sigma_1} & & & \\ & \ddots & & \\ & & \frac{1}{\sigma_r} & \\ & & & \boldsymbol{0}_{(n-r)\times(m-r)}\end{bmatrix}U^H.$$

命题 4.1.1

- 如果 A 可逆，则 $A^+=A^{-1}$.
- 如果 $A\boldsymbol{x}=\boldsymbol{b}$ 无解，那么 $\boldsymbol{x}=A^+\boldsymbol{b}$ 是最优最小二乘解，最小二乘解中长度最小的.
- 如果 $A\boldsymbol{x}=\boldsymbol{b}$ 有无穷多解，那么 $\boldsymbol{x}=A^+\boldsymbol{b}$ 是长度（范数）最小的解.

简单来说，A^+ 总是提供了“最优答案”.

证明 设 $A=U\Sigma V^{\mathrm{H}}$ 为 A 的奇异值分解.

1. 若 A 可逆，则 U,V 都是 n 阶酉矩阵，且 Σ 也是可逆矩阵，$A^+=A^{-1}$ 是容易的.
2. 若 $A\boldsymbol{x}=\boldsymbol{b}$ 无解，要验证 $\boldsymbol{x}=A^+\boldsymbol{b}$ 是最小二乘解，当然可以用矩阵运算直接验证它是方程组 $A^{\mathrm{H}}A\boldsymbol{x}=A^{\mathrm{H}}\boldsymbol{b}$ 的解，但我们还是从最小化误差出发进行验证.

   令 $\boldsymbol{x}=V\boldsymbol{y}$，并记 $\boldsymbol{c}=U^{\mathrm{H}}\boldsymbol{b}$. 由于酉矩阵保持向量的长度，我们可以将原问题转化为关于 $\boldsymbol{y}$ 的问题：我们要最小化 $\|A\boldsymbol{x}-\boldsymbol{b}\|$，而

   $$\|A\boldsymbol{x}-\boldsymbol{b}\|^2=\|U\Sigma V^T(V\boldsymbol{y})-\boldsymbol{b}\|^2=\|U(\Sigma\boldsymbol{y}-U^T\boldsymbol{b})\|^2=\|\Sigma\boldsymbol{y}-\boldsymbol{c}\|^2$$

将 $\boldsymbol{y} \in \mathbb{C}^n$ 分块为 $\boldsymbol{y} = \begin{bmatrix} \boldsymbol{y}_1 \\ \boldsymbol{y}_2 \end{bmatrix}$（其中 $\boldsymbol{y}_1 \in \mathbb{C}^r$），将 $\boldsymbol{c} \in \mathbb{C}^m$ 分块为 $\boldsymbol{c} = \begin{bmatrix} \boldsymbol{c}_1 \\ \boldsymbol{c}_2 \end{bmatrix}$（其中 $\boldsymbol{c}_1 \in \mathbb{C}^r$）. 代入上式得：

$$\left\| \begin{bmatrix} \Sigma_r & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} \boldsymbol{y}_1 \\ \boldsymbol{y}_2 \end{bmatrix} - \begin{bmatrix} \boldsymbol{c}_1 \\ \boldsymbol{c}_2 \end{bmatrix} \right\|^2 = \left\| \begin{bmatrix} \Sigma_r \boldsymbol{y}_1 - \boldsymbol{c}_1 \\ -\boldsymbol{c}_2 \end{bmatrix} \right\|^2 = \|\Sigma_r \boldsymbol{y}_1 - \boldsymbol{c}_1\|^2 + \|\boldsymbol{c}_2\|^2$$

要使该式最小，必须使第一项为零（因为 $\|\boldsymbol{c}_2\|^2$ 是常数，代表无法拟合的误差）. 因此，所有最小二乘解必须满足：

$$\Sigma_r \boldsymbol{y}_1 = \boldsymbol{c}_1 \implies \boldsymbol{y}_1 = \Sigma_r^{-1} \boldsymbol{c}_1$$

注意，此时 $\boldsymbol{y}_2$ 可以取任意值，因为它对应于零奇异值，不影响误差大小.

在所有最小二乘解中，还需要证明 $\boldsymbol{x} = A^+ \boldsymbol{b}$ 是范数最小的解. 由于 $\|\boldsymbol{x}\| = \|V\boldsymbol{y}\| = \|\boldsymbol{y}\|$，我们有：

$$\|\boldsymbol{y}\|^2 = \|\boldsymbol{y}_1\|^2 + \|\boldsymbol{y}_2\|^2$$

其中 $\|\boldsymbol{y}_1\|^2 = \|\Sigma_r^{-1} \boldsymbol{c}_1\|^2$ 已经被固定.

为了使总范数最小，显然应取 $\boldsymbol{y}_2 = \boldsymbol{0}$. 因此最优的 $\boldsymbol{y}$ 为：

$$\boldsymbol{y}_{\text{opt}} = \begin{bmatrix} \Sigma_r^{-1} \boldsymbol{c}_1 \\ \boldsymbol{0} \end{bmatrix} = \begin{bmatrix} \Sigma_r^{-1} & 0 \\ 0 & 0 \end{bmatrix} \boldsymbol{c} = \Sigma^+ \boldsymbol{c}$$

代回 $\boldsymbol{x}$：

$$\boldsymbol{x}_{\text{opt}} = V\boldsymbol{y}_{\text{opt}} = V\Sigma^+ \boldsymbol{c} = V\Sigma^+ U^T \boldsymbol{b} = A^+ \boldsymbol{b}$$

因此，$\boldsymbol{x} = A^+ \boldsymbol{b}$ 是范数最小的最小二乘解.

3. 若 $A\boldsymbol{x} = \boldsymbol{b}$ 有无穷多解，此时 $A\boldsymbol{x} = \boldsymbol{b}$ 相容，通解为 $\boldsymbol{x} = \boldsymbol{x}_0 + \boldsymbol{y}$，其中 $\boldsymbol{y} \in \mathcal{N}(A)$. 令 $\boldsymbol{x} = V\boldsymbol{z}$，则

$$A\boldsymbol{x} = U\Sigma\boldsymbol{z} = \boldsymbol{b} \implies \Sigma\boldsymbol{z} = U^{\mathrm{H}}\boldsymbol{b} = \boldsymbol{c}.$$

因此 $\boldsymbol{z}_1 = \Sigma_r^{-1} \boldsymbol{c}_1$，而 $\boldsymbol{z}_2$（对应零奇异值）任意取值. 由于

$$\|\boldsymbol{x}\|^2 = \|\boldsymbol{z}\|^2 = \|\boldsymbol{z}_1\|^2 + \|\boldsymbol{z}_2\|^2,$$

当 $\boldsymbol{z}_2 = 0$ 时 $\boldsymbol{x}$ 长度取到最小值，即 $\boldsymbol{z} = \Sigma^+ \boldsymbol{c}$，故

$$\boldsymbol{x}_{\min} = V\Sigma^+ U^{\mathrm{H}} \boldsymbol{b} = A^+ \boldsymbol{b}.$$

因此，$A^+ \boldsymbol{b}$ 是所有解中范数最小的.

例题 4.1.

假设我们在做物理实验，测量了一组数据 (t_i, y_i)，猜想它们满足线性关系 $y = kt + b$. 由此得到线性方程组 $A\boldsymbol{x} = \boldsymbol{y}$，其中：

$$A = \begin{bmatrix} t_1 & 1 \\ t_2 & 1 \\ \vdots & \vdots \\ t_m & 1 \end{bmatrix}, \quad \boldsymbol{x} = \begin{bmatrix} k \\ b \end{bmatrix}, \quad \boldsymbol{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{bmatrix}$$

由于数据点很多，这个方程组通常无解.

有奇异值分解，我们直接计算：

$$\boldsymbol{x} = A^+ \boldsymbol{y}$$

例题 4.2.

想象你拍了一张模糊的照片. 图像模糊的过程可以用矩阵乘法来模拟：

$$\boldsymbol{y} = A\boldsymbol{x} + \boldsymbol{b},$$

其中：

- $\boldsymbol{x}$ 是我们想要的清晰图像（展平为向量）.
- $\boldsymbol{y}$ 是我们看到的模糊图像.
- A 是“模糊算子”矩阵（描述了模糊的方式）.
- $\boldsymbol{b}$ 是噪声.

为了恢复清晰图像，我们当然想求 $\boldsymbol{x} = A^{-1}\boldsymbol{y}$. 但问题在于：

1. A 通常是一个巨大的、不可逆的病态矩阵.
2. 即使勉强求逆，噪声 $\boldsymbol{b}$ 也会被放大，导致恢复的图像依然噪点很严重.

但是利用 SVD 计算广义逆 A^+，我们可以进行截断.

$$A = U\Sigma V^H \implies A^+ = V\Sigma^+ U^H$$

在计算 Σ^+ 时，我们只保留那些**大的奇异值**，而把那些微小的奇异值（通常对应高频噪声）直接扔掉（置为 0）.

这样计算出的 $\boldsymbol{x} \approx A^+\boldsymbol{y}$ 不仅实现了“去模糊”，还顺带完成了“去噪”. 这就是 SVD 在图像处理中如此强大的原因.

例题 4.3.

我们再来看抖音或者 B 站是怎么推荐视频的. 假设我们有一个巨大的矩阵 R，行代表用户，列代表视频，里面的数值是评分. 这个矩阵非常稀疏（大部分人是没看过大部分电影的）.

我们的目标是“填补”这个矩阵. 我们可以假设用户的喜好是由少数几个“因素”（比如二次元、知识学习）决定的. 这意味着矩阵 R 近似于一个低秩矩阵.

利用 SVD，我们可以将 R 分解并只保留前 k 个最大的奇异值：

$$R \approx U_k \Sigma_k V_k^T$$

这个近似矩阵就能很好地预测用户对未观看视频的评分. 虽然现代算法更复杂，但基于 SVD 的矩阵分解是这一领域的基石.

4.1.2 几何意义：旋转-拉伸-旋转

考虑线性变换 $\mathbb{C}^n \to \mathbb{C}^n, \boldsymbol{x} \mapsto \boldsymbol{y} = A\boldsymbol{x}$，那么这个线性变换可以分解为三个线性变换的组合：

1. *旋转/反射* V^H：首先，向量 $\boldsymbol{x} \mapsto V^H\boldsymbol{x}$. 由于 V 是酉矩阵，这个变换相当于在 $\mathbb{C}^n$ 空间中进行一次旋转或反射.
2. *拉伸/缩放* Σ：接着，向量 $V^H\boldsymbol{x} \mapsto \Sigma V^H\boldsymbol{x}$. Σ 是对角矩阵，这个变换将向量的每个分量分别乘以对应的奇异值 σ_i. 这相当于沿着新坐标系的各个轴进行拉伸（如果 $\sigma_i > 1$）或压缩（如果 $\sigma_i < 1$）. 奇异值的大小直接反映了该方向上放缩的程度
3. *旋转/反射* U：最后，向量 $\Sigma V^H\boldsymbol{x} \mapsto U\Sigma V^H\boldsymbol{x} = A\boldsymbol{x}$. 这个变换相当于在 $\mathbb{C}^m$ 空间中再次进行旋转或反射.

因此，SVD 将任意复杂的线性变换分解为三个非常简单、易于理解的几何操作.

4.1.3 数值稳定性

在数值计算领域，**奇异值分解（SVD）的数值稳定性远优于特征值分解**. 对于任意矩阵（包括方阵），微小的数据扰动只会引起奇异值的微小变化；而对于非正规矩阵（如非对称矩阵），微小的扰动可能导致特征值发生巨大的漂移.

特性	特征值	奇异值
适用对象	方阵	任意矩阵
数值稳定性	**差**（针对非正规矩阵）	**极好**
对扰动的敏感度	敏感，误差可能被放大	不敏感，误差受控
几何意义	特征向量方向上的缩放	空间变换后的最大拉伸长度
计算可靠性	接近零的特征值很难算准	接近零的奇异值依然准确

为了展示特征值的不稳定性，我们一个经典的例子.

例题 4.4. 非对称矩阵的敏感性

考虑一个简单的 2×2 上三角矩阵 A：

$$A = \begin{pmatrix} 1 & 50000 \\ 0 & 1 \end{pmatrix}$$

1. 真实值：
   - **特征值**：由于是三角矩阵，特征值即对角线元素，均为 **1**.
   - **奇异值**：通过计算 $\sqrt{\lambda(A^TA)}$，其奇异值约为 **50000** 和 **0.00002**.
2. 引入微小扰动：假设计算机在存储或计算时产生了一个极小的舍入误差（例如 10^{-6}），使得矩阵变为 $\hat{A}$：

   $$\hat{A} = \begin{pmatrix} 1 & 50000 \\ 10^{-6} & 1 \end{pmatrix}$$

   注意：左下角仅仅增加了 0.000001，相对于 50000 来说微不足道.
3. 计算结果对比：
   - **特征值的变化（不稳定）**： $\hat{A}$ 的特征值满足 $\det(\hat{A}-\lambda I) = (1-\lambda)^2 - 50000\times 10^{-6} = 0$. 解得：

     $$\lambda = 1 \pm \sqrt{0.05} \approx 1.2236,\ 0.7764$$

     仅仅 10^{-6} 的扰动，导致特征值产生了约 **0.22** 的误差！相对误差非常大.
   - **奇异值的变化（稳定）**： $\hat{A}$ 的奇异值约为：

     $$\sigma \approx 50000.00002,\ 0.000019$$

     结果：扰动后的奇异值与原奇异值几乎完全一致，误差在 10^{-6} 量级以内.

从原理上来讲，导致特征值和奇异值稳定性差别，有如下几个原因：

1. **几何变换的本质不同**
   - **特征值**：描述的是矩阵在**特定方向**（特征向量）上的伸缩. 如果矩阵是非对称的，特征向量之间可能不正交（甚至夹角很小）. 当特征向量“几乎平行”时，微小的扰动会剧烈改变特征向量的方向，进而导致特征值剧烈波动.
   - **奇异值**：描述的是矩阵将单位球变换为椭球后的**轴长**. 无论矩阵如何，奇异值对应的左右奇异向量（U 和 V）**永远是正交的**. 这种正交基的刚性结构使得奇异值对扰动具有天然的抵抗力.

2. **矩阵性质：正规矩阵、一般矩阵**如果矩阵 A 是**正规矩阵**（满足 $A^{\mathrm{H}}A = AA^{\mathrm{H}}$，包括对称矩阵、正交矩阵等），其特征值分解也是稳定的. 但如果矩阵 A **不是正规矩阵**，其特征值分解涉及非正交变换，条件数可能非常大. 而 SVD 对所有矩阵都有效，因为 $A^{\mathrm{H}}A$ 和 AA^{H} 永远是对称半正定矩阵，计算稳定.

我们可以用数学不等式来严格证明奇异值的稳定性.

定理 4.1.2 (Weyl 不等式 / Mirsky 定理的推论)

设 A 和 $\hat{A} = A + E$ 是两个 $m \times n$ 矩阵，其中 E 是扰动矩阵（误差）. 设 σ_i 和 $\hat{\sigma}_i$ 分别是 A 和 $\hat{A}$ 的第 i 个奇异值（按降序排列）. 则对于任意 i，都有：

$$|\sigma_i - \hat{\sigma}_i| \le \|E\|_2 = \sigma_{\sup}(E)$$

证明 根据 Courant-Fischer 定理的推广（极大极小原理），第 k 个奇异值可以表示为子空间上的极值：

$$\sigma_k = \min_{\dim(S)=n-k+1} \sup_{\boldsymbol{x}\in S, \|\boldsymbol{x}\|=1} \|A\boldsymbol{x}\|$$

对于扰动矩阵 $\hat{A} = A + E$，利用向量范数的三角不等式 $\|(A+E)\boldsymbol{x}\| \le \|A\boldsymbol{x}\| + \|E\boldsymbol{x}\|$，我们可以得到：

$$\hat{\sigma}_k \le \sigma_k + \|E\|_2$$

同理，将 A 看作 $\hat{A} - E$，可得：

$$\sigma_k \le \hat{\sigma}_k + \|-E\|_2 = \hat{\sigma}_k + \|E\|_2$$

结合两式，即得证 $|\sigma_k - \hat{\sigma}_k| \le \|E\|_2$.

注 4.1.2

这个不等式告诉我们，奇异值的误差绝对不会超过扰动矩阵的谱范数. 如果误差 E 很小（例如机器精度 10^{-16}），那么算出的奇异值 $\hat{\sigma}_i$ 一定非常接近真实值 σ_i. 相比之下，特征值没有这样通用的、紧致的误差界.

4.2 矩阵范数

在向量空间中，范数（Norm）是一个为每个向量赋予“长度”或“大小”的函数. 类似地，矩阵范数将每一个矩阵映射到一个非负实数，用以度量矩阵的“大小”或“强度”.

定义 4.2.1 (矩阵范数)

从矩阵空间到实数的函数 $\|\cdot\|$ 被称为矩阵范数，如果它满足以下四个基本性质：

1. 非负性：对于任意矩阵 A，$\|A\| \ge 0$.
2. 正定性：$\|A\| = 0$ 当且仅当 A 是零矩阵.
3. 齐次性：对于任意 $c \in \mathbb{C}$ 和矩阵 A，$\|cA\| = |c| \cdot \|A\|$.
4. 三角不等式：对于任意矩阵 A 和 B，$\|A + B\| \le \|A\| + \|B\|$.

在矩阵分析中，我们通常还关心范数关于矩阵乘法的一个更强的性质：

5. 对于任意可相乘的矩阵 A 和 B，$\|AB\| \le \|A\| \cdot \|B\|$.

当然这并不是总会满足；但是满足次乘性的范数在分析矩阵序列、迭代算法收敛性等方面至关重要.

4.2.1 谱范数（算子范数）

谱范数（也称算子范数）的想法是：每一个矩阵 A 都对应于一个线性变换，它把一个向量 $\boldsymbol{x}$ “拉伸”成另一个向量 $A\boldsymbol{x}$. 谱范数就是衡量这个“最大拉伸倍数”.

对于向量 $\boldsymbol{x} = \begin{bmatrix} x_1 & x_2 & \cdots & x_n \end{bmatrix} \in \mathbb{C}^n$，我们定义过 $\|\boldsymbol{x}\| = (|x_1|^2 + |x_2|^2 + \cdots + |x_n|^2)^{1/2}$.

定义 4.2.2 (谱范数)

矩阵 A 的谱范数定义为：

$$\|A\| = \sup_{\boldsymbol{x}\neq\boldsymbol{0}} \frac{\|A\boldsymbol{x}\|}{\|\boldsymbol{x}\|} = \sup_{\|\boldsymbol{x}\|=1} \|A\boldsymbol{x}\|$$

谱范数满足范数定义的 1,2,3 是容易的. 因为向量长度满足三角不等式，所以

$$\|A+B\| = \sup_{\|\boldsymbol{x}\|=1} \|(A+B)\boldsymbol{x}\| \leq \sup_{\|\boldsymbol{x}\|=1} (\|A\boldsymbol{x}\| + \|B\boldsymbol{x}\|)$$

$$\leq \sup_{\|\boldsymbol{x}\|=1} \|A\boldsymbol{x}\| + \sup_{\|\boldsymbol{x}\|=1} \|B\boldsymbol{x}\| = \|A\| + \|B\|.$$

因此谱范数的确是良定义的矩阵范数.

例题 4.5.

若 $A = \boldsymbol{a}$ 本身是列向量，即 $n\times 1$ 矩阵，那么

$$\|A\| = \sup_{\|\boldsymbol{x}\|=1} \|A\boldsymbol{x}\| = \sup_{\|\boldsymbol{x}\|=1=1} \|\boldsymbol{a}\boldsymbol{x}\| = \boldsymbol{a}.$$

也就是说，我们把列向量视作矩阵，那么谱范数就是向量的长度.

例题 4.6.

若 $A = \boldsymbol{a}^T$ 本身是行向量，即 $1\times n$ 矩阵，那么

$$\|A\| = \sup_{\|\boldsymbol{x}\|=1} \|A\boldsymbol{x}\| = \sup_{\|\boldsymbol{x}\|=1} \left\|\boldsymbol{a}^{\mathrm{T}}\boldsymbol{x}\right\|.$$

一方面，对任意 $\boldsymbol{x}$，都有 $\left\|\boldsymbol{a}^{\mathrm{T}}\boldsymbol{x}\right\| \leq \|\boldsymbol{a}\|\,\|\boldsymbol{x}\|$；所以 $\sup_{\|\boldsymbol{x}\|=1} \left\|\boldsymbol{a}^{\mathrm{T}}\boldsymbol{x}\right\| \leq \|\boldsymbol{a}\|$. 另一方面，取 $\boldsymbol{x} = \frac{\bar{\boldsymbol{a}}}{\|\boldsymbol{a}\|}$，那么 $\left\|\boldsymbol{a}^{\mathrm{T}}\boldsymbol{x}\right\| = \|\boldsymbol{a}\|$，所以

$$\|A\| = \|\boldsymbol{a}\|.$$

也就是说，我们把行向量视作矩阵，那么谱范数也是向量的长度.

注 4.2.1

谱范数的定义天然地保证了相容性 $\|A\boldsymbol{x}\| \leq \|A\|\cdot\|\boldsymbol{x}\|$：这是因为按照 sup 的定义，对任意 $\boldsymbol{x}\neq 0$，我们有不等关系：

$$\frac{\|A\boldsymbol{x}\|}{\|\boldsymbol{x}\|} \leq \|A\|, \quad \text{即} \quad \|A\boldsymbol{x}\| \leq \|A\|\cdot\|\boldsymbol{x}\|.$$

命题 4.2.1

设 $A \in M_{m\times n}(\mathbb{R}), B \in M_{n\times k}(\mathbb{R})$，则 $\|AB\| \leq \|A\|\cdot\|B\|$.

这也不难证明：

$$\|AB\| = \sup_{\boldsymbol{x}\neq\boldsymbol{0}} \frac{\|AB\boldsymbol{x}\|}{\|\boldsymbol{x}\|} = \sup_{\substack{\boldsymbol{x}\neq\boldsymbol{0}\\ B\boldsymbol{x}\neq\boldsymbol{0}}} \frac{\|AB\boldsymbol{x}\|}{\|B\boldsymbol{x}\|}\frac{\|B\boldsymbol{x}\|}{\|\boldsymbol{x}\|}$$

$$\leq \sup_{\substack{\boldsymbol{x}\neq\boldsymbol{0}\\ B\boldsymbol{x}\neq\boldsymbol{0}}} \frac{\|AB\boldsymbol{x}\|}{\|B\boldsymbol{x}\|} \sup_{\substack{\boldsymbol{x}\neq\boldsymbol{0}\\ B\boldsymbol{x}\neq\boldsymbol{0}}} \frac{\|B\boldsymbol{x}\|}{\|\boldsymbol{x}\|}$$

$$\leq \sup_{\boldsymbol{y}\neq\boldsymbol{0}} \frac{\|A\boldsymbol{y}\|}{\|\boldsymbol{y}\|} \sup_{\boldsymbol{x}\neq\boldsymbol{0}} \frac{\|B\boldsymbol{x}\|}{\|\boldsymbol{x}\|} = \|A\|\cdot\|B\|.$$

定理 4.2.1 (谱范数的计算)

矩阵 A 的谱范数等于其最大奇异值.

$$\|A\| = \sigma_{\max}(A)$$

其中 $\sigma_{\max}(A)$ 是 A 的最大奇异值. 它也可以通过 $A^{\mathrm{H}}A$ 的特征值来计算:

$$\|A\| = \sqrt{\lambda_{\max}(A^{\mathrm{H}}A)}$$

这里 $\lambda_{\max}(\cdot)$ 表示最大特征值.

注 4.2.2

谱范数衡量了矩阵 A 对单位球（所有满足 $\|\boldsymbol{x}\| = 1$ 的向量 $\boldsymbol{x}$ 构成的集合）所能产生的最大拉伸. 单位球经过 A 变换后会变成一个椭球，而谱范数就是这个椭球最长半轴的长度.

证明 设 A 的奇异值分解为 $A = U\Sigma V^{\mathrm{H}}$，因为酉矩阵保持向量的长度，所以

$$\begin{aligned}\|A\| &= \sup_{\|\boldsymbol{x}\|=1} \left\|U\Sigma V^{\mathrm{H}}\boldsymbol{x}\right\| = \sup_{\|\boldsymbol{x}\|=1} \left\|\Sigma V^{\mathrm{H}}\boldsymbol{x}\right\| = \sup_{\|\boldsymbol{y}\|=1} \|\Sigma \boldsymbol{y}\| \\ &= \sup_{|y_1|^2+|y_2|^2+\cdots+|y_n|^2=1} \left(\sigma_1^2|y_1|^2 + \sigma_2^2|y_2|^2 + \cdots + \sigma_r^2|y_r|^2\right)^{1/2}.\end{aligned}$$

一方面，

$$\begin{aligned}\sigma_1^2|y_1|^2 + \sigma_2^2|y_2|^2 + \cdots + \sigma_r^2|y_r|^2 &\le \sigma_{\max}^2(|y_1|^2 + |y_2|^2 + \cdots + |y_r|^2) \\ &\le \sigma_{\max}^2(|y_1|^2 + |y_2|^2 + \cdots + |y_n|^2) = \sigma_{\max}^2,\end{aligned}$$

所以 $\|A\| \le \sigma_{\max}$. 另一方面，取 $y_1 = 1, y_2 = \cdots = 0$，$\left(\sigma_1^2|y_1|^2 + \sigma_2^2|y_2|^2 + \cdots + \sigma_r^2|y_r|^2\right)^{1/2} = \sigma_{\max}$. 综合这两方面得

$$\|A\| = \sigma_{\max} = \sqrt{\lambda_{\max}(A^{\mathrm{H}}A)}.$$

注 4.2.3

上述证明实际上也说明：矩阵左乘酉矩阵或者右乘酉矩阵都不改变谱范数.

定理 4.2.2 (谱范数下的低秩逼近)

设 $A \in M_{m\times n}(\mathbb{C})$，简化奇异值分解为 $A = \sigma_1\boldsymbol{u}_1\boldsymbol{v}_1^{\mathrm{H}} + \sigma_2\boldsymbol{u}_2\boldsymbol{v}_2^{\mathrm{H}} + \cdots + \sigma_r\boldsymbol{u}_r\boldsymbol{v}_r^{\mathrm{H}}$. 对任意 $1 \le k \le r$，令 $A_k = \sigma_1\boldsymbol{u}_1\boldsymbol{v}_1^{\mathrm{H}} + \sigma_2\boldsymbol{u}_2\boldsymbol{v}_2^{\mathrm{H}} + \cdots + \sigma_k\boldsymbol{u}_k\boldsymbol{v}_k^{\mathrm{H}}$，则对任意 $B \in M_{m\times n}(\mathbb{C})$ 且 $\operatorname{rank}(B) \le k$，我们都有不等式

$$\|A - A_k\| \le \|A - B\|.$$

证明 因为 $A - A_k$ 的最大奇异值为 σ_{k+1}，所以 $\|A - A_k\| = \sigma_{k+1}$，我们只需证明对任意秩大于等于 k 的矩阵 B，都有 $\|A - B\| \ge \sigma_{k+1}$.

注意到 $\mathcal{N}(B) = \mathcal{C}(B)^{\perp}$，所以 $\dim\mathcal{N}(B) = n - \dim\mathcal{C}(B) \ge n - k$. 记 $V_{k+1} = \begin{bmatrix}\boldsymbol{v}_1 & \boldsymbol{v}_2 & \cdots & \boldsymbol{v}_{k+1}\end{bmatrix}$，则

$$\begin{aligned}\dim(\mathcal{N}(B) \cap \dim\mathcal{C}(V_{k+1})) &= \dim(\mathcal{N}(B)) + \dim(\mathcal{C}(V_{k+1})) - \dim(\mathcal{N}(B) + \dim\mathcal{C}(V_{k+1})) \\ &\ge (n-k) + (k+1) - n = 1.\end{aligned}$$

所以存在非零向量 $\boldsymbol{v} \in \mathcal{N}(B) \cap \dim\mathcal{C}(V_{k+1})$，将之单位化，故可设 $\|\boldsymbol{v}\| = 1$. 因为 $\boldsymbol{v} \in \mathcal{C}(V_{k+1})$，所以存在 $\boldsymbol{x}$ 使得 $\boldsymbol{v} = V_{k+1}\boldsymbol{x}$，即 $\boldsymbol{v} = x_1\boldsymbol{v}_1 + \cdots + x_{k+1}\boldsymbol{v}_{k+1}$. $\|\boldsymbol{v}\| = 1$ 意思是 $|x_1|^2 + |x_2|^2 + \cdots + |x_{k+1}|^2 = 1$. 那么

$$\|A - B\| \ge \|(A-B)\boldsymbol{v}\| = \|A\boldsymbol{v}\| = \left\|\sum_{i=1}^{k+1}\sum_{j=1}^{r} x_i\sigma_j\boldsymbol{u}_j\boldsymbol{v}_j^{\mathrm{H}}\boldsymbol{v}_i\right\| = \left\|\sum_{i=1}^{k+1} x_i\sigma_i\boldsymbol{u}_i\right\|$$

因为 $\boldsymbol{u}_i$ 是两两正交的单位向量，根据勾股定理，

$$\|A-B\|=\left(\sum_{i=1}^{k+1}|x_i\sigma_i|^2\right)^{1/2}\geq\left(\sum_{i=1}^{k+1}|x_i\sigma_{k+1}|^2\right)^{1/2}=\sigma_{k+1}.$$

4.2.2 Frobenius 范数

这类范数将 $m\times n$ 的矩阵视为一个 mn 维的长列向量，然后直接应用向量范数.

定义 4.2.3 (Frobenius 范数)

$$\|A\|_F=\sqrt{\operatorname{trace}(A^{\mathrm{H}}A)}$$

命题 4.2.2

$$\|A\|_F=\sqrt{\sum_{i=1}^{m}\sum_{j=1}^{n}|a_{ij}|^2}=\sqrt{\sum_{i=1}^{r}\sigma_i^2}$$

证明 设 $A=\left[a_{ij}\right]$，$A^{\mathrm{H}}A$ 是 $n\times n$ 矩阵，它的第 j 个对角元为

$$\sum_{i=1}^{m}(A^{\mathrm{H}})_{ji}A_{ij}=\sum_{i=1}^{m}\bar{a}_{ij}a_{ij}=\sum_{i=1}^{m}|a_{ij}|^2.$$

所以

$$\operatorname{trace}(A^{\mathrm{H}}A)=\sum_{j=1}^{n}(A^{\mathrm{H}}A)_{jj}=\sum_{j=1}^{n}\sum_{i=1}^{m}|a_{ij}|^2.$$

设 A 的奇异值分解为 $A=U\Sigma V^{\mathrm{H}}$，则

$$\begin{aligned}\operatorname{trace}(A^{\mathrm{H}}A)&=\operatorname{trace}(U\Sigma V^{\mathrm{H}}V\Sigma^{\mathrm{H}}U^{\mathrm{H}})=\operatorname{trace}(U\Sigma\Sigma^{\mathrm{H}}U^{\mathrm{H}})\\&=\operatorname{trace}(U^{\mathrm{H}}U\Sigma\Sigma^{\mathrm{H}})=\operatorname{trace}(\Sigma\Sigma^{\mathrm{H}})\\&=\sum_{i=1}^{r}\sigma_i^2.\end{aligned}$$

例题 4.7.

- 如果 A 是列向量 $\boldsymbol{a}$ 或者行向量 $\boldsymbol{a}^{\mathrm{T}}$，则 $\|A\|_F=\|\boldsymbol{a}\|$.
- 如果 A 是分块矩阵 $\left[A_{ij}\right]$，则 $\|A\|_F^2=\sum_{i,j}\left\|A_{ij}\right\|_F^2$，因为它们都等于 A 所有元素模长的平方和.

注 4.2.4

上述证明实际上也说明：矩阵左乘酉矩阵或者右乘酉矩阵都不改变 Frobenius 范数.

命题 4.2.3

设 $1\leq i\leq k$，$Q\in M_{n\times k}(\mathbb{C})$ 是列酉正交矩阵，即 $Q^{\mathrm{H}}Q=I_k$，那么

$$\|AQ\|_F\leq\sqrt{\sigma_1^2+\sigma_2^2+\cdots+\sigma_k^2}.$$

证明 设 A 的奇异值分解为 $A=U\Sigma V^{\mathrm{H}}$，则

$$\|AQ\|_F^2=\operatorname{trace}((U\Sigma V^{\mathrm{H}}Q)^{\mathrm{H}}U\Sigma V^{\mathrm{H}}Q)=\operatorname{trace}(Q^{\mathrm{H}}V\Sigma^{\mathrm{H}}\Sigma V^{\mathrm{H}}Q)=\operatorname{trace}(\Sigma^{\mathrm{H}}\Sigma V^{\mathrm{H}}QQ^{\mathrm{H}}V)$$

令 $V^{\mathrm{H}}QQ^{\mathrm{H}}V=W\in M_{n\times n}(\mathbb{C})$，则 $W^{\mathrm{H}}=W$ 且 $W^2=W$，即 W 是酉正交投影矩阵，且 $\operatorname{rank}(W)=\operatorname{rank}(Q)=k$. 因

为 W 的特征值是 1 或者 0，所以

$$\operatorname{trace}(W) = W\text{的特征值 1 的个数} = \operatorname{rank}(W) = k.$$

设 $W = \left[w_{ij}\right]$，因为 W 是正交投影矩阵，所以对任意 $\boldsymbol{x}$，都有 $\|W\boldsymbol{x}\| \leq \|\boldsymbol{x}\|$，而对角元 $w_{ii} = \boldsymbol{e}_i^{\mathrm{H}} W \boldsymbol{e}_i$，所以

$$\bar{w}_{ii} = [w_{ii}]^{\mathrm{H}} = (\boldsymbol{e}_i^{\mathrm{H}} W \boldsymbol{e}_i)^{\mathrm{H}} = \boldsymbol{e}_i^{\mathrm{H}} W \boldsymbol{e}_i = w_{ii},$$

所以 $w_{ii} \in \mathbb{R}$ 且

$$|w_{ii}| = \left\|\boldsymbol{e}_i^{\mathrm{H}} W \boldsymbol{e}_i\right\| \leq \left\|\boldsymbol{e}_i^{\mathrm{H}}\right\| \|W\boldsymbol{e}_i\| \leq \left\|\boldsymbol{e}_i^{\mathrm{H}}\right\| \|\boldsymbol{e}_i\| = 1.$$

另一方面，因为 $W = W^2 = W^{\mathrm{H}} W$，所以对角元

$$w_{ii} = \sum_{j=1}^{n} |w_{ij}|^2 \geq 0.$$

所以我们证明了

$$0 \leq w_{ii} \leq 1, \qquad w_{11} + w_{22} + \cdots + w_{nn} = k.$$

此时

$$\begin{aligned} \|AQ\|_F^2 &= \sigma_1^2 w_{11} + \sigma_2^2 w_{22} + \cdots + \sigma_n^2 w_{nn} \\ &= \sigma_1^2 + \sigma_2^2 + \cdots + \sigma_k^2 \\ &\quad + \sigma_1^2(w_{11} - 1) + \sigma_2^2(w_{22} - 1) + \cdots + \sigma_k^2(w_{kk} - 1) + \sigma_{k+1}^2 w_{k+1,k+1} + \sigma_n^2 w_{nn} \end{aligned}$$

而

$$\begin{aligned} \sigma_1^2(1 - w_{11}) + \sigma_2^2(1 - w_{22}) + \cdots + \sigma_k^2(1 - w_{kk}) &\geq \sigma_k^2(k - (w_{11} + w_{22} + \cdots + w_{kk})) \\ &\geq \sigma_{k+1}^2(k - (w_{11} + w_{22} + \cdots + w_{kk})) \\ &= \sigma_{k+1}^2(w_{k+1,k+1} + \cdots + w_{nn}) \\ &\geq \sigma_{k+1}^2 w_{k+1,k+1} + \cdots + \sigma_n^2 w_{nn} \end{aligned}$$

所以

$$\|AQ\|_F \leq \sqrt{\sigma_1^2 + \sigma_2^2 + \cdots + \sigma_k^2}.$$

不同的范数从不同角度衡量矩阵，它们之间存在一些重要的关系.

命题 4.2.4 (谱范数与 Frobenius 范数的关系)

1. 谱范数是 Frobenius 范数的一个下界.
$$\|A\| \leq \|A\|_F$$
2. 如果矩阵 A 的秩为 r，我们有：
$$\|A\|_F \leq \sqrt{r} \cdot \|A\|$$

♠

这两个不等式都很直接，因为 $\|A\| = \sigma_{\sup}$，而 $\|A\|_F = \sqrt{\sum \sigma_i^2}$，后者包含了前者的平方以及所有其他奇异值的平方. 这些关系表明，当矩阵的秩很低时，这两个范数的值会比较接近.

命题 4.2.5

矩阵的 Frobenius 范数满足一下性质：

1. 设 $A, B \in M_{m\times n}(\mathbb{C})$，则 $\|A + B\|_F \leq \|A\|_F + \|B\|_F$.
2. 设 $A \in M_{m\times n}(\mathbb{C})$，$B \in M_{n\times k}(\mathbb{C})$，则 $\|AB\|_F \leq \|A\| \|B\|_F$，$\|AB\|_F \leq \|A\|_F \|B\|$.

♠

证明

1. 设 $A=\left[a_{ij}\right], B=\left[b_{ij}\right]$，则

$$\|A+B\|=\left(\sum_{i,j}|a_{ij}+b_{ij}|^2\right)^{1/2},\quad \|A\|=\left(\sum_{i,j}|a_{ij}|^2\right)^{1/2},\quad \|B\|=\left(\sum_{i,j}|b_{ij}|^2\right)^{1/2}.$$

那么

$$\|A+B\|_F\leq\|A\|_F+\|B\|_F \iff \sum_{i,j}|a_{ij}+b_{ij}|^2\leq\sum_{i,j}|a_{ij}|^2+2\left(\sum_{i,j}|a_{ij}|^2\right)^{1/2}\left(\sum_{i,j}|b_{ij}|^2\right)^{1/2}+\sum_{i,j}|b_{ij}|^2$$

$$\iff \sum_{i,j}(a_{ij}\overline{b}_{ij}+\overline{a}_{ij}b_{ij})\leq 2\left(\sum_{i,j}|a_{ij}|^2\right)^{1/2}\left(\sum_{i,j}|b_{ij}|^2\right)^{1/2}$$

根据 Cauchy-Schwartz 不等式，

$$\left|\sum_{i,j}a_{ij}\overline{b}_{ij}\right|\leq\left(\sum_{i,j}|a_{ij}|^2\right)^{1/2}\left(\sum_{i,j}|b_{ij}|^2\right)^{1/2},$$

$$\left|\sum_{i,j}\overline{a}_{ij}b_{ij}\right|\leq\left(\sum_{i,j}|a_{ij}|^2\right)^{1/2}\left(\sum_{i,j}|b_{ij}|^2\right)^{1/2}$$

相加即得.

2. 如果 B 是一个列向量 β，那么 $AB=A\beta$ 也是一个列向量，于是

$$\|AB\|_F=\|A\beta\|\leq\|A\|\,\|\beta\|=\|A\|\,\|B\|_F.$$

一般情形，设 $B=\begin{bmatrix}\beta_1 & \cdots & \beta_k\end{bmatrix}$，则

$$\|AB\|_F^2=\left\|\begin{bmatrix}A\beta_1 & \cdots & A\beta_k\end{bmatrix}\right\|_F^2=\sum_{i=1}^{k}\|A\beta\|_F^2\leq\sum_{i=1}^{k}\|A\|^2\,\|\beta\|_F^2=\|A\|^2\,\|B\|_F^2,$$

所以 $\|AB\|_F\leq\|A\|\,\|B\|_F$. 又

$$\|AB\|_F=\left\|B^{\mathrm{H}}A^{\mathrm{H}}\right\|\leq\left\|B^{\mathrm{H}}\right\|\left\|A^{\mathrm{H}}\right\|_F=\|A\|_F\,\|B\|.$$

定理 4.2.3 (Frobenius 范数下的低秩逼近)

设 $A\in M_{m\times n}(\mathbb{C})$，简化奇异值分解为 $A=\sigma_1\boldsymbol{u}_1\boldsymbol{v}_1^{\mathrm{H}}+\sigma_2\boldsymbol{u}_2\boldsymbol{v}_2^{\mathrm{H}}+\cdots+\sigma_r\boldsymbol{u}_r\boldsymbol{v}_r^{\mathrm{H}}$. 对任意 $1\leq k\leq r$，令 $A_k=\sigma_1\boldsymbol{u}_1\boldsymbol{v}_1^{\mathrm{H}}+\sigma_2\boldsymbol{u}_2\boldsymbol{v}_2^{\mathrm{H}}+\cdots+\sigma_k\boldsymbol{u}_k\boldsymbol{v}_k^{\mathrm{H}}$，则对任意 $B\in M_{m\times n}(\mathbb{C})$ 且 $\operatorname{rank}(B)\leq k$，我们都有不等式

$$\|A-A_k\|_F\leq\|A-B\|_F.$$

♡

证明 因为 $A-A_k$ 的奇异值是 $\sigma_{k+1},\cdots,\sigma_r$，所以 $\|A-A_k\|_F=\sigma_{k+1}^2+\cdots+\sigma_r^2$. 只需证明，对任意 $B\in M_{m\times n}(\mathbb{C})$ 且 $\operatorname{rank}(B)\leq k$，我们都有不等式

$$\|A-B\|_F\geq\sigma_{k+1}^2+\cdots+\sigma_r^2.$$

设 $\operatorname{rank}(B)=\ell\leq k$，$Q$ 满足 $Q^{\mathrm{H}}Q=I_\ell$ 且 $C(Q)=C(B)$；或者等价地说，Q 的列向量是 $C(B)$ 的标准正交基. 根据 Gram-Schmidt 正交化，这样的 Q 是存在的. 令 $P=QQ^{\mathrm{H}}$，是 $C(B)$ 的正交投影矩阵，满足 $P^{\mathrm{H}}=P$ 且 $P^2=P$. 因

为 B 的每一个列向量被 P 乘都不变，所以 $PB = B$，因此

$$\begin{aligned}\|A-B\|_F^2 &= \|A-PA+PA-PB\|_F^2 = \|(I-P)A+P(A-B)\|_F^2\\ &= \operatorname{trace}\left(\Big((I-P)A+P(A-B)\Big)^{\mathrm{H}}\Big((I-P)A+P(A-B)\Big)\right)\\ &= \operatorname{trace}(A^{\mathrm{H}}(I-P)^{\mathrm{H}}(I-P)A)+\operatorname{trace}(A^{\mathrm{H}}(I-P)^{\mathrm{H}}P(A-B))\\ &\quad+\operatorname{trace}((A-B)^{\mathrm{H}}P^{\mathrm{H}}(I-P)A)+\operatorname{trace}((A-B)^{\mathrm{H}}P^{\mathrm{H}}P(A-B))\\ &= \operatorname{trace}(AA^{\mathrm{H}}(I-P))+\operatorname{trace}((A-B)^{\mathrm{H}}P^{\mathrm{H}}P(A-B))\end{aligned}$$

因为 $\operatorname{trace}((A-B)^{\mathrm{H}}P^{\mathrm{H}}P(A-B)) = \|P(A-B)\|_F^2 \geq 0$，所以

$$\|A-B\|_F^2 \geq \operatorname{trace}(AA^{\mathrm{H}}(I-P)) = \operatorname{trace}(AA^{\mathrm{H}}) - \operatorname{trace}(AA^{\mathrm{H}}P).$$

又注意到

$$\operatorname{trace}(AA^{\mathrm{H}}P) = \operatorname{trace}(AA^{\mathrm{H}}QQ^{\mathrm{H}}) = \left\|A^{\mathrm{H}}Q\right\|_F^2 \leq \sigma_1^2+\sigma_2^2+\cdots+\sigma_\ell^2,$$

最后的不等号是根据命题4.2.3以及 A 和 A^{H} 有相同的奇异值. 所以

$$\|A-B\|_F^2 \geq \sum_{i=1}^{r}\sigma_i^2 - \sum_{i=1}^{\ell}\sigma_i^2 = \sum_{i=\ell+1}^{r}\sigma_i^2 \geq \sigma_{k+1}^2+\cdots+\sigma_r^2.$$

4.2.3 误差分析与条件数

在求解线性方程组 $A\boldsymbol{x} = \boldsymbol{b}$ 时，如果数据 A 或 $\boldsymbol{b}$ 存在微小扰动，解 $\boldsymbol{x}$ 会受到多大影响？这由**条件数**来衡量.

$$\operatorname{cond}(A) = \|A\|\cdot\|A^{-1}\|$$

条件数越大，方程组越“病态”，解对误差越敏感. 这里通常使用谱范数来定义条件数.

在科学计算和工程应用中，我们经常需要求解线性方程组 $A\boldsymbol{x} = \boldsymbol{b}$. 然而，实际数据往往是不精确的：

- 系数矩阵 A 可能来自实验测量，存在观测误差.
- 右端向量 $\boldsymbol{b}$ 可能包含噪声.
- 计算机进行浮点运算时，会产生舍入误差.

这就引出了一个核心问题：输入数据（A 或 $\boldsymbol{b}$）的微小变化，会导致解 $\boldsymbol{x}$ 发生多大的变化？

如果微小的误差导致解的巨大偏差，我们称该问题是“病态”的；反之，如果解的变化与输入误差在同一个数量级，则称该问题是“良态”的. **条件数**正是用来量化这一性质的指标. 虽然条件数可以基于任意矩阵范数定义，但在误差分析中，最常用的是基于谱范数的条件数.

定义 4.2.4 (矩阵的条件数)

设 A 是一个非奇异矩阵，其条件数定义为矩阵范数与其逆矩阵范数的乘积：

$$\operatorname{cond}(A) = \|A\|\cdot\|A^{-1}\|$$

如果矩阵 A 是奇异的（不可逆），则规定其条件数为无穷大.

条件数越大，矩阵越接近奇异，方程组越“病态”.

命题 4.2.6

1. $\operatorname{cond}(A) \geq 1$.
2. 正交矩阵（或酉矩阵）的条件数为 1，这意味着正交变换是数值最稳定的变换.

证明 根据谱范数的定义，$\|A\| = \sigma_{\max}(A)$. 对于逆矩阵 A^{-1}，其奇异值为 A 的奇异值的倒数，即 $\sigma_i(A^{-1}) = 1/\sigma_i(A)$. 因此，$\|A^{-1}\| = 1/\sigma_{\min}(A)$. 两者相乘即得证.

注 4.2.5 (几何解释)

条件数衡量了线性变换 A 对单位球变形的程度.

- 单位球经过 A 变换后变成一个椭球.
- 最长轴长度为 $\sigma_{\max}$，最短轴长度为 $\sigma_{\min}$.
- 如果 $\sigma_{\max} \gg \sigma_{\min}$（即条件数很大），椭球会被拉得非常细长，接近于一条线或一个平面（降维，即奇异）. 此时，沿着短轴方向的微小扰动，在反变换回原空间时，会被放大 $1/\sigma_{\min}$ 倍，导致解的巨大偏移.

我们可以通过数学推导来展示条件数是如何作为“误差放大倍数”的.

假设 A 是精确的，但 $\boldsymbol{b}$ 存在误差 $\Delta\boldsymbol{b}$，导致解 $\boldsymbol{x}$ 产生误差 $\Delta\boldsymbol{x}$.

$$A(\boldsymbol{x}+\Delta\boldsymbol{x}) = \boldsymbol{b}+\Delta\boldsymbol{b}$$

展开并减去原方程 $A\boldsymbol{x}=\boldsymbol{b}$，得到：

$$A(\Delta\boldsymbol{x}) = \Delta\boldsymbol{b} \implies \Delta\boldsymbol{x} = A^{-1}\Delta\boldsymbol{b} \implies \|\Delta\boldsymbol{x}\| \le \|A^{-1}\|\cdot\|\Delta\boldsymbol{b}\|$$

同时，对原方程取范数有 $\|\boldsymbol{b}\| = \|A\boldsymbol{x}\| \le \|A\|\cdot\|\boldsymbol{x}\|$，即：$\frac{1}{\|\boldsymbol{x}\|} \le \frac{\|A\|}{\|\boldsymbol{b}\|}$. 将两式结合，我们可以得到相对误差的关系：

$$\frac{\|\Delta\boldsymbol{x}\|}{\|\boldsymbol{x}\|} \le \underbrace{\|A\|\cdot\|A^{-1}\|}_{\mathrm{cond}(A)}\cdot\frac{\|\Delta\boldsymbol{b}\|}{\|\boldsymbol{b}\|}$$

因此，条件数越小，方程组解的相对误差就被数据的相对误差控制得越好. 在实际应用中，如果遇到高条件数的问题，通常需要采用正则化方法（如 Tikhonov 正则化）或高精度算术来缓解数值不稳定性.

如果 A 存在扰动 ΔA，且 $\|\Delta A\|$ 足够小，类似的推导可以得到：

$$\frac{\|\Delta\boldsymbol{x}\|}{\|\boldsymbol{x}\|} \lesssim \mathrm{cond}(A)\cdot\frac{\|\Delta A\|}{\|A\|}$$

例题 4.8. 希尔伯特矩阵的病态性

希尔伯特矩阵是数值分析中著名的“病态”矩阵. 其元素定义为 $H_{ij} = \frac{1}{i+j-1}$. 考虑 $n\times n$ 的希尔伯特矩阵 H_n. 随着 n 的增加，其条件数呈指数级增长.

- $n=3$ 时，$\mathrm{cond}(H_3)\approx 524$.
- $n=10$ 时，$\mathrm{cond}(H_{10})\approx 1.6\times 10^{13}$.

这意味着，对于 $H_{10}\boldsymbol{x}=\boldsymbol{b}$，如果 $\boldsymbol{b}$ 的误差在 10^{-16}（双精度浮点数的机器精度）量级，解 $\boldsymbol{x}$ 的误差可能达到 10^{-3} 甚至更大，导致计算结果完全不可信.

第三部分

张量积

第 3 部分目录

第 5 章 张量积及其应用 76
5.1 卷积 76
5.2 二维离散傅里叶变换 89
5.3 张量 90
5.4 张量的运算与分解 94
5.5 Tucker 分解 98
5.6 二维傅里叶变换与张量的深层关系 101

第 5 章 张量积及其应用

5.1 卷积

5.1.1 示例

卷积的实际应用极多，这里以一个非常直观且经典的应用为例：**图像边缘检测**（如 Sobel 算子）. 你几乎每天都在使用它——手机拍照的“锐化”、人脸识别预处理、自动驾驶的车道线识别，背后都有它的身影.

图像在计算机里是一个矩阵（灰度）或三个矩阵（RGB）. 边缘就是像素值发生剧烈跳变的地方（比如白纸上的黑字边界、天空与建筑的轮廓）. 检测边缘可以帮助机器“看懂”物体的形状，是计算机视觉的基石.

那么我们如何判断图像变化的剧烈程度呢？如果从函数的角度看，函数值变化的剧烈程度就是一阶导数；所以对于图像，像素差分大的地方就是边缘.

对于离散的图像数据，其水平方向的一阶差分是

$$\frac{\partial I}{\partial x} \approx I(x+1,y) - I(x,y)$$

这可以用一个简单的 1×2 核 $\begin{bmatrix}-1 & 1\end{bmatrix}$ 来实现：

$$\begin{bmatrix}-1 & 1\end{bmatrix}\begin{bmatrix}I(x,y)\\ I(x+1,y)\end{bmatrix}.$$

但是这有两个明显的问题：

- 只考虑两个相邻像素，对噪声非常敏感.
- 忽略了 y 方向的信息.

因此，我们经常使用 **Sobel 水平边缘检测核**：

$$G_x = \begin{bmatrix}-1 & 0 & +1\\ -2 & 0 & +2\\ -1 & 0 & +1\end{bmatrix} = \begin{bmatrix}1\\ 2\\ 1\end{bmatrix}\begin{bmatrix}-1 & 0 & 1\end{bmatrix} = \boldsymbol{v}\boldsymbol{h}^{\mathrm{T}}$$

注 5.1.1

G_x 对于图像矩阵的作用不是矩阵乘法，即不是左乘，也不是右乘. 假设有一个图像，以其中某个像素为

中心的 3×3 矩阵为：

$$\begin{bmatrix} 11 & 96 & 102 \\ 5 & 100 & 97 \\ 14 & 98 & 105 \end{bmatrix}$$

由 Sobel 算子处理后，其中心点处的值为：

$$\begin{bmatrix} 1 & 2 & 1 \end{bmatrix} \begin{bmatrix} 11 & 96 & 102 \\ 5 & 100 & 97 \\ 14 & 98 & 105 \end{bmatrix} \begin{bmatrix} -1 \\ 0 \\ 1 \end{bmatrix} = 366.$$

Sobel 算子 G_x 相比于 $\begin{bmatrix} -1 & 1 \end{bmatrix}$ 有三个优点：

- **平滑**：对 y 方向做平滑，降低噪声影响.
- **差分**：在 x 方向做中心差分，更加准确（因为中心对称）.
- **整数近似**：系数简单，计算速度快.

注 5.1.2

对于连续变量的函数 $f(x)$，它在 x 处的导数定义为：

$$f'(x) = \lim_{h\to0} \frac{f(x+h) - f(x)}{h}$$

在离散信号（图像像素间隔为 1）中，我们只能进行近似计算. 常用的几种差分近似如下：

- 前向差分：$f'(x) \approx f(x+1) - f(x) \to$ 对应核 $[-1, 1]$.
- 后向差分：$f'(x) \approx f(x) - f(x-1) \to$ 对应核 $[1, -1]$.
- 中心差分：$f'(x) \approx \frac{f(x+1)-f(x-1)}{2} \to$ 对应核 $[-1, 0, 1]$ 再除以 2.

为什么 $\begin{bmatrix} -1 & 0 & 1 \end{bmatrix}$ 是中心差分（未除以 2）？将 $\begin{bmatrix} -1 & 0 & 1 \end{bmatrix}$ 与信号 f 做离散卷积（不考虑边缘）：

$$\begin{bmatrix} -1 & 0 & 1 \end{bmatrix} \begin{bmatrix} f(x-1) \\ f(x) \\ f(x+1) \end{bmatrix} = f(x+1) - f(x-1)$$

这正是中心差分公式的分子部分（相差一个因子 2）. 因为在导数近似中还有分母 $2h$：

$$f'(x) \approx \frac{f(x+h) - f(x-h)}{2h},$$

这里步长 $h = 1$，所以真正的中心差分应为 $\frac{f(x+1)-f(x-1)}{2}$.

但在边缘检测等任务中，我们只关心相对大小，是否除以 2 不影响边缘强弱的比较（所有值成比例缩放）. 因此我们常常省略除以 2，直接使用 $\begin{bmatrix} -1 & 0 & 1 \end{bmatrix}$.

差分类型	核	表达式	优点	缺点
前向	$\begin{bmatrix} -1 & 1 \end{bmatrix}$	$f(x+1) - f(x)$	简单	非对称，输出位置偏移 0.5
后向	$\begin{bmatrix} 1 & -1 \end{bmatrix}$	$f(x) - f(x-1)$	简单	存在偏移
中心	$\begin{bmatrix} -1 & 0 & 1 \end{bmatrix}$	$f(x+1) - f(x-1)$	对称，无偏移，二阶精度	需 3 个点

中心差分的好处是对当前像素位置 x 对称，不会引入半个像素的偏移，并且精度比前向/后向高（误差为 $O(h^2)$ 而非 $O(h)$）.

Sobel 的 G_x 把 $[-1, 0, 1]$ 放在中间行，同时上下两行也用了同样的模式. 同时，我们权重 1 和 2，在 y 方向做了平滑：

$$I(x, y-1) + 2I(x, y) + I(x, y+1).$$

按理说应该乘以 $\frac{1}{4}$，同样的，我们忽略了这个统一的常数.

同样地，我们还有 **Sobel 垂直边缘检测核** G_y：

$$G_y = \begin{bmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ +1 & +2 & +1 \end{bmatrix}$$

例题 5.1.

假设有一个理想的垂直边缘：左边暗（值 =10），右边亮（值 =100）. 图像尺寸 55，边缘位于第 3 列：

$$I_{\text{clean}} = \begin{bmatrix} 10 & 10 & 100 & 100 & 100 \\ 10 & 10 & 100 & 100 & 100 \\ 10 & 10 & 100 & 100 & 100 \\ 10 & 10 & 100 & 100 & 100 \\ 10 & 10 & 100 & 100 & 100 \end{bmatrix}$$

给每个像素加上均匀随机噪声（范围 $[-5, +5]$，整数），得到带噪图像 I_{noisy}. 这里手写一个具体的噪声矩阵便于计算：

$$\text{Noise} = \begin{bmatrix} +4 & -2 & +3 & -1 & +5 \\ -3 & +1 & -4 & +2 & -2 \\ +2 & -5 & +0 & -3 & +1 \\ -1 & +4 & -2 & +5 & -3 \\ +5 & -1 & +3 & -4 & +2 \end{bmatrix}$$

于是，叠加后的带噪图像为：

$$I_{\text{noisy}} = I_{\text{clean}} + \text{Noise} = \begin{bmatrix} 14 & 8 & 103 & 99 & 105 \\ 7 & 11 & 96 & 102 & 98 \\ 12 & 5 & 100 & 97 & 101 \\ 9 & 14 & 98 & 105 & 97 \\ 15 & 9 & 103 & 96 & 102 \end{bmatrix}$$

以第三行为例，

- **前向差分**：结果是有四个分量的行向量 $\begin{bmatrix} -7 & 95 & -3 & 4 \end{bmatrix}$，因为第一个元素没有前向，所以没有计算. 这意味着第 3 行第 3 列位置处的前向差分（左导数）比较大，其他位置的左导数比较小，因此第 3 行第 2 列、第 3 列之间是边缘.
- **Sobel 算子**：结果是三个分量的行向量 $\begin{bmatrix} 354 & 366 & 3 \end{bmatrix}$，这意味着第 3 行第 2 列、第 3 行第 3 列位置处的中心差分比较大，其他位置的中心差分比较小，因此第 3 行第 2 列、第 3 列之间是边缘.

比较这两种算法的结果可知：

- 两种方法都能检测到真实边缘.
- 但在非边缘区域（平坦区），**前向差分**对噪声敏感，$-7, -3, 4$ 与 95 相比差距较小.
- **Sobel** 因为垂直方向平滑（加权平均），将噪声平均掉，非边缘输出接近 3 与 354 差距较大.

注 5.1.3

1. 对上面带噪声的图像的例子，用 G_y 取处理，结果接近 0，这说明水平方向没有边缘.
2. 一般来说，我们会将 G_x, G_y 处理后的结果按 $\sqrt{G_x^2 + G_y^2}$ 合成.

所谓卷积，可以理解为加权求和. 我们考虑数据集中的数据，往往不仅要考虑数据本身，还要考虑临近数据对该数据的影响，衡量这些影响的处理方式就是赋予一定的权重. 卷积有着广泛的应用，例如：

应用领域	卷积的具体作用
音频回声	输入信号与冲激响应（含延迟和衰减的脉冲）卷积，得到带回声的声音
图像模糊	与平均核或高斯核卷积，消除噪声
卷积神经网络	每一层用多个可学习卷积核自动提取特征
雷达/声纳	发射信号与回波的互相关（本质是卷积的变种），检测目标距离
通信信道均衡	接收信号与均衡器冲激响应的卷积，补偿多径干扰

5.1.2 卷积的向量描述

设 $\boldsymbol{x}=\begin{bmatrix}x_0 & x_1 & \cdots & x_n\end{bmatrix}^{\mathrm{T}}\in\mathbb{R}^{n+1}$，$\boldsymbol{y}=\begin{bmatrix}y_0 & y_1 & \cdots & y_m\end{bmatrix}^{\mathrm{T}}\in\mathbb{R}^{m+1}$. 那么 $\boldsymbol{x}$ 和 $\boldsymbol{y}$ 的卷积 $\boldsymbol{x}*\boldsymbol{y}$ 是 $m+n+1$ 维向量 $\boldsymbol{z}=\begin{bmatrix}z_0 & z_1 & \cdots & z_{m+n}\end{bmatrix}^{\mathrm{T}}\in\mathbb{R}^{m+n+1}$，定义为：

$$z_k=\sum_{i=0}^{k}x_iy_{k-i},$$

这里我们约定超出定义范围的 x_i,y_{k-i} 都是 0.

这个定义下的卷积是所谓的线性卷积，我们还有循环卷积. 循环卷积要求两个向量为维数相等：设 $\boldsymbol{x}=\begin{bmatrix}x_0 & x_1 & \cdots & x_n\end{bmatrix}^{\mathrm{T}}$ $\boldsymbol{y}=\begin{bmatrix}y_0 & y_1 & \cdots & y_n\end{bmatrix}^{\mathrm{T}}\in\mathbb{R}^{n+1}$,那么它们的循环卷积 $\boldsymbol{x}\circledast\boldsymbol{y}$ 也是 $n+1$ 为向量 $\boldsymbol{z}=\begin{bmatrix}z_0 & z_1 & \cdots & z_n\end{bmatrix}^{\mathrm{T}}$，定义为：

$$z_k=\sum_{i=0}^{n}x_iy_{k-i},$$

其中的指标按模 $n+1$ 理解，比如说 $x_{-1}=x_n,y_2=y_{1-n}$.

例题 5.2.

设 $x=\begin{bmatrix}3\\4\end{bmatrix},\boldsymbol{y}=\begin{bmatrix}1\\2\end{bmatrix}$，那么

1. 线性卷积 $\boldsymbol{x}*\boldsymbol{y}=\begin{bmatrix}1\cdot3\\1\cdot4+3\cdot2\\2\cdot4\end{bmatrix}=\begin{bmatrix}3\\10\\8\end{bmatrix}\in\mathbb{R}^3$
2. 循环卷积 $\boldsymbol{x}\circledast\boldsymbol{y}=\begin{bmatrix}3\cdot1+4\cdot3\\3\cdot2+4\cdot1\end{bmatrix}=\begin{bmatrix}11\\10\end{bmatrix}\in\mathbb{R}^2$

例题 5.3.

设 $x=\begin{bmatrix}1\\2\\3\end{bmatrix},\boldsymbol{y}=\begin{bmatrix}4\\5\\6\end{bmatrix}$，那么

1. 线性卷积 $\boldsymbol{x}*\boldsymbol{y}=\begin{bmatrix}1\cdot4\\1\cdot5+2\cdot4\\1\cdot6+2\cdot5+3\cdot4\\2\cdot6+3\cdot5\\3\cdot6\end{bmatrix}=\begin{bmatrix}4\\13\\28\\27\\18\end{bmatrix}\in\mathbb{R}^5$

2. 循环卷积 $\boldsymbol{x} \circledast \boldsymbol{y} = \begin{bmatrix} 1\cdot 4+2\cdot 6+3\cdot 5 \\ 1\cdot 5+2\cdot 4+3\cdot 6 \\ 1\cdot 6+2\cdot 5+3\cdot 4 \end{bmatrix} = \begin{bmatrix} 31 \\ 31 \\ 28 \end{bmatrix} \in \mathbb{R}^3$

线性卷积可以用多项式乘法来表示. 对于 $\boldsymbol{x} = \begin{bmatrix} x_0 & x_1 & \cdots & x_n \end{bmatrix}^{\mathrm{T}} \in \mathbb{R}^{n+1}$，以它的分量为系数，我们可以把它对应到多项式

$$P_{\boldsymbol{x}}(t) = x_0 + x_1 t + x_2 t^2 + \cdots + x_n t^n,$$

同样的，我们有 $P_{\boldsymbol{y}}(t) = y_0 + y_1 t + y_2 t^2 + \cdots + y_m t^m$，直接计算多项式乘法即可得到

$$P_{\boldsymbol{x}}(t) P_{\boldsymbol{y}}(t) = P_{\boldsymbol{x}*\boldsymbol{y}}(t).$$

循环卷积也可以用多项式乘法来表示. 假设 $\boldsymbol{x}, \boldsymbol{y} \in \mathbb{R}^{n+1}$，我们先做线性卷积 $\boldsymbol{x} * \boldsymbol{y}$，得到 $P_{\boldsymbol{x}*\boldsymbol{y}}(t)$，然后再把 $P_{\boldsymbol{x}*\boldsymbol{y}}(t)$ 中的项的次数按照除以 $n+1$ 的余数等同，然后合并.

例题 5.4.

设 $x = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}, \boldsymbol{y} = \begin{bmatrix} 4 \\ 5 \\ 6 \end{bmatrix}$，那么 $n = 2$，$P_{\boldsymbol{x}}(t) = 1 + 2t + 3t^2, P_{\boldsymbol{y}}(t) = 4 + 5t + 6t^2$，

$$P_{\boldsymbol{x}*\boldsymbol{y}}(t) = 4 + 13t + 28t^2 + 27t^3 + 18t^4,$$

我们要把 $P_{\boldsymbol{x}*\boldsymbol{y}}(t)$ 中的项的次数按照除以 $2+1=3$ 的余数等同. 那么 $t^3 \to t^0 = 1, t^4 \to t^1$，所以

$$4 + 13t + 28t^2 + 27t^3 + 18t^4 \to 4 + 13t + 28t^2 + 27 + 18t = 31 + 31t + 27t^2.$$

由此可见，循环卷积用多项式来表示效果只能说差强人意. 为了达到多项式合并上述单项的效果，令 $P = \begin{bmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \\ 1 & 0 & 0 \end{bmatrix}$，那么

$$P^0 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}, \quad P = \begin{bmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \\ 1 & 0 & 0 \end{bmatrix}, \quad P^2 = \begin{bmatrix} 0 & 0 & 1 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix},$$

并且 $P^{3k} = I_3, P^{1+3k} = P, P^{2+3k} = P^2$. 我们把 $\boldsymbol{x}$ 对应于 $P_{\boldsymbol{x}} = x_0 P^0 + x_1 P^1 + x_2 P^2$，把 $\boldsymbol{y}$ 对应于 $P_{\boldsymbol{y}} = y_0 P^0 + y_1 P^1 + y_2 P^2$，则

$$\begin{aligned} P_{\boldsymbol{x}} P_{\boldsymbol{y}} &= (P^0 + 2P^1 + 3P^2)(4P^0 + 5P^1 + 6P^2) \\ &= 4P^0 + 13P^1 + 28P^2 + 27P^3 + 18P^4 \\ &= (4P^0 + 27P^3) + (13P^1 + 18P^4) + 28P^2 \\ &= 31P^0 + 31P^1 + 28P^2. \end{aligned}$$

一般地，对于 $\boldsymbol{x},\boldsymbol{y}\in\mathbb{R}^{n+1}$，令

$$P=\begin{bmatrix}0&1&\cdots&0\\ \vdots&\vdots&\ddots&\vdots\\ 0&0&\cdots&1\\ 1&0&\cdots&0\end{bmatrix}=\begin{bmatrix}\mathbf{0}&I_n\\ 1&\mathbf{0}^{\mathrm{T}}\end{bmatrix}\in\mathbb{R}^{n+1},$$

这个矩阵被称作移位矩阵，P^2 是把 P 的后 n 行向上挪一行，第一行挪到最后一行；P^3 是把 P^2 的后 n 行向上挪一行，第一行挪到最后一行；以此类推. 用分块矩阵来写，则

$$P^k=\begin{bmatrix}\mathbf{0}&I_{n+1-k}\\ I_k&\mathbf{0}\end{bmatrix}$$

令 $P_{\boldsymbol{x}}=x_0P^0+x_1P^1+\cdots+x_nP^n, P_{\boldsymbol{y}}=y_0P^0+y_1P^1+\cdots+y_nP^n$，那么循环卷积 $\boldsymbol{x}\circledast\boldsymbol{y}$ 对应的矩阵 $P_{\boldsymbol{x}\circledast\boldsymbol{y}}=P_{\boldsymbol{x}}P_{\boldsymbol{y}}$.

定义 5.1.1

形如

$$\begin{bmatrix}c_0&c_1&c_2&\cdots&c_{n-2}&c_{n-1}\\ c_{n-1}&c_0&c_1&\cdots&c_{n-3}&c_{n-2}\\ c_{n-2}&c_{n-1}&c_0&\cdots&c_{n-4}&c_{n-3}\\ \vdots&\vdots&\vdots&\ddots&\vdots&\vdots\\ c_2&c_3&c_4&\cdots&c_0&c_1\\ c_1&c_2&c_3&\cdots&c_{n-1}&c_0\end{bmatrix}\tag{5.1}$$

的矩阵称为循环矩阵（circulant matrix）.

例题 5.5.

二、三阶循环矩阵形如

$$\begin{bmatrix}c_0&c_1\\ c_1&c_0\end{bmatrix}=\begin{bmatrix}c_0&0\\ 0&c_0\end{bmatrix}+\begin{bmatrix}0&c_1\\ c_1&0\end{bmatrix}.$$

$$\begin{bmatrix}c_0&c_1&c_2\\ c_2&c_0&c_1\\ c_1&c_2&c_0\end{bmatrix}=\begin{bmatrix}c_0&0&0\\ 0&c_0&0\\ 0&0&c_0\end{bmatrix}+\begin{bmatrix}0&c_1&0\\ 0&0&c_1\\ c_1&0&0\end{bmatrix}+\begin{bmatrix}0&0&c_2\\ c_2&0&0\\ 0&c_2&0\end{bmatrix}.$$

我们将证明任意的 n 阶复循环矩阵 C 在复数域上可对角化，C 的特征值可以用 n 次本原单位根 ζ_n 表示，C 的“特征向量矩阵”可取作 n 阶 Fourier 矩阵 F_n.

5.1.3 循环卷积与快速傅里叶变换

矩阵 P 有很好的性质. 把 P 作用在向量 $\begin{bmatrix}x_0&x_1&\cdots&x_n\end{bmatrix}^{\mathrm{T}}$ 上得到 $\begin{bmatrix}x_1&x_2&\cdots&x_n&x_0\end{bmatrix}^{\mathrm{T}}$，作用两次得到 $\begin{bmatrix}x_2&\cdots&x_n&x_0&x_1\end{bmatrix}^{\mathrm{T}}$，续知作用 $n+1$ 次后回到原始向量 $\begin{bmatrix}x_0&x_1&\cdots&x_n\end{bmatrix}^{\mathrm{T}}$. 由此也可以看出 $P^k\neq I\ (1\leq k\leq n)$.

令 $N=n+1$. 事实上 λ^N-1 也是 P 的特征多项式. 利用对矩阵第一列的 Laplace 展开，计算可得

$$\det(\lambda I_n-P)=\begin{vmatrix}\lambda&-1&&\\ &\lambda&\ddots&\\ &&\ddots&-1\\ -1&&&\lambda\end{vmatrix}=\lambda\cdot\lambda^{N-1}+(-1)^{N+1}(-1)(-1)^{N-1}=\lambda^N-1.$$

故 P 的复特征值是所有的 N 次本原单位根 $1,\zeta_N,\zeta_N^2,\cdots,\zeta_N^n$. P 的特征向量可以通过常规的方法求，即解齐次线性方程组 $Pz=\zeta_N^k z$，$0\leq k\leq n$. 但是鉴于 P 的特殊性，我们直接“猜出” P 的特征向量. 设 ζ 是任一 N 次单位根，P 作用在向量 $\begin{bmatrix}1 & \zeta & \zeta^2 & \cdots & \zeta^{N-1}\end{bmatrix}^{\mathrm{T}}$ 上得到的是 $\begin{bmatrix}\zeta & \zeta^2 & \cdots & \zeta^{N-1} & 1\end{bmatrix}^{\mathrm{T}}$. 由于 ζ 是 N 次单位根，即 $\zeta^N=1$，故后者是前者的 ζ 倍. 于是，对任意的 N 次单位根 ζ, 我们找到了一个属于 ζ 的特征向量 $\begin{bmatrix}1 & \zeta & \zeta^2 & \cdots & \zeta^{N-1}\end{bmatrix}^{\mathrm{T}}$.

取 $\zeta=1,\zeta_N,\zeta_N^2,\cdots,\zeta_N^{N-1}$，这就得到了 N 个特征向量，把这 N 个特征向量排成矩阵：

$$F_N=\begin{bmatrix}e_0 & e_1 & \cdots & e_{N-1}\end{bmatrix}=\begin{bmatrix}1 & 1 & 1 & \cdots & 1\\ 1 & \zeta_N & \zeta_N^2 & \cdots & \zeta_N^{N-1}\\ 1 & \zeta_N^2 & \zeta_N^{2\cdot 2} & \cdots & \zeta_N^{2(N-1)}\\ \vdots & \vdots & \vdots & \ddots & \vdots\\ 1 & \zeta_N^{N-1} & \zeta_N^{(N-1)2} & \cdots & \zeta_N^{(N-1)(N-1)}\end{bmatrix}.$$

称 F_N 为 N 阶 Fourier 矩阵.

命题 5.1.1

若将 F_N 的行、列下标用 $0,1,\cdots,N-1$ 表示，则 F_N 的第 (k,ℓ) 位置元素是 $\zeta_N^{k\ell}$，故 F_N 是（复）对称阵. ♠

命题 5.1.2

F_N 是 Vandermonde 矩阵. ♠

命题 5.1.3

F_N 的列 $e_0,e_1,\cdots,e_{N-1}$ 是 $\mathbb{C}^N$ 的一组正交基. ♠

证明 事实上，对任意的 $0\leq k,\ell\leq N-1,k\neq\ell$，计算得

$$\begin{aligned}\langle e_k,e_\ell\rangle&=\left\langle\begin{bmatrix}1 & \zeta_N^k & \zeta_N^{2k} & \cdots & \zeta_N^{(N-1)k}\end{bmatrix}^{\mathrm{T}},\begin{bmatrix}1 & \zeta_N^\ell & \zeta_N^{2\ell} & \vdots & \zeta_N^{(N-1)\ell}\end{bmatrix}^{\mathrm{T}}\right\rangle\\&=\sum_{m=0}^{N-1}\zeta_N^{mk}\overline{\zeta_N^{m\ell}}=\sum_{m=0}^{N-1}\zeta_N^{mk}\zeta_N^{-m\ell}=\sum_{m=0}^{N-1}\zeta_N^{(\ell-k)m}.\end{aligned}$$

第二行的推导中用到了 $\zeta_N^{mk}=(\bar{\zeta}_N)^{mk}=(\zeta_N^{-1})^{mk}=\zeta_N^{-mk}$，这是因为 ζ_N 的模为 1，故 $\bar{\zeta}_N=\zeta_N^{-1}$.

由于 $0\leq k\neq\ell\leq N-1$, 所以 $\ell-k\neq 0$ 且 $|\ell-k|\leq N-1$, 于是 $\zeta_N^{\ell-k}=\mathrm{e}^{\frac{2\pi\mathrm{i}}{N}(\ell-k)}\neq 1$. 另一方面，显然有 $(\zeta_N^{\ell-k})^N=\zeta_N^{N(\ell-k)}=1$. 所以

$$\sum_{m=0}^{N-1}\zeta_N^{(\ell-k)m}=1+\zeta_N^{\ell-k}+(\zeta_N^{\ell-k})^2+\cdots+(\zeta_N^{\ell-k})^{N-1}=\frac{1-\zeta_N^{(\ell-k)N}}{1-\zeta_N^{\ell-k}}=0.$$

于是 $\langle e_k,e_\ell\rangle=0,\forall k\neq\ell$. 又因 $e_0,e_1,\cdots,e_{N-1}$ 均不是零向量，故它们是 $\mathbb{C}^N$ 的正交基.

命题 5.1.4

$F_N\bar{F}_N=\bar{F}_NF_N=NI_N$, $F_N^{-1}=\frac{1}{N}\bar{F}_N$, $\frac{1}{\sqrt{N}}F_N$ 是酉阵. ♠

证明 事实上，由于 F_N 中元素 $\zeta_N^{k\ell}$ 的模均为 1，我们得知

$$\|e_0\|=\|e_1\|=\cdots=\|e_{N-1}\|=\sqrt{1^2+\cdots+1^2}=\sqrt{N},$$

故 $\frac{1}{\sqrt{N}}e_0,\frac{1}{\sqrt{N}}e_1,\cdots,\frac{1}{\sqrt{N}}e_{N-1}$ 是 $\mathbb{C}^N$ 的标准正交基，从而以它们为列构成的矩阵 $\frac{1}{\sqrt{N}}F_N$ 是酉阵，于是

$$\frac{1}{\sqrt{N}}F_N\left(\frac{1}{\sqrt{N}}F_N\right)^H=\left(\frac{1}{\sqrt{N}}F_N\right)^H\frac{1}{\sqrt{N}}F_N=I_N.$$

由于 $F_N^{\mathrm{T}} = F_N$, 所以 $F_N^H = \bar{F}_N^{\mathrm{T}} = \bar{F}_N$, 于是

$$\frac{1}{\sqrt{N}}F_N\frac{1}{\sqrt{N}}\bar{F}_N = \frac{1}{\sqrt{N}}\bar{F}_N\frac{1}{\sqrt{N}}F_N = I_N,$$

也就是 $F_N\bar{F}_N = \bar{F}_N F_N = NI_N$, 由此易知 $F_N^{-1} = \frac{1}{N}\bar{F}_N$.

例题 5.6.

规定 $F_1 = (1)$. 根据定义 $F_2 = \begin{bmatrix} 1 & 1 \\ 1 & \zeta_2 \end{bmatrix}$, 其中 $\zeta_2 = \mathrm{e}^{\frac{2\pi\mathrm{i}}{2}} = \mathrm{e}^{\pi\mathrm{i}} = -1$, 故 $F_2 = \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}$.

更多的例子

$$F_3 = \begin{bmatrix} 1 & 1 & 1 \\ 1 & \zeta_3 & \zeta_3^2 \\ 1 & \zeta_3^2 & \zeta_3^4 \end{bmatrix} = \begin{bmatrix} 1 & 1 & 1 \\ 1 & -\frac{1}{2}+\frac{\sqrt{3}}{2}\mathrm{i} & -\frac{1}{2}-\frac{\sqrt{3}}{2}\mathrm{i} \\ 1 & -\frac{1}{2}-\frac{\sqrt{3}}{2}\mathrm{i} & -\frac{1}{2}+\frac{\sqrt{3}}{2}\mathrm{i} \end{bmatrix},$$

$$F_4 = \begin{bmatrix} 1 & 1 & 1 & 1 \\ 1 & \zeta_4 & \zeta_4^2 & \zeta_4^3 \\ 1 & \zeta_4^2 & \zeta_4^4 & \zeta_4^6 \\ 1 & \zeta_4^3 & \zeta_4^6 & \zeta_4^9 \end{bmatrix} = \begin{bmatrix} 1 & 1 & 1 & 1 \\ 1 & \mathrm{i} & -1 & -\mathrm{i} \\ 1 & -1 & 1 & -1 \\ 1 & -\mathrm{i} & -1 & \mathrm{i} \end{bmatrix}.$$

将 F_4 的列按照第一列、第三列、第二列、第四列的顺序重新排列以后得到的矩阵是

$$\underbrace{\begin{bmatrix} 1 & 1 & 1 & 1 \\ 1 & \mathrm{i} & -1 & -\mathrm{i} \\ 1 & -1 & 1 & -1 \\ 1 & -\mathrm{i} & -1 & \mathrm{i} \end{bmatrix}}_{F_4}\underbrace{\begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}}_{P} = \begin{bmatrix} 1 & 1 & 1 & 1 \\ 1 & -1 & \mathrm{i} & -\mathrm{i} \\ 1 & 1 & -1 & -1 \\ 1 & -1 & -\mathrm{i} & \mathrm{i} \end{bmatrix},$$

其中左上角和左下角的 2 阶子块都恰是 F_2, 右上角的子块是 D_2F_2, 右下角的子块是 $-D_2F_2$, 其中 $D_2 = \mathrm{diag}(1, \mathrm{i})$. 于是

$$F_4P = \begin{bmatrix} F_2 & D_2F_2 \\ F_2 & -D_2F_2 \end{bmatrix} = \begin{bmatrix} I_2 & D_2 \\ I_2 & -D_2 \end{bmatrix}\begin{bmatrix} F_2 & 0 \\ 0 & F_2 \end{bmatrix}.$$

由于置换阵的逆矩阵同转置，所以

$$F_4 = \begin{bmatrix} I_2 & D_2 \\ I_2 & -D_2 \end{bmatrix}\begin{bmatrix} F_2 & 0 \\ 0 & F_2 \end{bmatrix}\underbrace{\begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}}_{P^{\mathrm{T}}}.$$

定义 5.1.2

对于 $\boldsymbol{x} \in \mathbb{R}^N$，其离散傅里叶变换定义为：

$$\mathcal{F}(\boldsymbol{x}) := F_N\boldsymbol{x}.$$

注 5.1.4

我们也可以定义逆变换：设 $\boldsymbol{w} \in \mathbb{R}^N$，如果 $\boldsymbol{x}$ 使得 $\boldsymbol{w} = \mathcal{F}(\boldsymbol{x})$，则定义 $\boldsymbol{w}$ 的离散傅里叶逆变换为

$$\boldsymbol{x} := \mathcal{F}^{-1}(\boldsymbol{w}),$$

根据命题5.1.4，

$$\boldsymbol{x} := \mathcal{F}^{-1}(\boldsymbol{w}) = \frac{1}{N}\bar{F}_N \boldsymbol{w}.$$

如果 $\boldsymbol{x} = \begin{bmatrix} x_0 & x_1 & \cdots x_{N-1} \end{bmatrix}^{\mathrm{T}}$，$\boldsymbol{w} = \mathcal{F}(\boldsymbol{x}) = \begin{bmatrix} w_0 & w_1 & \cdots w_{N-1} \end{bmatrix}^{\mathrm{T}}$，那么

$$w_i = \sum_{k=0}^{N-1} \zeta_N^{ik} x_k.$$

命题 5.1.5

$$\mathcal{F}(\boldsymbol{x} \circledast \boldsymbol{y}) = \mathcal{F}(\boldsymbol{x}) \odot \mathcal{F}(\boldsymbol{y}),$$

其中，$\mathcal{F}(\boldsymbol{x}) \odot \mathcal{F}(\boldsymbol{y})$ 的定义为：它的分量是 $\mathcal{F}(\boldsymbol{x})$ 与 $\mathcal{F}(\boldsymbol{y})$ 同一位置的分量乘积.

证明 $\mathcal{F}(\boldsymbol{x}) \odot \mathcal{F}(\boldsymbol{y})$ 的第 i 个分量为

$$\sum_{k=0}^{N-1} \zeta_N^{ik} \sum_{\ell=0}^{N-1} x_\ell y_{k-\ell} = \sum_{k=0}^{N-1}\sum_{\ell=0}^{N-1} \zeta_N^{i\ell} x_\ell \zeta_N^{i(k-\ell)} y_{k-\ell} = \left(\sum_{\ell=0}^{N-1} \zeta_N^{i\ell} x_\ell\right)\left(\sum_{k=0}^{N-1} \zeta_N^{ik} y_k\right)$$

根据命题5.1.4，

推论 5.1.1

如果 $\boldsymbol{x}, \boldsymbol{y} \in \mathbb{R}^N$，则

$$\boldsymbol{x} \circledast \boldsymbol{y} = \frac{1}{N}\bar{F}_N \left(\mathcal{F}(\boldsymbol{x}) \odot \mathcal{F}(\boldsymbol{y})\right).$$

离散傅立叶变换

$$\boldsymbol{w} = F_N \boldsymbol{x} \tag{5.2}$$

和离散傅立叶逆变换

$$\boldsymbol{x} = \frac{1}{N}\bar{F}_N \boldsymbol{w} \tag{5.3}$$

都可以用 Fourier 矩阵 F_N 表示. 快速 Fourier 变换 (FFT) 是快速计算离散 Fourier 变换 (离散傅里叶变换) 的方法. 由于(5.2)和(5.3)中的矩阵相差无几，确切的说，把 F_N 中的 N 次本原单位根 $\zeta_N = \mathrm{e}^{\frac{2\pi \mathrm{i}}{N}}$ 换成 $\bar{\zeta}_N = \zeta_N^{-1} = \mathrm{e}^{-\frac{2\pi \mathrm{i}}{N}}$，再把整个矩阵乘以常数因子 $\frac{1}{N}$ 就得到了 $\frac{1}{N}\bar{F}_N$，我们仅讨论如何快速计算逆变换，即如何快速计算 $F_N \boldsymbol{x}$，这里面用到的关键想法也适用于快速计算 $\frac{1}{N}\bar{F}_N \boldsymbol{w}$.

FFT 算法的关键是 N 是偶数时 Fourier 矩阵 F_N 和 $F_{N/2}$ 的关系.

定理 5.1.1

设 $N = 2n$ 是偶数，令 P_N 是第 $(1,1), (2,3), \cdots, (n, 2n-1), (n+1, 2), (n+2, 4), \cdots, (2n, 2n)$ 位置元素是 1，其余元素是 0 的 N 阶置换阵，$D_n = \mathrm{diag}(1, \zeta_N, \zeta_N^2, \cdots, \zeta_N^{n-1})$，则

$$F_N = \begin{bmatrix} I_n & D_n \\ I_n & -D_n \end{bmatrix} \begin{bmatrix} F_n & 0 \\ 0 & F_n \end{bmatrix} P_N. \tag{5.4}$$

证明 验证 $F_N P_N^{\mathrm{T}}$ 是将 F_N 的列按照第 $1, 3, \cdots, 2n-1, 2, 4, \cdots, 2n$ 的顺序重新排列后得到的矩阵. 验证若把重排后的矩阵分成上下左右四个 $n \times n$ 阶子阵，则左上角左下角都恰是 F_n，右上角和右下角分别是 $D_n F_n$ 和 $-D_n F_n$. 要用到 $\zeta_N^2 = \zeta_N$. 细节略.

理解(5.4)式的正确方式是把它作用在一个向量 $\boldsymbol{c} = \begin{bmatrix} c_0 & c_1 & \cdots & c_{2n-2} & c_{2n-1} \end{bmatrix}^{\mathrm{T}}$ 上.

首先，$P_N \boldsymbol{c} = \begin{bmatrix} c_0 & c_2 & \cdots & c_{2n-2} & c_1 & c_3 & \cdots & c_{2n-1} \end{bmatrix}^{\mathrm{T}}$，即左乘 P_N 是把 $\boldsymbol{c}$ 的分量按下标的奇偶性先偶后

奇重新排列且内部顺序不变. 记 $\boldsymbol{c}' = \begin{bmatrix} c_0 & c_2 & \cdots & c_{2n-2} \end{bmatrix}^{\mathrm{T}}, \boldsymbol{c}'' = \begin{bmatrix} c_1 & c_3 & \cdots & c_{2n-1} \end{bmatrix}^{\mathrm{T}}$，$P_N \boldsymbol{c} = \begin{bmatrix} \boldsymbol{c}' \\ \boldsymbol{c}'' \end{bmatrix}$，则

$$\begin{bmatrix} F_n & 0 \\ 0 & F_n \end{bmatrix} P_N \boldsymbol{c} = \begin{bmatrix} F_n & 0 \\ 0 & F_n \end{bmatrix} \begin{bmatrix} \boldsymbol{c}' \\ \boldsymbol{c}'' \end{bmatrix} = \begin{bmatrix} F_n \boldsymbol{c}' \\ F_n \boldsymbol{c}'' \end{bmatrix} = \begin{bmatrix} \boldsymbol{y}' \\ \boldsymbol{y}'' \end{bmatrix}.$$

其中 $\boldsymbol{y}' = F_n \boldsymbol{c}', \boldsymbol{y}'' = F_n \boldsymbol{c}''$ 是分别对 $\boldsymbol{c}', \boldsymbol{c}''$ 作 n 阶 Fourier 逆变换后得到的向量. 最后，

$$F_N \boldsymbol{c} = \begin{bmatrix} I_n & D_n \\ I_n & -D_n \end{bmatrix} \begin{bmatrix} \boldsymbol{y}' \\ \boldsymbol{y}'' \end{bmatrix} = \begin{bmatrix} y_1' + y_1'' \\ y_2' + \zeta_N y_2'' \\ \vdots \\ y_n' + \zeta_N^{n-1} y_n'' \\ y_1' - y_1'' \\ y_2' - \zeta_N y_2'' \\ \vdots \\ y_n' - \zeta_N^{n-1} y_n'' \end{bmatrix},$$

其中 $\boldsymbol{y}' = \begin{bmatrix} y_1' & \cdots & y_n' \end{bmatrix}^{\mathrm{T}}, \boldsymbol{y}'' = \begin{bmatrix} y_1'' & \cdots & y_n'' \end{bmatrix}$.

粗略的说，计算 $F_N \boldsymbol{c}$ 可以化解为一些置换，两次 $N/2$ 阶 Fourier 逆变换，$N/2$ 次乘法，和 N 次加减法. 若 $N/2$ 仍是偶数，则上面的两次 $N/2$ 阶 Fourier 逆变换都可化成置换，两次 $N/4$ 阶 Fourier 逆变换，$N/4$ 次乘法，和 $N/2$ 次加减法. 特别的，若 $N = 2^d$ 是 2 的 d 次幂，则我们可以如此迭代 d 次.

例题 5.7. $N = 2^3 = 8$

输入 $\boldsymbol{c} = \begin{bmatrix} c_0 & c_1 & c_2 & c_3 & c_4 & c_5 & c_6 & c_7 \end{bmatrix}^{\mathrm{T}}$. 为了计算 $F_8 c$，我们先把 $\boldsymbol{c}$ 重新排列成 $\begin{bmatrix} \boldsymbol{c}' \\ \boldsymbol{c}'' \end{bmatrix} = \begin{bmatrix} c_0 & c_2 & c_4 & c_6 & c_1 & c_3 & c_5 & c_7 \end{bmatrix}^{\mathrm{T}}$，然后计算 $F_4 \boldsymbol{c}'$ 和 $F_4 \boldsymbol{c}''$.

为了计算 $F_4 \boldsymbol{c}'$，我们先把 $\boldsymbol{c}' = \begin{bmatrix} c_0 & c_2 & c_4 & c_6 \end{bmatrix}^{\mathrm{T}}$ 重排为 $\begin{bmatrix} c_0 & c_4 & c_2 & c_6 \end{bmatrix}^{\mathrm{T}}$，然后计算 $F_2 \begin{bmatrix} c_0 \\ c_4 \end{bmatrix} = \begin{bmatrix} c_0 + c_4 \\ c_0 - c_4 \end{bmatrix}$ 和 $F_2 \begin{bmatrix} c_2 \\ c_6 \end{bmatrix} = \begin{bmatrix} c_2 + c_6 \\ c_2 - c_6 \end{bmatrix}$，于是

$$F_4 \boldsymbol{c}' = \begin{bmatrix} (c_0 + c_4) + (c_2 + c_6) \\ (c_0 - c_4) + (c_2 - c_6) \\ (c_0 + c_4) - (c_2 + c_6) \\ (c_0 - c_4) - (c_2 - c_6) \end{bmatrix}. \quad \text{同理，} \quad F_4 \boldsymbol{c}'' = \begin{bmatrix} (c_1 + c_5) + (c_3 + c_7) \\ (c_1 - c_5) + \mathrm{i}(c_3 - c_7) \\ (c_1 + c_5) - (c_3 + c_7) \\ (c_1 - c_5) - \mathrm{i}(c_3 - c_7) \end{bmatrix}.$$

最后我们回到第一层的第三步得到

$$F_8 \boldsymbol{c} = \begin{bmatrix} [(c_0 + c_4) + (c_2 + c_6)] + [(c_1 + c_5) + (c_3 + c_7)] \\ [(c_0 - c_4) + \mathrm{i}(c_2 - c_6)] + w_8 [(c_1 - c_5) + \mathrm{i}(c_3 - c_7)] \\ [(c_0 + c_4) - (c_2 + c_6)] + w_8^2 [(c_1 + c_5) - (c_3 + c_7)] \\ [(c_0 - c_4) - \mathrm{i}(c_2 - c_6)] + w_8^3 [(c_1 - c_5) - \mathrm{i}(c_3 - c_7)] \\ [(c_0 + c_4) + (c_2 + c_6)] - [(c_1 + c_5) + (c_3 + c_7)] \\ [(c_0 - c_4) + \mathrm{i}(c_2 - c_6)] - w_8 [(c_1 - c_5) + \mathrm{i}(c_3 - c_7)] \\ [(c_0 + c_4) - (c_2 + c_6)] - w_8^2 [(c_1 + c_5) - (c_3 + c_7)] \\ [(c_0 - c_4) - \mathrm{i}(c_2 - c_6)] - w_8^3 [(c_1 - c_5) - \mathrm{i}(c_3 - c_7)] \end{bmatrix}.$$

用 Fourier 矩阵的分解表示这个过程是

$$F_8 = \begin{bmatrix} I_4 & D_4 \\ I_4 & -D_4 \end{bmatrix} \begin{bmatrix} F_4 & 0 \\ 0 & F_4 \end{bmatrix} P_8$$

$$= \begin{bmatrix} I_4 & D_4 \\ I_4 & -D_4 \end{bmatrix} \begin{bmatrix} I_2 & D_2 & & \\ I_2 & -D_2 & & \\ & & I_2 & D_2 \\ & & I_2 & -D_2 \end{bmatrix} \begin{bmatrix} 1 & 1 & & & & & & \\ 1 & -1 & & & & & & \\ & & 1 & 1 & & & & \\ & & 1 & -1 & & & & \\ & & & & 1 & 1 & & \\ & & & & 1 & -1 & & \\ & & & & & & 1 & 1 \\ & & & & & & 1 & -1 \end{bmatrix} \begin{bmatrix} P_4 & 0 \\ 0 & P_4 \end{bmatrix} P_8.$$

最右边两个置换阵的乘积作用在 $\boldsymbol{c}$ 上等于

$$\begin{bmatrix} P_4 & 0 \\ 0 & P_4 \end{bmatrix} P_8 \begin{bmatrix} c_0 \\ c_1 \\ c_2 \\ c_3 \\ c_4 \\ c_5 \\ c_6 \\ c_7 \end{bmatrix} = \begin{bmatrix} c_0 \\ c_4 \\ c_2 \\ c_6 \\ c_1 \\ c_5 \\ c_3 \\ c_7 \end{bmatrix}.$$

注 5.1.5

Curious observation: $0,1,2,3,4,5,6,7$ 的二进制表示依次是

$$000, 001, 010, 011, 100, 101, 110, 111,$$

把以上二进制表示中的 digits 的顺序全部倒过来后我们得到

$$000, 100, 010, 110, 001, 101, 011, 111,$$

而这恰是 $0,4,2,6,1,5,3,7$ 的二进制表示.

当 $N = 2^d$ 时，生算 $F_N\boldsymbol{c}$ 需要进行 N^2 次乘法运算. 若用 Fourier 迭代，则大约只需 $\frac{N}{2}d = \frac{1}{2}N\log_2 N$ 次乘法运算，其中 d 是迭代的次数，$\frac{N}{2}$ 是每层迭代中最后一步需要的乘法的次数. 当 $N = 2^{10} = 1024$ 时，N^2 约等于 $1,000,000$, 而 $\frac{1}{2}N\log_2 N$ 约等于 5000. 由此可见，FFT 节省了很多计算耗能.

Fourier 变换在数学、物理、工程、信息等领域都有广泛应用，很多时候它可以用来压缩信号（比如一段录音或者一张图片），这是因为现实生活中遇到的信号一般比较光滑，所以它们的 Fourier 系数衰减的很快，用最前面的若干个 Fourier 系数重建的信号与原始信号相差无几，比如 JPEG, mp3 的压缩原理都是 Fourier 变换.

当 $w = \zeta_N^k, 0 \le k \le n-1$ 时，这些特征向量恰是 Fourier 矩阵 F_n 的列. F_n 可逆，于是我们得到

$$F_n^{-1} P F_n = \begin{bmatrix} 1 & & & \\ & \zeta_N & & \\ & & \ddots & \\ & & & \zeta_N^{n-1} \end{bmatrix}.$$

上式也可写作

$$\left(\frac{F_n}{\sqrt{n}}\right)^H P\left(\frac{F_n}{\sqrt{n}}\right)=\begin{bmatrix}1 & & & \\ & \zeta_N & & \\ & & \ddots & \\ & & & \zeta_N^{n-1}\end{bmatrix}.$$

这里，$\frac{F_n}{\sqrt{n}}$ 是酉阵.

P 中副对角线上的 1 往右上移动一格，左下角的 1 也往右上移动一格同时“分裂”成两个 1，得到的矩阵仍是置换阵，而且恰是 P^2.

若 $Pz=\lambda z$, 则 $P^2z=P(Pz)=P(\lambda z)=\lambda Pz=\lambda\lambda z=\lambda^2 z$. 这说明 P 的特征向量也是 P^2 的特征向量，且作为后者特征向量的特征值是作为前者特征向量的特征值的平方. 于是，Fourier 矩阵 F_n 也可把 P^2 对角化，而且 P^2 的“特征值矩阵”是 P 的“特征值矩阵”的平方.

$$F_n^{-1}P^2F_n=\begin{bmatrix}1 & & & \\ & \zeta_N^2 & & \\ & & \ddots & \\ & & & \zeta_N^{2(n-1)}\end{bmatrix}.$$

显而易见，以上结论可以推广到 P 的任意 m 次幂（$m\geq 1$）. 具体的说，我们有

$$F_n^{-1}P^mF_n=\begin{bmatrix}1 & & & \\ & \zeta_N^m & & \\ & & \ddots & \\ & & & (\zeta_N^{n-1})^m\end{bmatrix}.$$

任一 n 阶循环阵 C 是 $I_n,P,P^2,\cdots,P^{n-1}$ 的线性组合.

引理 5.1.1

设 C 是(5.1)式的 n 阶循环矩阵，P 是 (1.9) 中的 n 阶置换阵，则

$$C=c_0I+c_1P+c_2P^2+\cdots+c_{n-1}P^{n-1}.$$

♠

证明 容易.

定理 5.1.2

设 C 是(5.1)式中的 n 阶循环矩阵，令 $f(x)=c_0+c_1x+\cdots+c_{n-1}x^{n-1}$, F_n 是 n 阶 Fourier 矩阵，则

$$F_n^{-1}CF_n=\operatorname{diag}(f(1),f(\zeta_N),\cdots,f(\zeta_N^{n-1})).$$

♡

特别的，C 的特征值是 $f(1),f(\zeta_N),\cdots,f(\zeta_N^{n-1})$, 其行列式是

$$\det C=f(1)f(\zeta_N)\cdots f(\zeta_N^{n-1}).$$

证明 直接计算

$$
\begin{aligned}
F_n^{-1}CF_n &= F_n^{-1}(c_0I + c_1P + \cdots + c_{n-1}P^{n-1})F_n \\
&= c_0I + c_1(F_n^{-1}PF_n) + \cdots + c_{n-1}(F_n^{-1}P^{n-1}F_n) \\
&= c_0I + c_1\begin{bmatrix} 1 & & & \\ & \zeta_N & & \\ & & \ddots & \\ & & & \zeta_N^{n-1} \end{bmatrix} + \cdots + c_{n-1}\begin{bmatrix} 1 & & & \\ & \zeta_N^{n-1} & & \\ & & \ddots & \\ & & & (\zeta_N^{n-1})^{n-1} \end{bmatrix} \\
&= \begin{bmatrix} c_0 + c_1 + \cdots + c_{n-1} & & & \\ & c_0 + c_1\zeta_N + \cdots + c_{n-1}\zeta_N^{n-1} & & \\ & & \ddots & \\ & & & c_0 + c_1\zeta_N^{n-1} + \cdots + c_{n-1}(\zeta_N^{n-1})^{n-1} \end{bmatrix} \\
&= \begin{bmatrix} f(1) & & & \\ & f(\zeta_N) & & \\ & & \ddots & \\ & & & f(\zeta_N^{n-1}) \end{bmatrix}.
\end{aligned}
$$

例题 5.8.

2 阶循环阵 $C = \begin{bmatrix} c_0 & c_1 \\ c_1 & c_0 \end{bmatrix} = c_0I + c_1P$, 其中 $P = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$. 2 阶 Fouier 矩阵 $F_2 = \begin{bmatrix} 1 & 1 \\ 1 & \zeta_2 \end{bmatrix}$, $\zeta_2 = -1$.

F_2 的列 $\begin{bmatrix} 1 \\ 1 \end{bmatrix}, \begin{bmatrix} 1 \\ -1 \end{bmatrix}$ 是 C 的特征向量，特征值分别是 $f(1) = c_0 + c_1$, $f(-1) = c_0 - c_1$, 其中 $f(x) = c_0 + c_1x$.

F_2 把 C 对角化

$$
F_2^{-1}CF_2 = \begin{bmatrix} c_0 + c_1 & \\ & c_0 - c_1 \end{bmatrix}.
$$

C 的行列式是 $\det C = c_0^2 - c_1^2 = (c_0 + c_1)(c_0 - c_1) = f(1)f(-1)$.

例题 5.9.

3 阶循环阵 $C = \begin{bmatrix} c_0 & c_1 & c_2 \\ c_2 & c_0 & c_1 \\ c_1 & c_2 & c_0 \end{bmatrix}$ 的行列式用 Laplace 公式计算是

$$
\begin{aligned}
\det C &= c_0(c_0^2 - c_1c_2) - c_1(c_0c_2 - c_1^2) + c_2(c_2^2 - c_0c_1) \\
&= c_0^3 + c_1^3 + c_2^3 - 3c_0c_1c_2.
\end{aligned}
$$

另一方面，我们知道

$$
\det C = f(1)f(w)f(w^2) = (c_0 + c_1 + c_2)(c_0 + c_1w + c_2w^2)(c_0 + c_1w^2 + c_2w),
$$

其中 $w = \zeta_3 = \mathrm{e}^{\frac{2\pi\mathrm{i}}{3}} = -\frac{1}{2} + \frac{\sqrt{3}}{2}\mathrm{i}$.

5.2 二维离散傅里叶变换

前一节我们学习了向量（以为张量）的离散傅里叶变换和快速傅里叶变换的算法，这一节我们讨论二维的离散傅里叶变换. 为什么要研究二维以及更高维的离散傅里叶变换？因为现实世界中的数据往往是多维的：

- **图像**：二维空间信号（高度 × 宽度）
- **视频**：三维信号（高度 × 宽度 × 时间）
- **多光谱图像**：更高维数的数据

二维傅里叶变换使我们能够将图像从空间域（像素坐标）变换到频率域（空间频率），从而揭示图像中不同方向、不同尺度的结构信息.

对于二维连续函数 $f(x,y)$，其二维傅里叶变换为

$$F(u,v)=\iint_{-\infty}^{\infty} f(x,y)\,\mathrm{e}^{-2\pi(ux+vy)\mathrm{i}}\mathrm{d}x\mathrm{d}y. \tag{5.5}$$

对应的逆变换为

$$f(x,y)=\iint_{-\infty}^{\infty} F(u,v)\,\mathrm{e}^{2\pi(ux+vy)\mathrm{i}}\mathrm{d}u\mathrm{d}v. \tag{5.6}$$

注 5.2.1

如果从物理的角度去理解，函数表示电磁波信号，

- (x,y) 为空间域坐标
- (u,v) 为频率域坐标
- u 表示 x 方向的空间频率，v 表示 y 方向的空间频率

二维傅里叶变换的积分核为

$$\phi_{u,v}(x,y)=e^{j2\pi(ux+vy)}=\cos[2\pi(ux+vy)]+\sin[2\pi(ux+vy)]\mathrm{i}. \tag{5.7}$$

这些是二维复正弦波—它们在 x 和 y 两个方向上同时振荡. 当 u,v 不同时，这些波的方向和频率都不同.

- $\sqrt{u^2+v^2}$ 决定了波的径向频率
- $\theta=\tan^{-1}(v/u)$ 决定了波的传播方向

对于 $M\times N$ 的离散信号 $X=\left[x_{mn}\right]_{0\le m\le M-1,0\le n\le N-1}$，二维离散傅里叶变换定义为

$$w_{k\ell}=\sum_{m=0}^{M-1}\sum_{n=0}^{N-1} x_{mn}\mathrm{e}^{-2\pi\left(\frac{km}{M}+\frac{\ell n}{N}\right)\mathrm{i}}. \tag{5.8}$$

逆变换为

$$x_{mn}=\frac{1}{MN}\sum_{k=0}^{M-1}\sum_{\ell=0}^{N-1} w_{k\ell}\mathrm{e}^{2\pi\left(\frac{km}{M}+\frac{\ell n}{N}\right)\mathrm{i}}. \tag{5.9}$$

5.2.1 矩阵表示

我们有一个非常重要的观察：二维离散傅里叶变换可以写成矩阵形式. 令 $\boldsymbol{X}$ 为 $M\times N$ 的输入矩阵，$\boldsymbol{F}_M$ 为 M 阶傅里叶矩阵：

$$(\boldsymbol{F}_M)_{k,m}=\mathrm{e}^{-\frac{2\pi km}{M}\mathrm{i}},\qquad k,m=0,\dots,M-1. \tag{5.10}$$

命题 5.2.1

二维离散傅里叶变换可以表示为

$$\boldsymbol{W}=\mathcal{F}(\boldsymbol{X}):=\boldsymbol{F}_M\boldsymbol{X}\boldsymbol{F}_N^{\mathrm{T}}. \tag{5.11}$$

证明 证明很简单，就是矩阵乘法而已：

$$
\begin{aligned}
(\boldsymbol{F}_M \boldsymbol{X})_{kn} &= \sum_m \mathrm{e}^{-\frac{2\pi km}{M}\mathrm{i}} x_{mn}, \\
(\boldsymbol{F}_M \boldsymbol{X} \boldsymbol{F}_N^{\mathrm{T}})_{k\ell} &= \sum_n \left(\sum_m \mathrm{e}^{-\frac{2\pi km}{M}\mathrm{i}} x_{mn} \right) \mathrm{e}^{-\frac{2\pi \ell n}{N}\mathrm{i}} \\
&= \sum_m \sum_n x_{mn} \mathrm{e}^{-2\pi\left(\frac{km}{M}+\frac{\ell n}{N}\right)\mathrm{i}}.
\end{aligned}
$$

这正是二维离散傅里叶变换的定义式.

这个矩阵形式极为重要，它揭示了二维离散傅里叶变换与张量运算的联系.

性质 1. 卷积定理

设 $\boldsymbol{X} = \left[x_{mn}\right]$ 和 $\boldsymbol{Y} = \left[y_{mn}\right]$ 是两个 $M \times N$ 矩阵，它们的**循环卷积** $\boldsymbol{X} \circledast \boldsymbol{Y}$ 定义为

$$
z_{mn} = \sum_{i=0}^{M-1} \sum_{j=0}^{N-1} x_{ij} y_{(m-i)(n-j)},
$$

其中的指标分别按模 M 和 N 理解. 那么我们有

$$
\mathcal{F}(\boldsymbol{X} \circledast \boldsymbol{Y})_{k\ell} = \mathcal{F}(\boldsymbol{X})_{k\ell} \cdot \mathcal{F}(\boldsymbol{Y})_{k\ell},
$$

性质 2. 帕塞瓦尔定理

$$
\sum_{m=0}^{M-1} \sum_{n=0}^{N-1} |x_{mn}|^2 = \frac{1}{MN} \sum_{k=0}^{M-1} \sum_{\ell=0}^{N-1} |w_{k\ell}|^2.
$$

它的物理意义是：能量在空间域和频率域守恒.

另一方面，二维离散傅里叶变换和一维离散傅里叶变换也是有联系的：

性质 3. 可分离性—最重要性质

二维离散傅里叶变换可以分解为两次一维离散傅里叶变换的复合：

$$
w_{k\ell} = \sum_{m=0}^{M-1} \left[\sum_{n=0}^{N-1} x_{mn} \mathrm{e}^{-\frac{2\pi \ell n}{N}\mathrm{i}} \right] \mathrm{e}^{-\frac{2\pi km}{M}\mathrm{i}}. \tag{5.12}
$$

简而言之，二维离散傅里叶变换可以视作先对每一行变换，再对每一列做变换（或反之）. 从计算的角度，由于一维离散傅里叶变换有快速傅里叶变换的算法，因此计算复杂度从 $O(M^2N^2)$ 降至 $O\big(MN\log(MN)\big)$.

5.3 张量

二维离散傅里叶变换的每一层都可以看作是对数据张量的特定维数的线性变换.

表 5.1: 从标量到张量

对象	阶数	表示法	示例
标量	0 阶	$a \in \mathbb{R}$	温度、能量
向量	1 阶	$\boldsymbol{a} \in \mathbb{R}^N$	力、速度
矩阵	2 阶	$\boldsymbol{A} \in \mathbb{R}^{M\times N}$	图像、线性变换
张量	N 阶	$\mathcal{A} \in \mathbb{R}^{I_1\times\cdots\times I_N}$	高维数据

5.3.1 从标量、向量、矩阵到张量

定义 5.3.1

张量是多重线性映射. 一个 (p,q) 型张量是从 q 个对偶空间和 p 个原空间的笛卡尔积到标量域的多重线性映射. 在给定基底下，张量由多维数组表示.

以三阶张量 $\mathcal{A} \in \mathbb{R}^{I\times J\times K}$ 为例：

- **纤维 (Fiber)**：固定所有指标值，只变化一个指标得到的向量.
  - 列纤维 (Mode-1)：$\mathcal{A}(:,j,k)$
  - 行纤维 (Mode-2)：$\mathcal{A}(i,:,k)$
  - 管纤维 (Mode-3)：$\mathcal{A}(i,j,:)$
- **切片 (Slice)**：固定两个指标值，变化一个指标得到的矩阵.
  - 水平切片：$\mathcal{A}(i,:,:)$
  - 侧向切片：$\mathcal{A}(:,j,:)$
  - 正面切片：$\mathcal{A}(:,:,k)$

张量的矩阵化意在将高阶张量”压平”为矩阵，使得矩阵论的工具（SVD、特征值分解、Moore–Penrose 伪逆等）可以应用于张量数据. 它也是 Tucker 分解、HOSVD 等算法的基础操作.

设 $\mathcal{A} \in \mathbb{R}^{I_1\times I_2\times\cdots\times I_N}$ 是一个 N 阶张量. 它的 **Mode-n 展开**（也称为 n-模矩阵化）是按第 n 个指标展开成一个矩阵，记作 $\boldsymbol{A}_{(n)}$：

$$\boldsymbol{A}_{(n)} \in \mathbb{R}^{I_n\times M_n}, \qquad M_n = \prod_{\substack{k=1\\k\neq n}}^{N} I_k.$$

展开后，原张量中的元素 $a_{i_1 i_2\cdots i_N}$ 被映射到矩阵 $\boldsymbol{A}_{(n)}$ 的位置 (i_n, j)，其中

$$j = 1 + \sum_{\substack{k=1\\k\neq n}}^{N} (i_k - 1)J_k, \qquad J_k = \prod_{\substack{m=1\\m\neq n}}^{k-1} I_m.$$

这个公式可以理解为：将除第 n 维以外的所有指标“展平”成一个线性序号 j，按**高阶指标优先**的顺序排列.

对于三阶张量 $\mathcal{A} \in \mathbb{R}^{I\times J\times K}$，有三种展开，分别为：

1. **Mode-1 展开** $\boldsymbol{A}_{(1)} \in \mathbb{R}^{I\times JK}$：行对应第一维，列由 (j,k) 配对给出，其中指标 k 优先（即按 $\mathcal{A}(i,:,1), \mathcal{A}(i,:,2), \ldots$ 排列各正面切片）
2. **Mode-2 展开** $\boldsymbol{A}_{(2)} \in \mathbb{R}^{J\times IK}$：行对应第二维，列由 (i,k) 配对，指标 k 优先
3. **Mode-3 展开** $\boldsymbol{A}_{(3)} \in \mathbb{R}^{K\times IJ}$：行对应第三维，列由 (i,j) 配对，指标 j 优先

我们不打算写出一般公式，以下给一些实际的例子，感觉一下所谓的展开是什么意思.

例题 5.10. $2\times3\times2$ 张量的 Mode-1 展开

设 $\mathcal{A}\in\mathbb{R}^{2\times3\times2}$，其两个正面切片为：

$$\mathcal{A}(:,:,1)=\begin{bmatrix}a_{111}&a_{121}&a_{131}\\a_{211}&a_{221}&a_{231}\end{bmatrix},\qquad \mathcal{A}(:,:,2)=\begin{bmatrix}a_{112}&a_{122}&a_{132}\\a_{212}&a_{222}&a_{232}\end{bmatrix}.$$

Mode-1 展开按 k（第三维）先变化、j（第二维）后变化的顺序将所有切片横向并列：

$$\boldsymbol{A}_{(1)}=\begin{bmatrix}a_{111}&a_{121}&a_{131}&a_{112}&a_{122}&a_{132}\\a_{211}&a_{221}&a_{231}&a_{212}&a_{222}&a_{232}\end{bmatrix}\in\mathbb{R}^{2\times6}.$$

图示：每一行固定第 1 维指标 i；列的变化顺序是 $(j,k)=(1,1),(2,1),(3,1),(1,2),(2,2),(3,2)$，即 k 先变化（每个 k 内部 j 再循环一次）.

例题 5.11. $2\times3\times2$ 张量的 Mode-2 展开

同一张量的 Mode-2 展开. 先将张量视为沿第 2 维排列的三个" 侧面切片"（固定 j）：

$$\mathcal{A}(:,1,:)=\begin{bmatrix}a_{111}&a_{112}\\a_{211}&a_{212}\end{bmatrix},\ \mathcal{A}(:,2,:)=\begin{bmatrix}a_{121}&a_{122}\\a_{221}&a_{222}\end{bmatrix},\ \mathcal{A}(:,3,:)=\begin{bmatrix}a_{131}&a_{132}\\a_{231}&a_{232}\end{bmatrix}.$$

按 k（第三维）先变化、i（第一维）后变化的顺序横向并列：

$$\boldsymbol{A}_{(2)}=\begin{bmatrix}a_{111}&a_{112}&a_{211}&a_{212}\\a_{121}&a_{122}&a_{221}&a_{222}\\a_{131}&a_{132}&a_{231}&a_{232}\end{bmatrix}\in\mathbb{R}^{3\times4}.$$

注意这里 Mode-2 展开矩阵只有 $J=3$ 行，每行对应一个 j 值；列顺序是 $(i,k)=(1,1),(1,2),(2,1),(2,2)$ 的循环（k 优先）逐 j 拼接.

例题 5.12. $2\times2\times2$ 张量的完全展开

设 $\mathcal{A}\in\mathbb{R}^{2\times2\times2}$ 的元素为

$$a_{111}=1,\ a_{121}=3,\quad a_{112}=5,\ a_{122}=7,$$
$$a_{211}=2,\ a_{221}=4,\quad a_{212}=6,\ a_{222}=8.$$

即正面切片为：

$$\mathcal{A}(:,:,1)=\begin{bmatrix}1&3\\2&4\end{bmatrix},\qquad \mathcal{A}(:,:,2)=\begin{bmatrix}5&7\\6&8\end{bmatrix}.$$

Mode-1 展开（$I=2$ 行，$J\times K=2\times2=4$ 列，k 变化最快）：

$$\boldsymbol{A}_{(1)}=\big[\,\mathcal{A}(:,:,1),\ \mathcal{A}(:,:,2)\,\big]=\begin{bmatrix}1&3&5&7\\2&4&6&8\end{bmatrix}.$$

Mode-2 展开（$J=2$ 行，$I\times K=2\times 2=4$ 列，k 变化最快）：

$$\boldsymbol{A}_{(2)}=\big[\,\mathcal{A}(:,1,:),\ \mathcal{A}(:,2,:)\,\big]_{\text{按列展开}}=\begin{bmatrix}1&5&3&7\\2&6&4&8\end{bmatrix}.$$

Mode-3 展开（$K=2$ 行，$I\times J=2\times 2=4$ 列，j 变化最快）：

$$\boldsymbol{A}_{(3)}=\begin{bmatrix}1&3&2&4\\5&7&6&8\end{bmatrix}.$$

三个展开矩阵的阶数分别为 2×4、2×4、2×4，但元素的排列顺序完全不同.

理解展开的另一种视角是**纤维 (fiber)**. 对于 $\mathcal{A}\in\mathbb{R}^{I\times J\times K}$：

- Mode-1 纤维（列纤维）$\mathcal{A}(:,j,k)$：固定 j,k，变化 i. Mode-1 展开矩阵 $\boldsymbol{A}_{(1)}$ 的各列正是这些列纤维
- Mode-2 纤维（行纤维）$\mathcal{A}(i,:,k)$：固定 i,k，变化 j. $\boldsymbol{A}_{(2)}$ 的各列正是这些行纤维
- Mode-3 纤维（管纤维）$\mathcal{A}(i,j,:)$：固定 i,j，变化 k. $\boldsymbol{A}_{(3)}$ 的各列正是这些管纤维

纤维视图下的展开规则

张量的 Mode-n 展开矩阵 $\boldsymbol{A}_{(n)}$ 的列是张量的所有 Mode-n 纤维. 列的排列顺序是：其他指标按" 从 N 到 1 跳过 n" 的循环顺序变化，其中**较大序号的指标优先**.

矩阵化的逆操作称为**折叠**，将展开矩阵 $\boldsymbol{A}_{(n)}\in\mathbb{R}^{I_n\times M_n}$ 还原为原张量. 给定展开矩阵和原始维数 $(I_1,\dots,I_N)$，折叠操作是唯一确定的：

$$\operatorname{fold}_n(\boldsymbol{A}_{(n)})=\mathcal{A}.$$

在 MATLAB 中，这由 `reshape`$(\boldsymbol{A}_{(n)}^{\mathrm{T}},[I_1,\dots,I_N])$ 和 `permute` 组合实现.

注 5.3.1

设 $\mathcal{A}$ 是 N 阶张量，若其 Tucker 分解为 $\mathcal{A}=\mathcal{G}\times_1\boldsymbol{U}^{(1)}\times_2\cdots\times_N\boldsymbol{U}^{(N)}$，则 Mode-$n$ 展开有如下重要关系：

$$\boldsymbol{A}_{(n)}=\boldsymbol{U}^{(n)}\boldsymbol{G}_{(n)}\left(\boldsymbol{U}^{(N)}\otimes\cdots\otimes\boldsymbol{U}^{(n+1)}\otimes\boldsymbol{U}^{(n-1)}\otimes\cdots\otimes\boldsymbol{U}^{(1)}\right)^{\mathrm{T}}.$$

这个公式在 HOSVD 算法中至关重要，它将张量的 Mode-n 展开与因子矩阵的 Kronecker 积直接联系起来.

5.4 张量的运算与分解

5.4.1 Kronecker 积

Kronecker 积是两个矩阵（或张量）之间的运算. 对于 $\boldsymbol{A}\in\mathbb{R}^{m\times n}$ 和 $\boldsymbol{B}\in\mathbb{R}^{p\times q}$：

$$\boldsymbol{A}\otimes\boldsymbol{B}=\begin{bmatrix}a_{11}\boldsymbol{B}&a_{12}\boldsymbol{B}&\cdots&a_{1n}\boldsymbol{B}\\a_{21}\boldsymbol{B}&a_{22}\boldsymbol{B}&\cdots&a_{2n}\boldsymbol{B}\\\vdots&\vdots&\ddots&\vdots\\a_{m1}\boldsymbol{B}&a_{m2}\boldsymbol{B}&\cdots&a_{mn}\boldsymbol{B}\end{bmatrix}\in\mathbb{R}^{mp\times nq}.$$

关键性质（在傅里叶分析中至关重要）：

$$(\boldsymbol{A}\otimes\boldsymbol{B})(\boldsymbol{C}\otimes\boldsymbol{D})=(\boldsymbol{AC})\otimes(\boldsymbol{BD}), \tag{5.13}$$

$$(\boldsymbol{A}\otimes\boldsymbol{B})^{-1}=\boldsymbol{A}^{-1}\otimes\boldsymbol{B}^{-1}, \tag{5.14}$$

$$\operatorname{vec}(\boldsymbol{AXB}^{\mathrm{T}})=(\boldsymbol{B}\otimes\boldsymbol{A})\operatorname{vec}(\boldsymbol{X}). \tag{5.15}$$

其中 vec(·) 是向量化算子，将矩阵按列堆叠为向量.

5.4.2 Mode-n 乘积（张量与矩阵的乘法）

张量 $\mathcal{A}\in\mathbb{R}^{I_1\times\cdots\times I_N}$ 与矩阵 $\boldsymbol{U}\in\mathbb{R}^{J\times I_n}$ 的 Mode-n 乘积：

$$(\mathcal{A}\times_n\boldsymbol{U})_{i_1\cdots i_{n-1}ji_{n+1}\cdots i_N}=\sum_{i_n=1}^{I_n}a_{i_1\cdots i_N}u_{ji_n}. \tag{5.16}$$

结果是一个新张量，维数为 $I_1\times\cdots\times I_{n-1}\times J\times I_{n+1}\times\cdots\times I_N$.

5.4.3 缩并 (Contraction)

张量的缩并是指对两个指标求和. 例如，矩阵乘法就是 $(1,2)$ 型张量的缩并：

$$\boldsymbol{C}=\boldsymbol{AB}\implies c_{ij}=\sum_k a_{ik}b_{kj}.$$

更高阶张量的缩并更多样化，例如对三阶张量的两个指标求和.

5.4.4 CP 分解

CP 分解的全称为 **CANDECOMP/PARAFAC**，由两个独立的工作共同命名：

- **CANDECOMP** (Canonical Decomposition) — Carroll & Chang, 1970，源自心理测量学
- **PARAFAC** (Parallel Factor Analysis) — Harshman, 1970，源自语音学

两者的核心思想完全相同：将一个高阶张量表示为**最少个秩-1 张量的和**. CP 分解是矩阵 SVD 向高阶张量的最直接推广，其简洁的数学结构使其成为张量分析中最基本、最常用的工具之一.

定义 5.4.1 (CP 分解)

对于 N 阶张量 $\mathcal{A}\in\mathbb{R}^{I_1\times I_2\times\cdots\times I_N}$，其 CP 分解为

$$\mathcal{A}\approx\sum_{r=1}^{R}\boldsymbol{a}_r^{(1)}\circ\boldsymbol{a}_r^{(2)}\circ\cdots\circ\boldsymbol{a}_r^{(N)}, \tag{5.17}$$

其中：

- $\boldsymbol{a}_r^{(n)}\in\mathbb{R}^{I_n}$ 称为第 r 个因子在第 n 模上的载荷向量
- $\circ$ 表示向量外积 **(outer product)**：$(\boldsymbol{a}\circ\boldsymbol{b}\circ\boldsymbol{c})_{ijk}=a_ib_jc_k$
- R 称为 **CP** 秩（或张量的秩）
- 各因子向量通常被归一化，幅度信息吸收进权重 λ_r

注 5.4.1

理论上，CP 秩（记为 $\operatorname{rank}(\mathcal{A})$）被定义为能够精确重构该张量所需的最少秩一张量的个数 R，即满足上述等式成立的最小正整数 R. 尽管从定义看与矩阵的秩非常相似，但张量秩比矩阵秩复杂得多，主要体现在以下几个方面：

- 计算复杂度（**NP-hard**）：矩阵的秩可以通过高斯消元法或奇异值分解（SVD）在多项式时间内求出. 然而，确定一个高阶张量的真实 CP 秩是一个 **NP-hard** 问题. 这意味着对于大规模高维数据，从理论上精确计算其最小 CP 秩在计算上是不可行的.

- 域的相关性：矩阵的秩在实数域 $\mathbb{R}$ 和复数域 $\mathbb{C}$ 上是相同的. 但对于张量，其在实数域下的秩可能与在复数域下的秩不同. 例如，某些实值张量在 $\mathbb{R}$ 上的秩为 3，但在 $\mathbb{C}$ 上的秩可能仅为 2.
- 缺乏半连续性：矩阵的低秩逼近具有良好的性质，但张量集合的边界行为非常复杂（如“退化”现象），导致寻找最优低秩逼近并不总是有解.

在实际的数据科学、机器学习及信号处理应用中，我们几乎从不追求理论上的“最小精确秩”，而是将 R 视为一个人为设定的超参数.
实际数据通常包含噪声. 如果我们强行寻找能完美还原数据的理论秩，往往会得到一个极大的 R 值，这不仅会导致严重的过拟合（将噪声也当作特征学习），还会带来巨大的计算成本. 因此，实用中的 CP 分解通常写作(5.17)的近似形式，此时的 R 代表了使用者希望提取的潜在因子（**Latent Factors**）的数量. 例如在推荐系统中，R 对应预设的用户兴趣类别数；在化学计量学中，R 对应混合样本中的化学成分种类数.

由于无法预先知道最佳的 R，工程上通常采用以下策略进行选择：

1. 试错法与碎石图（**Scree Plot**）：尝试一系列递增的 R 值（如 $R = 2, 3, \ldots, 10$），计算重构误差（如 Frobenius 范数下的相对误差）. 绘制误差随 R 变化的曲线，选取误差下降趋于平缓的“拐点”作为合适的秩.
2. 核心一致性诊断（**Core Consistency Diagnostic**）：这是一种专门用于 CP 分解的诊断工具. 通过计算 Tucker 分解核心张量的一致性指标，若该指标在某个 R 处突然大幅下降，则说明该 R 超过了数据的真实结构复杂度.
3. 交叉验证（**Cross-Validation**）：将数据分为训练集和验证集，选择能使验证集预测误差最小的 R.

当处理四维及以上的高维张量时（如“用户 × 商品 × 时间 × 地点”），随着 R 的增加，参数数量呈指数增长（称为维数灾难）. 此时，即使设定了较小的 R，传统的交替最小二乘法（ALS）也可能面临内存溢出或收敛缓慢的问题. 针对这种情况，现代实践中常引入随机化 **CP** 分解（**Randomized CP**），通过随机投影降低计算维度，从而在可接受的时间内获得稳定的近似解.

总而言之，理解 CP 秩的关键在于区分“数学上的存在性”与“工程上的可用性”. 在实际操作中，我们应当根据具体的业务需求和数据特性，灵活地选择一个适中的 R 值，以在模型复杂度与数据还原度之间取得最佳平衡.

对于三阶张量 $\mathcal{A} \in \mathbb{R}^{I\times J\times K}$，CP 分解的完整形式为

$$\mathcal{A} = \sum_{r=1}^{R} \lambda_r \, \boldsymbol{u}_r \circ \boldsymbol{v}_r \circ \boldsymbol{w}_r, \tag{5.18}$$

其中 λ_r 是权重标量（通常按非增排列），$\boldsymbol{u}_r \in \mathbb{R}^I, \boldsymbol{v}_r \in \mathbb{R}^J, \boldsymbol{w}_r \in \mathbb{R}^K$. 用元素的形式也可以写成：

$$a_{ijk} \approx \sum_{r=1}^{R} u_{ir} \, v_{jr} \, w_{kr}, \tag{5.19}$$

或者带权重的完整形式：

$$a_{ijk} = \sum_{r=1}^{R} \lambda_r \, u_{ir} \, v_{jr} \, w_{kr}.$$

用**因子矩阵**来表示，也可以写得紧凑一些：

$$\boldsymbol{U} = [\boldsymbol{u}_1, \ldots, \boldsymbol{u}_R] \in \mathbb{R}^{I\times R}, \qquad \boldsymbol{V} = [\boldsymbol{v}_1, \ldots, \boldsymbol{v}_R] \in \mathbb{R}^{J\times R}, \qquad \boldsymbol{W} = [\boldsymbol{w}_1, \ldots, \boldsymbol{w}_R] \in \mathbb{R}^{K\times R}.$$

则 CP 分解可以表示为

$$\boldsymbol{A}_{(1)} \approx \boldsymbol{U} \, (\boldsymbol{W} \odot \boldsymbol{V})^{\mathrm{T}}, \tag{5.20}$$

其中 $\odot$ 表示 Khatri–Rao 积（按列 Kronecker 积）：

$$\boldsymbol{W} \odot \boldsymbol{V} = [\boldsymbol{w}_1 \otimes \boldsymbol{v}_1,\ \boldsymbol{w}_2 \otimes \boldsymbol{v}_2,\ \ldots,\ \boldsymbol{w}_R \otimes \boldsymbol{v}_R] \in \mathbb{R}^{JK \times R}.$$

例题 5.13. 矩阵的 CP 秩

对于一个矩阵 $\boldsymbol{A} \in \mathbb{R}^{I \times J}$（二阶张量），CP 分解退化为矩阵的秩-$R$ SVD：

$$\boldsymbol{A} = \sum_{r=1}^{R} \boldsymbol{u}_r \circ \boldsymbol{v}_r = \boldsymbol{U}\boldsymbol{V}^{\mathrm{T}}.$$

当要求 $\boldsymbol{u}_r, \boldsymbol{v}_r$ 分别正交时，这就是截断 SVD. 因此，CP 分解是 SVD 向高阶张量的直接推广.

与 Tucker 分解不同，CP 分解在非常温和的条件下是**本质唯一**的. Kruskal (1977) 证明了：

性质 1. 唯一性（Kruskal 定理）

对于三阶张量，若

$$k_{\boldsymbol{U}} + k_{\boldsymbol{V}} + k_{\boldsymbol{W}} \geq 2R + 2,$$

其中 $k_{\boldsymbol{U}}$ 是 $\boldsymbol{U}$ 的 Kruskal 秩（任意 $k_{\boldsymbol{U}}$ 列线性无关的最大数），则 CP 分解在列置换和列缩放的意义下唯一.

这一性质使 CP 分解在**盲源分离**中极具价值：即使没有先验信息，分解结果仍可识别出物理上可解释的潜变量.

性质 2. 置换与缩放模糊性

CP 分解的唯一性仅限于以下两个平凡自由度：

$$\text{置换：}\quad \pi(r) = \sigma(r), \tag{5.21}$$

$$\text{缩放：}\quad \boldsymbol{a}_r^{(n)} \leftarrow \alpha_r^{(n)} \boldsymbol{a}_r^{(n)},\quad \prod_{n=1}^{N} \alpha_r^{(n)} = 1. \tag{5.22}$$

即因子向量的列顺序可以交换，且各因子之间可以相互补偿尺度因子.

5.4.4.1 算法：交替最小二乘 (ALS)

CP 分解的标准算法是 ALS (Alternating Least Squares)，它交替地固定 $N-1$ 个因子矩阵、更新第 N 个.

算法: CP-ALS

Input: $\mathcal{A} \in \mathbb{R}^{I_1 \times I_2 \times \cdots \times I_N}$，目标秩 R

1. **初始化**：随机或使用 HOSVD 初始化 $\boldsymbol{U}^{(1)}, \ldots, \boldsymbol{U}^{(N)}$
2. **迭代**直至收敛或达最大迭代次数： 对 $n = 1, \ldots, N$:
   1. 计算 **Khatri–Rao 积**：
   $$\boldsymbol{Z} = \boldsymbol{U}^{(N)} \odot \cdots \odot \boldsymbol{U}^{(n+1)} \odot \boldsymbol{U}^{(n-1)} \odot \cdots \odot \boldsymbol{U}^{(1)}$$
   2. 展开张量：$\boldsymbol{A}_{(n)} \in \mathbb{R}^{I_n \times (\prod_{k \neq n} I_k)}$
   3. 最小二乘更新：
   $$\boldsymbol{U}^{(n)} \leftarrow \boldsymbol{A}_{(n)} \boldsymbol{Z} \left(\boldsymbol{Z}^{\mathrm{T}} \boldsymbol{Z}\right)^{\dagger}$$
   其中 $(\cdot)^{\dagger}$ 表示 Moore–Penrose 伪逆
3. **归一化**：将 $\boldsymbol{U}^{(n)}$ 的各列归一化，幅度存入 λ_r

Output: $\lambda_r, \boldsymbol{U}^{(1)}, \ldots, \boldsymbol{U}^{(N)}$

注 5.4.2 (ALS 的优缺点)

- 优点：每一步都是标准的最小二乘问题，实现简单，对三阶张量尤为高效.
- 缺点：
  1. 收敛可能很慢，尤其在 R 较大时
  2. 可能收敛到局部极小（算法不保证全局最优）
  3. 对初始化敏感，建议多次随机重启计算
  4. 存在退化问题：两个因子分量趋于无穷大但相互抵消，导致 ALS 发散

有一些常用的改进措施：

- **Line Search** 增强：在 ALS 迭代中引入线性搜索加速收敛 (Bro, 1998)
- 阻尼 **ALS (Damped ALS)**：加入步长控制，避免振荡和发散
- 非负 **CP (NCP)**：约束所有因子非负，适合光谱数据等非负物理量
- 稀疏 **CP**：加入 ℓ_1 正则化鼓励因子稀疏
- 正交 **CP**：强制因子正交，牺牲拟合优度换取可解释性

注 5.4.3

以下罗列一些 CP 分解的典型应用

1. 荧光光谱分析：激发-发射矩阵数据集构成三阶张量（样本 × 激发波长 × 发射波长），CP 分解可唯一地识别出各荧光团的光谱和浓度.
2. 盲源分离 **(BSS)**：CP 分解的唯一性使其天然适合从混合信号中恢复独立源，无需像 ICA 那样假设非高斯性.
3. 化学计量学：PARAFAC 是化学计量学中最标准的工具之一，用于色谱-质谱联用数据的多路解析.
4. 潜在变量模型：CP 分解等价于一个多视角潜在变量模型，每个因子对应一个潜在维数.
5. 时间序列分析：将多维时间序列构建为张量，CP 分解提取潜在的时空模式.

5.4.5 CP 与 Fourier 的联系：循环卷积的 CP 结构

循环卷积与 CP 分解有深刻的代数联系. 对于两个一维信号 $\boldsymbol{x}, \boldsymbol{y} \in \mathbb{R}^N$，它们的循环卷积为 $\boldsymbol{x} \circledast \boldsymbol{y}$，分量为

$$(\boldsymbol{x} \circledast \boldsymbol{y})_k = \sum_{i=0}^{N-1} x_i y_{k-i}$$

其中的下标按模 N 理解. 引入**循环移位矩阵 $\boldsymbol{P}_N$**，则循环卷积可写为

$$\boldsymbol{x} \circledast \boldsymbol{y} = \sum_{i=0}^{N-1} x_i \boldsymbol{P}_N^i \boldsymbol{y}.$$

将 $\boldsymbol{P}_N^k$ 视为线性映射，循环卷积核 $\boldsymbol{H}_{\boldsymbol{x}}$ 是**循环矩阵** $\boldsymbol{H}_{\boldsymbol{x}} = \sum_i x_i \boldsymbol{P}_N^i$，而离散傅里叶变换将其对角化：$\boldsymbol{F}_N \boldsymbol{H}_{\boldsymbol{x}} \boldsymbol{F}_N^{-1} = \operatorname{diag}(\hat{\boldsymbol{x}})$.

从 CP 角度：**二维循环卷积可以用秩-N 的 CP 分解表示**. 卷积核矩阵 $\boldsymbol{H}_{\boldsymbol{x}}$ 实际上是

$$\boldsymbol{H}_{\boldsymbol{x}} = \sum_{i=0}^{N-1} x_i \boldsymbol{P}_N^i,$$

其中每个 $\boldsymbol{P}_N^i$ 是一个置换矩阵（秩 N 的 CP 分量），$\boldsymbol{H}_{\boldsymbol{x}}$ 本身是循环矩阵. 离散傅里叶变换的对角化性质

$$\boldsymbol{F}_N \boldsymbol{P}_N^k \boldsymbol{F}_N^{-1} = \operatorname{diag}(\omega_N^k, \omega_N^{2k}, \ldots, \omega_N^{Nk})$$

则对应 CP 分解在傅里叶域的因子化表示.

对于二维循环卷积（如图像的循环卷积），其卷积核是一个**块循环矩阵**，可以用二维离散傅里叶变换和 Kronecker 积对角化：

$$\boldsymbol{H}_{\mathrm{2D}} = \sum_{m,n} x[m,n] \, (\boldsymbol{P}_M^m \otimes \boldsymbol{P}_N^n).$$

这对应一个秩不超过 MN 的 CP 分解，而二维离散傅里叶变换将其循环卷积变换为逐点乘法.

5.4.5.1 CP 秩与多维离散傅里叶变换的结构

离散傅里叶变换矩阵本身具有 CP 结构. N 点离散傅里叶变换矩阵 $\boldsymbol{F}_N$（其元素为 ω_N^{kn}）可以看作三阶张量

$$\mathcal{F}(k,n,\omega) = \omega^{kn}$$

沿频率轴的一个切片. 对于固定的 $\omega = \omega_N$，$\boldsymbol{F}_N$ 本身不是低秩的. 但考虑**多维离散傅里叶变换矩阵的张量化**：

$$\boldsymbol{F}_{N_1} \otimes \boldsymbol{F}_{N_2} \otimes \cdots \otimes \boldsymbol{F}_{N_D}$$

其每一行/列对应一个多维频率. 如果将这个 Kronecker 积展开为高阶张量，CP 分解可以揭示多维离散傅里叶变换的张量列车 (TT) 结构（见下文张量列车分解）.

5.5 Tucker 分解

矩阵的奇异值分解 (SVD) 将一个矩阵 $\boldsymbol{A} \in \mathbb{R}^{M \times N}$ 分解为

$$\boldsymbol{A} = \boldsymbol{U} \boldsymbol{\Sigma} \boldsymbol{V}^{\mathrm{T}} = \sum_{r=1}^{R} \sigma_r \, \boldsymbol{u}_r \circ \boldsymbol{v}_r,$$

其中 $R = \min(M,N)$，$\boldsymbol{u}_r, \boldsymbol{v}_r$ 是正交奇异向量，σ_r 是奇异值. SVD 在数据压缩、降维去噪中的成功自然地引出一个问题：能否将 SVD 推广到高阶张量？Tucker 分解正是对这一问题的回答.

设有一个 N 阶张量 $\mathcal{A} \in \mathbb{R}^{I_1 \times I_2 \times \cdots \times I_N}$. Tucker 分解旨在将 $\mathcal{A}$ 近似表示为一个核心张量与 N 个因子矩阵的乘积：

$$\mathcal{A} \approx \mathcal{G} \times_1 \boldsymbol{U}^{(1)} \times_2 \boldsymbol{U}^{(2)} \times_3 \cdots \times_N \boldsymbol{U}^{(N)} \tag{5.23}$$

其中：

- $\mathcal{G} \in \mathbb{R}^{R_1 \times R_2 \times \cdots \times R_N}$ 称为**核心张量 (Core Tensor)**. 它的维数满足 $R_n \le I_n$ $(n = 1, \ldots, N)$，用于刻画各个模态因子之间的交互强度与高阶关联.
- $\boldsymbol{U}^{(n)} \in \mathbb{R}^{I_n \times R_n}$ 称为第 n 模态的**因子矩阵 (Factor Matrix)**. 要求其列向量为标准正交基（即 $\boldsymbol{U}^{(n)\mathrm{T}} \boldsymbol{U}^{(n)} = \boldsymbol{I}_{R_n}$），代表了原始张量在第 n 个维度上的主成分方向或特征子空间.
- $\times_n$ 表示张量与矩阵的 **n-模积 (mode-n product)**.

Tucker 解的目标是寻找最优的 $\mathcal{G}$ 和 $\{\boldsymbol{U}^{(n)}\}_{n=1}^{N}$，使得误差（通常采用 Frobenius 范数）最小：

$$\min_{\mathcal{G},\{\boldsymbol{U}^{(n)}\}} \left\| \mathcal{A} - \mathcal{G} \times_1 \boldsymbol{U}^{(1)} \times_2 \cdots \times_N \boldsymbol{U}^{(N)} \right\|_F^2$$

注 5.5.1 (关于因子矩阵 $U^{(n)}$ 的物理意义)

从线性代数的角度来看，因子矩阵 $\boldsymbol{U}^{(n)}$ 可以视为原始张量在第 n 个模态（维度）展开后的特征基. 在实际计算中（例如通过高阶奇异值分解 HOSVD），$\boldsymbol{U}^{(n)}$ 的列向量通常取为张量沿第 n 模态展开矩阵的前 R_n 个左奇异向量.

注 5.5.2

Tucker 分解可视为高阶主成分分析 **(Higher-Order PCA, HOPCA)**. 与矩阵 PCA 不同的是，Tucker 分解允许沿每个模提取不同数量的主成分 ($P \neq Q \neq R$)，因此更加灵活.

注 5.5.3

Tucker 分解的参数随阶数指数增长（$\prod_n R_n$ 项），在阶数很高时变得不可行. 张量列车分解 (Tensor Train, TT) 通过链式结构将高阶张量分解为一系列三阶核心张量的链式乘积，参数数量降至 $O(NR^2I)$，是 Tucker 分解在高维场景下的重要替代.

$$\mathcal{A}(i_1, i_2, \ldots, i_N) = \sum_{\alpha_1, \ldots, \alpha_{N-1}} \mathcal{G}_1(1, i_1, \alpha_1)\, \mathcal{G}_2(\alpha_1, i_2, \alpha_2) \cdots \mathcal{G}_N(\alpha_{N-1}, i_N, 1),$$

其中 $\mathcal{G}_n \in \mathbb{R}^{R_{n-1} \times I_n \times R_n}$ 是 TT-核心，$R_0 = R_N = 1$. 这是一种高效的张量表示方法，特别适合处理高维数据.

例题 5.14.

对于三阶张量 $\mathcal{A} \in \mathbb{R}^{I \times J \times K}$，Tucker 分解的元素形式为

$$a_{ijk} \approx \sum_{p=1}^{P} \sum_{q=1}^{Q} \sum_{r=1}^{R} g_{pqr}\, u_{ip}\, v_{jq}\, w_{kr},$$

其中 $P \leq I$, $Q \leq J$, $R \leq K$.

利用 Mode-n 展开，Tucker 分解可以写成等价的矩阵形式：

$$\boldsymbol{A}_{(n)} = \boldsymbol{U}^{(n)} \boldsymbol{G}_{(n)} \left(\boldsymbol{U}^{(N)} \otimes \cdots \otimes \boldsymbol{U}^{(n+1)} \otimes \boldsymbol{U}^{(n-1)} \otimes \cdots \otimes \boldsymbol{U}^{(1)}\right)^{\mathrm{T}}.$$

这揭示了 Tucker 分解与矩阵 SVD 的深层联系：沿每个模的展开矩阵被分解为因子矩阵 $\boldsymbol{U}^{(n)}$ 与一个” 折叠的” 矩阵的乘积.

5.5.1 性质

性质 1. 正交性

若 Tucker 分解中各因子矩阵列正交，则核心张量具有 **全正交**性：

$$\langle \mathcal{G}_{i_n=\alpha}, \mathcal{G}_{i_n=\beta} \rangle = 0 \quad (\alpha \neq \beta),$$

这就是说，核心张量沿同一模的不同切片是正交的. 这里 $\langle \cdot, \cdot \rangle$ 是张量内积.

性质 2. 保持 Frobenius 范数

当所有因子矩阵正交时，

$$\|\mathcal{A}\|_F^2 = \|\mathcal{G}\|_F^2 = \sum_{p,q,r} g_{pqr}^2.$$

即：核心张量元素的平方和等于原张量的总能量.

性质 3. 非唯一性

与矩阵 SVD 不同（奇异值排序保证了唯一性），**Tucker 分解不具有唯一性**. 如果对核心张量加一个可逆变换 $\boldsymbol{Q}$ 并对因子矩阵进行逆变换 $\boldsymbol{Q}^{-1}$，则分解保持不变：

$$\mathcal{G} \times_n \boldsymbol{U}^{(n)} = (\mathcal{G} \times_n \boldsymbol{Q}) \times_n (\boldsymbol{U}^{(n)} \boldsymbol{Q}^{-1}).$$

这一自由度可通过附加其它约束条件（如正交性、稀疏性、非负性）来获得特定性质的分解.

例题 5.15.

我们有一些常用的特殊形式的 Tucker 分解

- **Tucker-1 分解**：仅沿一个模做分解，等价于对该模的展开矩阵做 SVD：

$$\mathcal{A} = \mathcal{G} \times_1 \boldsymbol{U}^{(1)} \quad \Longleftrightarrow \quad \boldsymbol{A}_{(1)} = \boldsymbol{U}^{(1)} \boldsymbol{G}_{(1)}.$$

- **Tucker-2 分解**：固定一个因子矩阵为单位矩阵（即不对该模进行压缩）. 例如，对三阶张量：

$$\mathcal{A} = \mathcal{G} \times_1 \boldsymbol{U} \times_2 \boldsymbol{V} \times_3 \boldsymbol{I}.$$

  这在第三维较小时有用（如彩色图像 $M \times N \times 3$，第三维仅 3 个通道）.
- **秩-$(R_1, R_2, \ldots, R_N)$ 截断**：只保留每个模上前 R_n 个主成分，得到近似分解.

5.5.2 与 CP 分解的对比

我们列一个表格，把 Tucker 分解和 CP 分解进行对比

表 5.2: Tucker 分解与 CP 分解的对比

特征	Tucker 分解	CP 分解
参数数量	$\prod_n R_n + \sum_n I_n R_n$	$R \sum_n I_n$
核心张量	全张量 $\mathcal{G}$（各模可不同大小）	对角张量 $\mathcal{G}$（所有模等大小）
灵活性	各模可独立选择 R_n	所有模共享同一个 R
唯一性	不唯一（需附加约束）	在温和条件下唯一
计算	HOSVD + HOOI 迭代	ALS 交替最小二乘
算法保证	HOOI 保证收敛到驻点	ALS 可能陷入局部极小

5.5.3 算法

高阶 SVD (HOSVD) 是 Tucker 分解最基本的计算方法，由 De Lathauwer 等 (2000) 提出. HOSVD 计算出的 Tucker 分解是**准最优**的 (quasi-optimal). 对于固定秩 $(R_1, \ldots, R_N)$，截断 HOSVD 的近似误差满足

$$\|\mathcal{A} - \hat{\mathcal{A}}_{\text{HOSVD}}\|_F \le \sqrt{N}\, \|\mathcal{A} - \mathcal{A}_{\text{opt}}\|_F,$$

即它偏离最优解不超过 $\sqrt{N}$ 倍.

例题 5.16. 三阶张量的 HOSVD

给定 $\mathcal{A} \in \mathbb{R}^{I\times J\times K}$:

1. 计算 Mode-1 展开矩阵 $\boldsymbol{A}_{(1)} \in \mathbb{R}^{I\times JK}$ 的 SVD，取 P 个左奇异向量 $\Rightarrow \boldsymbol{U}$
2. 计算 Mode-2 展开矩阵 $\boldsymbol{A}_{(2)} \in \mathbb{R}^{J\times IK}$ 的 SVD，取 Q 个左奇异向量 $\Rightarrow \boldsymbol{V}$
3. 计算 Mode-3 展开矩阵 $\boldsymbol{A}_{(3)} \in \mathbb{R}^{K\times IJ}$ 的 SVD，取 R 个左奇异向量 $\Rightarrow \boldsymbol{W}$
4. 核心张量 $\mathcal{G} = \mathcal{A} \times_1 \boldsymbol{U}^{\mathrm{T}} \times_2 \boldsymbol{V}^{\mathrm{T}} \times_3 \boldsymbol{W}^{\mathrm{T}}$

每个步骤都是矩阵 SVD，因此算法稳定且并行友好.

除了 HOSVD 算法，我们还有高阶正交迭代 (HOOI) 算法. HOSVD 是好的初始化，但未必是最优解. HOOI 通过交替优化进一步提高近似精度. HOOI 的每一步单调地减小近似误差 $\|\mathcal{A} - \hat{\mathcal{A}}\|_F$，因此算法保证收敛（可能到局部最优）.

5.5.4 Tucker 分解的典型应用

1. **数据压缩**：$P \ll I$, $Q \ll J$, $R \ll K$ 时，存储量从 IJK 降至 $PQR + IP + JQ + KR$，对高光谱图像、视频等大尺度数据非常有效.
2. **降噪**：保留主要 Tucker 秩，截断噪声对应的奇异方向.
3. **奇异值检测**：核心张量的大元素或因子矩阵中偏离模式的成分可指示异常.
4. **张量补全**：借助 Tucker 低秩假设，由部分观测恢复完整张量（见后文傅里叶域方法）.
5. **多模态数据分析**：各因子矩阵分别解释不同模态的结构（如 fMRI 中的空间 × 时间 × 被试）.

5.6 二维傅里叶变换与张量的深层关系

5.6.1 图像

一张灰度图像是定义在 $\{0,\dots,M-1\}\times\{0,\dots,N-1\}$ 上的函数，自然地对应一个**二阶张量**（矩阵）：

$$I \in \mathbb{R}^{M\times N}.$$

彩色图像有三个通道，对应三阶张量：

$$I_{\mathrm{rgb}} \in \mathbb{R}^{M\times N\times 3}.$$

多光谱图像对应更高阶的张量：

$$I_{\mathrm{multi}} \in \mathbb{R}^{M\times N\times B} \quad (B \text{ 为波段数}).$$

视频对应四阶张量：

$$V \in \mathbb{R}^{H\times W\times C\times T} \quad (\text{高} \times \text{宽} \times \text{通道} \times \text{时间}).$$

在这一视角下，所有图像处理操作—包括傅里叶变换—都是对张量的线性或非线性变换.

5.6.2 2D 离散傅里叶变换

我们从矩阵表示 $\boldsymbol{F} = \boldsymbol{F}_M \boldsymbol{X} \boldsymbol{F}_N^{\mathrm{T}}$ 出发，利用其向量形式：

$$\mathrm{vec}(\boldsymbol{F}) = \mathrm{vec}(\boldsymbol{F}_M \boldsymbol{X} \boldsymbol{F}_N^{\mathrm{T}}) = (\boldsymbol{F}_N \otimes \boldsymbol{F}_M)\,\mathrm{vec}(\boldsymbol{X}).$$

2D 离散傅里叶变换的向量形式是一个 Kronecker 积矩阵 $\boldsymbol{F}_N \otimes \boldsymbol{F}_M$ 作用于向量化的图像. 从张量角度看，这是对二阶张量的一个线性变换，而该变换矩阵本身是两个一阶变换矩阵的 Kronecker 积（即张量积）.

可分离性 $\boldsymbol{F} = \boldsymbol{F}_M \boldsymbol{X} \boldsymbol{F}_N^{\mathrm{T}}$ 从张量视角可以有更深刻的解释：2D 离散傅里叶变换是**两个独立的一维离散傅里叶变换的 Mode 乘积**：

$$\mathcal{F} = \mathcal{X} \times_1 \boldsymbol{F}_M \times_2 \boldsymbol{F}_N,$$

其中 $\mathcal{X}$ 是二阶张量（图像），Mode-1 乘 $\boldsymbol{F}_M$ 作用于行（第一维数），Mode-2 乘 $\boldsymbol{F}_N$ 作用于列（第二维数）.

对 D 阶张量，可以在所有 D 个模上分别应用离散傅里叶变换，得到 D 维傅里叶变换：

$$\mathcal{F} = \mathcal{X} \times_1 \boldsymbol{F}_{N_1} \times_2 \boldsymbol{F}_{N_2} \times_3 \cdots \times_D \boldsymbol{F}_{N_D}.$$

这等价于 D 维离散傅里叶变换，而用 Kronecker 积，也可以表示成：

$$\mathrm{vec}(\mathcal{F}) = (\boldsymbol{F}_{N_D} \otimes \cdots \otimes \boldsymbol{F}_{N_2} \otimes \boldsymbol{F}_{N_1})\ \mathrm{vec}(\mathcal{X}).$$

受上述观察启发，我们可以定义**沿张量任意模的傅里叶变换**：对于张量 $\mathcal{A} \in \mathbb{C}^{I_1 \times I_2 \times \cdots \times I_N}$，沿 Mode-$n$ 的傅里叶变换定义为

$$\mathcal{B} = \mathcal{A} \times_n \boldsymbol{F}_{I_n},$$

其中 $\boldsymbol{F}_{I_n}$ 是 I_n 点的离散傅里叶变换矩阵. 沿多个模的傅里叶变换则对应多个 Mode 乘积的复合：

$$\mathcal{B} = \mathcal{A} \times_{n_1} \boldsymbol{F}_{I_{n_1}} \times_{n_2} \boldsymbol{F}_{I_{n_2}} \times_{n_3} \cdots$$

例题 5.17.

[Tube-Fiber 视角下的离散傅里叶变换] 对于三阶张量 $\mathcal{A} \in \mathbb{C}^{I \times J \times K}$，考虑沿 Mode-3（管纤维方向）的傅里叶变换：

$$\hat{\mathcal{A}}(:,:,k) = \sum_{t=1}^{K} \mathcal{A}(:,:,t)\, e^{-j2\pi(k-1)(t-1)/K}. \tag{5.24}$$

这等价于对每个 (i,j) 位置的管纤维独立做 1D 离散傅里叶变换.

5.6.3 更深层的数学联系

5.6.3.1 群表示论视角

离散傅里叶变换实际上是**循环群 $\mathbb{Z}/N\mathbb{Z}$ 上的傅里叶分析**. 对于阿贝尔群，所有不可约表示都是一维的，因此离散傅里叶变换矩阵由这些表示构成.

对于二维离散傅里叶变换，考虑群 $\mathbb{Z}/M\mathbb{Z} \times \mathbb{Z}/N\mathbb{Z}$. 其不可约表示为

$$\chi_{k,\ell}(m,n) = \mathrm{e}^{2\pi(\frac{km}{M}+\frac{\ell n}{N})\mathrm{i}},$$

正好对应 2D 离散傅里叶变换的基底.

从张量角度看，群表示的张量积给出了直积群的表示：

$$\rho_{k,\ell}(m,n) = \rho_k^{(1)}(m) \otimes \rho_\ell^{(2)}(n).$$

这正是二维离散傅里叶变换的可分离性—$\boldsymbol{F}_M \otimes \boldsymbol{F}_N$—在群表示论中的自然体现.

5.6.3.2 张量积 Hilbert 空间

图像可以看作 Hilbert 空间 $\ell^2(\mathbb{Z}/M\mathbb{Z} \times \mathbb{Z}/N\mathbb{Z})$ 中的元素. 该空间有正交分解：

$$\ell^2(\mathbb{Z}/M\mathbb{Z} \times \mathbb{Z}/N\mathbb{Z}) \cong \ell^2(\mathbb{Z}/M\mathbb{Z}) \otimes \ell^2(\mathbb{Z}/N\mathbb{Z}).$$

二维离散傅里叶变换是该空间上的酉算子，且可分解为：

$$\mathcal{F}_{MN} = \mathcal{F}_M \otimes \mathcal{F}_N.$$

这可以推广到更高维：

$$\mathcal{F}_{N_1 N_2 \cdots N_D} = \mathcal{F}_{N_1} \otimes \mathcal{F}_{N_2} \otimes \cdots \otimes \mathcal{F}_{N_D}.$$